


UNIVERSIDAD DE OVIEDO

Escuela de Ingeniería Informática

Grado en Ingeniería Informática del Software



Universidad de Oviedo

TRABAJO DE FIN DE GRADO

Análisis de electrocardiogramas como imagen con redes convolucionales y modelos abiertos de visión y lenguaje en escenarios de pocos datos

*Estudio comparativo del aprendizaje supervisado y el aprendizaje
en contexto*

Electrocardiogram image analysis with convolutional networks and open vision language models
under limited labeled data

Autor Alejandro Moris Lara

Tutor Nahuel Costa Cortez

Oviedo, Junio de 2026

Curso académico 2025/2026

Resumen

Este Trabajo de Fin de Grado estudia el análisis de electrocardiogramas representados como imagen en un escenario de pocos datos etiquetados. La pregunta de fondo no es únicamente si una CNN puede clasificar trazados, sino cuándo compensa entrenar un modelo visual específico y cuándo podría ser más razonable utilizar modelos de visión y lenguaje con aprendizaje en contexto. El caso clínico elegido es el síndrome de Brugada, tratado siempre como problema de triaje: una alerta del sistema debe priorizar revisión experta y nunca confirmar ni descartar por sí sola el diagnóstico.

El flujo clínico condiciona esta interpretación. En la práctica, un patrón sospechoso de Brugada requiere lectura especializada del ECG, valoración de síntomas y antecedentes, posible recolocación de derivaciones precordiales derechas en espacios superiores y, en pacientes seleccionados con sospecha persistente y ECG basal no concluyente, una prueba farmacológica con bloqueantes del canal de sodio. Esa prueba puede desenmascarar un patrón tipo 1, pero debe interpretarse dentro del contexto clínico y excluyendo fenocopias. Por ello, el modelo desarrollado se plantea como filtro de priorización, no como clasificador diagnóstico autónomo.

La memoria integra dos dominios. El primero es un simulador controlado de morfología QRS/ST que genera imágenes de V1, V2 y V3 con etiquetas derivadas de reglas observables. El segundo es el conjunto Brugada HUCA, procesado desde registros clínicos reales para obtener ventanas de las derivaciones precordiales derechas y una etiqueta binaria de caso Brugada confirmado frente a control. La evaluación se organiza por paciente mediante validación leave-one-out, presupuestos reducidos de $K = \{2, 4, 8, 16, 32\}$ ejemplos y tres semillas por presupuesto.

La fase experimental cerrada corresponde a la rama CNN. ResNet18 funciona de forma clara en el simulador: la exactitud equilibrada media pasa de 0,625 con $K = 2$ a 0,848 con $K = 32$, con sensibilidad 0,883, especificidad 0,812, F1 0,673 y área ROC 0,857. Sin embargo, en Brugada HUCA el comportamiento cae cerca del azar. La mejor exactitud equilibrada del modelo base se obtiene con $K = 16$, 0,516, mientras que $K = 32$ queda en 0,499. La sensibilidad permanece moderada, pero la especificidad es baja.

Se revisa además una rama de adaptación de dominio con aprendizaje autosupervisado, CORAL, MMD y DANN. Las cuatro variantes se ejecutan para $K = 16$ y $K = 32$. El

mejor resultado real aparece con MMD y $K = 32$, con exactitud equilibrada 0,549, F1 0,498, sensibilidad 0,649 y especificidad 0,448. La mejora es medible pero insuficiente: incluso después de adaptar dominios, la CNN no ofrece un rendimiento robusto para datos reales de Brugada con tan pocos ejemplos.

Esta evidencia negativa es parte central del TFG. La rama CNN establece una línea base reproducible y muestra el límite práctico de entrenar modelos visuales específicos en régimen de pocos datos. Sobre esa base se plantea la siguiente fase: comparar contra modelos abiertos de visión y lenguaje, como Gemma 4 y MedGemma, usando los mismos presupuestos K dentro del contexto. La memoria deja esa pipeline VLM/ICL documentada, con mensajes, validación JSON y controles, pero sin métricas porque todavía no existen inferencias completas y auditadas.

Abstract

This Bachelor's Thesis studies electrocardiogram analysis when the ECG is treated as an image and only a small number of labeled examples is available. The central question is not only whether a CNN can classify traces, but when it is worth training a task-specific visual model and when vision-language models with in-context learning may become a better option. The clinical use case is Brugada syndrome, framed strictly as triage: a model alert should prioritize expert review, never confirm or rule out the diagnosis by itself.

The clinical workflow is essential for this framing. In routine practice, a suspicious Brugada pattern requires expert ECG review, assessment of symptoms and family history, possibly recording right precordial leads in higher intercostal spaces, and, in selected patients with persistent suspicion and a non-diagnostic baseline ECG, a sodium-channel blocker challenge. Such a test can unmask a type 1 pattern, but it must be interpreted together with the clinical context and after excluding phenocopies. Therefore, the system studied here is a prioritization filter, not an autonomous diagnostic classifier.

The work combines two domains. The first one is a controlled QRS/ST morphology simulator that renders V1, V2 and V3 images and assigns labels from observable rules. The second one is the Brugada HUCA dataset, processed from real clinical recordings into right precordial lead windows with a binary target: confirmed Brugada case versus control. Evaluation is patient-level leave-one-out cross-validation with reduced budgets $K = \{2, 4, 8, 16, 32\}$ and three seeds per budget.

The completed experimental phase corresponds to the CNN branch. ResNet18 performs clearly on the simulator: mean balanced accuracy rises from 0.625 at $K = 2$ to 0.848 at $K = 32$, with sensitivity 0.883, specificity 0.812, F1 0.673 and ROC AUC 0.857. On Brugada HUCA, however, performance drops close to chance. The best baseline balanced accuracy is obtained at $K = 16$, 0.516, while $K = 32$ reaches 0.499. Sensitivity remains moderate, but specificity is low.

A domain adaptation branch is also reviewed and executed. The tested methods are self-supervised learning, CORAL, MMD and DANN, evaluated at $K = 16$ and $K = 32$. The best real-data result is obtained by MMD at $K = 32$, with balanced accuracy 0.549, F1 0.498, sensitivity 0.649 and specificity 0.448. The improvement is measurable but insufficient: even after domain adaptation, the CNN branch is not robust on real Brugada data under such limited

supervision.

This negative evidence is a central contribution. The CNN branch establishes a reproducible baseline and exposes the practical limit of training task-specific visual models in the few-data regime. On top of that baseline, the next phase is defined as a comparison against open vision-language models, such as Gemma 4 and MedGemma, using the same K budgets as in-context demonstrations. The thesis documents the VLM/ICL pipeline, prompts, JSON validation and controls, but reports no VLM metrics because complete audited inference artifacts are not yet available.

Palabras clave

Palabras clave: electrocardiograma, análisis de imágenes médicas, clasificación multietiqueta, redes neuronales convolucionales, modelos de visión y lenguaje, aprendizaje en contexto, pocos datos, datos sintéticos, adaptación de dominio, síndrome de Brugada.

Keywords: electrocardiogram, medical image analysis, multilabel classification, convolutional neural networks, vision language models, in context learning, limited labeled data, synthetic data, domain adaptation, Brugada syndrome.

Índice general

Resumen	I
Abstract	III
Palabras clave	V
1. Introducción	1
1.1. Motivación clínica	1
1.2. Motivación metodológica	2
1.3. Pregunta de investigación	3
1.4. Hipótesis	4
1.5. Objetivos	4
1.6. Contribuciones	5
1.7. Alcance	5
1.8. Estructura de la memoria	5
2. Fundamentos clínicos y técnicos	7
2.1. Origen y representación del electrocardiograma	7
2.2. Morfología básica de un latido	8
2.3. Hallazgos morfológicos utilizados en el proyecto	9
2.3.1. Morfología compatible con bloqueo de rama derecha	9
2.3.2. Elevación del segmento ST	9
2.3.3. Inversión de la onda T	10
2.3.4. Síndrome de Brugada como caso motivador	10
2.4. La señal y la imagen como representaciones	12
2.5. Datos sintéticos y modelos gaussianos	13
2.6. Clasificación multietiqueta	14

2.7.	Redes neuronales convolucionales	15
2.8.	Modelos de visión y lenguaje	16
2.9.	Aprendizaje multimodal en contexto	16
2.10.	Explicabilidad y fidelidad	17
2.11.	Cambio de dominio y adaptación	18
2.12.	Implicaciones para el diseño experimental	18
3.	Trabajos relacionados	20
3.1.	Alcance de la revisión	20
3.2.	Aprendizaje profundo sobre señales electrocardiográficas	20
3.3.	Análisis directo de imágenes de ECG	21
3.4.	Datos sintéticos para ECG	22
3.5.	Conjuntos que integran señal, imagen y texto	22
3.6.	Modelos multimodales especializados en ECG	23
3.7.	Aprendizaje multimodal en contexto	24
3.8.	Gemma 4 y MedGemma	24
3.9.	Síntesis comparativa	25
3.10.	Hueco de investigación	26
4.	Diseño experimental	27
4.1.	Pregunta experimental	27
4.2.	Canalización experimental	28
4.3.	Unidades de análisis	29
4.4.	Presupuestos de pocos ejemplos	29
4.5.	Modelo CNN evaluado	30
4.6.	Adaptación de dominio	30
4.7.	Métricas	31
4.8.	Estado de cierre	32
5.	Simulador y conjunto de datos sintético	33
5.1.	Objetivo del dominio sintético	33
5.2.	Representación matemática	34

5.3.	Muestreo temporal	35
5.4.	Rangos de parámetros	35
5.5.	Familias generadoras	36
5.5.1.	Familia normal	36
5.5.2.	Morfología RBBB	36
5.5.3.	Elevación de ST	36
5.5.4.	Inversión de T	37
5.5.5.	Familia Brugada	37
5.6.	Reglas de coherencia morfológica	37
5.7.	Muestreo con rechazo	38
5.8.	Validadores y semántica de las etiquetas	39
5.9.	Renderizado de las señales	39
5.10.	Construcción del conjunto de datos	40
5.11.	Comprobación de integración	41
5.12.	Control de calidad del simulador	42
5.12.1.	Nivel estructural	42
5.12.2.	Nivel semántico	42
5.12.3.	Nivel distribucional	42
5.12.4.	Nivel visual	42
5.13.	Riesgos de atajos visuales	43
5.14.	Limitaciones del simulador	43
6.	Modelos	45
6.1.	Entrada común	45
6.2.	Dos formas de usar K	46
6.3.	CNN ResNet18	46
6.4.	Validación por paciente	47
6.5.	Grad CAM	48
6.6.	Adaptación de dominio	48
6.7.	Modelos de visión y lenguaje	49
6.8.	Controles previstos para VLM	50

6.9.	Criterio de comparación	50
7.	Resultados en el conjunto sintético	51
7.1.	Curva por presupuesto	51
7.2.	Matriz de confusión	52
7.3.	Inspección cualitativa	53
7.4.	Conclusión del dominio sintético	54
8.	Evaluación con Brugada HUCA	55
8.1.	Cohorte final	55
8.2.	Preprocesamiento	56
8.3.	Resultados CNN base	56
8.4.	Brecha sintético-real	58
8.5.	Adaptación de dominio	59
8.6.	Inspección cualitativa	61
8.7.	Conclusión en datos reales	61
9.	Discusión	63
9.1.	Qué demuestra el simulador	63
9.2.	Qué demuestra HUCA	63
9.3.	Por qué no basta la adaptación de dominio	64
9.4.	Pocos datos y decisión de modelo	64
9.5.	Interpretabilidad	65
9.6.	Relación con VLM e ICL	65
9.7.	Limitaciones	65
9.8.	Lectura final	66
10.	Gestión, ética, privacidad y marco normativo	67
10.1.	Planificación del proyecto	67
10.1.1.	Alcance y carga de trabajo	67
10.1.2.	Fases y calendario	68
10.2.	Gestión de riesgos	69
10.3.	Recursos y estimación de coste	70

10.4.	Gestión de configuración y trazabilidad	71
10.5.	Principios éticos	71
10.5.1.	Proporcionalidad y finalidad	71
10.5.2.	Riesgos para las personas	72
10.5.3.	Intervención humana	72
10.6.	Protección de datos	72
10.6.1.	Marco general	72
10.6.2.	Aplicación al proyecto	73
10.7.	Licencias y reutilización	73
10.8.	Regulación de sistemas de inteligencia artificial	74
10.8.1.	Reglamento europeo de inteligencia artificial	74
10.8.2.	Producto sanitario	74
10.8.3.	Espacio Europeo de Datos de Salud	75
10.9.	Equidad, robustez y transparencia	75
10.10.	Sostenibilidad	75
10.11.	Compromiso de uso responsable	75
11.	Conclusiones	77
11.1.	Conclusiones principales	77
11.2.	Objetivos alcanzados	78
11.3.	Respuesta a la pregunta de investigación	78
11.4.	Trabajo futuro	78
11.5.	Cierre	79
A.	Configuración experimental	80
A.1.	Entorno de software	80
A.2.	Conjunto sintético QRS/ST	81
A.3.	Brugada HUCA	82
A.4.	Configuración CNN	83
A.5.	Configuración de adaptación de dominio	83
A.6.	Configuración VLM pendiente	84

B. Resultados completos	85
B.1. CNN en el conjunto sintético	85
B.2. CNN en Brugada HUCA	85
B.3. Comparación de dominios	86
B.4. Adaptación de dominio	86
B.5. Artefactos	86
C. Mensajes y respuestas estructuradas	88
C.1. Criterio de conservación	88
C.2. Mensaje de sistema	88
C.3. Tarea multietiqueta mínima	89
C.4. Tarea multietiqueta descrita	89
C.5. Consultas binarias	90
C.5.1. RBBB	90
C.5.2. Elevación de ST	91
C.5.3. Inversión de la onda T	91
C.6. Ejemplos de respuestas	92
C.7. Construcción del contexto	92
C.8. Análisis de la salida	93
D. Reproducción	94
D.1. Preparación del entorno	94
D.2. Generación de datos	94
D.3. Entrenamiento CNN	94
D.4. Adaptación de dominio	95
D.5. Comparaciones e informes	95
D.6. VLM como TODO reproducible	96
D.7. Compilación de la memoria	96
Bibliografía	97

Índice de figuras

1.1. Uso previsto del sistema: triaje de sospecha y priorización de revisión, no diagnóstico autónomo.	2
1.2. Flujo conceptual del TFG: misma entrada visual, dos formas de usar pocos ejemplos y lectura clínica común de triaje.	3
2.1. Morfología básica de un latido electrocardiográfico renderizado como imagen.	8
2.2. Ejemplos clínicos de morfología Brugada. Izquierda: CardioNetworks/ECGpedia, CC BY-SA 3.0 [8]. Derecha: figura de Napolitano y Priori, reutilizada bajo CC BY 2.0 [9].	11
2.3. Representación esquemática de los hallazgos visuales que motivan el triaje de patrón Brugada.	11
2.4. Transformación de una señal numérica a una imagen de ECG y ejemplos de cambio de dominio visual.	13
3.1. Evolución de los enfoques automáticos para ECG considerados en el TFG.	26
4.1. Orientación clínica del prototipo: una alerta prioriza revisión y posible circuito diagnóstico, pero no decide el diagnóstico.	27
4.2. Diseño experimental: CNN como línea base cerrada y VLM/ICL como comparador central pendiente.	28
4.3. Validación leave-one-out por paciente y selección de presupuestos K	30
4.4. Métodos de adaptación de dominio revisados y ejecutados sobre la rama experimental.	31
5.1. Construcción de un beat mediante átomos gaussianos y suma resultante.	35
5.2. Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador.	40
5.3. Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV.	43

6.1. Recorridos de entrada y evaluación: CNN cerrada y VLM/ICL preparado como comparador de pocos datos.	45
6.2. Ejemplo Grad CAM del modelo CNN sobre el conjunto sintético.	48
6.3. Canalización VLM/ICL prevista: selección de ejemplos, prompt multimodal, modelo local, validación JSON y controles.	49
7.1. Exactitud equilibrada de la CNN sobre el conjunto sintético según el presupuesto K	52
7.2. Matriz de confusión agregada del conjunto sintético para $K = 32$	53
7.3. Ejemplo Grad CAM del modelo sintético.	54
8.1. Canalización de preprocesamiento de Brugada HUCA para V1, V2 y V3.	56
8.2. Exactitud equilibrada de la CNN base sobre Brugada HUCA.	57
8.3. Matriz de confusión agregada de Brugada HUCA para $K = 16$	57
8.4. Comparación de exactitud equilibrada entre el conjunto sintético y Brugada HUCA.	58
8.5. Comparación de F1 entre el conjunto sintético y Brugada HUCA.	58
8.6. Exactitud equilibrada de las variantes de adaptación de dominio.	60
8.7. F1 de las variantes de adaptación de dominio.	60
8.8. Ejemplo Grad CAM del modelo CNN sobre Brugada HUCA.	61
10.1. Plan temporal del proyecto y cierre de los experimentos principales.	69

Índice de tablas

2.1. Relación entre el concepto clínico y la aproximación operativa del proyecto	12
2.2. Comparación entre la señal temporal y la imagen electrocardiográfica . . .	13
3.1. Síntesis de trabajos relacionados	25
4.1. Conjuntos utilizados en los experimentos cerrados.	29
4.2. Estado de los bloques experimentales al cierre de la memoria.	32
5.1. Átomos utilizados para construir un beat	34
5.2. Relación entre familias generadoras y rasgos favorecidos	37
5.3. Criterios operativos de los validadores sintéticos	39
5.4. Configuración final del conjunto sintético QRS/ST	41
6.1. Configuración CNN utilizada en las campañas finales.	47
7.1. Resultados CNN ResNet18 sobre el conjunto sintético QRS/ST.	51
8.1. Cohorte Brugada HUCA utilizada en la evaluación CNN.	55
8.2. Resultados CNN ResNet18 sobre Brugada HUCA.	56
8.3. Comparación de adaptación de dominio sobre Brugada HUCA.	59
10.1. Distribución prevista de la dedicación del proyecto.	68
10.2. Calendario general del Trabajo de Fin de Grado.	68
10.3. Riesgos principales del proyecto.	70
A.1. Dependencias principales declaradas por el proyecto.	80
A.2. Configuración del conjunto sintético final.	81
A.3. Configuración del conjunto real procesado.	82
A.4. Hiperparámetros de la CNN final.	83

A.5. Configuración de la rama de adaptación de dominio.	83
B.1. Resultados completos de la CNN sobre el conjunto sintético.	85
B.2. Resultados completos de la CNN base sobre Brugada HUCA.	85
B.3. Exactitud equilibrada sintética frente a real.	86
B.4. Resultados completos de adaptación de dominio sobre Brugada HUCA. . .	86

CAPÍTULO 1

Introducción

El electrocardiograma es una señal temporal, pero una parte importante de su circulación clínica ocurre como imagen: papel, PDF, captura de pantalla o trazado incrustado en una historia. Esta doble naturaleza abre una pregunta práctica: si el dato disponible ya es visual, ¿merece la pena entrenar un modelo de visión específico o puede aprovecharse un modelo multimodal general mediante ejemplos en contexto?

Este Trabajo de Fin de Grado aborda esa pregunta en un escenario deliberadamente difícil: pocos datos etiquetados, trazados electrocardiográficos y sospecha de síndrome de Brugada. El objetivo no es construir un producto sanitario ni un clasificador diagnóstico autónomo. La orientación correcta es la de triaje clínico: priorizar trazados que merecen revisión temprana por especialistas y generar evidencia reproducible sobre qué familia de modelos resulta más útil en cada régimen de datos.

1.1 Motivación clínica

El síndrome de Brugada se asocia a un patrón electrocardiográfico característico en derivaciones precordiales derechas, especialmente el patrón tipo 1. Sin embargo, el diagnóstico no se reduce a reconocer una forma de onda. El ECG puede ser dinámico, el patrón puede aparecer de forma espontánea, durante fiebre o tras una prueba con bloqueantes del canal de sodio, y existen fenocopias que deben excluirse [1, 6].

Por esta razón, el sistema propuesto no responde a la pregunta “¿tiene este paciente Brugada?”. Responde a una pregunta previa y más prudente: “¿debe este trazado revisarse antes y, si procede, continuar el circuito clínico?”. En un flujo asistencial real, una alerta automática tendría que terminar en revisión experta, posible registro con derivaciones V1-V2 en espacios intercostales superiores y, solo en pacientes seleccionados, una prueba farmacológica monitorizada. La decisión final seguiría siendo clínica.

Uso previsto: triaje de sospecha, no diagnóstico automático

La salida del modelo solo decide prioridad de revisión; la decisión clínica queda en el circuito asistencial



El test con bloqueantes de sodio se realiza solo en pacientes seleccionados y monitorizados; no es una prueba de cribado indiscriminada.

Figura 1.1. Uso previsto del sistema: triaje de sospecha y priorización de revisión, no diagnóstico autónomo.

1.2 Motivación metodológica

Los modelos supervisados de ECG funcionan bien cuando existen cohortes grandes, diversas y bien etiquetadas. Trabajos previos han mostrado que las redes convolucionales pueden extraer información diagnóstica de trazados renderizados a gran escala [15]. El problema aparece al comienzo de un proyecto biomédico, cuando solo hay pocos ejemplos revisados y la enfermedad o la definición operativa son raras.

Este TFG compara dos formas de usar esos pocos ejemplos. La primera es el enfoque clásico: una CNN usa los K ejemplos para actualizar sus pesos. La segunda es el enfoque de aprendizaje en contexto: un modelo de visión y lenguaje mantiene sus pesos fijos y recibe los K ejemplos dentro del mensaje. La pregunta de investigación no es cuál tecnología es más moderna, sino a partir de qué punto compensa entrenar y cuándo resulta más razonable aprovechar conocimiento visual previo mediante ICL.

La fase cerrada de esta memoria corresponde a la primera rama. Se entrena una CNN ResNet18, se evalúa en un simulador controlado, se traslada a Brugada HUCA y se revisa una rama de adaptación de dominio. Esa evidencia no pretende cerrar la comparación contra VLM. Pretende establecer la línea base que la siguiente fase debe superar o matizar.




Figura 1.2. Flujo conceptual del TFG: misma entrada visual, dos formas de usar pocos ejemplos y lectura clínica común de triaje.

1.3 Pregunta de investigación

La pregunta general del trabajo es:

En ECG como imagen y con pocos datos etiquetados, ¿cuándo merece la pena entrenar una CNN específica y cuándo puede ser preferible usar modelos de visión y lenguaje con aprendizaje en contexto para apoyar triaje de sospecha de Brugada?

La memoria actual responde de forma completa a la parte CNN de esa pregunta mediante tres subpreguntas:

1. ¿Puede una CNN aprender señal visual útil en un simulador QRS/ST controlado con presupuestos K muy pequeños?
2. ¿Se mantiene ese aprendizaje al pasar a Brugada HUCA, un conjunto real con variabilidad clínica y etiqueta binaria de caso confirmado frente a control?
3. ¿La adaptación de dominio reduce de forma suficiente la brecha entre el dominio sintético y el dominio real?

La parte VLM/ICL queda definida como siguiente fase experimental. No se reportan métricas VLM porque todavía no existen inferencias completas y auditadas. Incluir números no ejecutados rompería la trazabilidad del estudio.

1.4 Hipótesis

El trabajo parte de cinco hipótesis operativas:

1. El simulador QRS/ST genera diferencias visuales suficientes para que una CNN aprenda por encima del azar.
2. El rendimiento CNN mejora al aumentar K en el dominio sintético, donde las etiquetas proceden de reglas controladas.
3. La misma CNN pierde rendimiento en Brugada HUCA por cambio de dominio visual y por cambio de significado de la etiqueta.
4. La adaptación de dominio mejora parcialmente el resultado real, pero no elimina la limitación de pocos datos.
5. Si la CNN no alcanza rendimiento robusto ni con adaptación, queda justificada la comparación posterior con VLM/ICL como estrategia alternativa para la fase de escasez de etiquetas.

1.5 Objetivos

El objetivo general es construir una canalización reproducible que permita comparar estrategias de ECG como imagen en régimen de pocos datos, con orientación de triaje clínico.

Los objetivos específicos son:

1. Generar un conjunto sintético QRS/ST con imágenes de V1, V2 y V3 y etiquetas derivadas de reglas morfológicas.
2. Construir un conjunto Brugada HUCA procesado, separado por paciente y con exclusiones documentadas.
3. Entrenar ResNet18 mediante validación leave-one-out para $K = \{2, 4, 8, 16, 32\}$ y tres semillas.
4. Medir exactitud equilibrada, F1, sensibilidad, especificidad, área ROC, precisión media y matrices de confusión.
5. Comparar rendimiento sintético y real para cuantificar la brecha de dominio.
6. Revisar, corregir y ejecutar una rama de adaptación de dominio con SSL, CORAL, MMD y DANN.
7. Interpretar los resultados CNN como línea base para decidir si entrenar modelos visuales específicos es razonable con pocos datos.

8. Documentar la pipeline VLM/ICL como comparador central pendiente, con prompts, controles y validación de salida.

1.6 Contribuciones

Las contribuciones cerradas son:

- un simulador y un conjunto sintético auditado con 100 pacientes y 300 imágenes;
- un preprocesado real de Brugada HUCA con 317 pacientes, 951 imágenes y 46 exclusiones;
- resultados CNN completos en sintético y HUCA;
- resultados de adaptación de dominio para cuatro métodos;
- gráficas, tablas, matrices de confusión y ejemplos Grad CAM;
- una lectura negativa útil: la CNN aprende en sintético, pero no alcanza rendimiento robusto en HUCA real con pocos datos ni con adaptación;
- una pipeline VLM/ICL preparada como siguiente comparador, sin métricas no auditadas;
- una memoria orientada a triaje clínico prudente.

1.7 Alcance

El trabajo no valida un producto sanitario. No estima utilidad clínica prospectiva ni sustituye revisión por especialista. La etiqueta sintética deriva de reglas internas y la etiqueta real de HUCA representa caso Brugada confirmado frente a control. Estas dos tareas están relacionadas, pero no son equivalentes.

La línea VLM no es decorativa ni secundaria. Forma parte de la pregunta de investigación completa, porque representa una forma distinta de explotar pocos ejemplos. En esta entrega queda como TODO reproducible por una razón de integridad: no existen todavía predicciones completas, métricas agregadas ni auditoría equivalente a la rama CNN.

1.8 Estructura de la memoria

El capítulo 2 presenta los fundamentos clínicos y técnicos. El capítulo 3 revisa trabajos relacionados. El capítulo 4 fija el diseño experimental. El capítulo 5 describe el simulador. El capítulo 6 detalla la CNN, la adaptación de dominio y la pipeline VLM pendiente. Los capítulos 7 y 8 presentan los resultados sintéticos y reales. El capítulo 9 discute las implicaciones

para la comparación CNN frente a VLM/ICL y el capítulo 11 cierra el trabajo.

CAPÍTULO 2

Fundamentos clínicos y técnicos

2.1 Origen y representación del electrocardiograma

El electrocardiograma registra diferencias de potencial producidas por la actividad eléctrica del corazón. La señal observada en cada derivación no corresponde a una estructura anatómica aislada. Es la proyección de un proceso eléctrico tridimensional sobre un eje definido por la posición de los electrodos. Por esta razón una misma activación puede generar deflexiones distintas según la derivación desde la que se observe.

El ECG convencional utiliza doce derivaciones obtenidas a partir de diez electrodos. Las derivaciones I, II, III, aVR, aVL y aVF describen la actividad en el plano frontal. Las derivaciones V1 a V6 ofrecen una perspectiva precordial en el plano horizontal. La colocación de los electrodos, la ganancia, la velocidad de registro y el filtrado influyen en la apariencia final. Las recomendaciones de estandarización insisten en conservar estos parámetros porque una modificación técnica puede alterar amplitudes, duraciones y relaciones espaciales que después se utilizan durante la interpretación [2].

La representación clínica habitual utiliza una velocidad de 25 mm por segundo y una ganancia de 10 mm por mV. Con esa convención, un milímetro horizontal equivale a 40 ms y un milímetro vertical equivale a 0,1 mV. Estas equivalencias permiten estimar intervalos y amplitudes directamente sobre el papel. Cuando el trazado se transforma en una imagen digital, la relación física deja de estar garantizada si la imagen se redimensiona, se recorta o se fotografía sin una referencia de escala.

El presente trabajo no intenta reconstruir el vector cardíaco completo. La unidad experimental es una imagen de un latido sintético semejante a una ventana precordial derecha. Esta simplificación permite controlar el complejo QRS, el segmento ST y la onda T. También impide aplicar de forma literal criterios que requieren comparar varias derivaciones. La memoria distinguirá por tanto entre la definición clínica de un hallazgo y la aproximación visual utilizada por el simulador.

2.2 Morfología básica de un latido

Un latido normal puede describirse mediante una secuencia de ondas y segmentos. La onda P refleja la despolarización auricular. El intervalo PR incluye la propagación desde las aurículas hasta el sistema de conducción ventricular. El complejo QRS representa la despolarización ventricular. El punto J marca la transición entre el final del QRS y el comienzo del segmento ST. La onda T se relaciona con la repolarización ventricular.

Las letras Q, R y S no designan posiciones anatómicas fijas. La onda Q es la primera deflexión negativa anterior a una deflexión positiva. La onda R es la primera deflexión positiva del complejo ventricular. La onda S es una deflexión negativa posterior a una onda R. Si aparece una segunda deflexión positiva, se denomina R prima. Esta nomenclatura describe la geometría de la señal y no establece por sí sola un diagnóstico.

El segmento ST se evalúa con respecto a una referencia isoelectrica. En un registro real, esa referencia puede aproximarse mediante el segmento TP o el segmento PR según el contexto. La elevación o depresión no se interpreta de forma independiente. Importan la derivación, la magnitud, la morfología, la distribución espacial y el cuadro clínico. Las recomendaciones de la AHA, el ACCF y la HRS separan de forma explícita la descripción del segmento ST, la onda T y el intervalo QT porque cada elemento aporta información diferente [4].

La onda T también depende de la derivación. Una deflexión negativa puede ser fisiológica en algunas posiciones y patológica en otras. Su significado cambia según la edad, el sexo, la secuencia de activación ventricular, los cambios del segmento ST y la presencia de otras alteraciones. El proyecto no intenta resolver esta interpretación completa. La etiqueta de inversión de T indica únicamente que la región tardía del latido sintético presenta una deflexión negativa que satisface las reglas operativas del conjunto.




Figura 2.1. Morfología básica de un latido electrocardiográfico renderizado como imagen.

2.3 Hallazgos morfológicos utilizados en el proyecto

2.3.1 Morfología compatible con bloqueo de rama derecha

El bloqueo de rama derecha es una alteración de la conducción intraventricular. En su forma completa se caracteriza por una duración del QRS igual o superior a 120 ms y por una morfología terminal compatible en las derivaciones apropiadas. Las recomendaciones de estandarización describen patrones como rsR prima o rSR prima en V1 o V2, junto con una onda S ensanchada en derivaciones laterales [3].

La segunda deflexión positiva en las derivaciones precordiales derechas aparece por la activación tardía del ventrículo derecho. No obstante, una forma semejante a rsR prima en una sola derivación no basta para diagnosticar un bloqueo completo. También deben considerarse la duración global del QRS, la morfología en I y V6, la posición de los electrodos y otras causas de retraso terminal.

El simulador solo representa una ventana semejante a una derivación precordial. Por ello la etiqueta RBBB se entiende como *morfología compatible con bloqueo de rama derecha*. El validador busca dos máximos positivos separados por una deflexión negativa, exige que el segundo máximo aparezca en una posición tardía y comprueba una anchura terminal mínima. Esta regla captura una forma visual útil para el experimento, pero no reproduce el criterio clínico completo.

2.3.2 Elevación del segmento ST

El segmento ST comienza en el punto J y termina con el inicio de la onda T. Su desplazamiento se mide con respecto a una referencia isoelectrica. La magnitud clínicamente relevante depende de la derivación, del sexo, de la edad y de la situación diagnóstica. Además, una elevación puede aparecer en contextos diferentes, entre ellos isquemia aguda, pericarditis, repolarización precoz, alteraciones de conducción y síndromes de onda J.

La etiqueta sintética ST_ELEVATION no representa ninguna etiología concreta. El validador exige actividad ventricular suficiente y comprueba que la amplitud media alrededor del punto J y durante el segmento ST sea positiva. Se trata de una definición geométrica diseñada para separar imágenes, no de un umbral clínico expresado en milímetros.

Esta distinción evita una inferencia incorrecta. El modelo aprende a reconocer una región elevada después del QRS. No aprende por ese hecho a diferenciar un patrón de Brugada, un infarto agudo u otra causa. Esa diferenciación requeriría varias derivaciones, contexto clínico y un conjunto de etiquetas mucho más amplio.

2.3.3 Inversión de la onda T

La onda T refleja la repolarización ventricular y suele aparecer después del segmento ST. Su polaridad normal varía entre derivaciones. También puede modificarse como consecuencia secundaria de una secuencia anómala de despolarización. Por ejemplo, una alteración de conducción puede producir cambios discordantes del segmento ST y de la onda T.

En el conjunto sintético, la inversión se define mediante una deflexión tardía negativa. El validador comprueba la profundidad mínima, la posición temporal del mínimo y la duración de la región situada por debajo de un nivel negativo. La regla incluye además condiciones sobre el QRS y el segmento ST para evitar que una oscilación temprana se confunda con una onda T.


La etiqueta T_WAVE_INVERSION expresa por tanto una propiedad visual localizada. No determina si la inversión es primaria, secundaria, fisiológica o patológica. Esta limitación deberá conservarse cuando el modelo se evalúe con datos reales.

2.3.4 Síndrome de Brugada como caso motivador


El síndrome de Brugada es un síndrome arrítmico hereditario asociado a riesgo de fibrilación ventricular y muerte súbita. Su definición ha evolucionado a medida que se ha estudiado la especificidad de los patrones espontáneos y provocados. El elemento electrocardiográfico central es el patrón tipo 1, caracterizado por elevación descendente del segmento ST en derivaciones precordiales derechas y onda T negativa [5, 1].

La guía europea de 2022 sitúa el patrón tipo 1 en V1 o V2 colocadas en espacios intercostales estándar o superiores [1]. Esta colocación es relevante porque registrar V1 y V2 más arriba puede aumentar la sensibilidad para observar el patrón [7]. Aun así, el trazado aislado no debe interpretarse fuera del circuito clínico: hay que valorar síntomas, antecedentes familiares, fiebre, fármacos, alteraciones electrolíticas y fenocopias.

Cuando existe sospecha clínica y el ECG basal no es diagnóstico, puede realizarse una prueba farmacológica con bloqueantes del canal de sodio, como ajmalina, flecainida, procainamida o pilsicainida según disponibilidad local. Esta prueba intenta desenmascarar un patrón tipo 1 en un entorno monitorizado. La literatura reciente advierte que no debe usarse como cribado indiscriminado: la especificidad no es perfecta, no existe un patrón oro absoluto independiente del propio ECG y la indicación depende de síntomas, historia familiar y trazado basal [6]. Por tanto, en este TFG una predicción positiva debe entenderse como señal de triaje que podría conducir a revisión especializada y, si procede, a esta vía diagnóstica, no como diagnóstico final.



(a) ECG con morfología tipo 1 en V1 y V2.



(b) Patrones tipo 1, 2 y 3 usados como referencia visual.

Figura 2.2. Ejemplos clínicos de morfología Brugada. Izquierda: CardioNetworks/ECGpedia, CC BY-SA 3.0 [8]. Derecha: figura de Napolitano y Priori, reutilizada bajo CC BY 2.0 [9].

La relación con el bloqueo de rama derecha requiere una precisión adicional. El trazado tipo 1 puede recordar visualmente a una alteración terminal del QRS. Sin embargo, el mecanismo y los criterios no son equivalentes. La onda J del patrón de Brugada se concentra en las derivaciones precordiales derechas y no necesita la onda S lateral recíproca que forma parte del bloqueo de rama derecha [10]. En este TFG, RBBB se utiliza como una etiqueta morfológica auxiliar y no como requisito clínico para Brugada.

La familia generadora BRUGADA introduce una elevación inicial del segmento ST, una caída progresiva y una onda T negativa. Después de generar la señal, los tres validadores independientes determinan qué hallazgos están presentes. La familia de origen se conserva como metadato, mientras que la tarea predictiva utiliza únicamente las etiquetas observables. Esta separación es importante: el simulador crea un caso visual para probar modelos, no una reproducción diagnóstica del síndrome.




Figura 2.3. Representación esquemática de los hallazgos visuales que motivan el triaje de patrón Brugada.

Tabla 2.1. Relación entre el concepto clínico y la aproximación operativa del proyecto

Hallazgo	Interpretación clínica resumida	Aproximación utilizada en el conjunto sintético
RBBB	Trastorno de conducción que requiere duración y morfología compatibles en varias derivaciones	Dos máximos positivos en la región ventricular, una depresión intermedia y actividad terminal tardía y ancha
Elevación ST	Desplazamiento del punto J y del segmento ST cuya relevancia depende de derivación y contexto	Media positiva en ventanas posteriores al QRS junto con actividad ventricular suficiente
Inversión T	Onda T negativa con significado dependiente de la derivación y de la secuencia de activación	Deflexión tardía negativa con profundidad, posición y duración mínimas
Brugada tipo 1	Patrón descendente en precordiales derechas que debe interpretarse dentro de criterios clínicos	Familia generadora que combina elevación inicial, descenso del ST y T negativa. No se utiliza como etiqueta diagnóstica

2.4 La señal y la imagen como representaciones

Una señal digital conserva muestras de amplitud ordenadas en el tiempo. Esta representación permite medir intervalos, aplicar filtros y comparar derivaciones con una escala conocida. La imagen es el resultado de transformar esas muestras mediante un proceso de renderizado. Contiene la forma visible del trazado, pero también incorpora decisiones de presentación.

El renderizado establece el tamaño del lienzo, la cuadrícula, el grosor de la línea, los márgenes y la disposición de las derivaciones. Una red puede utilizar cualquiera de esos elementos si están correlacionados con la etiqueta. Por ello un conjunto de imágenes debe controlar que la clase no pueda deducirse a partir de una marca, un recorte o una diferencia de resolución.

La imagen posee una ventaja práctica cuando la señal original no está disponible. Sangha y colaboradores demostraron que un modelo multietiqueta podía analizar ECG renderizados y mantener un rendimiento alto en registros externos y trazados impresos [15]. Gliner y colaboradores mostraron además que una CNN puede trabajar con fotografías de ECG, aunque la diferencia de formato requiere estrategias específicas de adaptación [17].

La alternativa consiste en digitalizar primero la imagen. El trabajo de Wu y colaboradores desarrolló una herramienta automática para segmentar trazados impresos y reconstruir las

señales [16]. La digitalización permite reutilizar modelos temporales, pero introduce errores cuando las derivaciones se solapan o la calidad del documento es baja. El análisis directo de imagen y la digitalización no son soluciones excluyentes. Responden a compromisos distintos.

Tabla 2.2. Comparación entre la señal temporal y la imagen electrocardiográfica

Aspecto	Señal temporal	Imagen
Información primaria	Muestras de amplitud con frecuencia conocida	Geometría visible después del renderizado
Medición de intervalos	Directa si se conoce la frecuencia de muestreo	Depende de escala, resolución y posibles transformaciones
Disponibilidad histórica	Limitada cuando solo se conserva el documento	Frecuente en informes, PDF, papel y fotografías
Variabilidad técnica	Filtros, fabricantes y frecuencia de muestreo	Incluye además cuadrícula, color, perspectiva, recorte y compresión
Modelos habituales	Convoluciones unidimensionales, recurrentes y transformadores	CNN, transformadores visuales y modelos de visión y lenguaje
Riesgo principal	Dependencia del dispositivo y del preprocesado temporal	Aprendizaje de rasgos de estilo que no pertenecen a la fisiología




Figura 2.4. Transformación de una señal numérica a una imagen de ECG y ejemplos de cambio de dominio visual.

2.5 Datos sintéticos y modelos gaussianos

Los datos sintéticos permiten controlar factores que resultan difíciles de aislar en una colección clínica. Es posible generar clases equilibradas, conocer los parámetros que originan cada señal y repetir exactamente el proceso. También se evita utilizar información de pacientes durante las primeras fases del desarrollo.

Un modelo sintético no elimina el problema de los datos. Lo transforma. La validez depende de que las reglas de generación representen los rasgos que se quieren estudiar y de

que no introduzcan atajos visuales. Una morfología demasiado regular puede producir un conjunto fácil para una red y poco informativo sobre el comportamiento en registros reales.

La representación mediante ondas gaussianas cuenta con precedentes en el procesamiento de ECG. Sayadi y colaboradores describieron un modelo dinámico basado en ondas gaussianas para generar señales y realizar filtrado bayesiano [18]. En el presente proyecto se adopta una variante más simple y directamente controlable. Cada componente se define como

$$g_i(t) = a_i \exp \left(-\frac{(t - \mu_i)^2}{2\sigma_i^2} \right), \quad (2.1)$$

donde a_i controla la amplitud, μ_i determina la posición temporal y σ_i regula la anchura. El latido completo se obtiene mediante

$$x(t) = \sum_{i=1}^M g_i(t). \quad (2.2)$$

La suma incluye componentes para P, Q, R, S, R prima, punto J, segmento ST y onda T. Los parámetros se muestrean dentro de intervalos dependientes de la familia generadora. Después se aplican relaciones temporales para mantener un orden coherente. Finalmente, un validador decide si la señal satisface las condiciones mínimas de la familia solicitada.

Este procedimiento es un muestreo con rechazo. Si la señal no supera el validador se descarta y se genera otra. La estrategia mejora la consistencia interna, aunque también puede concentrar las muestras cerca de las regiones que aceptan las reglas. La tasa de aceptación y la distribución de parámetros deben analizarse como parte del control de calidad.

Los simuladores de mayor fidelidad utilizan modelos electrofisiológicos y geometrías cardíacas completas. MedalCare XL, por ejemplo, ofrece miles de ECG sintéticos de doce derivaciones obtenidos mediante simulaciones electrofisiológicas [19]. Ese enfoque persigue realismo fisiológico y requiere un coste computacional mayor. El simulador de este TFG persigue interpretabilidad y control local. No son alternativas equivalentes.

2.6 Clasificación multietiqueta

En clasificación multiclase cada ejemplo se asigna a una categoría exclusiva. En clasificación multietiqueta, una muestra se asocia con un subconjunto de etiquetas. Esta formulación es adecuada cuando los hallazgos pueden coexistir [31].

Sea L el número de etiquetas. Para una imagen x , la referencia se representa mediante un vector

$$\mathbf{y} = (y_1, \dots, y_L), \quad y_j \in \{0, 1\}. \quad (2.3)$$

Una red convolucional produce un logit z_j por etiqueta. La función sigmoide transforma cada logit en una probabilidad independiente

$$\hat{p}_j = \frac{1}{1 + \exp(-z_j)}. \quad (2.4)$$

La pérdida habitual es la entropía cruzada binaria

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{L} \sum_{j=1}^L [y_j \log(\hat{p}_j) + (1 - y_j) \log(1 - \hat{p}_j)]. \quad (2.5)$$

La independencia de las salidas no significa que las etiquetas sean estadísticamente independientes. La red puede aprender representaciones compartidas y aprovechar coocurrencias. Sin embargo, una coocurrencia excesiva puede crear atajos. Si todas las ondas T negativas aparecen siempre junto con elevación del ST, el modelo puede predecir una etiqueta a partir de la otra sin observar la región correcta.

La decisión binaria requiere un umbral. El valor 0,5 es una referencia simple, pero no tiene por qué ser óptimo para todas las etiquetas. Los umbrales deben fijarse con el conjunto de validación y conservarse para el test. Ajustarlos con el conjunto de prueba produciría una estimación optimista.

En los modelos de visión y lenguaje la salida no es una probabilidad sigmoide. El sistema genera texto o un objeto estructurado. La evaluación necesita convertir esa respuesta a un vector binario y registrar de forma separada las respuestas que no cumplen el esquema. Esta diferencia forma parte del protocolo y no debe ocultarse durante la comparación.

2.7 Redes neuronales convolucionales

Una convolución aplica un conjunto de filtros compartidos sobre regiones locales de una imagen. Las primeras capas detectan transiciones y contornos. Las capas posteriores combinan esas respuestas para construir patrones de mayor escala. En una imagen de ECG, la red puede aprender inclinaciones, picos, valles y relaciones entre regiones temporales.

El uso de pesos compartidos aporta cierta tolerancia a desplazamientos pequeños. Sin embargo, el ECG no es completamente invariante a la posición. Una deflexión negativa tiene un significado diferente si aparece dentro del QRS o en la región de la onda T. La arquitectura debe conservar suficiente información espacial y el preprocesado debe alinear los latidos.

En este trabajo la referencia convolucional cerrada es una ResNet18 preentrenada. Las

conexiones residuales facilitan la optimización de redes profundas al aprender transformaciones relativas a la entrada de cada bloque [28]. El uso de pesos de ImageNet no garantiza una ventaja en ECG, pero aporta filtros visuales iniciales útiles para contornos, trazos y texturas cuando el número de ejemplos etiquetados es pequeño.

La evaluación debe comprobar si esa transferencia visual se mantiene fuera del simulador. Un resultado alto en imágenes sintéticas puede reflejar que la red aprendió reglas de renderizado, mientras que un resultado más bajo en datos reales puede revelar ruido, variabilidad clínica o diferencias en la definición de etiqueta.

2.8 Modelos de visión y lenguaje

Un modelo de visión y lenguaje combina una representación visual con un modelo generativo de texto. La imagen se transforma en vectores que el componente lingüístico puede atender durante la generación. La salida puede adoptar la forma de una respuesta libre, una explicación o una estructura con campos definidos.

Flamingo mostró que un modelo multimodal entrenado con secuencias intercaladas de imagen y texto podía adaptarse a tareas mediante ejemplos incluidos en el contexto [23]. Este paradigma evita actualizar los pesos para cada tarea. Las demostraciones especifican la relación entre entrada y salida durante la inferencia.

Gemma 4 admite texto e imagen y permite ajustar el número de tokens visuales dedicados a cada imagen [26]. Un presupuesto visual mayor conserva más detalle, aunque incrementa el coste. Esta decisión es relevante para ECG porque los cambios morfológicos pueden ocupar una región pequeña del lienzo.

MedGemma 1.5 es un modelo multimodal médico basado en Gemma 3. Su entrenamiento incluye radiología, histopatología, dermatología, fondo de ojo, documentos y registros clínicos [27]. La documentación oficial no presenta el ECG como modalidad principal de entrenamiento. También indica que el modelo debe adaptarse y validarse antes de cualquier uso específico. Por tanto, su condición de modelo médico no permite asumir un mejor rendimiento sobre trazados electrocardiográficos.

2.9 Aprendizaje multimodal en contexto

En aprendizaje en contexto se proporciona una secuencia de demostraciones

$$\mathcal{D}_K = \{(x_1, y_1), \dots, (x_K, y_K)\} \quad (2.6)$$

antes de la consulta objetivo x^* . El modelo genera una estimación condicionada por la instrucción y por las demostraciones

$$\hat{y}^* = f_{\theta}(x^*, \mathcal{D}_K, \text{instrucción}), \quad (2.7)$$

sin modificar los parámetros θ .

El número de ejemplos no determina por sí solo la calidad del contexto. Importan la selección, la diversidad, el orden y la coherencia entre la imagen y la etiqueta. Qin y colaboradores identificaron la recuperación multimodal, el orden interno de cada demostración y la posición de la instrucción como factores relevantes [25].

Chen y colaboradores observaron que varios modelos podían depender más del texto que de la información visual contenida en las demostraciones [24]. Esta observación justifica los controles del proyecto. En el control de respuestas permutadas se conservan las imágenes y se destruye la asociación correcta con la etiqueta. En el control sin imágenes se mantiene la estructura textual y se elimina la evidencia visual de las demostraciones.

Si un modelo mejora solo con demostraciones correctas y pierde esa mejora en ambos controles, existe evidencia de que utiliza la correspondencia multimodal. Si mantiene el rendimiento con respuestas permutadas, puede estar ignorando las demostraciones o explotando la distribución de clases. Si funciona sin las imágenes de apoyo, la mejora puede proceder del formato de respuesta o de la descripción textual.

2.10 Explicabilidad y fidelidad

Los mapas de activación de clase permiten visualizar qué regiones de una imagen influyen en una salida. Grad CAM utiliza los gradientes de una clase para ponderar los mapas de activación de una capa convolucional [29]. En una tarea de ECG, una explicación razonable debería destacar regiones distintas para QRS, segmento ST y onda T.

Un mapa visual no demuestra causalidad clínica. La resolución suele ser inferior a la imagen de entrada y el resultado depende de la capa seleccionada. También puede señalar una región amplia aunque el modelo utilice un artefacto local. Su función en este proyecto será detectar comportamientos incompatibles con la tarea, no certificar una explicación.

Las explicaciones generadas por un modelo de visión y lenguaje plantean un problema diferente. El texto puede describir correctamente la morfología aunque esa descripción no haya causado la predicción. La plausibilidad lingüística y la fidelidad del razonamiento son propiedades distintas. La evaluación principal utilizará respuestas estructuradas. Las justificaciones se analizarán como un artefacto cualitativo separado.

2.11 Cambio de dominio y adaptación

El dominio sintético y el dominio real difieren en fisiología, adquisición y presentación. El simulador genera un único latido alineado, con una cuadrícula uniforme y sin variabilidad entre pacientes. Un ECG real contiene ruido, deriva de línea base, diferencias de frecuencia cardíaca, trazos superpuestos, anotaciones y múltiples derivaciones.

Una red puede obtener un rendimiento elevado en sintético y fallar en real si aprende características exclusivas del renderizado. Este fenómeno es un cambio de dominio. La adaptación intenta aprender representaciones útiles para la tarea y poco informativas sobre el origen de la muestra.

El entrenamiento adversarial de dominio introduce un clasificador que intenta distinguir muestras fuente y objetivo. El extractor recibe una señal de gradiente invertida para reducir esa capacidad de discriminación [30]. Gliner y colaboradores aplicaron este principio a imágenes de ECG capturadas con teléfono y mostraron que datos objetivo sin etiqueta podían mejorar la transferencia [17].

La adaptación no sustituye la evaluación externa. Alinear distribuciones puede ocultar diferencias relevantes si las prevalencias o las relaciones entre etiquetas cambian. El protocolo deberá comparar el rendimiento antes y después, conservar un conjunto real independiente y analizar cada etiqueta.

2.12 Implicaciones para el diseño experimental

Los fundamentos anteriores determinan varias decisiones. La primera es que las etiquetas se describirán como hallazgos morfológicos. La segunda es que la familia BRUGADA no se convertirá en un diagnóstico automático. La tercera es que CNN y modelos de visión y lenguaje recibirán exactamente la misma imagen objetivo.

La separación por pacientes no puede evaluarse en el conjunto sintético porque cada imagen se genera de forma independiente. En datos reales será obligatoria para impedir que registros de una misma persona aparezcan en entrenamiento y test. También será necesario preservar la escala o documentar cualquier normalización.

El rendimiento se analizará por etiqueta porque cada hallazgo ocupa una región distinta. La coincidencia exacta medirá si se recupera el conjunto completo. La sensibilidad y la especificidad mostrarán qué tipo de error domina. La medida F1 resumirá el equilibrio entre precisión y sensibilidad.

Finalmente, cualquier conclusión sobre utilidad clínica quedará condicionada a una evaluación real. El dominio sintético responde preguntas sobre aprendibilidad, sensibilidad al contexto y comportamiento relativo de los modelos. No permite estimar por sí solo la

seguridad de un sistema médico.

CAPÍTULO 3

Trabajos relacionados

3.1 Alcance de la revisión

La revisión se centra en trabajos que ayudan a responder la pregunta experimental del TFG. Se consideran cinco líneas. La primera estudia el diagnóstico automático a partir de señales de ECG. La segunda utiliza el trazado como imagen. La tercera genera datos sintéticos. La cuarta desarrolla modelos multimodales para imágenes electrocardiográficas. La quinta analiza aprendizaje en contexto con demostraciones visuales.

La búsqueda bibliográfica se actualizó hasta el 22 de junio de 2026. Se priorizaron artículos revisados por pares, conjuntos publicados con documentación técnica, guías clínicas y tarjetas oficiales de modelo. Los resultados no se comparan como si procedieran del mismo banco de pruebas. Las bases de datos, las etiquetas y las métricas difieren entre estudios.

Esta precaución es necesaria porque una exactitud alta en una tarea binaria no puede compararse directamente con una clasificación multietiqueta. Tampoco es equivalente evaluar imágenes renderizadas desde señales limpias que fotografías de documentos clínicos. La revisión se utiliza para identificar decisiones de diseño y huecos metodológicos.

3.2 Aprendizaje profundo sobre señales electrocardiográficas

El análisis automático moderno se desarrolló principalmente sobre señales temporales. Las convoluciones unidimensionales permiten aprender filtros directamente sobre las muestras y evitan diseñar manualmente todas las características. Las redes profundas amplían el campo receptivo hasta integrar información distribuida a lo largo de varios segundos.

Ribeiro y colaboradores entrenaron una red profunda con más de dos millones de ECG de doce derivaciones procedentes de una red brasileña de telemedicina [11]. El sistema reconocía seis alteraciones y fue comparado con médicos en un subconjunto anotado. El trabajo mostró que una gran colección clínica puede sostener un clasificador temporal de alto rendimiento.

Su escala también señala una limitación para enfermedades poco frecuentes. Reunir millones de registros con etiquetas fiables no es una estrategia disponible para todos los proble-

mas. Además, las etiquetas de rutina pueden reflejar criterios locales, versiones de software y variabilidad entre observadores.

PTB XL proporcionó un punto de referencia abierto con 21 837 ECG de doce derivaciones y 71 enunciados potencialmente multietiqueta [12]. Sus particiones recomendadas facilitan comparaciones reproducibles. MIMIC IV ECG amplió la escala hasta aproximadamente 800 000 registros vinculables con información clínica [13]. Estos recursos resultan valiosos para preentrenamiento y validación, aunque no garantizan una cantidad suficiente de cada condición rara.

La literatura sobre señal establece dos referencias para el presente trabajo. Primero, una arquitectura supervisada puede aprender morfología electrocardiográfica cuando dispone de datos adecuados. Segundo, el rendimiento depende de la correspondencia entre el dominio de entrenamiento y la población objetivo. El simulador se utiliza para estudiar el régimen anterior a una gran colección clínica, no para competir con sistemas entrenados sobre millones de registros.

3.3 Análisis directo de imágenes de ECG

El análisis de imagen aborda situaciones en las que el trazado está disponible como documento. Gliner y colaboradores compararon redes que recibían señales digitales y redes que recibían imágenes de doce derivaciones [14]. Su estudio incluyó ocho condiciones para el modelo temporal y una evaluación visual centrada en fibrilación auricular. También aplicó transformaciones que imitaban capturas con teléfono.

Sangha y colaboradores desarrollaron una CNN multietiqueta a partir de 2 228 236 registros brasileños convertidos en imagen [15]. El modelo predijo seis etiquetas clínicas y se evaluó en una cohorte externa alemana y en ECG impresos. El estudio demostró que la representación visual puede generalizar cuando el entrenamiento incorpora escala, diversidad y variación de formato.

La principal diferencia con este TFG es la disponibilidad de datos. Sangha y colaboradores estudian aprendizaje supervisado a gran escala. El presente trabajo pregunta qué ocurre antes de alcanzar esa escala y compara el entrenamiento de una CNN con el uso inmediato de demostraciones en un modelo abierto.

La imagen puede analizarse directamente o convertirse de nuevo a señal. Wu y colaboradores desarrollaron un sistema automático de digitalización y evaluaron la correlación entre la señal reconstruida y la original [16]. Los resultados fueron altos en formatos favorables y disminuyeron cuando había solapamiento entre derivaciones. Esta variabilidad muestra que la digitalización añade sus propios fallos.

El trabajo de Gliner y colaboradores de 2023 se centra en la transferencia desde imáge-

nes limpias a fotografías y formatos no observados [17]. Su arquitectura adversarial utiliza muestras objetivo sin etiqueta para reducir la dependencia del estilo de adquisición. Esta línea es directamente relevante para la futura transición del simulador a datos reales.

3.4 Datos sintéticos para ECG

La generación sintética aparece en varios niveles de fidelidad. Los modelos gaussianos representan ondas mediante funciones paramétricas. Su principal ventaja es la interpretabilidad. Cada cambio puede relacionarse con amplitud, posición o anchura. Sayadi y colaboradores emplearon un modelo de este tipo dentro de un sistema dinámico para generación y filtrado [18].

Los modelos electrofisiológicos simulan la propagación eléctrica sobre geometrías cardíacas. MedalCare XL contiene 16 900 ECG sintéticos de doce derivaciones para un grupo sano y siete patologías [19]. La colección aporta señales con una base mecánica y permite estudiar condiciones difíciles de equilibrar en datos clínicos.

También existen modelos generativos aprendidos. Los modelos de difusión condicionados pueden producir señales asociadas a enunciados diagnósticos [20]. Su flexibilidad es mayor que la de un simulador manual, pero la relación entre cada parámetro y la morfología final resulta menos directa. Además, la calidad debe evaluarse mediante diversidad, fidelidad clínica y utilidad para tareas posteriores.

El simulador del proyecto ocupa un punto deliberadamente simple. No intenta reproducir un torso, un corazón tridimensional o una distribución clínica completa. Genera un latido para estudiar tres hallazgos localizados. Esta decisión reduce el realismo y mejora la capacidad de auditar las reglas.

La literatura sintética también advierte de un riesgo. Un conjunto generado puede amplificar los supuestos del modelo de simulación. Si la variabilidad no incluye ruido, escalas y formas intermedias, el clasificador aprenderá una frontera más limpia que la que existe en práctica clínica. La evaluación real sigue siendo necesaria.

3.5 Conjuntos que integran señal, imagen y texto

Los modelos multimodales necesitan datos alineados. Una imagen sin informe permite clasificación supervisada, pero no ofrece una relación rica entre morfología y lenguaje. Un informe sin trazado tampoco permite comprobar si la explicación se apoya en evidencia visual.

MEETI se publicó en 2026 como una extensión de MIMIC IV ECG [22]. El recurso sincroniza señales, imágenes renderizadas, parámetros por latido e interpretaciones textuales. Cubre hasta 784 680 registros de 160 597 pacientes. Las imágenes se generan con una escala

estándar y las interpretaciones detalladas se producen mediante un modelo de lenguaje a partir de informes y parámetros.

MEETI reduce la barrera de entrada para estudiar alineamiento multimodal a gran escala. También requiere una lectura crítica. Parte del texto es generado por un modelo y no constituye una nueva anotación clínica independiente. El recurso resulta adecuado para pre-entrenamiento, recuperación y generación de informes, pero la evaluación diagnóstica debe conservar etiquetas y conjuntos de referencia validados.

El proyecto no utiliza por ahora MEETI porque su tarea se limita a un latido sintético y tres hallazgos. Sin embargo, este conjunto ofrece una ruta futura para ampliar la representación hacia doce derivaciones y para comparar imagen, señal y texto sobre los mismos registros.

3.6 Modelos multimodales especializados en ECG

Los modelos generalistas de visión y lenguaje han sido entrenados principalmente con imágenes naturales, documentos y contenido web. Un trazado electrocardiográfico posee una estructura diferente. La información se codifica en deflexiones delgadas, relaciones temporales y comparaciones entre derivaciones. Esta distancia de dominio puede limitar la interpretación directa.

Liu y colaboradores introdujeron ECGInstruct, PULSE y ECGBench [21]. ECGInstruct contiene más de un millón de pares de imagen y texto que cubren reconocimiento de características, ritmo, morfología y generación de informes. PULSE es un modelo de siete mil millones de parámetros adaptado a ECG. ECGBench evalúa cuatro tareas en nueve conjuntos e incluye imágenes sintéticas y reales.

Los autores informan que PULSE supera a modelos multimodales generalistas en su banco de pruebas [21]. Este resultado apoya la idea de que el conocimiento visual específico importa. Al mismo tiempo, PULSE se ha entrenado con una colección masiva de instrucciones. No responde a la misma pregunta que este TFG, centrada en utilizar un modelo generalista sin ajuste cuando solo existen unos pocos ejemplos.

PULSE constituye una referencia futura importante. Si se incorpora al protocolo, permitiría separar tres niveles. El primero sería una CNN especializada mediante entrenamiento supervisado. El segundo sería un modelo generalista mediante aprendizaje en contexto. El tercero sería un modelo multimodal ya adaptado a ECG.

La aparición de PULSE modifica el estado del arte, pero no elimina la pregunta de investigación. Un modelo especializado puede no estar disponible para una modalidad rara, una definición local o un nuevo protocolo. El aprendizaje en contexto sigue siendo relevante durante las fases tempranas de formulación y recogida de datos.

3.7 Aprendizaje multimodal en contexto

Flamingo estableció una arquitectura capaz de recibir secuencias intercaladas de imágenes y texto y de resolver tareas con demostraciones [23]. El resultado impulsó el uso de modelos multimodales como sistemas que pueden adaptarse durante la inferencia.

Los estudios posteriores muestran que esta capacidad es frágil. Chen y colaboradores evaluaron si los modelos utilizaban la parte visual de las demostraciones [24]. Encontraron una dependencia dominante del contenido textual en varios bancos. La selección de ejemplos basada en similitud visual seguía aportando valor, pero la imagen dentro de la demostración podía tener menos influencia de la esperada.

Qin y colaboradores estudiaron la selección, el orden y la construcción de los ejemplos [25]. Sus resultados muestran que la recuperación multimodal y la posición de la instrucción afectan al rendimiento. Esto impide tratar K como la única variable. Dos contextos con el mismo número de ejemplos pueden contener información muy diferente.

El protocolo del repositorio responde a estas observaciones. Cada valor positivo de K se repite con tres semillas. Las variantes con respuestas permutadas y demostraciones sin imagen actúan como controles. Las instrucciones breves y las descripciones morfológicas permiten medir el efecto del conocimiento incluido en el texto.

3.8 Gemma 4 y MedGemma

Gemma 4 es una familia abierta y multimodal publicada por Google DeepMind en 2026. Sus variantes admiten texto e imagen, contexto extenso y resolución visual variable [26]. El presupuesto de tokens visuales permite estudiar un compromiso entre detalle y coste. La posibilidad de ejecución local facilita experimentos reproducibles y reduce la necesidad de enviar imágenes a un servicio externo.

El proyecto selecciona Gemma 4 como modelo generalista principal. Esta elección no se justifica mediante una afirmación previa de superioridad en ECG. Se justifica por su disponibilidad abierta, su capacidad para recibir varias imágenes y su compatibilidad con servidores de inferencia locales. El rendimiento deberá establecerse mediante los experimentos.

MedGemma 1.5 se incluye como referencia médica. El modelo ha recibido adaptación con diferentes modalidades clínicas [27]. Sin embargo, su tarjeta no presenta el ECG como una modalidad central y exige validación específica. La comparación permitirá comprobar si el preentrenamiento médico general aporta una ventaja sobre un modelo generalista más reciente.

Las versiones exactas deberán registrarse porque Gemma 4 y MedGemma pertenecen a generaciones base distintas. También deben conservarse la resolución, el presupuesto vi-

sual, la plantilla de conversación y la configuración de inferencia. Sin esa información la comparación no sería reproducible.

3.9 Síntesis comparativa

La tabla 3.1 resume los trabajos más relacionados. Las cifras indican la escala del estudio original y no deben interpretarse como tamaños directamente comparables. Algunas colecciones contienen señales, otras imágenes renderizadas y otras pares multimodales.

Tabla 3.1. Síntesis de trabajos relacionados

Trabajo	Entrada	Escala	Aportación	Relación con este TFG
Ribeiro et al. [11]	Señal de doce derivaciones	Más de dos millones de ECG	Clasificación profunda de seis alteraciones	Referencia supervisada a gran escala
Wagner et al. [12]	Señal de doce derivaciones	21 837 ECG	Conjunto abierto multietiqueta con particiones recomendadas	Ejemplo de recurso real para transferencia futura
Gliner et al. [14]	Señal e imagen	41 830 registros recopilados	Comparación entre entrada digital y visual con artefactos de captura	Evidencia de viabilidad del ECG como imagen
Sangha et al. [15]	Señal e imagen	2 228 236 ECG de entrenamiento	Diagnóstico multietiqueta con validación externa e impresa	Referencia visual supervisada a gran escala
Wu et al. [16]	Imagen de papel	515 registros de validación	Reconstrucción automática de señales desde documentos	Alternativa al análisis directo de imagen
Gliner et al. [17]	Imagen limpia y fotografía	79 226 imágenes etiquetadas y 39 613 imágenes objetivo sin etiqueta	Adaptación adversarial entre formatos	Base para la transferencia sintético real
Gillette et al. [19]	Señal sintética de doce derivaciones	16 900 ECG	Simulación electrofisiológica de ocho grupos	Contraste con el simulador paramétrico simple
Liu et al. [21]	Imagen y texto	Más de un millón de instrucciones	PULSE, ECGInstruct y ECGBench	Referencia especializada para modelos multimodales
Zhang et al. [22]	Señal, imagen, parámetros y texto	Hasta 784 680 registros	Recurso multimodal alineado basado en MIMIC IV ECG	Ruta de ampliación hacia datos clínicos multimodales

Evolucion de enfoques automaticos para ECG usados como contexto del TFG




Figura 3.1. Evolución de los enfoques automáticos para ECG considerados en el TFG.

3.10 Hueco de investigación

La literatura demuestra que el ECG puede analizarse como señal y como imagen. También ofrece modelos especializados capaces de interpretar trazados después de un entrenamiento multimodal de gran escala. Queda menos caracterizado el periodo inicial de un proyecto, cuando las etiquetas son escasas y todavía no se ha decidido si compensa entrenar un modelo específico.

Los estudios de imagen suelen utilizar miles o millones de ejemplos. Los trabajos de aprendizaje en contexto utilizan tareas generales y no siempre comprueban si la información visual de las demostraciones es necesaria. Los modelos especializados en ECG parten de conjuntos de instrucciones masivos. Ninguna de estas líneas responde de forma directa a la comparación planteada aquí.


El TFG aborda ese hueco mediante un presupuesto común de ejemplos. La CNN utiliza las muestras para modificar sus pesos. Gemma 4 y MedGemma las utilizan dentro del contexto. Los controles permiten comprobar si el modelo multimodal aprovecha la correspondencia visual. El simulador ofrece una tarea conocida antes de introducir la variabilidad clínica.

La contribución esperada no es una nueva arquitectura. Es una caracterización experimental del régimen de uso. La rama CNN cerrada en esta memoria responde a la primera mitad: qué ocurre cuando se entrena un modelo visual específico con muy pocos ejemplos y se intenta transferirlo a un dominio real. La rama VLM/ICL deberá completar la segunda mitad: comprobar si el mismo presupuesto K , usado como contexto en lugar de como entrenamiento, mejora la relación entre rendimiento, coste y trazabilidad.

CAPÍTULO 4

Diseño experimental

El diseño experimental se organiza alrededor de dos decisiones. La primera es clínica: el sistema se plantea como apoyo de triaje para sospecha de Brugada, no como diagnóstico autónomo. La segunda es metodológica: se comparan dos formas de usar pocos ejemplos etiquetados. La CNN aprende modificando sus pesos; el VLM previsto aprenderá en contexto, sin ajuste de parámetros.



El test con bloqueantes de sodio se realiza solo en pacientes seleccionados y monitorizados; no es una prueba de cribado indiscriminada.

Figura 4.1. Orientación clínica del prototipo: una alerta prioriza revisión y posible circuito diagnóstico, pero no decide el diagnóstico.

4.1 Pregunta experimental

La pregunta completa del TFG es cuándo rentar entrenar un modelo visual específico frente a utilizar un modelo de visión y lenguaje con aprendizaje en contexto. Como la campaña VLM no dispone todavía de inferencias auditadas, esta memoria cierra el primer brazo de la comparación: la rama CNN.

El brazo CNN debe responder si el enfoque supervisado clásico es suficiente con tan pocos datos. Para ello se evalúa primero en un dominio controlado, después en Brugada HUCA y finalmente con adaptación de dominio. Si la CNN falla en el dominio real incluso tras estas

técnicas, el resultado no es accesorio: es la evidencia que justifica ejecutar la comparación VLM/ICL.

El estudio se cierra con tres familias de experimentos:

- CNN ResNet18 sobre el conjunto sintético QRS/ST con etiqueta derivada de patrón Brugada operativo.
- CNN ResNet18 sobre Brugada HUCA con etiqueta de caso confirmado frente a control.
- Adaptación de dominio desde sintético a HUCA mediante aprendizaje autosupervisado, CORAL, MMD y DANN.

Los modelos abiertos de visión y lenguaje quedan fuera de la evidencia empírica final, pero no fuera del diseño. La infraestructura, los mensajes, los controles y la validación de salida se documentan porque son el segundo brazo de la comparación. No se reportan métricas VLM porque no existen predicciones completas auditadas.

4.2 Canalización experimental

La figura 4.2 resume la canalización. Las imágenes sintéticas y reales se convierten al mismo formato visual de entrada. La ruta CNN entrena modelos con presupuestos reducidos, evalúa por paciente, agrega predicciones por derivación y produce tablas, curvas, matrices de confusión y Grad CAM. La ruta VLM prevista reutiliza las mismas imágenes y presupuestos K , pero introduce los ejemplos como demostraciones dentro del prompt.




Figura 4.2. Diseño experimental: CNN como línea base cerrada y VLM/ICL como comparador central pendiente.

4.3 Unidades de análisis

La unidad de separación es siempre el paciente. En el conjunto sintético, cada paciente simulado contiene tres imágenes correspondientes a V1, V2 y V3. En Brugada HUCA, cada paciente clínico aporta las ventanas renderizadas de esas derivaciones precordiales de rechas. El modelo produce una probabilidad por imagen y la decisión de paciente se obtiene promediando las probabilidades de sus derivaciones antes de aplicar el umbral.


Tabla 4.1. Conjuntos utilizados en los experimentos cerrados.

Conjunto	Pacientes	Imágenes	Positivos	Negativos	Tarea
Sintético QRS/ST	100	300	20	80	Detección derivada de patrón Brugada operativo: RBBB, elevación ST e inversión T presentes
Brugada HUCA	317	951	116	201	Caso Brugada confirmado frente a control, excluyendo categorías limítrofes o no equivalentes

La diferencia entre ambas tareas es deliberada y debe conservarse al interpretar los resultados. En el simulador se evalúa composición morfológica derivada de reglas. En HUCA se evalúa una etiqueta clínica binaria disponible en los metadatos. Por tanto, el salto sintético-real no mide únicamente cambio de renderizado, sino también un cambio de definición de etiqueta.

4.4 Presupuestos de pocos ejemplos

Los presupuestos de entrenamiento son $K = \{2, 4, 8, 16, 32\}$. Para cada K positivo se ejecutan tres semillas: 42, 123 y 2026. La selección de ejemplos se realiza dentro de cada pliegue, sin utilizar el paciente reservado para test. El objetivo no es maximizar rendimiento con todos los datos, sino medir cómo evoluciona cada estrategia cuando las etiquetas son escasas.



LOOCV por paciente, tres semillas por K positivo y agregacion por probabilidad media de V1/V2/V3.

Figura 4.3. Validación leave-one-out por paciente y selección de presupuestos K .

En cada ejecución se conserva el identificador de pliegue, la semilla, los pacientes usados como ejemplos, las predicciones por imagen y las métricas agregadas. El informe de auditoría final verifica 1500 predicciones de paciente en el simulador y 4755 predicciones de paciente en HUCA para la CNN base.

4.5 Modelo CNN evaluado

El modelo supervisado final es ResNet18 con pesos iniciales de ImageNet y una cabeza binaria. Aunque el simulador original contiene tres hallazgos morfológicos, la campaña cerrada utiliza una etiqueta derivada de patrón Brugada operativo: positiva cuando las condiciones necesarias están simultáneamente presentes y negativa cuando el paciente simulado es normal o incompleto. Esta reducción facilita la comparación con HUCA, donde la etiqueta disponible es binaria.

El entrenamiento utiliza `BCEWithLogitsLoss`, ponderación automática de la clase positiva cuando procede, AdamW y selección interna de umbral sobre el subconjunto de validación del pliegue. La métrica principal es la exactitud equilibrada porque la prevalencia positiva es desigual y porque interesa medir sensibilidad y especificidad de forma simétrica.

4.6 Adaptación de dominio

La rama de adaptación de dominio se revisa y ejecuta como extensión del modelo base. Sus métodos son:


- **SSL**: preentrenamiento autosupervisado sobre imágenes sin etiqueta antes del ajuste supervisado.
- **CORAL**: penalización para acercar covarianzas de características entre origen sintético y destino real.
- **MMD**: penalización de discrepancia entre distribuciones de características de ambos

dominios.

- **DANN**: aprendizaje adversario con inversión de gradiente para reducir información específica del dominio [30].

Estas variantes se evalúan en $K = 16$ y $K = 32$, los presupuestos con mayor interés tras observar la curva del modelo base. La comparación se realiza contra la CNN HUCA sin adaptación en los mismos valores de K . Si estas variantes no recuperan rendimiento suficiente, el hallazgo refuerza la necesidad de probar una estrategia distinta, no solo más regularización de la CNN.

Adaptacion de dominio sin etiquetas QRS/ST reales



La adaptacion usa el dominio real como distribucion visual, no como fuente de etiquetas morfologicas. Por eso sigue siendo un experimento de transferencia y triaje, no una prueba diagnostica autonoma.

Figura 4.4. Métodos de adaptación de dominio revisados y ejecutados sobre la rama experimental.

4.7 Métricas

Se reportan exactitud, exactitud equilibrada, F1, precisión, sensibilidad, especificidad, área ROC y precisión media. Las tablas principales muestran la media y la desviación estándar sobre tres semillas. Además, para cada configuración se guardan matrices de confusión agregadas, curvas ROC/PR y predicciones por paciente.

La exactitud equilibrada se define como:

$$BA = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right).$$

Esta métrica es especialmente importante en HUCA, donde un modelo puede obtener sensibilidad moderada a costa de marcar demasiados controles como positivos. En una herramienta de triaje ese comportamiento puede ser tolerable solo si se declara como alerta preliminar y se acompaña de revisión clínica. En la comparación futura con VLM/ICL se usará el mismo criterio principal para evitar que el cambio de familia de modelo cambie la regla de evaluación.

4.8 Estado de cierre

Tabla 4.2. Estado de los bloques experimentales al cierre de la memoria.

Bloque	Estado	Evidencia disponible
Simulador QRS/ST	Completo	Datos, pliegues LOOCV, entrenamiento CNN, tablas, curvas, matriz de confusión y Grad CAM
Brugada HUCA	Completo	Datos procesados, pliegues por paciente, entrenamiento CNN, comparación sintético-real y Grad CAM
Adaptación de dominio	Completo	SSL, CORAL, MMD y DANN ejecutados para $K = 16$ y $K = 32$, con comparación agregada
VLM e ICL	TODO documentado	Segundo brazo de la comparación: código, mensajes, controles y contrato de evaluación preparados; faltan inferencias completas y métricas auditadas
Auditoría final	Completa para CNN	<code>final_cnn_package_ready</code> : OK; VLM marcado explícitamente como TODO

Este estado evita mezclar resultados cerrados con trabajo futuro. Las conclusiones cuantitativas de esta memoria se apoyan únicamente en CNN y adaptación de dominio, pero la interpretación metodológica apunta directamente a la siguiente fase: probar si VLM/ICL mejora la relación entre rendimiento, coste y cantidad de datos etiquetados.

CAPÍTULO 5

Simulador y conjunto de datos sintético

5.1 Objetivo del dominio sintético

La disponibilidad de datos sintéticos permite estudiar una pregunta metodológica sin esperar a reunir una cohorte clínica extensa. En este trabajo el simulador actúa como un laboratorio controlado. Cada beat se construye a partir de componentes interpretables, se valida mediante reglas explícitas y se transforma en una imagen que puede entregarse tanto a una CNN como a un modelo de visión y lenguaje.

El objetivo no es reproducir toda la fisiología cardíaca. Un simulador clínicamente exhaustivo tendría que modelar varias derivaciones, cambios de frecuencia, interacción entre ciclos, conducción auricular y ventricular, ruido de adquisición, variación anatómica y efectos del dispositivo. El sistema implementado reduce el problema a un único beat de apariencia precordial derecha. Esta simplificación permite controlar tres hallazgos visuales que intervienen en la motivación del proyecto.

El uso de datos sintéticos cumple cuatro funciones:

1. Generar etiquetas sin depender de anotación manual para cada imagen.
2. Separar la forma de una onda de factores externos como fabricante, hospital o estilo de documento.
3. Construir presupuestos de ejemplos con tamaños exactos y semillas conocidas.
4. Reservar una familia generadora compuesta para estudiar transferencia.

La contrapartida es una brecha inevitable entre el dominio sintético y el real. El simulador puede demostrar que una tarea controlada es aprendible. No puede demostrar que el mismo rendimiento se mantenga en un ECG clínico. Esa distinción se conserva en toda la memoria.

5.2 Representación matemática

Cada beat se define como una suma de diez átomos gaussianos. Para el átomo i , la amplitud a_i , el centro temporal μ_i y la anchura σ_i determinan la función

$$g_i(t) = a_i \exp \left(-\frac{(t - \mu_i)^2}{2\sigma_i^2} \right). \quad (5.1)$$

La señal completa es

$$x(t) = \sum_{i=1}^{10} g_i(t). \quad (5.2)$$

El signo de a_i controla la dirección de la deflexión. El valor absoluto de a_i controla su magnitud. El parámetro μ_i desplaza el componente sobre el eje temporal y σ_i modifica su extensión. La suma permite formar transiciones suaves sin introducir discontinuidades.

La elección de gaussianas se inspira en modelos sintéticos previos que representan ondas electrocardiográficas mediante componentes paramétricos [18]. El presente simulador es más sencillo que un modelo dinámico electrofisiológico. Su ventaja es la capacidad de relacionar cada modificación con una región visual concreta.

Tabla 5.1. Átomos utilizados para construir un beat

Átomo	Región principal	Función dentro del generador
P	Onda P	Añade una deflexión auricular positiva anterior al QRS
Q	Inicio del QRS	Permite una pequeña deflexión negativa, aunque la configuración actual la mantiene anulada
R	QRS inicial	Produce el primer máximo positivo ventricular
S	QRS central	Forma la deflexión negativa posterior a R
R_prime	QRS terminal	Introduce un segundo máximo positivo y permite una forma RSR prima
J_elev	Punto J	Controla la transición entre el final del QRS y el segmento ST
ST1	ST inicial	Modela elevación temprana y la parte descendente de una forma cóncava
ST2	ST tardío	Controla la continuidad hacia la onda T
T1	Onda T principal	Define la polaridad y la magnitud principal de la repolarización
T2	Cola de la onda T	Suaviza y prolonga la repolarización




Figura 5.1. Construcción de un beat mediante átomos gaussianos y suma resultante.

5.3 Muestreo temporal

La configuración final utiliza una frecuencia de 500 Hz y una duración de 900 ms. El número de muestras se calcula como

$$N = \text{round} \left(\frac{D}{1000} f_s \right), \quad (5.3)$$

donde D es la duración en milisegundos y f_s la frecuencia de muestreo. Con los valores finales se obtienen 450 muestras. El vector temporal es

$$t_n = \frac{1000n}{f_s}, \quad n \in \{0, \dots, N - 1\}. \quad (5.4)$$

Los rangos de la repolarización se definieron sobre una duración de referencia de 900 ms. Cuando cambia la duración del beat, los centros posteriores a 390 ms se adaptan mediante

$$\mu_i^{(D)} = 390 + \left(\mu_i^{(900)} - 390 \right) \frac{D - 390}{900 - 390}. \quad (5.5)$$

Las anchuras de los componentes tardíos se escalan por el mismo factor, con un mínimo que impide gaussianas degeneradas. Los componentes anteriores al punto de pivote no se desplazan. De este modo el QRS conserva su posición mientras que ST y T se comprimen o expanden para ocupar la duración disponible.

5.4 Rangos de parámetros

La generación comienza con un andamiaje compartido. Cada átomo dispone de intervalos para a , μ y σ . Después se aplican sustituciones específicas de la familia. El muestreo dentro de cada intervalo es uniforme. La distribución final no es uniforme porque las reglas morfológicas y los validadores rechazan parte de las propuestas.

Los rangos no deben interpretarse como límites clínicos. Son parámetros de un generador visual. Por ejemplo, el átomo R_{prime} tiene amplitud casi nula en la familia normal y puede alcanzar valores mayores en RBBB. Los átomos J_{elev} , ST1 y ST2 permanecen cerca de cero en una señal normal y se desplazan hacia amplitudes positivas en la familia de elevación del ST.

Separar rangos y validadores responde a dos responsabilidades distintas. Los rangos hacen probable una morfología. Los validadores determinan si la señal terminada satisface la definición operativa. Si ambos elementos se mezclaran, cualquier cambio visual podría alterar de manera silenciosa el significado de las etiquetas.

5.5 Familias generadoras

El simulador contiene cinco familias de origen. Una familia selecciona rangos de muestreo y reglas de coherencia, pero no determina directamente el vector objetivo.

5.5.1 Familia normal

La familia NORMAL reduce la amplitud de R prima, mantiene la región J y ST próxima a la línea base y fuerza ondas T positivas. También exige que la señal no satisfaga ninguno de los tres validadores de hallazgos. Esta exclusión explícita es necesaria porque una señal generada con rangos normales podría producir por azar una combinación que superase un umbral patológico.

5.5.2 Morfología RBBB

La familia RBBB favorece una segunda deflexión positiva posterior a S. La posición de R prima se obliga a aparecer al menos 24 ms después del centro de S. Su amplitud no puede quedar por debajo del 80 por ciento de la amplitud de R dentro de los límites permitidos. También se amplía su anchura respecto a la primera R.

El resultado busca una forma RSR prima visible. No reproduce todos los criterios clínicos de bloqueo completo de rama derecha, que dependen de la duración global del QRS y de la distribución entre derivaciones [3]. Por ello la etiqueta se denomina morfología compatible en el texto interpretativo.

5.5.3 Elevación de ST

La familia ST_ELEVATION utiliza amplitudes positivas en el punto J y en los dos componentes del ST. La primera sección del ST se ensancha para evitar un pico estrecho que pudiera confundirse con una deflexión del QRS. El validador exige además actividad ventricular positiva y negativa suficiente, con el fin de descartar señales planas elevadas.

5.5.4 Inversión de T

La familia T_WAVE_INVERSION hace negativas las dos componentes de T y las separa de la región ST. También puede producir una R prima moderada y una elevación pequeña de J. Esta elección permite coocurrencias con RBBB y ST. El validador exige que la deflexión negativa sea tardía, suficientemente profunda y mantenida.

5.5.5 Familia Brugada

La familia BRUGADA implementa únicamente una forma coved o tipo 1 esquemática. Combina elevación de J, ST inicial positivo, descenso posterior e inversión de T. La amplitud de R prima es menor que en la familia RBBB pura, pero puede mantener una alteración terminal del QRS.

El nombre de la familia no se incorpora al vector objetivo. Una señal aceptada por el validador interno de Brugada se vuelve a evaluar mediante los validadores independientes de RBBB, elevación de ST e inversión de T. Por tanto puede recibir una combinación parcial de hallazgos. Esta decisión convierte la familia en una prueba de composición y evita utilizar una etiqueta clínica que el simulador no puede justificar.

Tabla 5.2. Relación entre familias generadoras y rasgos favorecidos

Familia	Modificación dominante	Interpretación experimental
NORMAL	ST próximo a cero, T positiva y R prima mínima	Referencia sin hallazgos operativos
RBBB	Segundo máximo positivo tardío y ancho	Componente terminal del QRS
ST elevado	Punto J y ST positivos	Componente de elevación posterior al QRS
Inversión de T	Repolarización tardía negativa	Componente de inversión de T
BRUGADA	J elevado, ST descendente y T negativa	Familia compuesta reservable para transferencia

5.6 Reglas de coherencia morfológica

El muestreo independiente de los átomos puede producir órdenes temporales incoherentes. Para reducir este problema se aplican reglas deterministas antes de sumar las gaussianas. Q debe preceder a R. S debe aparecer después de R y ser más ancha. J se sitúa después de S. Los dos componentes del ST se ordenan tras J. T1 y T2 ocupan la región final.

Estas reglas no garantizan fisiología. Garantizan una geometría mínima para que ca-

da parámetro conserve una interpretación. Las reglas específicas de una familia refuerzan relaciones adicionales, como la posición tardía de R prima o el signo negativo de T.

Modificar una regla puede tener efectos indirectos. Mover T1 cambia el resultado del validador de inversión y también puede alterar la media tardía del ST. Por eso cada cambio debe acompañarse de una nueva generación de ejemplos, un análisis de frecuencias y una comprobación de aceptación.

5.7 Muestreo con rechazo

El procedimiento de generación utiliza muestreo con rechazo. Para una familia c , el algoritmo sigue los siguientes pasos:

1. Combinar los rangos base con los rangos específicos de c .
2. Adaptar los componentes tardíos a la duración solicitada.
3. Muestrear los parámetros de los diez átomos.
4. Aplicar las reglas de orden y coherencia.
5. Sumar los átomos sobre el vector temporal.
6. Evaluar el validador correspondiente a c .
7. Aceptar la señal si supera las reglas o volver al paso de muestreo.

El límite por defecto es de 400 intentos. Si no se obtiene una señal válida, el generador lanza un error e incluye las últimas métricas calculadas. El número de intento se almacena en los metadatos de cada muestra. Esta variable permite detectar rangos mal alineados con los validadores.

Sea q_c la probabilidad de aceptación de una propuesta de la familia c . El número esperado de intentos antes de una aceptación es aproximadamente

$$\mathbb{E}[A_c] = \frac{1}{q_c}. \quad (5.6)$$

Una familia que requiere muchos intentos puede seguir generando imágenes correctas, pero revela que gran parte de su espacio paramétrico no satisface la definición operativa. Las tasas de aceptación deben registrarse cuando se cierre la versión final del simulador.

5.8 Validadores y semántica de las etiquetas

Los validadores operan sobre ventanas temporales de la señal terminada. Las ventanas posteriores a 390 ms se adaptan mediante la ecuación 5.5. Las amplitudes se expresan en mV y las duraciones en ms.

Tabla 5.3. Criterios operativos de los validadores sintéticos

Validador	Condiciones necesarias
RBBB	Dos máximos positivos entre 240 y 470 ms, separación mínima de 28 ms, primer máximo superior a 0,12 mV, segundo máximo superior a 0,20 mV, mínimo intermedio inferior a $-0,05$ mV, segundo máximo posterior a 345 ms y anchura terminal superior a 38 ms por encima de 0,10 mV
Elevación de ST	Máximo del QRS superior a 0,28 mV, mínimo del QRS inferior a $-0,14$ mV, media de J superior a 0,09 mV y media del ST superior a 0,09 mV
Inversión de T	Máximo del QRS superior a 0,22 mV, máximo de R prima superior a 0,08 mV, media del ST superior a $-0,03$ mV, mínimo de T inferior a $-0,12$ mV, mínimo posterior al umbral temporal equivalente a 640 ms y más de 45 ms por debajo de $-0,05$ mV
Normal	Máximo del QRS superior a 0,22 mV, mínimo inferior a $-0,10$ mV, media de ST entre $-0,04$ y 0,05 mV, máximo de T superior a 0,12 mV, R prima inferior a 0,10 mV y rechazo de los tres hallazgos
Brugada	Máximo del QRS superior a 0,18 mV, mínimo inferior a $-0,16$ mV, media de J superior a 0,09 mV, media de ST superior a 0,08 mV, ST temprano al menos 0,03 mV por encima del ST tardío y mínimo de T inferior a $-0,08$ mV

Los umbrales se diseñaron para separar morfologías del simulador. No deben trasladarse a un ECG real ni compararse de forma directa con criterios clínicos. Un ECG real requiere calibración, derivaciones identificadas, velocidad de papel conocida y valoración del contexto. Los estándares clínicos revisados en el capítulo 2 se utilizan para orientar la forma general, no para validar pacientes.

Las tres etiquetas finales se calculan de forma independiente. Para una señal aceptada, se ejecutan los validadores de RBBB, ST y TWI y se construye un vector binario. Este paso puede producir coocurrencias que no coinciden con la familia. La etiqueta final es una propiedad de la señal, no una copia del mecanismo que la generó.

5.9 Renderizado de las señales

Cada beat se representa sobre un lienzo cuadrado. La configuración final guarda imágenes de 896 por 896 píxeles a 130 puntos por pulgada. El eje horizontal utiliza una cuadrícula menor cada 40 ms y una cuadrícula mayor cada 200 ms. El eje vertical utiliza divisiones menores de 0,1 mV y mayores de 0,5 mV. La señal se dibuja en negro con un grosor de dos puntos y la cuadrícula en rosa con dos intensidades.

El renderizado conserva títulos de ejes y valores numéricos. Estos elementos aportan información de escala, pero también pueden transformarse en atajos si los límites cambian entre muestras. Por ese motivo, los límites horizontal y vertical se fijan para todas las imágenes.

nes de la campaña final. La inspección visual verifica que ninguna familia posee un encuadre, margen o patrón de marcas propio.

No se aplicarán reflejos horizontales. Invertir el eje temporal cambiaría el orden fisiológico de las ondas. Tampoco se aplicarán reflejos verticales, ya que intercambiarían elevación y depresión. Las transformaciones visuales admisibles deben conservar la semántica, como pequeñas variaciones de grosor, contraste, desplazamiento y escala dentro de límites conocidos.

Ejemplos sintéticos por familia generadora




Figura 5.2. Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador.

5.10 Construcción del conjunto de datos

El constructor crea primero un ejemplo de verificación por familia. Después genera el número solicitado de beats y asigna una semilla independiente a cada muestra. Finalmente crea las particiones y guarda las imágenes.

Cada fila del manifiesto contiene:

- ruta relativa de la imagen
- nombre de la partición

- familia generadora
- semilla de la muestra
- número de intento de aceptación
- subtipo cuando corresponde
- índice interno
- tres columnas binarias de etiquetas

Además se genera un esquema de etiquetas y un resumen con frecuencias por partición, familia, etiqueta y combinación. Los manifiestos CSV permiten entrenar modelos visuales sin depender de la estructura de carpetas. Los ficheros JSON conservan información para auditoría y generación de informes.

Tabla 5.4. Configuración final del conjunto sintético QRS/ST

Elemento	Total	Organización	Finalidad
Pacientes simulados	100	20 por familia fuente	Construir una cohorte equilibrada por mecanismo generador
Imágenes	300	Copia del beat central en V1, V2 y V3	Evaluar el mismo contrato visual que en HUCA
Pliegues LOOCV	100	Un paciente reservado por pliegue	Medir rendimiento agregado por paciente
Presupuestos K	5	2, 4, 8, 16 y 32 ejemplos	Estudiar aprendizaje supervisado con pocos datos

5.11 Comprobación de integración

La configuración final se ejecutó para generar 100 pacientes sintéticos, 300 imágenes, pliegues LOOCV y resúmenes de etiquetas. El conjunto contiene 20 pacientes con los tres hallazgos presentes y 80 pacientes normales o incompletos. Las combinaciones observadas incluyen NORMAL, RBBB, RBBB+ST, RBBB+ST+TWI, RBBB+TWI y TWI.

Esta comprobación no se limita a una prueba de humo: es el conjunto utilizado en la campaña CNN sintética. Su función es demostrar que la ruta de generación, aceptación, partición y escritura es operativa y que el conjunto final conserva variabilidad suficiente para estudiar la curva por K .

La inspección visual mostró que las familias pueden compartir etiquetas. Una muestra de elevación del ST puede satisfacer además el validador RBBB. Una muestra generada como inversión de T puede presentar una segunda deflexión positiva terminal. Este comportamiento confirma que el problema no es una clasificación encubierta de cinco carpetas.

5.12 Control de calidad del simulador

La validación del conjunto sintético se organiza en cuatro niveles.

5.12.1 Nivel estructural

Se comprueba que cada señal tiene 450 muestras, que sus valores son finitos y que las imágenes tienen dimensiones constantes. Los manifiestos deben contener todas las rutas y no puede haber duplicados entre pliegues de evaluación.

5.12.2 Nivel semántico

Se recalculan las etiquetas directamente desde la señal cuando esta se conserva. Los valores de los validadores se comparan con las columnas del manifiesto. La familia normal debe tener el vector vacío. La familia Brugada debe superar su regla interna aunque su vector final pueda contener una combinación parcial.

5.12.3 Nivel distribucional

Se analizan las frecuencias de cada etiqueta y de cada combinación. Un balance perfecto por familia no implica balance por etiqueta. Si una combinación domina el conjunto, la macro F_1 puede ocultar que el modelo utiliza coocurrencias. Se revisarán matrices entre familia y etiqueta, distribuciones de intentos y rangos de amplitud.

5.12.4 Nivel visual

Se generan paneles sin intervención del modelo. La revisión busca ondas truncadas, escalas diferentes, textos que revelen la clase, cuadrículas inconsistentes, trazos fuera del lienzo y formas que no se correspondan con sus métricas. Una muestra que pasa reglas numéricas pero resulta visualmente inverosímil debe motivar una revisión del generador.




Figura 5.3. Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV.

5.13 Riesgos de atajos visuales

Un modelo puede obtener resultados altos sin aprender la morfología pretendida. Entre los atajos posibles se encuentran límites automáticos del eje, diferencias de antialiasing, márgenes asociados a la amplitud, densidad de cuadrícula, nombres de fichero y estructura de carpetas.

Para reducir estos riesgos, las imágenes se cargarán desde el manifiesto y la familia no se entregará al modelo. Los límites visuales serán constantes. Los nombres de fichero solo contendrán un contador. La evaluación incluirá recortes de la zona de trazado y versiones sin texto de ejes como análisis de sensibilidad. Si el rendimiento cae de forma drástica al retirar elementos no fisiológicos, se investigará el origen antes de interpretar los resultados.

También se comprobará la atención espacial de las CNN mediante Grad CAM [29]. La finalidad no es demostrar causalidad, sino detectar si las regiones activas se concentran en QRS, ST y T o en elementos periféricos.

5.14 Limitaciones del simulador

El simulador representa un beat aislado y una geometría semejante a una derivación precordial. No modela doce derivaciones ni una transformación eléctrica común entre ellas. No incluye variabilidad entre beats, arritmias, intervalos dependientes de frecuencia, ruido muscular, deriva de línea base, interferencia de red, pérdida de electrodos ni compresión de documentos.

La forma de cada onda se construye con gaussianas. Esta elección produce curvas suaves y puede simplificar bordes que en un ECG real son más irregulares. Los validadores se basan en ventanas y umbrales creados para este dominio. Una señal clínica no debe procesarse con ellos como si fueran reglas diagnósticas.

La familia Brugada es una aproximación a una morfología coved. No representa la heterogeneidad del síndrome, la variación entre derivaciones ni la posibilidad de patrones intermitentes. Su uso se limita a estudiar composición visual de los tres hallazgos.

Estas limitaciones no invalidan el laboratorio sintético. Delimitan qué afirmaciones puede sostener. El dominio permite comparar eficiencia de ejemplos bajo condiciones controladas. La validez clínica dependerá de la evaluación externa descrita en el capítulo de datos reales.

CAPÍTULO 6

Modelos

Este capítulo describe las dos familias de modelos que definen el TFG. La evidencia empírica cerrada corresponde a la CNN y a sus variantes de adaptación de dominio. Los modelos de visión y lenguaje no se presentan como adorno futuro, sino como el segundo brazo de la comparación metodológica: una forma alternativa de usar los mismos pocos ejemplos sin actualizar pesos.

6.1 Entrada común

Todos los modelos trabajan con imágenes de ECG. En la CNN, cada imagen corresponde a una derivación precordial derecha renderizada y redimensionada a 224 por 224 píxeles. En la línea VLM prevista, la misma imagen se incluirá en un mensaje multimodal junto con instrucciones y, si procede, ejemplos en contexto. La comparación solo tiene sentido porque ambos enfoques reciben la misma evidencia visual y se evalúan por paciente.




Figura 6.1. Recorridos de entrada y evaluación: CNN cerrada y VLM/ICL preparado como comparador de pocos datos.

6.2 Dos formas de usar K

El presupuesto K tiene significados distintos según el modelo. En la CNN, K determina cuántos pacientes etiquetados se usan para optimizar los pesos. El aprendizaje ocurre durante el entrenamiento y la inferencia posterior solo aplica la red ajustada. En un VLM con aprendizaje en contexto, K determina cuántas demostraciones se incluyen en el prompt. Los pesos permanecen fijos y el aprendizaje se produce de forma implícita durante la generación.

Esta diferencia es la razón de la comparación. Si K es muy pequeño, entrenar una CNN puede producir alta varianza, sobreajuste o dependencia de atajos visuales. Un VLM, en cambio, podría aprovechar conocimiento visual previo y usar los ejemplos para fijar el formato de la tarea. También puede fallar: puede ignorar la imagen, apoyarse en el texto o devolver respuestas inválidas. Por eso la rama VLM requiere controles específicos.

6.3 CNN ResNet18

El modelo supervisado ejecutado es una ResNet18 de `torchvision` con pesos iniciales `DEFAULT`. La cabeza de clasificación se sustituye por una salida binaria. En los experimentos sintéticos, la etiqueta positiva indica que el paciente simulado cumple simultáneamente los hallazgos operativos asociados al patrón Brugada derivado. En HUCA, la etiqueta positiva indica caso Brugada confirmado frente a control.

La pérdida es `BCEWithLogitsLoss`. Cuando el pliegue lo requiere, la clase positiva se pondera automáticamente a partir de los ejemplos de entrenamiento. El optimizador es AdamW, con tasa de aprendizaje 3×10^{-4} , lote de 32 imágenes y 20 épocas máximas. La selección de umbral se realiza en validación interna mediante exactitud equilibrada derivada por paciente; si no hay validación suficiente, se conserva el umbral 0,5.

Tabla 6.1. Configuración CNN utilizada en las campañas finales.

Propiedad	Valor
Arquitectura	ResNet18 con cabeza binaria
Inicialización	Pesos DEFAULT de Torchvision para ResNet18
Entrada	RGB, 224 por 224 píxeles
Pérdida	BCEWithLogitsLoss, loss_pos_weight=auto
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Épocas máximas	20
Tamaño de lote	32
Presupuestos	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026
Umbral	Seleccionado por validación con exactitud equilibrada por paciente
Agregación	Media de probabilidades de V1, V2 y V3 antes del umbral

6.4 Validación por paciente

El entrenamiento y la evaluación se organizan mediante validación leave-one-out. En cada pliegue se reserva un paciente completo y se entrena con un subconjunto de K pacientes del resto. Esto evita que imágenes de un mismo paciente aparezcan simultáneamente en entrenamiento y test. En HUCA esta restricción es indispensable porque las tres derivaciones de un paciente comparten adquisición, calibración y contexto clínico.

El informe de cada ejecución guarda:

- configuración de entrenamiento;
- pacientes seleccionados como ejemplos;
- probabilidades por imagen;
- predicción agregada por paciente;
- umbral elegido;
- matriz de confusión y métricas;
- paneles Grad CAM para inspección cualitativa.

6.5 Grad CAM

Grad CAM se utiliza como diagnóstico cualitativo, no como explicación clínica suficiente [29]. El mapa indica regiones que influyen en el logit del modelo, pero no prueba que la red haya aprendido un criterio médico correcto. En esta memoria se usa para comprobar si las activaciones se concentran en zonas plausibles del trazado y para detectar errores en los que una atención visual razonable termina en una decisión equivocada.




Figura 6.2. Ejemplo Grad CAM del modelo CNN sobre el conjunto sintético.

6.6 Adaptación de dominio

La adaptación de dominio se entrena con el conjunto sintético como origen etiquetado y HUCA como destino no etiquetado durante el ajuste. La evaluación final sigue realizándose sobre HUCA por paciente. Se revisan cuatro variantes:

- **SSL.** Preentrenamiento SimCLR durante tres épocas sobre imágenes del dominio destino y posterior ajuste supervisado. En el código se reproduce con `METHOD=ssl`, que internamente llama al pipeline con `domain_adaptation=none` y

`ssl_pretrain_epochs=3.`

- **CORAL**. Penalización de covarianzas para aproximar la estructura de características de origen y destino.
- **MMD**. Penalización de discrepancia de medias en kernel con escalas 0,5, 1,0, 2,0 y 4,0.
- **DANN**. Clasificador de dominio adversario con inversión de gradiente [30].

Las pérdidas de adaptación se ponderan con 0,1 y se activan de forma progresiva durante el entrenamiento. Esta rama responde a una pregunta concreta: si la CNN falla por cambio de dominio visual, alinear representaciones debería recuperar parte del rendimiento. Los resultados muestran que la mejora existe, pero es demasiado pequeña para cerrar el problema.

6.7 Modelos de visión y lenguaje

La línea VLM queda preparada para la siguiente fase experimental. Su objetivo será comparar aprendizaje supervisado con aprendizaje en contexto bajo el mismo presupuesto K . La CNN modifica pesos con ejemplos etiquetados; el VLM mantiene pesos fijos y recibe ejemplos dentro del mensaje. Esta diferencia convierte a los VLM en una alternativa especialmente relevante cuando etiquetar nuevos ECG es lento o caro.

El modelo abierto principal previsto es Gemma 4 y la referencia médica prevista es MedGemma. Ambos se servirán localmente mediante vLLM cuando haya recursos disponibles. La respuesta esperada será un JSON validado, sin explicación libre obligatoria, para evitar que una salida con formato incorrecto se mezcle con una predicción válida.




Figura 6.3. Canalización VLM/ICL prevista: selección de ejemplos, prompt multimodal, modelo local, validación JSON y controles.

6.8 Controles previstos para VLM

Cuando se ejecute la campaña VLM, deberán conservarse al menos tres condiciones:

- **Normal:** ejemplos con imagen y respuesta correcta.
- **Respuestas permutadas:** las imágenes de ejemplo se mantienen, pero las respuestas se barajan para medir dependencia real de la correspondencia imagen-etiqueta.
- **Ejemplos sin imagen:** el contexto conserva texto y respuestas, pero elimina la evidencia visual de las demostraciones.

Estos controles son necesarios porque un VLM puede aprovechar sesgos textuales, frecuencia de etiquetas o formato del mensaje sin interpretar la morfología del ECG. Si el rendimiento no cae con respuestas permutadas o sin imágenes, la mejora no podría atribuirse a aprendizaje multimodal real. Hasta que no existan esos resultados, el VLM se mantiene como procedimiento reproducible pendiente.

6.9 Criterio de comparación

La comparación principal entre métodos se hará con exactitud equilibrada por paciente. F1, sensibilidad, especificidad, área ROC y precisión media se reportan como métricas complementarias. También se compararán coste de entrenamiento, coste por inferencia, tasa de respuestas inválidas, latencia y necesidad de hardware.

La lectura esperada no será CNN contra VLM como competición abstracta. Será una curva de decisión: con qué K , qué coste y qué robustez conviene entrenar un modelo específico; y en qué zona de pocos datos puede rentar usar ICL para obtener una señal preliminar de triaje. En el cierre actual, todas las conclusiones cuantitativas proceden de CNN y adaptación de dominio. Esa base es precisamente el punto de partida de la comparación VLM.

CAPÍTULO 7

Resultados en el conjunto sintético

El primer bloque de resultados evalúa si la CNN puede aprender la tarea en un entorno controlado. El conjunto sintético contiene 100 pacientes simulados y 300 imágenes, con tres derivaciones por paciente. La etiqueta positiva corresponde a la presencia simultánea de los hallazgos operativos que definen el patrón Brugada derivado en el simulador. Hay 20 pacientes positivos y 80 normales o incompletos.

7.1 Curva por presupuesto

La tabla 7.1 muestra la media y la desviación estándar sobre tres semillas. La tendencia es clara: con $K = 2$ y $K = 4$ el modelo ya supera el azar en exactitud equilibrada, pero aún produce muchos falsos positivos. A partir de $K = 16$ aparece una mejora sustancial y con $K = 32$ se obtiene el mejor punto de la campaña.

Tabla 7.1. Resultados CNN ResNet18 sobre el conjunto sintético QRS/ST.

K	BA	F1	Sens.	Esp.	ROC AUC
2	$0,625 \pm 0,022$	0,401	0,650	0,600	0,520
4	$0,631 \pm 0,042$	0,407	0,617	0,646	0,566
8	$0,685 \pm 0,023$	0,468	0,683	0,688	0,629
16	$0,773 \pm 0,013$	0,569	0,800	0,746	0,755
32	$0,848 \pm 0,030$	0,673	0,883	0,812	0,857




Figura 7.1. Exactitud equilibrada de la CNN sobre el conjunto sintético según el presupuesto K .

El incremento entre $K = 8$ y $K = 16$ es el cambio más importante de la curva. El modelo pasa de una exactitud equilibrada media de 0,685 a 0,773, lo que indica que ocho ejemplos todavía no cubren suficientemente la variabilidad de combinaciones morfológicas. Con $K = 32$, la sensibilidad alcanza 0,883 y la especificidad 0,812, una combinación razonable para una tarea controlada de alerta morfológica.

7.2 Matriz de confusión

La matriz agregada de $K = 32$ resume el mejor punto sintético. En las tres semillas se acumulan 53 verdaderos positivos, 195 verdaderos negativos, 45 falsos positivos y 7 falsos negativos. El error dominante sigue siendo marcar como positivos algunos pacientes incompletos, aunque el número de falsos negativos es bajo.




Figura 7.2. Matriz de confusión agregada del conjunto sintético para $K = 32$.

En un contexto de triaje, esta distribución de errores sería preferible a la situación inversa: el modelo tiende a avisar de más antes que a omitir positivos. Sin embargo, el conjunto sintético no representa pacientes reales y sus etiquetas proceden de reglas internas; por tanto, este resultado solo demuestra aprendizaje de la tarea simulada.

7.3 Inspección cualitativa

El panel Grad CAM de la figura 7.3 muestra que el modelo atiende a regiones del complejo QRS, el punto J y la repolarización. La inspección es coherente con la definición de la etiqueta, pero no sustituye a una validación clínica. Grad CAM ayuda a detectar fallos obvios de atención; no certifica que la red razone como un especialista.




Figura 7.3. Ejemplo Grad CAM del modelo sintético.

7.4 Conclusión del dominio sintético

El dominio sintético confirma tres hechos. Primero, el renderizado contiene información visual suficiente para entrenar una CNN con pocos ejemplos. Segundo, el presupuesto importa: por debajo de $K = 16$ el comportamiento es útil pero irregular; con $K = 32$ el modelo mejora simultáneamente sensibilidad, especificidad, F1 y área ROC. Tercero, este buen rendimiento no puede trasladarse de forma directa a clínica porque las imágenes sintéticas son más limpias y las etiquetas están definidas por el propio generador.

Por ese motivo, el siguiente capítulo contrasta estos resultados con Brugada HUCA y mide explícitamente la brecha de dominio.

CAPÍTULO 8

Evaluación con Brugada HUCA

El segundo bloque de resultados utiliza Brugada HUCA, un conjunto de ECG clínicos reales asociado al síndrome de Brugada [38]. La finalidad de este capítulo es medir cuánto se degrada el modelo al abandonar el simulador y evaluar si la adaptación de dominio recupera parte de esa pérdida. Este capítulo es clave para la comparación futura con VLM: si una CNN entrenada y adaptada con pocos ejemplos no supera de forma robusta el dominio real, queda justificada la búsqueda de estrategias que usen conocimiento previo e in-context learning.

8.1 Cohorte final

El procesamiento parte de 363 pacientes. Se excluyen 46 casos con patrón basal limítrofe que no deben mezclarse como positivos o negativos en la tarea principal. La cohorte final contiene 317 pacientes: 116 casos Brugada confirmados y 201 controles. Para cada paciente se generan tres imágenes, una por V1, V2 y V3, lo que produce 951 imágenes.

Tabla 8.1. Cohorte Brugada HUCA utilizada en la evaluación CNN.


Grupo	Pacientes	Imágenes
Brugada confirmado	116	348
Control	201	603
Excluido por patrón basal limítrofe	46	—
Total evaluado	317	951

La etiqueta real disponible no es equivalente a las tres etiquetas morfológicas del simulador. HUCA no contiene anotaciones independientes de RBBB, elevación ST e inversión T para cada imagen. Por ello, el experimento real se formula como caso Brugada confirmado frente a control y sus conclusiones se limitan a triaje de esa variable clínica.

8.2 Preprocesamiento

La preparación selecciona las derivaciones precordiales derechas, detecta un latido central y recorta una ventana de 300 ms antes de R y 600 ms después de R. La salida conserva el identificador de paciente, derivación, etiqueta clínica, ruta de imagen y plan de pliegues LOOCV. El objetivo es obtener una representación visual comparable a la sintética sin borrar la variabilidad propia del ECG real.

Preparacion de Brugada-HUCA



La etiqueta QRS/ST real no se inventa: HUCA aporta clinical_brugada para evaluar la regla final derivada.

Esto separa el detector morfológico entrenado en sintético de la referencia clínica usada para triaje y auditoría patient-level.

Figura 8.1. Canalización de preprocesamiento de Brugada HUCA para V1, V2 y V3.

La separación por paciente es obligatoria. Si V1, V2 y V3 de un mismo paciente se repartieran entre entrenamiento y test, el modelo podría aprovechar características de adquisición o escala en lugar de aprender rasgos clínicamente relevantes.

8.3 Resultados CNN base

La tabla 8.2 resume la CNN base entrenada y evaluada sobre HUCA. A diferencia del dominio sintético, aumentar K no produce una mejora monotonica. El mejor punto de exactitud equilibrada aparece con $K = 16$, pero solo alcanza 0,516. Con $K = 32$ la exactitud equilibrada baja a 0,499.

Tabla 8.2. Resultados CNN ResNet18 sobre Brugada HUCA.

K	BA	F1	Sens.	Esp.	ROC AUC
2	0,509 $\pm$ 0,010	0,484	0,693	0,325	0,525
4	0,509 $\pm$ 0,023	0,493	0,730	0,289	0,495
8	0,490 $\pm$ 0,018	0,469	0,672	0,308	0,496
16	0,516 $\pm$ 0,023	0,480	0,658	0,375	0,569
32	0,499 $\pm$ 0,012	0,466	0,644	0,355	0,491




Figura 8.2. Exactitud equilibrada de la CNN base sobre Brugada HUCA.

La sensibilidad es moderada, pero la especificidad es baja. En el mejor punto $K = 16$, la matriz agregada de tres semillas contiene 229 verdaderos positivos, 226 verdaderos negativos, 377 falsos positivos y 119 falsos negativos. El modelo tiende a sobredetectar casos Brugada, lo que podría ser aceptable únicamente como alerta preliminar, pero no como herramienta de descarte.




Figura 8.3. Matriz de confusión agregada de Brugada HUCA para $K = 16$.

8.4 Brecha sintético-real

La comparación directa muestra una brecha de dominio marcada. En el simulador la exactitud equilibrada aumenta hasta 0,848 con $K = 32$. En HUCA, el modelo se mantiene alrededor de 0,50. Esto indica que la señal visual aprendida en condiciones controladas no se transfiere de forma directa a la variabilidad clínica.




Figura 8.4. Comparación de exactitud equilibrada entre el conjunto sintético y Brugada HUCA.




Figura 8.5. Comparación de F1 entre el conjunto sintético y Brugada HUCA.

La brecha tiene varias causas plausibles: ruido y variabilidad de adquisición, diferencias de escala, presencia de múltiples fenotipos, etiqueta clínica no reducible a una sola ventana de ECG y ausencia de anotaciones morfológicas finas en HUCA. El resultado no invalida el simulador; delimita su alcance.

8.5 Adaptación de dominio

La rama de adaptación de dominio entrena con imágenes sintéticas etiquetadas y utiliza HUCA como dominio destino no etiquetado. Se ejecutan cuatro variantes: SSL, CORAL, MMD y DANN. La tabla 8.3 compara cada método con la línea base en $K = 16$ y $K = 32$.

Tabla 8.3. Comparación de adaptación de dominio sobre Brugada HUCA.

Método	K	BA	F1	Sens.	Esp.
Base	16	0,516 $\pm$ 0,023	0,480	0,658	0,375
SSL	16	0,477 $\pm$ 0,027	0,458	0,658	0,297
CORAL	16	0,524 $\pm$ 0,008	0,481	0,641	0,408
MMD	16	0,516 $\pm$ 0,019	0,474	0,635	0,396
DANN	16	0,515 $\pm$ 0,019	0,470	0,621	0,410
Base	32	0,499 $\pm$ 0,012	0,466	0,644	0,355
SSL	32	0,503 $\pm$ 0,014	0,476	0,672	0,333
CORAL	32	0,528 $\pm$ 0,013	0,480	0,632	0,423
MMD	32	0,549 $\pm$ 0,029	0,498	0,649	0,448
DANN	32	0,509 $\pm$ 0,028	0,472	0,644	0,375




Figura 8.6. Exactitud equilibrada de las variantes de adaptación de dominio.




Figura 8.7. F1 de las variantes de adaptación de dominio.

La mejor configuración es MMD con $K = 32$, con BA 0,549 y especificidad 0,448. La mejora frente a la línea base de $K = 32$ es de 0,049 puntos de exactitud equilibrada. Es una señal positiva para la adaptación, pero todavía insuficiente para considerar el sistema clínicamente robusto.

8.6 Inspección cualitativa

El Grad CAM real confirma que las activaciones pueden localizarse sobre regiones del trazado, pero también muestra la dificultad de interpretar modelos entrenados con pocos ejemplos sobre datos clínicos heterogéneos. La atención visual no compensa la falta de especificidad ni resuelve la diferencia entre etiqueta clínica y morfología observable.




Figura 8.8. Ejemplo Grad CAM del modelo CNN sobre Brugada HUCA.

8.7 Conclusión en datos reales

La conclusión de HUCA es prudente. La CNN detecta parte de los casos positivos, pero genera demasiados falsos positivos y no supera de forma amplia el azar en exactitud equilibrada. La adaptación de dominio mejora el mejor punto hasta 0,549, con MMD en $K = 32$, pero la brecha sintético-real sigue dominando el comportamiento.

En términos de aplicación, estos resultados solo apoyan un uso de investigación para priorización de revisión. No apoyan diagnóstico autónomo, descarte automático ni toma de decisiones clínicas sin especialista. En términos metodológicos, el resultado deja una línea

base exigente: la siguiente fase debe comprobar si VLM/ICL puede mejorar esta situación con los mismos presupuestos K , o si la escasez de datos afecta de forma parecida a ambas familias.

CAPÍTULO 9

Discusión

El resultado principal del trabajo no es que la CNN funcione bien. El resultado principal es más matizado: la CNN aprende una tarea visual controlada, pero no consigue trasladar ese aprendizaje a Brugada HUCA de forma robusta cuando el número de ejemplos etiquetados es muy pequeño. En el simulador alcanza 0,848 de exactitud equilibrada con $K = 32$; en HUCA la línea base queda cerca de 0,50 y la mejor adaptación de dominio solo llega a 0,549. Esta brecha es la evidencia que da sentido a la comparación posterior con VLM/ICL.

9.1 Qué demuestra el simulador

El simulador demuestra que la formulación como imagen es viable para una CNN. La red aprende rasgos relacionados con QRS, punto J, segmento ST y onda T, y mejora al aumentar el presupuesto de ejemplos. El salto entre $K = 8$ y $K = 16$ sugiere que la tarea necesita una cobertura mínima de variabilidad morfológica; por debajo de ese rango, la selección de ejemplos pesa demasiado.

Sin embargo, el simulador no demuestra capacidad diagnóstica. Sus etiquetas se generan con reglas internas, las imágenes son limpias y las familias morfológicas están más separadas que en práctica clínica. El valor del simulador es experimental: permite comprobar código, métricas, agregación por paciente y sensibilidad al número de ejemplos antes de utilizar datos reales.

9.2 Qué demuestra HUCA

HUCA introduce la dificultad que faltaba en el simulador. La etiqueta es clínica, los registros son heterogéneos y una ventana de V1, V2 o V3 no contiene por sí sola todo el proceso diagnóstico. El rendimiento obtenido indica que la CNN capta parte de la señal positiva, pero con baja especificidad. En la práctica, esto significa que el modelo avisa demasiado.

Ese comportamiento puede tener sentido en un sistema de triaje preliminar si se presenta como ayuda para priorizar revisión. No tiene sentido como sistema de descarte. Una herramienta que produce muchos falsos positivos aumenta carga de revisión; una herramienta que produce falsos negativos puede retrasar casos relevantes. Con los números actuales, la

única lectura responsable es investigación y apoyo exploratorio.

9.3 Por qué no basta la adaptación de dominio

La brecha sintético-real tiene dos componentes. El primero es visual: el ECG real contiene ruido, variabilidad de escala, diferencias de adquisición y trazados menos regulares. El segundo es semántico: la etiqueta sintética deriva de una composición de hallazgos, mientras que HUCA aporta una etiqueta clínica binaria. Aunque ambas tareas estén relacionadas con Brugada, no son idénticas.

La adaptación de dominio mejora parcialmente este escenario. CORAL y MMD aumentan la especificidad en $K = 32$, y MMD obtiene el mejor resultado global. Aun así, la mejora es modesta. Esto sugiere que alinear características visuales no basta cuando la etiqueta objetivo cambia de naturaleza o cuando faltan anotaciones morfológicas finas en el dominio real.

Este punto es importante para la tesis completa. Si el problema fuera solo de estilo visual, una buena adaptación debería acercar mucho más ambos dominios. El resultado sugiere que la dificultad también está en la definición clínica, en la heterogeneidad de casos y en la cantidad de ejemplos disponibles. Por eso la siguiente comparación no debe limitarse a más técnicas de adaptación, sino incorporar modelos que ya contienen conocimiento visual y textual previo.

9.4 Pocos datos y decisión de modelo

El estudio confirma que K importa, pero no de la misma forma en todos los dominios. En sintético, más ejemplos casi siempre ayudan. En HUCA, aumentar de $K = 16$ a $K = 32$ no mejora la línea base. Esto puede deberse a variabilidad de la selección, al pequeño tamaño efectivo, a que los ejemplos añadidos no cubren subfenotipos relevantes o a que la arquitectura aprende atajos visuales no generalizables.

La pregunta útil no es si una CNN es "buena." "mala". La pregunta útil es en qué región del espacio de datos conviene entrenarla. Con muchos ejemplos, una CNN o un transformer visual especializado puede ser la solución natural. Con muy pocos ejemplos, el coste de ajustar pesos puede no compensar. Ahí aparece la hipótesis VLM/ICL: usar ejemplos como demostraciones y explotar conocimiento previo del modelo. Esta memoria no demuestra esa hipótesis, pero sí demuestra que la línea CNN deja margen para probarla.

9.5 Interpretabilidad

Grad CAM aporta una comprobación cualitativa útil: los mapas no se concentran de forma absurda en márgenes o ruido de fondo. En varios ejemplos aparecen activaciones sobre zonas plausibles del complejo QRS y la repolarización. Pero la interpretabilidad visual no salva el rendimiento. Un mapa razonable puede acompañar a una clasificación incorrecta, y un mapa localizado no equivale a una justificación clínica.

En futuras versiones será necesario combinar Grad CAM con análisis por subgrupos, calibración, revisión de errores por especialista y anotaciones morfológicas independientes. Sin esas capas, la explicación se debe presentar como diagnóstico técnico del modelo, no como validación médica.

9.6 Relación con VLM e ICL

La línea VLM no se introduce porque las CNN sean irrelevantes, sino porque los resultados CNN son insuficientes en el régimen de datos disponible. La comparación prevista es justa: misma imagen, mismos presupuestos K , separación por paciente y mismas métricas. La diferencia estará en cómo se usan los ejemplos.

Un VLM podría aportar tres ventajas. Primero, conocimiento visual previo aprendido de colecciones amplias. Segundo, capacidad de seguir instrucciones clínicas y devolver salidas estructuradas. Tercero, adaptación rápida mediante demostraciones sin reentrenamiento. También podría fallar por tres razones simétricas: ignorar detalles finos del ECG, depender del texto del prompt o producir respuestas inválidas. Por eso la pipeline incluye controles con etiquetas permutadas y ejemplos sin imagen.

La hipótesis sigue abierta. La memoria documenta mensajes, controles y validación de JSON, pero no reporta resultados. Adelantar conclusiones sobre Gemma 4 o MedGemma sin predicciones auditadas rompería la trazabilidad del estudio. Lo que sí queda demostrado es la necesidad de esa fase: la CNN establece una línea base reproducible y muestra que entrenar un modelo visual específico no resuelve por sí solo el escenario de Brugada HUCA con pocos datos.

9.7 Limitaciones

Las principales limitaciones son:

- El conjunto real procede de un único dominio clínico y necesita validación externa.
- La etiqueta HUCA disponible no separa hallazgos morfológicos individuales.
- El preprocesamiento reduce cada ECG a ventanas de V1, V2 y V3 alrededor de un latido

central.

- Los presupuestos de entrenamiento son deliberadamente pequeños y pueden dejar subgrupos sin representación.
- No se ha realizado calibración clínica ni estimación formal de utilidad neta.
- VLM e ICL quedan como trabajo pendiente cuantitativo, aunque forman parte central del diseño comparativo.

9.8 Lectura final

Desde ingeniería, el paquete experimental está completo para CNN: datos, simuladores, entrenamientos, adaptación, métricas, gráficas, auditoría y reproducción. Desde clínica, el rendimiento real todavía es insuficiente para una herramienta autónoma. Desde metodología, el valor principal es haber convertido esa insuficiencia en una línea base medible.

La siguiente decisión experimental ya está planteada: ejecutar VLM/ICL con los mismos presupuestos y decidir, con datos, a partir de cuándo renta entrenar un modelo visual específico y cuándo puede ser preferible usar aprendizaje en contexto para triaje preliminar.

CAPÍTULO 10

Gestión, ética, privacidad y marco normativo

10.1 Planificación del proyecto

10.1.1 Alcance y carga de trabajo

El Trabajo de Fin de Grado tiene una carga de 12 créditos ECTS. El Real Decreto 1125/2003 establece una dedicación de entre 25 y 30 horas por crédito [41]. La planificación adopta el límite inferior de 25 horas y fija una referencia de 300 horas. Esta cifra no representa un registro automático del tiempo ya consumido, sino el presupuesto de esfuerzo utilizado para organizar el proyecto.

La tabla 10.1 distribuye la dedicación entre revisión, diseño, implementación, evaluación y documentación. La generación sintética y la infraestructura de experimentación reciben una fracción elevada porque condicionan tanto a las redes convolucionales como a los modelos de visión y lenguaje.

Tabla 10.1. Distribución prevista de la dedicación del proyecto.

Actividad	Horas
Revisión bibliográfica y clínica	28
Requisitos y protocolo experimental	20
Simulador y construcción de datos	48
Infraestructura VLM y diseño de mensajes	35
Implementación de redes convolucionales	35
Ejecución de experimentos sintéticos	42
Datos reales y adaptación de dominio	28
Análisis estadístico y visualización	20
Redacción de la memoria	34
Control de calidad y preparación de la defensa	10
Total	300

10.1.2 Fases y calendario

El proyecto se estructura entre octubre de 2025 y junio de 2026. Las fases se solapan de forma controlada. La revisión bibliográfica continúa durante el desarrollo, mientras que la redacción se inicia antes de cerrar los resultados para documentar decisiones que de otro modo podrían perderse.

Tabla 10.2. Calendario general del Trabajo de Fin de Grado.

Periodo	Actividades principales
Octubre y noviembre de 2025	Definición del problema, revisión clínica, análisis de trabajos relacionados y diseño inicial
Diciembre de 2025 y enero de 2026	Desarrollo del simulador, validadores y formatos de imagen
Febrero y marzo de 2026	Canalización VLM, mensajes, esquemas JSON y controles de aprendizaje en contexto
Abril de 2026	Diseño e integración de las redes convolucionales y pruebas de reproducibilidad
Mayo de 2026	Experimentos sintéticos, preparación de datos reales y adaptación de dominio
Junio de 2026	Análisis, cierre de la memoria, revisión integral y defensa




Figura 10.1. Plan temporal del proyecto y cierre de los experimentos principales.

Los hitos de control son la validación visual del simulador, la reproducción de una ejecución VLM, la integración de la CNN, el cierre de los pliegues de datos reales, la congelación de resultados y la generación de la versión final de la memoria. Cada hito debe producir un artefacto revisable.

10.2 Gestión de riesgos

La tabla 10.3 recoge los riesgos principales, su efecto y la respuesta prevista. La probabilidad se valora de forma cualitativa antes de cerrar los experimentos.

Tabla 10.3. Riesgos principales del proyecto.

Riesgo	Prioridad	Medida de respuesta
Retraso en la integración de la CNN	Alta	Definir primero una línea base mínima reproducible y separar mejoras opcionales
Acceso insuficiente a GPU	Alta	Ejecutar pruebas pequeñas, estimar coste antes del barrido y conservar reanudación por registro
Salidas VLM inválidas	Media	Forzar esquema JSON, validar cada respuesta y contabilizar los fallos
Fuga entre entrenamiento y prueba	Alta	Crear divisiones por paciente o semilla generativa antes del ajuste y guardar los identificadores
Diferencia excesiva entre dominios	Alta	Medir transferencia directa y añadir armonización, ajuste fino y adaptación como experimentos separados
Etiquetas reales no equivalentes	Alta	Separar diagnóstico y morfología y exigir anotación específica para la segunda tarea
Cambios de versión del modelo	Media	Registrar identificador exacto, fecha, revisión y parámetros de servicio
Resultados incompletos al cerrar la memoria	Alta	Mantener marcadores explícitos y no rellenar tablas con estimaciones no ejecutadas

Los riesgos se revisan al terminar cada bloque. Una desviación no se corrige ocultando el alcance pendiente, sino reduciendo de forma explícita los experimentos secundarios y protegiendo las comparaciones principales.

10.3 Recursos y estimación de coste

El desarrollo local requiere un equipo capaz de ejecutar Python, generar imágenes y compilar LaTeX. El servicio de un modelo abierto de visión y lenguaje requiere una GPU con memoria suficiente. La configuración preparada solicita una NVIDIA A6000 para Gemma 4 E4B. La disponibilidad real, la versión de vLLM y el modelo cargado deberán registrarse en cada ejecución.

No se asigna un importe ficticio al cómputo. El coste de una campaña se calculará mediante

$$C_{\text{computo}} = \sum_{j=1}^m h_j c_j, \quad (10.1)$$

donde h_j es el número de horas consumidas por el recurso j y c_j es su precio por

hora en la fecha de contratación. El informe final incluirá tiempo de GPU, tiempo de CPU, almacenamiento y, si se emplea un servicio propietario como control, número de tokens y tarifa vigente.

También se registrará el tiempo por muestra y el consumo máximo de memoria. Estas magnitudes permiten comparar métodos aunque el precio comercial cambie. El coste de personal no se monetiza, pero queda representado por la distribución de 300 horas.

10.4 Gestión de configuración y trazabilidad

El repositorio Git actúa como fuente de verdad del código, los mensajes y la memoria. Cada campaña experimental debe guardar:

- revisión del repositorio
- versiones de Python y dependencias
- identificador del modelo y revisión de pesos
- parámetros de generación, servicio y evaluación
- semillas y divisiones de datos
- mensaje de sistema, mensaje de tarea y esquema de respuesta
- predicciones sin procesar, métricas derivadas y registro de errores

Los resultados agregados no sustituyen a las predicciones. Conservar ambos niveles permite detectar errores de análisis y recalcular métricas sin repetir inferencias costosas. Los archivos generados deben ser inmutables o incorporar un identificador de ejecución que evite sobrescrituras accidentales.

Las dependencias de redes convolucionales ya están declaradas como extra opcional del proyecto mediante PyTorch y Torchvision. El entorno de servicio vLLM se gestiona por separado porque la campaña VLM no forma parte de los resultados cerrados. Antes de incorporar esa línea será necesario registrar revisión de pesos, versión del servidor, plantilla de conversación y predicciones completas.

10.5 Principios éticos

10.5.1 Proporcionalidad y finalidad

La finalidad del trabajo es comparar métodos de reconocimiento de morfologías electrocardiográficas y estudiar su transferencia con pocos datos. No se pretende automatizar

decisiones asistenciales. El alcance se limita a investigación retrospectiva y desarrollo metodológico.

La proporcionalidad exige emplear la cantidad mínima de datos necesaria, evitar variables clínicas no relacionadas con los objetivos y escoger modelos cuya complejidad esté justificada por la pregunta experimental. La disponibilidad de una variable no constituye por sí sola una razón para utilizarla.

10.5.2 Riesgos para las personas

Aunque los datos estén anonimizados o seudonimizados, un error metodológico puede generar conclusiones engañosas sobre una población clínica poco numerosa. Los principales riesgos indirectos son la sobreestimación del rendimiento, el sesgo por selección, la ausencia de calibración, la confusión entre morfología y diagnóstico y la generalización fuera del centro de origen.

La mitigación incluye validación por paciente, intervalos de confianza, documentación de exclusiones, análisis por subgrupos cuando el tamaño lo permita y lenguaje prudente. No se presentará una mejora estadística como beneficio clínico sin un estudio diseñado para esa finalidad.

10.5.3 Intervención humana

Las anotaciones clínicas y la interpretación de discrepancias requieren supervisión experta. En un uso futuro, el sistema solo podría actuar como apoyo y sus resultados deberían mostrarse junto con la señal original, la calidad de entrada y una indicación de incertidumbre. La persona responsable de la decisión no debe quedar condicionada por una salida presentada como certeza.

10.6 Protección de datos

10.6.1 Marco general

Los datos de salud son una categoría especial en el artículo 9 del Reglamento General de Protección de Datos [42]. Su tratamiento exige una base jurídica adecuada y garantías reforzadas. Los principios del artículo 5 incluyen licitud, limitación de finalidad, minimización, exactitud, limitación del plazo de conservación, integridad, confidencialidad y responsabilidad proactiva.

La protección desde el diseño y por defecto, recogida en el artículo 25, implica que la arquitectura del proyecto debe reducir la exposición desde el inicio. El artículo 32 exige medidas de seguridad apropiadas al riesgo. Cuando un tratamiento pueda implicar un alto riesgo,

el artículo 35 prevé una evaluación de impacto. Para investigación científica, el artículo 89 requiere salvaguardias técnicas y organizativas.

En España, la Ley Orgánica 3/2018 completa este marco [43]. Su disposición adicional decimoséptima regula tratamientos de datos de salud con fines de investigación y contempla el uso de datos seudonimizados bajo condiciones específicas. Entre las garantías relevantes se encuentran la separación entre información clínica y datos que permitan reidentificar, el acceso restringido y la revisión ética. La Ley 14/2007 de Investigación biomédica añade principios de consentimiento, confidencialidad y control ético [44].

10.6.2 Aplicación al proyecto

Brugada HUCA se publica sin información identificativa y su documentación declara anonimización mediante Safe Harbor [38]. El proyecto conservará únicamente los campos necesarios para las tareas definidas. Los identificadores públicos se transformarán en claves internas cuando se creen derivados, evitando incorporarlos a nombres de figura destinados a difusión.

Las medidas mínimas son almacenamiento local controlado, permisos restringidos, cifrado del dispositivo, ausencia de datos clínicos en servicios no autorizados, copias de seguridad protegidas y registro de procedencia. Las claves de API no se incluyen en el repositorio ni en la memoria. Si se incorporan datos adicionales no anónimos, deberá revisarse la base jurídica y realizarse el análisis de impacto antes del tratamiento.

La guía de la Agencia Española de Protección de Datos sobre gestión del riesgo y evaluaciones de impacto ofrece una referencia práctica para esa revisión [45]. La evaluación no puede sustituirse por una declaración genérica de anonimización.

10.7 Licencias y reutilización

El código propio deberá publicar una licencia compatible con las dependencias y con los objetivos de difusión. Las imágenes sintéticas pueden regenerarse a partir del código y sus metadatos. Para datos externos se respetarán sus términos individuales.

Brugada HUCA utiliza CC BY SA 4.0. Toda redistribución de material derivado debe conservar atribución, indicar cambios y aplicar la licencia correspondiente. PTB XL y MI-MIC IV ECG tienen condiciones de acceso y reutilización propias que deben comprobarse en su versión concreta. No se copiarán datos clínicos dentro del repositorio público.

Los pesos de modelos de terceros también pueden imponer condiciones. El identificador comercial o técnico del modelo no basta. Deben conservarse la licencia, la revisión descargada y las restricciones de uso vigentes en la fecha del experimento.

10.8 Regulación de sistemas de inteligencia artificial

10.8.1 Reglamento europeo de inteligencia artificial

El Reglamento 2024/1689 establece las normas europeas en materia de inteligencia artificial [46]. Su artículo 2 contempla una exclusión para sistemas y modelos desarrollados y puestos en servicio específicamente con la única finalidad de investigación y desarrollo científicos antes de su comercialización o puesta en servicio. Esta exclusión es coherente con el alcance metodológico del TFG, pero no cubre automáticamente una prueba clínica en condiciones reales ni un producto desplegado.

Si el sistema se integrara en un producto sanitario, su clasificación dependería de la finalidad prevista y de su relación con la legislación sectorial. El artículo 6 vincula determinados productos sujetos a evaluación de conformidad por terceros con la categoría de alto riesgo.

A fecha de 22 de junio de 2026, el texto original prevé la aplicación general desde el 2 de agosto de 2026 y un calendario específico para sistemas asociados a productos regulados. El Consejo y el Parlamento anunciaron el 7 de mayo de 2026 un acuerdo político para desplazar determinadas obligaciones de alto riesgo al 2 de diciembre de 2027 y al 2 de agosto de 2028 [47]. Mientras el cambio no quede consolidado en el texto jurídico aplicable, cualquier proyecto de despliegue debe comprobar de nuevo las fechas y obligaciones vigentes. La memoria evita presentar un calendario legislativo en transición como si fuera definitivo.

10.8.2 Producto sanitario

El Reglamento 2017/745 establece que un programa puede ser producto sanitario cuando el fabricante le atribuye una finalidad médica específica [48]. La intención declarada, las funciones, los usuarios y el contexto de uso son determinantes. Un prototipo de investigación que clasifica imágenes para comparar algoritmos no adquiere por ello una autorización clínica.

Si se desarrollara una herramienta para apoyar diagnóstico, pronóstico o tratamiento, habría que analizar la cualificación y clasificación del programa, la gestión de riesgos, la evaluación clínica, el ciclo de vida y la vigilancia posterior. La guía MDCG 2019 11, revisada en junio de 2025, orienta la cualificación y clasificación del software [49]. La guía MDCG 2025 6 estudia la interacción entre el Reglamento de productos sanitarios y el Reglamento de Inteligencia Artificial [50].

Por tanto, la memoria y la interfaz deben incluir una limitación visible de uso. El sistema no está validado como producto sanitario y no debe utilizarse para diagnosticar, descartar enfermedad ni decidir tratamiento.

10.8.3 Espacio Europeo de Datos de Salud

El Reglamento 2025/327 crea el Espacio Europeo de Datos de Salud [51]. Su aplicación comienza de forma escalonada desde el 26 de marzo de 2027. Aunque no constituye la base jurídica inmediata de este trabajo, será relevante para futuros proyectos que reutilicen datos sanitarios a escala europea. Cualquier extensión deberá revisar sus reglas de acceso, finalidad secundaria y entornos seguros.

10.9 Equidad, robustez y transparencia

La base sintética no representa grupos demográficos. Por tanto, no permite medir diferencias de rendimiento por sexo, edad, origen o comorbilidad. La fase real deberá describir las variables disponibles y analizar subgrupos solo cuando exista tamaño suficiente y una razón clínica. La ausencia de un análisis no debe interpretarse como ausencia de sesgo.

El modelo puede aprender propiedades del renderizado, del equipo o del centro. Las pruebas de robustez incluirán cambios de resolución, cuadrícula, recorte, contraste y ruido dentro de límites plausibles. Una caída intensa ante transformaciones inocuas indicaría dependencia de señales espurias.

La transparencia se apoya en mensajes exactos, esquemas de respuesta, versiones, matrices de confusión, ejemplos de error y descripción de datos. Las explicaciones visuales como Grad CAM pueden ayudar a auditar una CNN [29], pero no demuestran causalidad ni corrección clínica.

10.10 Sostenibilidad

El impacto ambiental se reduce evitando barridos sin hipótesis, reutilizando predicciones, ejecutando primero pruebas pequeñas y deteniendo configuraciones claramente defectuosas según reglas previas. Se preferirán modelos abiertos de tamaño compatible con el objetivo experimental y se informará del tiempo de acelerador.

La comparación entre CNN y VLM debe considerar no solo la métrica, sino también coste de entrenamiento, coste por inferencia, latencia y posibilidad de despliegue local. Un incremento marginal de rendimiento puede no justificar un aumento grande de consumo.

10.11 Compromiso de uso responsable

El producto de este TFG es un prototipo de investigación reproducible. Sus resultados deberán leerse dentro del conjunto, las etiquetas y el protocolo empleados. No se autoriza su uso autónomo con pacientes. Cualquier evolución clínica necesitará validación externa, evaluación prospectiva, supervisión profesional, revisión ética y cumplimiento regulatorio

específico.

Esta limitación no reduce el valor del trabajo. Al contrario, delimita con precisión qué evidencia aporta y qué preguntas permanecen abiertas.

CAPÍTULO 11

Conclusiones

Este TFG entrega una canalización reproducible para estudiar ECG como imagen en escenarios de pocos datos y con orientación de triaje clínico. La comparación completa se plantea entre CNN entrenadas con pocos ejemplos y modelos de visión y lenguaje usados mediante aprendizaje en contexto. La evidencia cuantitativa cerrada corresponde a la primera rama: simulación, entrenamiento CNN, evaluación real, adaptación de dominio, gráficas, tablas, Grad CAM y auditoría final.

11.1 Conclusiones principales

La primera conclusión es que la CNN aprende de forma clara en el dominio sintético. Con $K = 32$, ResNet18 alcanza una exactitud equilibrada de 0,848, sensibilidad de 0,883 y especificidad de 0,812. Esto valida el simulador como entorno de prueba para morfologías QRS/ST y confirma que el protocolo de pocos ejemplos puede capturar señal visual cuando la distribución está controlada.

La segunda conclusión es que la transferencia a ECG clínicos reales es difícil. En Brugada HUCA, la mejor línea base obtiene 0,516 de exactitud equilibrada con $K = 16$. La sensibilidad es moderada, pero la especificidad baja impide usar el modelo como herramienta de diagnóstico o descarte. El resultado solo es compatible con investigación en triaje, siempre con revisión clínica posterior.

La tercera conclusión es que la adaptación de dominio ayuda de forma limitada. MMD con $K = 32$ mejora el mejor punto real hasta 0,549 de exactitud equilibrada y 0,448 de especificidad. La mejora confirma que alinear dominios puede aportar valor, pero no elimina la brecha entre simulador y HUCA.

La cuarta conclusión es la más importante para el diseño global: con estos datos, entrenar una CNN específica no basta. Ni el preentrenamiento visual estándar ni la adaptación de dominio recuperan un rendimiento robusto en Brugada HUCA. Esta evidencia establece el precedente necesario para la fase VLM/ICL, donde los mismos ejemplos K se usarán como demostraciones en contexto.

11.2 Objetivos alcanzados

Se han alcanzado los objetivos técnicos principales:

- generación y validación de un conjunto sintético QRS/ST con 100 pacientes y 300 imágenes;
- construcción de Brugada HUCA procesado con 317 pacientes incluidos, 951 imágenes y 46 exclusiones documentadas;
- ejecución completa de CNN ResNet18 para $K = \{2, 4, 8, 16, 32\}$ y tres semillas;
- comparación sintético-real con métricas agregadas y gráficas;
- revisión, corrección y ejecución de la rama de adaptación de dominio;
- auditoría final con todos los experimentos CNN marcados como completos;
- documentación de la pipeline VLM/ICL como comparador central pendiente.

11.3 Respuesta a la pregunta de investigación

La respuesta actual es parcial pero útil. Sí, una CNN puede aprender señal visual a partir de pocos ejemplos cuando la tarea está controlada. No, ese rendimiento no se traslada automáticamente a datos reales de Brugada. La adaptación de dominio mejora el resultado, pero todavía no alcanza un nivel suficiente para una herramienta clínica robusta.

Por tanto, en este punto no se puede afirmar que entrenar una CNN sea la estrategia adecuada para el régimen de datos disponible. Lo que sí puede afirmarse es que la rama CNN ya proporciona una línea base sólida para medir el valor añadido de VLM/ICL. La comparación final deberá responder si el aprendizaje en contexto consigue una mejor relación entre rendimiento, coste y cantidad de datos etiquetados.

11.4 Trabajo futuro

El siguiente paso natural es completar la línea VLM/ICL. Para ello deben ejecutarse Gemma 4 y MedGemma con los mismos presupuestos K , conservar predicciones por muestra, validar JSON, registrar versión de modelo y servidor, y comparar contra CNN únicamente cuando el paquete VLM supere la auditoría de completitud.

También sería necesario ampliar la validación real. Las prioridades son obtener anotaciones morfológicas independientes en HUCA, evaluar calibración, revisar errores con especialistas, probar validación externa, estudiar subgrupos clínicos y explorar arquitecturas o preentrenamientos específicamente adaptados a ECG.

11.5 Cierre

El trabajo deja una base experimental cerrada y honesta. La CNN funciona bien en el simulador, funciona solo de manera limitada en HUCA y mejora modestamente con MMD. Esa evidencia no permite diagnóstico autónomo, pero sí aporta un marco reproducible para triaje de sospecha y para la pregunta metodológica que guía la siguiente fase: cuándo rentar entrenar modelos visuales específicos y cuándo conviene recurrir a modelos de visión y lenguaje con aprendizaje en contexto.

APÉNDICE A

Configuración experimental

Este apéndice resume la configuración necesaria para reproducir los experimentos cerrados. Los valores proceden de los scripts y artefactos generados en el repositorio, no de un plan prospectivo.

A.1 Entorno de software

El proyecto declara Python 3.12 o posterior y utiliza uv como gestor de entorno. Las dependencias directas y opcionales relevantes se recogen en la tabla A.1.

Tabla A.1. Dependencias principales declaradas por el proyecto.

Paquete	Versión mínima
Matplotlib	3.9
NumPy	2.0
OpenAI Python	2.35.1
pandas	2.2
Pillow	10.4
Pydantic	2.8
scikit-learn	1.5
tqdm	4.66
PyTorch, extra <code>cnn</code>	2.3
Torchvision, extra <code>cnn</code>	0.18
WFDB, extra <code>real-data</code>	4.1
pytest, extra <code>dev</code>	8.3
Ruff, extra <code>dev</code>	0.6

La memoria se compila con XeLaTeX a través del helper local de compilación. Los experimentos CNN se ejecutan con backend Matplotlib Agg para generar informes sin interfaz gráfica.

A.2 Conjunto sintético QRS/ST

Tabla A.2. Configuración del conjunto sintético final.

Propiedad	Valor
Fuente	<code>ecg_few.simulator</code>
Pacientes	100
Imágenes	300
Familias fuente	NORMAL, RBBB, ST_ELEVATION, T_WAVE_INVERSION, COMBINED_QRS_ST
Pacientes por familia	20
Derivaciones renderizadas	V1, V2 y V3
Frecuencia de muestreo	500 Hz
Duración del beat	900 ms
Resolución de guardado	130 ppp
Positivos derivados	20
Negativos o incompletos	80
Presupuestos	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026

La etiqueta positiva se obtiene cuando RBBB, elevación ST e inversión T están presentes simultáneamente. La agregación de paciente promedia las probabilidades de las derivaciones y después aplica el umbral seleccionado.

A.3 Brugada HUCA

Tabla A.3. Configuración del conjunto real procesado.

Propiedad	Valor
Fuente	Brugada HUCA 1.0.0
Pacientes brutos	363
Pacientes excluidos	46 por patrón basal limítrofe
Pacientes incluidos	317
Imágenes incluidas	951
Casos confirmados	116
Controles	201
Derivaciones	V1, V2 y V3
Ventana	300 ms antes de R y 600 ms después de R
Frecuencia de origen	100 Hz
Resolución de guardado	130 ppp
Separación	Leave-one-out por paciente

HUCA no contiene anotaciones independientes para las tres etiquetas morfológicas del simulador. La tarea real utiliza la etiqueta clínica `clinical_brugada`.

A.4 Configuración CNN

Tabla A.4. Hiperparámetros de la CNN final.

Propiedad	Valor
Arquitectura	ResNet18
Pesos iniciales	default de Torchvision
Entrada	RGB, 224 por 224
Salida	Un logit binario
Pérdida	BCEWithLogitsLoss con <code>loss_pos_weight=auto</code>
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Lote	32
Épocas máximas	20
Estrategia de umbral	<code>val_derived_balanced_accuracy</code>
Métrica principal	Exactitud equilibrada por paciente
Grad CAM	12 paneles en sintético y 6 en HUCA por ejecución agregada

A.5 Configuración de adaptación de dominio

Tabla A.5. Configuración de la rama de adaptación de dominio.

Propiedad	Valor
Origen etiquetado	<code>data/simulator_qrs</code>
Destino no etiquetado	<code>data/brugada_huca</code>
Métodos	SSL, CORAL, MMD y DANN
Presupuestos	$K = 16$ y $K = 32$
Semillas	42, 123 y 2026
Peso de adaptación	0,1
Escalas MMD	0,5, 1,0, 2,0 y 4,0
SSL	SimCLR durante 3 épocas, <code>ssl_pretrain_lr=0.0001</code>
Política de destino	Transductiva compartida, sin etiquetas destino en la pérdida supervisada

A.6 Configuración VLM pendiente

La línea VLM forma parte del diseño comparativo, pero no de las métricas cerradas. La configuración prevista se mantiene para que la siguiente fase use la misma base experimental que la CNN:

- modelos abiertos: Gemma 4 y MedGemma;
- servidor local compatible con API de vLLM;
- temperatura 0;
- salida JSON validada;
- presupuestos $K = \{0, 2, 4, 8, 16, 32\}$ o el subconjunto que se congele antes de ejecutar;
- controles con respuestas permutadas y ejemplos sin imagen.

Los resultados VLM deberán añadirse únicamente cuando existan predicciones por muestra, tablas agregadas, matrices de confusión y auditoría equivalente a la de CNN. Hasta entonces, la rama CNN actúa como línea base cerrada y la rama VLM/ICL como comparador central pendiente.

APÉNDICE B

Resultados completos

Este apéndice reúne las tablas de resultados agregadas utilizadas en los capítulos 7 y 8. Todas las cifras son medias sobre tres semillas salvo los recuentos, que acumulan las predicciones de las tres ejecuciones.

B.1 CNN en el conjunto sintético

Tabla B.1. Resultados completos de la CNN sobre el conjunto sintético.

K	Acc.	BA	F1	Prec.	Sens.	Esp.	AP
2	0,610	$0,625 \pm 0,022$	0,401	0,291	0,650	0,600	0,268
4	0,640	$0,631 \pm 0,042$	0,407	0,304	0,617	0,646	0,268
8	0,687	$0,685 \pm 0,023$	0,468	0,357	0,683	0,688	0,383
16	0,757	$0,773 \pm 0,013$	0,569	0,442	0,800	0,746	0,534
32	0,827	$0,848 \pm 0,030$	0,673	0,545	0,883	0,812	0,614

B.2 CNN en Brugada HUCA

Tabla B.2. Resultados completos de la CNN base sobre Brugada HUCA.

K	Acc.	BA	F1	Prec.	Sens.	Esp.	AP
2	0,460	$0,509 \pm 0,010$	0,484	0,372	0,693	0,325	0,404
4	0,450	$0,509 \pm 0,023$	0,493	0,373	0,730	0,289	0,388
8	0,442	$0,490 \pm 0,018$	0,469	0,360	0,672	0,308	0,383
16	0,478	$0,516 \pm 0,023$	0,480	0,379	0,658	0,375	0,478
32	0,461	$0,499 \pm 0,012$	0,466	0,366	0,644	0,355	0,423

B.3 Comparación de dominios

Tabla B.3. Exactitud equilibrada sintética frente a real.

K	Sintético BA	HUCA BA
2	0,625	0,509
4	0,631	0,509
8	0,685	0,490
16	0,773	0,516
32	0,848	0,499

B.4 Adaptación de dominio

Tabla B.4. Resultados completos de adaptación de dominio sobre Brugada HUCA.

Método	K	Acc.	BA	F1	Prec.	Sens.	Esp.
Base	16	0,478	0,516 $\pm$ 0,023	0,480	0,379	0,658	0,375
SSL	16	0,429	0,477 $\pm$ 0,027	0,458	0,351	0,658	0,297
CORAL	16	0,493	0,524 $\pm$ 0,008	0,481	0,384	0,641	0,408
MMD	16	0,484	0,516 $\pm$ 0,019	0,474	0,378	0,635	0,396
DANN	16	0,487	0,515 $\pm$ 0,019	0,470	0,378	0,621	0,410
Base	32	0,461	0,499 $\pm$ 0,012	0,466	0,366	0,644	0,355
SSL	32	0,457	0,503 $\pm$ 0,014	0,476	0,368	0,672	0,333
CORAL	32	0,499	0,528 $\pm$ 0,013	0,480	0,388	0,632	0,423
MMD	32	0,522	0,549 $\pm$ 0,029	0,498	0,404	0,649	0,448
DANN	32	0,473	0,509 $\pm$ 0,028	0,472	0,373	0,644	0,375

B.5 Artefactos

Los artefactos principales quedan en:

- reports/loocv/cnn_simulator_qrs/
- reports/loocv/cnn/
- reports/loocv/cnn_comparison/
- reports/loocv/cnn_domain_adaptation/

-
- `reports/loocv/audit/`
 - `outputs/cnn_simulator_qrs_loocv/`
 - `outputs/cnn_loocv/`
 - `outputs/cnn_domain_adaptation/`

La auditoría final marca como completos los conjuntos, los informes CNN, la comparación sintético-real y la adaptación de dominio. La línea VLM queda registrada como TODO cuantitativo y no aparece en estas tablas porque todavía no existen inferencias auditadas. Su función dentro del TFG es comparar, en una fase posterior, si el mismo presupuesto K usado como contexto puede superar la línea base CNN cerrada aquí.

APÉNDICE C

Mensajes y respuestas estructuradas

C.1 Criterio de conservación

Los mensajes forman parte de la configuración experimental. Una modificación de una palabra puede alterar la respuesta de un modelo de visión y lenguaje. Por esta razón se conservan los textos completos, su ruta y la revisión del repositorio. Los listados siguientes reproducen la versión utilizada para preparar la campaña.

C.2 Mensaje de sistema

Ruta: prompts/system/default.md

```
1 You are analyzing synthetic images of single ECG beats from a precordial-like
  lead.
2
3 This is a visual morphology classification task. It is not a patient diagnosis.
4
5 Use the waveform shown in the image as the only evidence. Follow the requested
  JSON schema exactly. Do not add explanations, markdown, or additional keys
  .
6
7 Relevant terminology:
8
9 - Q is the first negative deflection before any positive ventricular
  deflection.
10 - R is the first positive ventricular deflection.
11 - S is the negative deflection after R.
12 - R prime is a second positive deflection after S.
13 - The J point marks the transition from the end of the QRS complex to the ST
  segment.
14 - The T wave follows the ST segment and represents ventricular repolarization.
```


C.3 Tarea multietiqueta mínima

Ruta: prompts/multilabel/label_only.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Decide whether each visual morphology finding is present:
4
5 - RBBB
6 - ST_ELEVATION
7 - T_WAVE_INVERSION
8
9 Return only valid JSON with boolean values for exactly these keys:
10
11 {
12   "RBBB": true,
13   "ST_ELEVATION": false,
14   "T_WAVE_INVERSION": false
15 }
```

C.4 Tarea multietiqueta descrita

Ruta: prompts/multilabel/morphology_described.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Evaluate these visual morphology findings.
4
5 RBBB:
6
7 - Look for an RSR prime pattern with an initial positive R wave, a negative S
  wave, and a distinct second positive peak.
8 - The second positive peak should occur late in the QRS region.
9 - The terminal positive component should be visibly broad rather than a narrow
  isolated spike.
10
11 ST_ELEVATION:
12
13 - The ST region begins after the QRS complex at the J point and ends before
  the T wave.
14 - In the absence of elevation, this region remains close to the baseline.
15 - ST elevation is present when the trace remains visibly above the baseline
  after the QRS complex.
16 - The elevated region may be smooth, concave, convex, or coved.
17
18 T_WAVE_INVERSION:
```

```
19
20 - The T wave follows the ST region.
21 - An upright T wave forms a positive late deflection.
22 - T wave inversion is present when the late repolarization wave forms a
    sustained negative deflection below the baseline.
23
24 Return only valid JSON with boolean values for exactly these keys:
25
26 {
27   "RBBB": true,
28   "ST_ELEVATION": false,
29   "T_WAVE_INVERSION": false
30 }
```

C.5 Consultas binarias

C.5.1 RBBB

Ruta: prompts/binary/rbbb.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Finding: RBBB.
4
5 Operational visual definition:
6
7 - Look for an RSR prime pattern with an initial positive R wave, a negative S
    wave, and a distinct second positive peak.
8 - The second positive peak should occur late in the QRS region.
9 - The terminal positive component should be visibly broad rather than a narrow
    isolated spike.
10
11 Question: Is the RBBB morphology present?
12
13 Return only valid JSON:
14
15 {
16   "finding": "RBBB",
17   "present": true
18 }
19
20 Use `false` instead of `true` when the finding is absent.
```

C.5.2 Elevación de ST

Ruta: prompts/binary/st_elevation.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Finding: ST_ELEVATION.
4
5 Operational visual definition:
6
7 - The ST region begins after the QRS complex at the J point and ends before
8   the T wave.
9 - In the absence of elevation, this region remains close to the baseline.
10 - ST elevation is present when the trace remains visibly above the baseline
11   after the QRS complex.
12 - The elevated region may be smooth, concave, convex, or coved.
13
14 Question: Is ST_ELEVATION present?
15
16 Return only valid JSON:
17
18 {
19   "finding": "ST_ELEVATION",
20   "present": true
21 }
22
23 Use `false` instead of `true` when the finding is absent.
```

C.5.3 Inversión de la onda T

Ruta: prompts/binary/t_wave_inversion.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Finding: T_WAVE_INVERSION.
4
5 Operational visual definition:
6
7 - The T wave follows the ST region.
8 - An upright T wave forms a positive late deflection.
9 - T wave inversion is present when the late repolarization wave forms a
10   sustained negative deflection below the baseline.
11
12 Question: Is T_WAVE_INVERSION present?
13
14 Return only valid JSON:
```

```
15 {  
16   "finding": "T_WAVE_INVERSION",  
17   "present": true  
18 }  
19  
20 Use `false` instead of `true` when the finding is absent.
```

C.6 Ejemplos de respuestas

Una respuesta multietiqueta válida contiene exactamente tres booleanos:

```
1 {  
2   "RBBB": true,  
3   "ST_ELEVATION": true,  
4   "T_WAVE_INVERSION": false  
5 }
```

El siguiente contenido es JSON válido, pero no cumple el contrato porque incorpora una clave adicional:

```
1 {  
2   "RBBB": true,  
3   "ST_ELEVATION": true,  
4   "T_WAVE_INVERSION": false,  
5   "explanation": "The trace is elevated."  
6 }
```

La respuesta siguiente tampoco es admisible porque utiliza cadenas en lugar de booleanos:

```
1 {  
2   "RBBB": "true",  
3   "ST_ELEVATION": "false",  
4   "T_WAVE_INVERSION": "false"  
5 }
```

En la tarea binaria, el nombre del hallazgo debe coincidir con la consulta. Una respuesta con **finding** distinto se registra como error aunque el booleano sea correcto.

C.7 Construcción del contexto

Para $K > 0$, cada demostración contiene el mensaje de tarea, una imagen y la respuesta correcta. Las demostraciones se seleccionan una vez por ejecución y se reutilizan para todas las imágenes objetivo. Los identificadores quedan almacenados en el fichero de predicciones.

El control de respuestas permutadas reasigna las soluciones entre demostraciones. El control de demostraciones sin imagen conserva el texto y la respuesta, pero retira la entrada visual de cada ejemplo. La imagen objetivo nunca se retira.

C.8 Análisis de la salida

El servidor recibe un esquema JSON cuando admite `json_schema`. El texto devuelto se valida de nuevo mediante modelos Pydantic. Se conservan el texto original, la predicción analizada, la latencia, el uso informado y cualquier excepción.

El análisis principal no elimina silenciosamente las respuestas fallidas. Una campaña puede calcular un análisis secundario sobre respuestas válidas, pero debe informar también la tasa de error y considerar los fallos como predicciones incorrectas en la comparación principal.

APÉNDICE D

Reproducción

Este apéndice describe el procedimiento utilizado para regenerar datos, entrenar las CNN, construir los informes y compilar la memoria. Los comandos se ejecutan desde la raíz del repositorio.

D.1 Preparación del entorno

```
1 uv sync --extra dev --extra cnn --extra real-data
2 uv run --no-sync python --version
```

Para las campañas CNN se recomienda fijar el backend de Matplotlib:

```
1 export MPLBACKEND=Agg
```

D.2 Generación de datos

El conjunto sintético QRS/ST se regenera con:

```
1 scripts/run/build_simulator_qrs_dataset.sh
```

El conjunto Brugada HUCA procesado se construye desde la descarga local de Physio-Net:

```
1 scripts/run/build_brugada_huca_dataset.sh
```

Los resultados esperados son:

- data/simulator_qrs: 100 pacientes, 300 imágenes y pliegues LOOCV;
- data/brugada_huca: 317 pacientes incluidos, 951 imágenes y 46 exclusiones documentadas.

D.3 Entrenamiento CNN

La campaña sintética se lanza con:

```
1 RESUME=0 scripts/run/run_cnn_simulator_qrs_loocv.sh
```

La campaña real HUCA se lanza con:

```
1 RESUME=0 scripts/run/run_cnn_loocv.sh
```

Ambos scripts usan por defecto $K = 2, 4, 8, 16, 32$, semillas 42, 123 y 2026, ResNet18, 20 épocas, lote 32 y selección de umbral por exactitud equilibrada de validación.

D.4 Adaptación de dominio

La rama de adaptación se ejecuta método a método:

```
1 METHOD=ssl RESUME=0 scripts/run/run_cnn_domain_adaptation_loocv.sh
2 METHOD=coral RESUME=0 scripts/run/run_cnn_domain_adaptation_loocv.sh
3 METHOD=mmd RESUME=0 scripts/run/run_cnn_domain_adaptation_loocv.sh
4 METHOD=dann RESUME=0 scripts/run/run_cnn_domain_adaptation_loocv.sh
```

El método `ssl` se reproduce como preentrenamiento SimCLR de tres épocas y ajuste supervisado sin pérdida adicional de adaptación. CORAL, MMD y DANN usan el peso de adaptación 0,1. La salida queda en `outputs/cnn_domain_adaptation/` y `reports/loocv/cnn_domain_adaptation/`.

D.5 Comparaciones e informes

La comparación sintético-real se reconstruye con:

```
1 scripts/run/build_loocv_comparison.sh
```

La comparación de adaptación de dominio se genera con:

```
1 uv run --no-sync python scripts/eval/compare_cnn_domain_adaptation_reports.py
```

La auditoría final se lanza con:

```
1 scripts/run/audit_loocv_results.sh
```

El cierre correcto debe incluir:

- `all_cnn_experiments_complete`: OK;
- `cnn_domain_adaptation_complete`: OK;
- `final_cnn_package_ready`: OK;
- `vlm_results_status`: TODO.

D.6 VLM como TODO reproducible

La infraestructura VLM queda preparada como segundo brazo de la comparación, aunque no forma parte de las métricas de esta memoria. Cuando se disponga del servidor y del modelo, la campaña deberá ejecutarse con:

```
1 scripts/run/run_vlm_loocv.sh
2 scripts/run/validate_vlm_loocv.sh
```

Antes de incorporar resultados VLM al documento deben existir, como mínimo:

- `reports/loocv/vlm/vlm_summary_by_seed.csv`;
- `reports/loocv/vlm/vlm_summary_by_k.csv`;
- matrices de confusión por K ;
- predicciones por muestra;
- auditoría sin elementos TODO para VLM.

D.7 Compilación de la memoria

La memoria se compila desde el helper local de LaTeX:

```
1 python scripts/compile_latex.py D:/Python_D/ecg/ecg-few/thesis/thesis/main.tex
   --compiler tectonic --json
```

Después de compilar, el PDF debe renderizarse a imágenes y revisarse visualmente para comprobar que las tablas, figuras, cabeceras, pies de página y referencias no presentan solapes ni elementos pendientes.

Bibliografía

- [1] Zeppenfeld, K. y colaboradores. 2022 ESC Guidelines for the management of patients with ventricular arrhythmias and the prevention of sudden cardiac death. *European Heart Journal*, 43(40), 3997–4126, 2022. <https://doi.org/10.1093/eurheartj/ehac262>.
- [2] Kligfield, P., Gettes, L. S., Bailey, J. J. y colaboradores. Recommendations for the standardization and interpretation of the electrocardiogram. Part I. The electrocardiogram and its technology. *Circulation*, 115(10), 1306–1324, 2007. <https://doi.org/10.1161/CIRCULATIONAHA.106.180200>.
- [3] Surawicz, B., Childers, R., Deal, B. J., Gettes, L. S. y colaboradores. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part III. Intraventricular conduction disturbances. *Circulation*, 119(10), e235–e240, 2009. <https://doi.org/10.1161/CIRCULATIONAHA.108.191095>.
- [4] Rautaharju, P. M., Surawicz, B. y Gettes, L. S. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part IV. The ST segment, T and U waves, and the QT interval. *Circulation*, 119(10), e241–e250, 2009. <https://doi.org/10.1161/CIRCULATIONAHA.108.191096>.
- [5] Sieira, J. y Brugada, P. The definition of the Brugada syndrome. *European Heart Journal*, 38(40), 3029–3034, 2017. <https://doi.org/10.1093/eurheartj/ehx490>.
- [6] Wilde, A. A. M., Semsarian, C., Marquez, M. F. y colaboradores. Use, misuse, and pitfalls of the drug challenge test in the diagnosis of the Brugada syndrome. *European Heart Journal*, 44(27), 2427–2439, 2023. <https://doi.org/10.1093/eurheartj/ehad295>.
- [7] BrugadaDrugs.org Advisory Board. Diagnostic drugs for Brugada syndrome. BrugadaDrugs.org, consultada el 28 de junio de 2026. https://www.brugadadrugs.org/druglist_diagnostic/.
- [8] CardioNetworks y ECGpedia. Brugada syndrome type1 example4. Wikimedia Commons, licencia CC BY-SA 3.0, consultada el 28 de junio de

2026. [https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_\(CardioNetworks_ECGpedia\).png](https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_(CardioNetworks_ECGpedia).png).
- [9] Napolitano, C. y Priori, S. G. Brugada syndrome. *Orphanet Journal of Rare Diseases*, 1, 35, 2006. <https://doi.org/10.1186/1750-1172-1-35>.
- [10] Corrado, D., Pelliccia, A., Heidbuchel, H. y colaboradores. Recommendations for interpretation of 12 lead electrocardiogram in the athlete. *European Heart Journal*, 31(2), 243–259, 2010. <https://doi.org/10.1093/eurheartj/ehp473>.
- [11] Ribeiro, A. H. y colaboradores. Automatic diagnosis of the 12 lead ECG using a deep neural network. *Nature Communications*, 11, 1760, 2020. <https://doi.org/10.1038/s41467-020-15432-4>.
- [12] Wagner, P., Strodthoff, N., Bousseljot, R. D. y colaboradores. PTB XL, a large publicly available electrocardiography dataset. *Scientific Data*, 7, 154, 2020. <https://doi.org/10.1038/s41597-020-0495-6>.
- [13] Gow, B., Pollard, T., Nathanson, L. A. y colaboradores. MIMIC IV ECG. Diagnostic Electrocardiogram Matched Subset. Version 1.0. PhysioNet, 2023. <https://doi.org/10.13026/4nqg-sb35>.
- [14] Gliner, V., Keidar, N., Makarov, V. y colaboradores. Automatic classification of healthy and disease conditions from images or digital standard 12 lead electrocardiograms. *Scientific Reports*, 10, 16331, 2020. <https://doi.org/10.1038/s41598-020-73060-w>.
- [15] Sangha, V. y colaboradores. Automated multilabel diagnosis on electrocardiographic images and signals. *Nature Communications*, 13, 1583, 2022. <https://doi.org/10.1038/s41467-022-29153-3>.
- [16] Wu, H., Patel, K. H. K., Li, X. y colaboradores. A fully automated paper ECG digitisation algorithm using deep learning. *Scientific Reports*, 12, 20963, 2022. <https://doi.org/10.1038/s41598-022-25284-1>.
- [17] Gliner, V., Makarov, V., Avetisyan, A. I., Schuster, A. y Yaniv, Y. Using domain adaptation for classification of healthy and disease conditions from mobile captured images of standard 12 lead electrocardiograms. *Scientific Reports*, 13, 14023, 2023. <https://doi.org/10.1038/s41598-023-40693-6>.
- [18] Sayadi, O., Shamsollahi, M. B. y Clifford, G. D. Synthetic ECG generation and Bayesian filtering using a Gaussian wave based dynamical model. *Physiological Measurement*, 31(10), 1309–1329, 2010. <https://doi.org/10.1088/0967-3334/31/10/005>.

-
- [19] Gillette, K. y colaboradores. MedalCare XL. 16 900 healthy and pathological synthetic 12 lead ECGs from electrophysiological simulations. *Scientific Data*, 10, 531, 2023. <https://doi.org/10.1038/s41597-023-02416-4>.
- [20] Lopez Alcaraz, J. M. y Strodthoff, N. Diffusion based conditional ECG generation with structured state space models. arXiv:2301.08227, 2023. <https://doi.org/10.48550/arXiv.2301.08227>.
- [21] Liu, R., Bai, Y., Yue, X. y Zhang, P. Teaching multimodal language models to comprehend 12 lead electrocardiographic images. *npj Digital Medicine*, 9, 349, 2026. <https://doi.org/10.1038/s41746-026-02551-3>.
- [22] Zhang, D., Lan, X., Geng, S. y colaboradores. MEETI. A multimodal ECG dataset from MIMIC IV ECG with signals, images, features and interpretations. *Scientific Data*, 13, 527, 2026. <https://doi.org/10.1038/s41597-026-06796-1>.
- [23] Alayrac, J. B., Donahue, J., Luc, P. y colaboradores. Flamingo. A visual language model for few shot learning. *Advances in Neural Information Processing Systems*, 35, 23716–23736, 2022. <https://arxiv.org/abs/2204.14198>.
- [24] Chen, S., Han, Z., He, B., Liu, J., Buckley, M., Qin, Y., Torr, P., Tresp, V. y Gu, J. Can multimodal large language models truly perform multimodal in context learning. *IEEE/CVF Winter Conference on Applications of Computer Vision*, 6000–6010, 2025. <https://doi.org/10.1109/WACV61041.2025.00585>.
- [25] Qin, L., Chen, Q., Fei, H., Chen, Z., Li, M. y Che, W. What factors affect multimodal in context learning. An in depth exploration. *Advances in Neural Information Processing Systems*, 37, 2024. <https://arxiv.org/abs/2410.20482>.
- [26] Google DeepMind. Gemma 4 model card. Google AI for Developers, 2026. https://ai.google.dev/gemma/docs/core/model_card_4.
- [27] Google Health AI Developer Foundations. MedGemma 1.5 model card. Google for Developers, 2026. <https://developers.google.com/health-ai-developer-foundations/medgemma/model-card>.
- [28] He, K., Zhang, X., Ren, S. y Sun, J. Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770–778, 2016. <https://doi.org/10.1109/CVPR.2016.90>.
- [29] Selvaraju, R. R. y colaboradores. Grad CAM. Visual explanations from deep networks via gradient based localization. *Proceedings of the IEEE International Conference on Computer Vision*, 618–626, 2017. <https://doi.org/10.1109/ICCV.2017.74>.

-
- [30] Ganin, Y. y colaboradores. Domain adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59), 1–35, 2016. <https://jmlr.org/papers/v17/15-239.html>.
- [31] Tsoumakas, G. y Katakis, I. Multi label classification. An overview. *International Journal of Data Warehousing and Mining*, 3(3), 1–13, 2007. <https://doi.org/10.4018/jdwm.2007070101>.
- [32] PyTorch Contributors. Reproducibility. PyTorch documentation, consultada el 22 de junio de 2026. <https://docs.pytorch.org/docs/stable/notes/randomness.html>.
- [33] PyTorch Contributors. BCEWithLogitsLoss. PyTorch documentation, consultada el 22 de junio de 2026. <https://docs.pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html>.
- [34] Torchvision Contributors. ResNet18 and pretrained weights. Torchvision documentation, consultada el 22 de junio de 2026. <https://docs.pytorch.org/vision/stable/models/generated/torchvision.models.resnet18.html>.
- [35] Loshchilov, I. y Hutter, F. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019. <https://arxiv.org/abs/1711.05101>.
- [36] vLLM Project. OpenAI compatible server. vLLM documentation, consultada el 22 de junio de 2026. https://docs.vllm.ai/en/latest/serving/online_serving/openai_compatible_server/.
- [37] vLLM Project. Gemma 4 usage guide. vLLM recipes, consultada el 22 de junio de 2026. <https://docs.vllm.ai/projects/recipes/en/latest/Google/Gemma4.html>.
- [38] Moris Lara, A., Álvarez López, M., Juliá del Prado, L. y colaboradores. Brugada HUCA. 12 Lead ECG Recordings from 76 Confirmed Brugada Syndrome Cases and 287 Controls. Version 1.0.0. PhysioNet, 2026. <https://doi.org/10.13026/5g9p-ya33>.
- [39] Collins, G. S., Moons, K. G. M., Dhiman, P. y colaboradores. TRIPOD+AI statement. Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378, 2024. <https://doi.org/10.1136/bmj-2023-078378>.
- [40] Moons, K. G. M., Damen, J. A. A. G., Kaul, T. y colaboradores. PROBAST+AI. An updated quality, risk of bias and applicability assessment tool for prediction models

using regression or artificial intelligence methods. *BMJ*, 388, e082505, 2025. <https://doi.org/10.1136/bmj-2024-082505>.

- [41] España. Real Decreto 1125/2003, de 5 de septiembre, por el que se establece el sistema europeo de créditos y el sistema de calificaciones. *Boletín Oficial del Estado*, 2003. <https://www.boe.es/buscar/act.php?id=BOE-A-2003-17643>.
- [42] Unión Europea. Reglamento 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales. *Diario Oficial de la Unión Europea*, 2016. <https://eur-lex.europa.eu/eli/reg/2016/679/oj/spa>.
- [43] España. Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales. *Boletín Oficial del Estado*, 2018. <https://www.boe.es/buscar/act.php?id=BOE-A-2018-16673>.
- [44] España. Ley 14/2007, de 3 de julio, de Investigación biomédica. *Boletín Oficial del Estado*, 2007. <https://www.boe.es/buscar/act.php?id=BOE-A-2007-12945>.
- [45] Agencia Española de Protección de Datos. Gestión del riesgo y evaluación de impacto en tratamientos de datos personales. AEPD, 2021. Documento oficial de la AEPD.
- [46] Unión Europea. Reglamento 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial. *Diario Oficial de la Unión Europea*, 2024. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/spa>.
- [47] Consejo de la Unión Europea. AI Act. Council and Parliament strike a deal on rules for high risk AI and streamlining of implementation. Comunicado de prensa, 7 de mayo de 2026. Comunicado oficial del Consejo.
- [48] Unión Europea. Reglamento 2017/745 sobre los productos sanitarios. *Diario Oficial de la Unión Europea*, 2017. <https://eur-lex.europa.eu/eli/reg/2017/745/oj/spa>.
- [49] Medical Device Coordination Group. Guidance on Qualification and Classification of Software in Regulation 2017/745 and Regulation 2017/746. MDCG 2019 11 revision 1. Comisión Europea, junio de 2025. https://health.ec.europa.eu/document/download/b45335c5-1679-4c71-a91c-2915bf7c4f00_en.
- [50] Medical Device Coordination Group. Frequently Asked Questions on the Interplay between the Medical Devices Regulation and the Artificial Intelligence Act. MDCG 2025 6. Comisión Europea, 2025. https://health.ec.europa.eu/document/download/d1c9c10f-3bd2-4eb5-8512-2b9cd18a3fc2_en.

-
- [51] Unión Europea. Reglamento 2025/327 relativo al Espacio Europeo de Datos de Salud. *Diario Oficial de la Unión Europea*, 2025. <https://eur-lex.europa.eu/eli/reg/2025/327/oj/spa>.