


UNIVERSIDAD DE OVIEDO

Escuela de Ingeniería Informática

Grado en Ingeniería Informática del Software



Universidad de Oviedo

TRABAJO DE FIN DE GRADO

Análisis de electrocardiogramas como imagen con redes convolucionales y modelos abiertos de visión y lenguaje en escenarios de pocos datos

*Estudio comparativo del aprendizaje supervisado y el aprendizaje
en contexto*

Electrocardiogram image analysis with convolutional networks and open vision language models
under limited labeled data

Autor Alejandro Moris Lara

Tutor Nahuel Costa Cortez

Oviedo, Junio de 2026

Curso académico 2025/2026

Resumen

Este Trabajo de Fin de Grado plantea una comparación experimental entre dos estrategias para analizar electrocardiogramas representados como imagen cuando los datos etiquetados son escasos. La pregunta central es directa: con un mismo presupuesto de K ejemplos etiquetados, ¿cuándo compensa entrenar un modelo de visión específico (CNN) y cuándo resulta preferible aprovechar el conocimiento multimodal de un modelo de visión y lenguaje (VLM) mediante aprendizaje en contexto? El caso clínico motivador es la sospecha de síndrome de Brugada, una canalopatía hereditaria del canal de sodio asociada a muerte súbita cardíaca.

El trabajo se enmarca estrictamente como apoyo al triaje clínico. En la práctica asistencial, cuando un ECG sugiere un patrón sospechoso de Brugada, se inicia un circuito que incluye lectura especializada del trazado, valoración de síntomas y antecedentes familiares, posible recolocación de las derivaciones V1 y V2 en espacios intercostales superiores y, en pacientes seleccionados con sospecha persistente y ECG basal no concluyente, una prueba farmacológica con bloqueantes del canal de sodio (ajmalina, flecainida, procainamida o pil-sicainida) en un entorno monitorizado con capacidad de reanimación. Esta prueba puede desenmascarar un patrón tipo 1, pero debe interpretarse dentro del contexto clínico y tras excluir fenocopias. El modelo desarrollado no diagnostica ni descarta pacientes: prioriza trazados que merecen revisión temprana por especialistas.

La memoria integra dos dominios. El primero es un simulador controlado de morfología QRS/ST que genera imágenes de V1, V2 y V3 con etiquetas derivadas de reglas observables. El segundo es el conjunto Brugada HUCA, procesado desde registros clínicos reales con 317 pacientes incluidos, 951 imágenes y una etiqueta binaria de caso Brugada confirmado frente a control. La evaluación se organiza por paciente mediante validación leave-one-out, presupuestos reducidos de $K = \{2, 4, 8, 16, 32\}$ ejemplos y tres semillas por presupuesto.

La rama CNN cumple una función deliberada: demostrar empíricamente que el enfoque supervisado clásico no funciona con tan pocos datos, ni siquiera con técnicas de adaptación de dominio. ResNet18 aprende de forma clara en el simulador, con exactitud equilibrada de 0,848 para $K = 32$, sensibilidad 0,883 y especificidad 0,812. Sin embargo, en Brugada HUCA el rendimiento cae cerca del azar: la mejor exactitud equilibrada del modelo base es 0,516 con $K = 16$. La adaptación de dominio (SSL, CORAL, MMD, DANN) mejora el mejor punto hasta 0,549 con MMD y $K = 32$, una mejora insuficiente para considerar el

sistema robusto.

Esta evidencia negativa constituye una contribución central del TFG. No se trata de un fallo del proyecto, sino del resultado que fundamenta la hipótesis principal: si entrenar un modelo visual específico no basta con pocos datos, el conocimiento multimodal previo de un VLM podría compensar esa escasez. Sobre esa base, la rama VLM/ICL se desarrolla como comparador principal: Gemma 4 y MedGemma reciben las mismas imágenes y los mismos presupuestos K , pero los ejemplos se incluyen como demostraciones en el prompt sin actualizar pesos. El documento incorpora el protocolo completo, los mensajes, la validación JSON, los controles y las tablas de resultados preparadas; solo las celdas numéricas VLM quedan marcadas como *por ejecutar* para no inventar inferencias.

Abstract

This Bachelor's Thesis presents an experimental comparison between two strategies for analyzing electrocardiograms represented as images under data scarcity. The central question is direct: given the same budget of K labeled examples, when is it worth training a task-specific vision model (CNN) and when is it preferable to leverage the multimodal knowledge of a vision-language model (VLM) through in-context learning? The motivating clinical case is suspected Brugada syndrome, a hereditary sodium channel disorder associated with sudden cardiac death.

The work is strictly framed as clinical triage support. In routine practice, when an ECG suggests a suspicious Brugada pattern, a clinical circuit is initiated that includes expert ECG reading, assessment of symptoms and family history, possible repositioning of leads V1 and V2 in higher intercostal spaces (second or third instead of the standard fourth), and, in selected patients with persistent suspicion and a non-diagnostic baseline ECG, a pharmacological challenge with sodium channel blockers (ajmaline, flecainide, procainamide, or pilsicainide) in a monitored setting with advanced cardiac life support capabilities. This test can unmask a Type 1 pattern but must be interpreted within the clinical context and after excluding phenocopies. The model developed here does not diagnose or rule out patients: it prioritizes traces that deserve early expert review.

The work integrates two domains. The first is a controlled QRS/ST morphology simulator that renders V1, V2 and V3 images with labels from observable rules. The second is the Brugada HUCA dataset, processed from real clinical recordings with 317 included patients, 951 images and a binary label of confirmed Brugada case versus control. Evaluation is patient-level leave-one-out cross-validation with reduced budgets $K = \{2, 4, 8, 16, 32\}$ and three seeds per budget.

The CNN branch serves a deliberate purpose: to empirically demonstrate that the classical supervised approach does not work with so few data, even with domain adaptation techniques. ResNet18 learns clearly on the simulator, reaching balanced accuracy 0.848 at $K = 32$, sensitivity 0.883 and specificity 0.812. On Brugada HUCA, however, performance drops close to chance: the best baseline balanced accuracy is 0.516 at $K = 16$. Domain adaptation (SSL, CORAL, MMD, DANN) improves the best point to 0.549 with MMD at $K = 32$, an improvement that remains insufficient for a robust system.

This negative evidence is a central contribution of the thesis. It is not a project failure but the result that grounds the main hypothesis: if training a task-specific visual model is not enough with few data, the prior multimodal knowledge of a VLM could compensate for that scarcity. On that basis, the VLM/ICL branch is developed as the main comparator: Gemma 4 and MedGemma receive the same images and the same K budgets, but examples are included as in-context demonstrations without updating weights. The document includes the full protocol, prompts, JSON validation, controls and prepared result tables; only the numerical VLM cells are marked as *to be run* so that no inference results are invented.

Palabras clave

Palabras clave: electrocardiograma, análisis de imágenes médicas, clasificación multitiqueta, redes neuronales convolucionales, modelos de visión y lenguaje, aprendizaje en contexto, pocos datos, datos sintéticos, adaptación de dominio, síndrome de Brugada.

Keywords: electrocardiogram, medical image analysis, multilabel classification, convolutional neural networks, vision language models, in context learning, limited labeled data, synthetic data, domain adaptation, Brugada syndrome.

Índice general

Resumen	I
Abstract	III
Palabras clave	V
1. Introducción	1
1.1. Motivación clínica	1
1.1.1. Circuito clínico de confirmación	2
1.1.2. Posición del sistema propuesto en el circuito	3
1.2. Motivación metodológica	4
1.3. Pregunta de investigación	5
1.4. Hipótesis	5
1.5. Objetivos	6
1.6. Contribuciones	7
1.7. Alcance	7
1.8. Estructura de la memoria	8
2. Fundamentos clínicos y técnicos	9
2.1. Origen y representación del electrocardiograma	9
2.2. Morfología básica de un latido	10
2.3. Hallazgos morfológicos utilizados en el proyecto	10
2.3.1. Morfología compatible con bloqueo de rama derecha	10
2.3.2. Elevación del segmento ST	11
2.3.3. Inversión de la onda T	11
2.3.4. Síndrome de Brugada: caso motivador y circuito diagnóstico	12
2.4. La señal y la imagen como representaciones	15

2.5.	Datos sintéticos y modelos gaussianos	16
2.6.	Clasificación multietiqueta	17
2.7.	Redes neuronales convolucionales	18
2.8.	Modelos de visión y lenguaje	19
2.9.	Aprendizaje multimodal en contexto	20
2.10.	Explicabilidad y fidelidad	21
2.11.	Cambio de dominio y adaptación	21
2.12.	Implicaciones para el diseño experimental	22
3.	Trabajos relacionados	23
3.1.	Alcance de la revisión	23
3.2.	Aprendizaje profundo sobre señales electrocardiográficas	23
3.3.	Análisis directo de imágenes de ECG	24
3.4.	Datos sintéticos para ECG	25
3.5.	Conjuntos que integran señal, imagen y texto	25
3.6.	Modelos multimodales especializados en ECG	26
3.7.	Aprendizaje multimodal en contexto	27
3.8.	Gemma 4 y MedGemma	28
3.9.	Síntesis comparativa	29
3.10.	Hueco de investigación	30
4.	Diseño experimental	32
4.1.	Pregunta experimental	32
4.2.	Canalización experimental	33
4.3.	Orientación clínica: triaje, no diagnóstico	34
4.4.	Unidades de análisis	34
4.5.	Presupuestos de pocos ejemplos	35
4.6.	Modelo CNN evaluado	36
4.7.	Adaptación de dominio	36
4.8.	Métricas	37
4.9.	Estado de cierre	37

5. Simulador y conjunto de datos sintético	39
5.1. Objetivo del dominio sintético	39
5.2. Representación matemática	40
5.3. Muestreo temporal	41
5.4. Rangos de parámetros	41
5.5. Familias generadoras	42
5.5.1. Familia normal	42
5.5.2. Morfología RBBB	42
5.5.3. Elevación de ST	42
5.5.4. Inversión de T	43
5.5.5. Familia Brugada	43
5.6. Reglas de coherencia morfológica	43
5.7. Muestreo con rechazo	44
5.8. Validadores y semántica de las etiquetas	45
5.9. Renderizado de las señales	45
5.10. Construcción del conjunto de datos	46
5.11. Comprobación de integración	47
5.12. Control de calidad del simulador	48
5.12.1. Nivel estructural	48
5.12.2. Nivel semántico	48
5.12.3. Nivel distribucional	48
5.12.4. Nivel visual	48
5.13. Riesgos de atajos visuales	49
5.14. Limitaciones del simulador	49
6. Modelos	51
6.1. Entrada común	51
6.2. Dos formas de usar K	52
6.2.1. CNN: K como conjunto de entrenamiento	52
6.2.2. VLM: K como demostraciones en contexto	53
6.2.3. Síntesis: la misma evidencia, mecanismos opuestos	54

6.3.	CNN ResNet18	54
6.4.	Validación por paciente	55
6.5.	Grad CAM	56
6.6.	Adaptación de dominio	56
6.7.	Modelos de visión y lenguaje	57
6.7.1.	Motivación: por qué un VLM para pocos datos	57
6.7.2.	Gemma 4: modelo generalista de código abierto	58
6.7.3.	MedGemma: adaptación al dominio médico	58
6.7.4.	Pipeline de inferencia VLM	58
6.8.	Controles previstos para VLM	59
6.9.	Criterio de comparación	61
7.	Resultados en el conjunto sintético	63
7.1.	Curva por presupuesto	63
7.2.	Matriz de confusión	64
7.3.	Inspección cualitativa	65
7.4.	Conclusión del dominio sintético	66
8.	Evaluación con Brugada HUCA	67
8.1.	Cohorte final	67
8.2.	Preprocesamiento	68
8.3.	Resultados CNN base	68
8.4.	Brecha sintético-real	70
8.5.	Adaptación de dominio	72
8.6.	Inspección cualitativa	73
8.7.	Conclusión en datos reales: evidencia que motiva la comparación con VLM	74
9.	Evaluación VLM/ICL	75
9.1.	Objetivo del brazo VLM	75
9.2.	Modelos evaluados	75
9.3.	Presupuestos y demostraciones	76
9.4.	Contrato de salida	76

9.5.	Condiciones experimentales	76
9.6.	Agregación por paciente	77
9.7.	Scripts y artefactos de ejecución	77
9.8.	Tablas de resultados preparadas	78
9.9.	Comparación final prevista	79
9.10.	Figuras de resultados reservadas	80
9.11.	Criterio de lectura	80
10.	Discusión	81
10.1.	Qué demuestra el simulador	81
10.2.	Qué demuestra HUCA	81
10.3.	Por qué no basta la adaptación de dominio	82
10.4.	Pocos datos y decisión de modelo	82
10.5.	Interpretabilidad	83
10.6.	Relación con VLM e ICL	83
10.6.1.	Por qué la CNN no basta y qué cambia con un VLM	83
10.6.2.	ICL frente a entrenamiento: dos paradigmas distintos	84
10.6.3.	La pregunta correcta y el papel de la línea base CNN	84
10.6.4.	¿A partir de qué K conviene entrenar frente a usar ICL?	85
10.6.5.	Gemma 4 y MedGemma: hipótesis diferenciadas	85
10.7.	Implicaciones para triaje clínico	86
10.8.	Limitaciones	86
10.9.	Lectura final	87
11.	Gestión, ética, privacidad y marco normativo	88
11.1.	Planificación del proyecto	88
11.1.1.	Alcance y carga de trabajo	88
11.1.2.	Fases y calendario	89
11.2.	Gestión de riesgos	90
11.3.	Recursos y estimación de coste	91
11.4.	Gestión de configuración y trazabilidad	92
11.5.	Principios éticos	92

11.5.1. Proporcionalidad y finalidad	92
11.5.2. Riesgos para las personas	93
11.5.3. Intervención humana	93
11.6. Protección de datos	93
11.6.1. Marco general	93
11.6.2. Aplicación al proyecto	94
11.7. Licencias y reutilización	94
11.8. Regulación de sistemas de inteligencia artificial	95
11.8.1. Reglamento europeo de inteligencia artificial	95
11.8.2. Producto sanitario	95
11.8.3. Espacio Europeo de Datos de Salud	96
11.9. Equidad, robustez y transparencia	96
11.10. Sostenibilidad	96
11.11. Compromiso de uso responsable	96
12. Conclusiones	98
12.1. Conclusiones principales	98
12.2. Objetivos alcanzados	99
12.3. Respuesta a la pregunta de investigación	99
12.4. Trabajo futuro	100
12.4.1. Paso inmediato: ejecución de la rama VLM/ICL	100
12.4.2. Validación clínica ampliada	101
12.5. Cierre	101
A. Configuración experimental	102
A.1. Entorno de software	102
A.2. Conjunto sintético QRS/ST	103
A.3. Brugada HUCA	104
A.4. Configuración CNN	105
A.5. Configuración de adaptación de dominio	105
A.6. Configuración VLM/ICL	106

B. Resultados completos	107
B.1. CNN en el conjunto sintético	107
B.2. CNN en Brugada HUCA	107
B.3. Comparación de dominios	108
B.4. Adaptación de dominio	108
B.5. Artefactos	108
C. Mensajes y respuestas estructuradas	110
C.1. Criterio de conservación	110
C.2. Mensaje de sistema	110
C.3. Tarea multietiqueta mínima	111
C.4. Tarea multietiqueta descrita	111
C.5. Consultas binarias	112
C.5.1. RBBB	112
C.5.2. Elevación de ST	113
C.5.3. Inversión de la onda T	113
C.6. Ejemplos de respuestas	114
C.7. Construcción del contexto	114
C.8. Análisis de la salida	115
D. Reproducción	116
D.1. Preparación del entorno	116
D.2. Generación de datos	116
D.3. Entrenamiento CNN	116
D.4. Adaptación de dominio	117
D.5. Comparaciones e informes	117
D.6. Ejecución VLM/ICL	118
D.7. Compilación de la memoria	119
Bibliografía	120

Índice de figuras

2.1. Ejemplos clínicos de morfología Brugada. Izquierda: CardioNetworks/ECGpedia, CC BY-SA 3.0 [8]. Derecha: figura de Napolitano y Priori, reutilizada bajo CC BY 2.0 [9].	14
2.2. Representación esquemática de los hallazgos visuales que motivan el triaje de patrón Brugada.	14
4.1. Canalización experimental: la CNN establece la línea base supervisada y el VLM/ICL constituye el comparador central propuesto.	33
4.2. Validación leave-one-out por paciente y selección de presupuestos K	35
4.3. Métodos de adaptación de dominio revisados y ejecutados sobre la rama experimental.	37
5.1. Construcción de un beat mediante átomos gaussianos y suma resultante.	41
5.2. Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador.	46
5.3. Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV.	49
6.1. Recorridos de entrada y evaluación: la CNN actualiza pesos con los K ejemplos etiquetados; el VLM los recibe como demostraciones en el prompt sin modificar parámetros.	52
6.2. Ejemplo Grad CAM del modelo CNN sobre el conjunto sintético.	56
6.3. Canalización VLM/ICL: selección de demostraciones, construcción del prompt multimodal, generación local, validación JSON y controles de ablación.	59
7.1. Exactitud equilibrada de la CNN sobre el conjunto sintético según el presupuesto K	64
7.2. Matriz de confusión agregada del conjunto sintético para $K = 32$	65
7.3. Ejemplo Grad CAM del modelo sintético.	66

8.1. Canalización de preprocesamiento de Brugada HUCA para V1, V2 y V3. . .	68
8.2. Exactitud equilibrada de la CNN base sobre Brugada HUCA.	69
8.3. Matriz de confusión agregada de Brugada HUCA para $K = 16$	70
8.4. Comparación de exactitud equilibrada entre el conjunto sintético y Brugada HUCA.	71
8.5. Comparación de F1 entre el conjunto sintético y Brugada HUCA.	71
8.6. Exactitud equilibrada de las variantes de adaptación de dominio.	72
8.7. F1 de las variantes de adaptación de dominio.	73
8.8. Ejemplo Grad CAM del modelo CNN sobre Brugada HUCA.	74
9.1. Figura prevista para la comparación final de exactitud equilibrada entre CNN y VLM/ICL.	80
9.2. Figura prevista para matrices de confusión de Gemma 4 y MedGemma 1.5.	80
11.1. Plan temporal del proyecto y cierre de los experimentos principales.	90

Índice de tablas

2.1. Relación entre el concepto clínico y la aproximación operativa del proyecto	15
2.2. Comparación entre la señal temporal y la imagen electrocardiográfica . . .	16
3.1. Síntesis de trabajos relacionados	30
4.1. Conjuntos utilizados en los experimentos cerrados.	35
4.2. Estado de los bloques experimentales al cierre de la memoria.	38
5.1. Átomos utilizados para construir un beat	40
5.2. Relación entre familias generadoras y rasgos favorecidos	43
5.3. Criterios operativos de los validadores sintéticos	45
5.4. Configuración final del conjunto sintético QRS/ST	47
6.1. Uso del presupuesto K según la familia de modelos.	54
6.2. Configuración CNN utilizada en las campañas finales.	55
7.1. Resultados CNN ResNet18 sobre el conjunto sintético QRS/ST.	63
8.1. Cohorte Brugada HUCA utilizada en la evaluación CNN.	67
8.2. Resultados CNN ResNet18 sobre Brugada HUCA.	69
8.3. Comparación de adaptación de dominio sobre Brugada HUCA.	72
9.1. Condiciones experimentales VLM/ICL.	77
9.2. Resultados VLM/ICL previstos para Gemma 4 sobre Brugada HUCA. . . .	78
9.3. Resultados VLM/ICL previstos para MedGemma 1.5 sobre Brugada HUCA.	78
9.4. Controles VLM/ICL previstos para verificar uso multimodal real.	79
9.5. Matriz de decisión CNN frente a VLM/ICL.	79
11.1. Distribución prevista de la dedicación del proyecto.	89

11.2. Calendario general del Trabajo de Fin de Grado.	89
11.3. Riesgos principales del proyecto.	91
A.1. Dependencias principales declaradas por el proyecto.	102
A.2. Configuración del conjunto sintético final.	103
A.3. Configuración del conjunto real procesado.	104
A.4. Hiperparámetros de la CNN final.	105
A.5. Configuración de la rama de adaptación de dominio.	105
B.1. Resultados completos de la CNN sobre el conjunto sintético.	107
B.2. Resultados completos de la CNN base sobre Brugada HUCA.	107
B.3. Exactitud equilibrada sintética frente a real.	108
B.4. Resultados completos de adaptación de dominio sobre Brugada HUCA. . .	108

CAPÍTULO 1

Introducción

El electrocardiograma es una señal temporal, pero una parte sustancial de su circulación clínica ocurre como imagen: papel térmico, PDF, captura de pantalla o trazado incrustado en una historia electrónica. Esta doble naturaleza abre una pregunta práctica con implicaciones metodológicas profundas: si el dato disponible ya es visual y los ejemplos etiquetados son escasos, ¿merece la pena entrenar un modelo de visión específico — con las limitaciones inherentes de los pocos datos — o puede aprovecharse un modelo multimodal de visión y lenguaje (VLM) que, sin actualizar sus pesos, reciba los pocos ejemplos directamente en el contexto del prompt?

Este Trabajo de Fin de Grado aborda esa pregunta en un escenario deliberadamente difícil: pocos datos etiquetados, trazados electrocardiográficos renderizados como imagen y sospecha de síndrome de Brugada, una canalopatía hereditaria infrecuente. La orientación no es construir un producto sanitario ni un clasificador diagnóstico autónomo, sino investigar qué familia de modelos — CNN entrenadas específicamente frente a VLM con aprendizaje en contexto (ICL) — resulta más útil para apoyar un sistema de triaje clínico que priorice la revisión temprana de trazados sospechosos por parte de especialistas.

La estructura experimental del trabajo sigue una progresión lógica. En primer lugar, se entrena una CNN ResNet18 con presupuestos de datos muy reducidos ($K \in \{2, 4, 8, 16, 32\}$) para establecer una línea base supervisada. Los resultados de esta rama constituyen un precedente empírico: demuestran que los modelos de visión tradicionales, incluso con técnicas de adaptación de dominio, no alcanzan rendimiento robusto cuando los datos etiquetados son escasos. Este resultado negativo justifica y motiva la segunda rama experimental, que constituye la propuesta principal del trabajo: el uso de modelos de visión y lenguaje — concretamente Gemma 4 y MedGemma — con aprendizaje en contexto, donde los pocos ejemplos disponibles se proporcionan directamente en el prompt sin actualizar pesos del modelo.

1.1 Motivación clínica

El síndrome de Brugada es un trastorno arrítmico hereditario asociado a disfunción de los canales de sodio cardíacos, que predispone a fibrilación ventricular y muerte súbita car-

díaca, particularmente en varones jóvenes durante el reposo o el sueño [1, 6]. Su prevalencia estimada varía entre 1:2 000 y 1:5 000 según la población, pero la cifra real es probablemente superior dado que muchos portadores permanecen asintomáticos hasta un primer evento arrítmico potencialmente letal.

El sello diagnóstico del síndrome es el patrón electrocardiográfico tipo 1 de Brugada: una elevación del segmento ST de morfología convexa (*coved*) ≥ 2 mm en al menos una derivación precordial derecha (V1, V2), seguida de una onda T negativa [6]. Este patrón se distingue de los tipos 2 y 3 (morfología en silla de montar, *saddleback*), que por sí solos no son diagnósticos. Además, existen fenocopias — elevaciones del ST de apariencia similar producidas por causas reversibles como fiebre, alteraciones electrolíticas, isquemia o fármacos — que deben excluirse antes de establecer el diagnóstico [5].

La dificultad clínica radica en que el patrón tipo 1 puede no estar presente de forma espontánea en el ECG basal. El trazado puede ser dinámico: aparecer y desaparecer con la fiebre, la ingesta de determinados fármacos o incluso de forma circadiana. Por ello, un ECG basal normal no excluye el síndrome. Esta intermitencia convierte al síndrome de Brugada en un candidato especialmente difícil para cualquier sistema automático de detección basado en una única captura.

1.1.1 Circuito clínico de confirmación

El flujo asistencial ante la sospecha de Brugada sigue una secuencia bien definida de pasos con complejidad creciente:

1. **ECG estándar de 12 derivaciones.** Se examina el trazado en busca de patrones sugestivos en V1 y V2. Un patrón tipo 1 espontáneo, en ausencia de fenocopias, es por sí solo diagnóstico si se acompaña de criterios clínicos.
2. **Revisión por especialista.** Ante un trazado con elevación del ST sospechosa o un patrón tipo 2/3, el caso se remite a un cardiólogo o electrofisiólogo para valoración detallada.
3. **Reposicionamiento de derivaciones V1/V2 en espacios intercostales superiores.** Se registra un nuevo ECG colocando los electrodos V1 y V2 uno o dos espacios intercostales por encima de la posición estándar (segundo o tercer espacio intercostal). Esta maniobra aumenta la sensibilidad para desenmascarar un patrón tipo 1 oculto en la posición estándar [5].
4. **Prueba de provocación farmacológica.** En pacientes seleccionados con sospecha clínica persistente y ECG no diagnóstico, se realiza una prueba con bloqueantes del canal de sodio. Los fármacos utilizados incluyen ajmalina (1 mg/kg IV en 5 minutos), fle-

cainida (2 mg/kg IV en 10 minutos o 400 mg oral), procainamida (10 mg/kg IV en 10 minutos) o pilsicainida (1 mg/kg IV) [7]. La prueba se realiza en un entorno monitorizado con disponibilidad de equipo de reanimación cardiopulmonar, dado el riesgo de inducción de arritmias durante la administración del fármaco. La prueba es positiva cuando se desenmascara un patrón tipo 1 inequívoco.

5. **Interpretación en contexto clínico.** El resultado de la prueba farmacológica debe interpretarse integrando la historia clínica, los antecedentes familiares de muerte súbita, la presencia de síncope inexplicados y la exclusión de fenocopias. Un patrón tipo 1 inducido farmacológicamente, combinado con criterios clínicos, establece el diagnóstico según el consenso vigente [6].
6. **Decisión clínica final.** La estratificación del riesgo y las decisiones terapéuticas — incluyendo la posible indicación de desfibrilador automático implantable (DAI) — corresponden exclusivamente al equipo clínico.

1.1.2 Posición del sistema propuesto en el circuito

El sistema desarrollado en este TFG se sitúa exclusivamente en la fase más temprana de este circuito: el cribado inicial automatizado de trazados ECG. Su función es la de **triaje o priorización**: ante un volumen de trazados, el modelo señala aquellos que presentan patrones visualmente compatibles con sospecha de Brugada y que, por tanto, merecen revisión prioritaria por parte de un especialista.

Es fundamental subrayar lo que el sistema **no hace**:

- No diagnostica ni descarta el síndrome de Brugada.
- No sustituye la revisión experta del trazado.
- No reemplaza la prueba de provocación farmacológica ni ningún paso del circuito clínico.
- No emite recomendaciones terapéuticas.

Cuando el modelo señala un trazado como sospechoso, la acción esperada es que ese trazado entre en el circuito clínico descrito: revisión experta, posible reposicionamiento de derivaciones, y en pacientes seleccionados con sospecha persistente, prueba farmacológica monitorizada con bloqueantes del canal de sodio. El resultado de esta prueba debe interpretarse dentro del contexto clínico completo, excluyendo fenocopias. La decisión final es siempre del equipo clínico.

Esta orientación de triaje prudente es especialmente relevante para el síndrome de Brugada, donde la prevalencia baja hace que los sistemas de detección automática operen con

una probabilidad pretest baja, y donde un falso negativo puede tener consecuencias letales si el paciente no recibe seguimiento adecuado.

1.2 Motivación metodológica

El aprendizaje supervisado profundo ha demostrado capacidad para extraer información diagnóstica de trazados electrocardiográficos a gran escala. Trabajos previos han mostrado que las redes convolucionales pueden clasificar arritmias y detectar patologías a partir de señales de ECG con cohortes de cientos de miles de registros [11, 15]. Sin embargo, estos resultados dependen de un requisito previo exigente: la disponibilidad de conjuntos de datos grandes, diversos y bien etiquetados.

El problema aparece al comienzo de cualquier proyecto biomédico orientado a patologías raras. En el caso del síndrome de Brugada, los datos etiquetados son inherentemente escasos por tres razones convergentes: la baja prevalencia del síndrome, la necesidad de confirmación diagnóstica mediante prueba farmacológica o documentación de patrón tipo 1 espontáneo, y la variabilidad en la presentación electrocardiográfica. Cuando solo se dispone de decenas de ejemplos etiquetados, las estrategias convencionales de entrenamiento supervisado — incluso con transferencia de aprendizaje, aumento de datos y adaptación de dominio — enfrentan limitaciones fundamentales: los modelos no ven suficiente variabilidad para generalizar, las curvas de aprendizaje se saturan prematuramente y la regularización no compensa la falta de cobertura del espacio de entrada.

Este TFG aborda esta limitación comparando dos paradigmas radicalmente distintos para explotar pocos ejemplos etiquetados de ECG como imagen:

1. **CNN con entrenamiento supervisado (línea base).** Una red convolucional ResNet18 se entrena con los K ejemplos disponibles, actualizando sus pesos mediante descenso de gradiente. Se incluyen técnicas de adaptación de dominio (CORAL, MMD, DANN [30]) para intentar reducir la brecha entre un dominio sintético controlado y el dominio real. Esta rama establece el rendimiento alcanzable con modelos de visión tradicionales en régimen de escasez.
2. **VLM con aprendizaje en contexto (propuesta principal).** Un modelo de visión y lenguaje — Gemma 4 y MedGemma [26, 27] — mantiene sus pesos fijos y recibe los K ejemplos directamente dentro del prompt multimodal. El modelo aprovecha su conocimiento visual y lingüístico preexistente, adquirido durante el preentrenamiento a gran escala, para interpretar los trazados sin ninguna actualización de pesos. Esta rama investiga si el conocimiento multimodal previo de los VLM compensa la escasez de datos específicos del dominio.

La pregunta metodológica central no es cuál tecnología es más reciente, sino una cuestión práctica con implicaciones directas para proyectos biomédicos con datos escasos: ¿compensa el conocimiento visual previo de un VLM la ausencia de entrenamiento específico? ¿O el entrenamiento supervisado, incluso con pocos datos, sigue siendo preferible?

Los resultados de la rama CNN — que muestran que el entrenamiento supervisado con pocos datos no alcanza rendimiento robusto en el dominio real, incluso con adaptación de dominio — constituyen un precedente empírico negativo que justifica directamente la exploración de VLM/ICL como alternativa. Si entrenar un modelo de visión específico no funciona con pocos datos, la pregunta natural es si un modelo que ya posee conocimiento visual y médico general puede compensar esa carencia sin necesidad de actualizar pesos.

1.3 Pregunta de investigación

La pregunta central del trabajo es:

Dado un conjunto reducido de imágenes de ECG etiquetadas y un objetivo de triaje de sospecha de síndrome de Brugada, ¿cuándo resulta preferible entrenar una CNN específica frente a utilizar modelos de visión y lenguaje con aprendizaje en contexto? ¿Compensa el conocimiento multimodal preexistente de los VLM la escasez de datos etiquetados que limita a los modelos supervisados tradicionales?

Esta pregunta general se descompone en las siguientes subpreguntas:

1. ¿Puede una CNN aprender señal visual útil en un simulador QRS/ST controlado con presupuestos K muy pequeños?
2. ¿Se mantiene ese aprendizaje al pasar a Brugada HUCA, un conjunto real con variabilidad clínica y etiqueta binaria de caso confirmado frente a control?
3. ¿La adaptación de dominio reduce de forma suficiente la brecha entre el dominio sintético y el dominio real?
4. ¿Los VLM con aprendizaje en contexto (Gemma 4, MedGemma) superan el rendimiento de la CNN entrenada cuando los datos etiquetados son escasos?
5. ¿A partir de qué umbral de datos etiquetados, si existe, el entrenamiento supervisado de una CNN iguala o supera al VLM/ICL?

1.4 Hipótesis

El trabajo parte de cinco hipótesis operativas:

1. El simulador QRS/ST genera diferencias visuales suficientes para que una CNN aprenda por encima del azar en el dominio sintético.
2. El rendimiento de la CNN mejora al aumentar K en el dominio sintético, donde las etiquetas proceden de reglas controladas.
3. La misma CNN pierde rendimiento significativo en Brugada HUCA por cambio de dominio visual y por cambio de significado de la etiqueta, evidenciando las limitaciones del entrenamiento supervisado con pocos datos.
4. La adaptación de dominio mejora parcialmente el resultado real, pero no elimina la limitación fundamental impuesta por la escasez de datos etiquetados.
5. Si la CNN no alcanza rendimiento robusto ni con adaptación de dominio, los VLM con aprendizaje en contexto — que aprovechan conocimiento visual y médico adquirido durante el preentrenamiento multimodal a gran escala — deben ofrecer un rendimiento superior sin necesidad de actualización de pesos, compensando con conocimiento previo lo que la CNN no puede aprender por falta de datos.

1.5 Objetivos

El objetivo general es construir una canalización experimental reproducible que compare el rendimiento de CNN entrenadas frente a VLM con aprendizaje en contexto para triaje de sospecha de Brugada a partir de ECG como imagen en régimen de pocos datos.

Los objetivos específicos son:

1. Generar un conjunto sintético QRS/ST con imágenes de V1, V2 y V3 y etiquetas derivadas de reglas morfológicas.
2. Construir un conjunto Brugada HUCA procesado, separado por paciente y con exclusiones documentadas.
3. Entrenar ResNet18 mediante validación leave-one-out para $K = \{2, 4, 8, 16, 32\}$ y tres semillas como línea base supervisada.
4. Medir exactitud equilibrada, F1, sensibilidad, especificidad, área ROC, precisión media y matrices de confusión.
5. Evaluar cuatro métodos de adaptación de dominio (SSL, CORAL, MMD, DANN) para cuantificar su capacidad de mitigar la brecha entre dominio sintético y real.
6. Interpretar los resultados CNN como evidencia empírica de las limitaciones del entrenamiento supervisado con pocos datos.

7. Desarrollar la pipeline VLM/ICL con Gemma 4 y MedGemma, incluyendo prompts estructurados, control de alucinaciones, validación de salida, condiciones de ablación y variación del número de ejemplos en contexto.
8. Comparar cuantitativamente el rendimiento CNN frente a VLM/ICL para cada régimen de datos y extraer recomendaciones prácticas.

1.6 Contribuciones

Las contribuciones del trabajo son:

- Un simulador y un conjunto sintético auditado con 100 pacientes y 300 imágenes de trazados QRS/ST.
- Un preprocesado del conjunto real Brugada HUCA con 317 pacientes, 951 imágenes y 46 exclusiones documentadas.
- Resultados CNN completos en dominio sintético y real (Brugada HUCA), incluyendo curvas de aprendizaje, matrices de confusión y mapas Grad-CAM.
- Resultados de adaptación de dominio para cuatro métodos (SSL, CORAL, MMD, DANN).
- Una lectura negativa empíricamente fundamentada: la CNN aprende en el dominio sintético, pero no alcanza rendimiento robusto en el dominio real con pocos datos, ni siquiera con adaptación de dominio. Esta evidencia negativa constituye el precedente que justifica la exploración de VLM/ICL.
- Una pipeline VLM/ICL con Gemma 4 y MedGemma como propuesta principal para el régimen de pocos datos, con prompts controlados, validación de salida, tablas de resultados preparadas y métricas comparables.
- Una comparación sistemática CNN frente a VLM/ICL que permite identificar en qué régimen de datos cada enfoque resulta preferible.
- Una memoria orientada a triaje clínico prudente, con descripción detallada del circuito de confirmación diagnóstica del síndrome de Brugada.

1.7 Alcance

El trabajo no valida un producto sanitario. No estima utilidad clínica prospectiva ni sustituye la revisión por especialista. La etiqueta sintética deriva de reglas internas y la etiqueta real de HUCA representa caso Brugada confirmado frente a control. Estas dos tareas

están relacionadas, pero no son equivalentes.

La línea VLM/ICL no es decorativa ni secundaria. Constituye la propuesta principal del trabajo, motivada directamente por la evidencia empírica de que los modelos de visión tradicionales (CNN) no alcanzan rendimiento suficiente con pocos datos. La comparación CNN frente a VLM/ICL es el eje vertebrador de la memoria: los resultados CNN establecen el precedente negativo que los VLM deben superar o matizar, y la comparación conjunta permite extraer conclusiones prácticas sobre qué estrategia adoptar en función del presupuesto de datos disponible.

Los resultados se circunscriben a los conjuntos de datos empleados (sintético QRS/ST y Brugada HUCA) y no son directamente generalizables a otras poblaciones, otros patrones electrocardiográficos o dispositivos de adquisición distintos sin validación adicional.

1.8 Estructura de la memoria

El capítulo 2 presenta los fundamentos clínicos del síndrome de Brugada y los fundamentos técnicos de CNN, adaptación de dominio y modelos de visión y lenguaje. El capítulo 3 revisa trabajos relacionados en clasificación de ECG como imagen y en aprendizaje con pocos datos. El capítulo 4 fija el diseño experimental del estudio comparativo. El capítulo 5 describe el simulador QRS/ST. El capítulo 6 detalla las arquitecturas y configuraciones de la CNN, la adaptación de dominio y la pipeline VLM/ICL con Gemma 4 y MedGemma. Los capítulos 7 y 8 presentan los resultados de la rama CNN en el dominio sintético y real. El capítulo 9 desarrolla la evaluación VLM/ICL con sus condiciones, controles y tablas de resultados preparadas. El capítulo 10 discute las implicaciones de la comparación CNN frente a VLM/ICL y el capítulo 12 cierra el trabajo con las conclusiones y líneas futuras.

CAPÍTULO 2

Fundamentos clínicos y técnicos

2.1 Origen y representación del electrocardiograma

El electrocardiograma registra diferencias de potencial producidas por la actividad eléctrica del corazón. La señal observada en cada derivación no corresponde a una estructura anatómica aislada. Es la proyección de un proceso eléctrico tridimensional sobre un eje definido por la posición de los electrodos. Por esta razón una misma activación puede generar deflexiones distintas según la derivación desde la que se observe.

El ECG convencional utiliza doce derivaciones obtenidas a partir de diez electrodos. Las derivaciones I, II, III, aVR, aVL y aVF describen la actividad en el plano frontal. Las derivaciones V1 a V6 ofrecen una perspectiva precordial en el plano horizontal. La colocación de los electrodos, la ganancia, la velocidad de registro y el filtrado influyen en la apariencia final. Las recomendaciones de estandarización insisten en conservar estos parámetros porque una modificación técnica puede alterar amplitudes, duraciones y relaciones espaciales que después se utilizan durante la interpretación [2].

La representación clínica habitual utiliza una velocidad de 25 mm por segundo y una ganancia de 10 mm por mV. Con esa convención, un milímetro horizontal equivale a 40 ms y un milímetro vertical equivale a 0,1 mV. Estas equivalencias permiten estimar intervalos y amplitudes directamente sobre el papel. Cuando el trazado se transforma en una imagen digital, la relación física deja de estar garantizada si la imagen se redimensiona, se recorta o se fotografía sin una referencia de escala.

El presente trabajo no intenta reconstruir el vector cardíaco completo. La unidad experimental es una imagen de un latido sintético semejante a una ventana precordial derecha. Esta simplificación permite controlar el complejo QRS, el segmento ST y la onda T. También impide aplicar de forma literal criterios que requieren comparar varias derivaciones. La memoria distinguirá por tanto entre la definición clínica de un hallazgo y la aproximación visual utilizada por el simulador.

2.2 Morfología básica de un latido

Un latido normal puede describirse mediante una secuencia de ondas y segmentos. La onda P refleja la despolarización auricular. El intervalo PR incluye la propagación desde las aurículas hasta el sistema de conducción ventricular. El complejo QRS representa la despolarización ventricular. El punto J marca la transición entre el final del QRS y el comienzo del segmento ST. La onda T se relaciona con la repolarización ventricular.

Las letras Q, R y S no designan posiciones anatómicas fijas. La onda Q es la primera deflexión negativa anterior a una deflexión positiva. La onda R es la primera deflexión positiva del complejo ventricular. La onda S es una deflexión negativa posterior a una onda R. Si aparece una segunda deflexión positiva, se denomina R prima. Esta nomenclatura describe la geometría de la señal y no establece por sí sola un diagnóstico.

El segmento ST se evalúa con respecto a una referencia isoelectrica. En un registro real, esa referencia puede aproximarse mediante el segmento TP o el segmento PR según el contexto. La elevación o depresión no se interpreta de forma independiente. Importan la derivación, la magnitud, la morfología, la distribución espacial y el cuadro clínico. Las recomendaciones de la AHA, el ACCF y la HRS separan de forma explícita la descripción del segmento ST, la onda T y el intervalo QT porque cada elemento aporta información diferente [4].

La onda T también depende de la derivación. Una deflexión negativa puede ser fisiológica en algunas posiciones y patológica en otras. Su significado cambia según la edad, el sexo, la secuencia de activación ventricular, los cambios del segmento ST y la presencia de otras alteraciones. El proyecto no intenta resolver esta interpretación completa. La etiqueta de inversión de T indica únicamente que la región tardía del latido sintético presenta una deflexión negativa que satisface las reglas operativas del conjunto.

2.3 Hallazgos morfológicos utilizados en el proyecto

2.3.1 Morfología compatible con bloqueo de rama derecha

El bloqueo de rama derecha es una alteración de la conducción intraventricular. En su forma completa se caracteriza por una duración del QRS igual o superior a 120 ms y por una morfología terminal compatible en las derivaciones apropiadas. Las recomendaciones de estandarización describen patrones como rsR prima o rSR prima en V1 o V2, junto con una onda S ensanchada en derivaciones laterales [3].

La segunda deflexión positiva en las derivaciones precordiales derechas aparece por la activación tardía del ventrículo derecho. No obstante, una forma semejante a rsR prima en una sola derivación no basta para diagnosticar un bloqueo completo. También deben considerarse

la duración global del QRS, la morfología en I y V6, la posición de los electrodos y otras causas de retraso terminal.

El simulador solo representa una ventana semejante a una derivación precordial. Por ello la etiqueta RBBB se entiende como *morfología compatible con bloqueo de rama derecha*. El validador busca dos máximos positivos separados por una deflexión negativa, exige que el segundo máximo aparezca en una posición tardía y comprueba una anchura terminal mínima. Esta regla captura una forma visual útil para el experimento, pero no reproduce el criterio clínico completo.

2.3.2 Elevación del segmento ST

El segmento ST comienza en el punto J y termina con el inicio de la onda T. Su desplazamiento se mide con respecto a una referencia isoelectrica. La magnitud clínicamente relevante depende de la derivación, del sexo, de la edad y de la situación diagnóstica. Además, una elevación puede aparecer en contextos diferentes, entre ellos isquemia aguda, pericarditis, repolarización precoz, alteraciones de conducción y síndromes de onda J.

La etiqueta sintética ST_ELEVATION no representa ninguna etiología concreta. El validador exige actividad ventricular suficiente y comprueba que la amplitud media alrededor del punto J y durante el segmento ST sea positiva. Se trata de una definición geométrica diseñada para separar imágenes, no de un umbral clínico expresado en milímetros.

Esta distinción evita una inferencia incorrecta. El modelo aprende a reconocer una región elevada después del QRS. No aprende por ese hecho a diferenciar un patrón de Brugada, un infarto agudo u otra causa. Esa diferenciación requeriría varias derivaciones, contexto clínico y un conjunto de etiquetas mucho más amplio.

2.3.3 Inversión de la onda T

La onda T refleja la repolarización ventricular y suele aparecer después del segmento ST. Su polaridad normal varía entre derivaciones. También puede modificarse como consecuencia secundaria de una secuencia anómala de despolarización. Por ejemplo, una alteración de conducción puede producir cambios discordantes del segmento ST y de la onda T.

En el conjunto sintético, la inversión se define mediante una deflexión tardía negativa. El validador comprueba la profundidad mínima, la posición temporal del mínimo y la duración de la región situada por debajo de un nivel negativo. La regla incluye además condiciones sobre el QRS y el segmento ST para evitar que una oscilación temprana se confunda con una onda T.

La etiqueta T_WAVE_INVERSION expresa por tanto una propiedad visual localizada. No determina si la inversión es primaria, secundaria, fisiológica o patológica. Esta limitación

deberá conservarse cuando el modelo se evalúe con datos reales.

2.3.4 Síndrome de Brugada: caso motivador y circuito diagnóstico

El síndrome de Brugada es una canalopatía hereditaria del canal de sodio, frecuentemente asociada a mutaciones en el gen *SCN5A*, que predispone a fibrilación ventricular y muerte súbita cardíaca. Su prevalencia se estima entre 1 y 5 por cada 10 000 personas, con predominio en varones adultos jóvenes, aunque puede manifestarse a cualquier edad. A pesar de su baja prevalencia, su asociación con arritmias malignas lo convierte en un problema clínico relevante [5].

El elemento electrocardiográfico central es el patrón tipo 1, también denominado patrón *coved*: una elevación descendente del segmento ST de al menos 2 mm en las derivaciones precordiales derechas V1 o V2, seguida de una onda T negativa. Este patrón es el único considerado diagnóstico según las guías vigentes [1]. Los patrones tipo 2 y tipo 3, descritos históricamente, ya no se consideran suficientes por sí solos para establecer el diagnóstico.

La definición ha evolucionado con el tiempo. Los criterios actuales aceptan que el patrón tipo 1, ya sea espontáneo o inducido, es suficiente para el diagnóstico de síndrome de Brugada en ausencia de otras causas que lo expliquen [1]. No obstante, el contexto clínico es fundamental: síntomas como síncope inexplicado, respiración agónica nocturna, antecedentes familiares de muerte súbita o arritmias ventriculares documentadas refuerzan la sospecha y orientan la estratificación del riesgo.


Circuito diagnóstico clínico

El diagnóstico del síndrome de Brugada sigue un circuito clínico estructurado que no puede reducirse al reconocimiento automático de un patrón en una imagen:


1. **ECG basal de 12 derivaciones.** La evaluación comienza con un ECG estándar. Si el trazado muestra un patrón tipo 1 espontáneo en V1 o V2, el diagnóstico se puede establecer tras excluir fenocopias y otras causas de elevación del ST.
2. **Recolocación de derivaciones precordiales.** Cuando el ECG basal es sospechoso pero no concluyente, las guías recomiendan registrar V1 y V2 en espacios intercostales superiores (segundo o tercero en lugar del cuarto estándar). Esta maniobra aumenta la sensibilidad para detectar el patrón tipo 1, porque la posición más alta acerca el electrodo al tracto de salida del ventrículo derecho [7].
3. **Valoración clínica integral.** Se evalúan síntomas actuales y pasados, historia familiar de muerte súbita o síndrome de Brugada confirmado, exposición a fármacos o situaciones que puedan provocar fenocopias (fiebre, trastornos electrolíticos, isquemia) y comorbilidades.

-
4. **Prueba farmacológica con bloqueantes del canal de sodio.** En pacientes seleccionados con sospecha persistente y ECG basal no diagnóstico, se realiza una prueba de provocación farmacológica. Los fármacos empleados son bloqueantes del canal de sodio de clase I: ajmalina (la más utilizada, administrada por vía intravenosa a dosis aproximada de 1 mg/kg durante 10 minutos), flecainida, procainamida o pilsicainida según la disponibilidad local [6]. La prueba se administra en un entorno monitorizado con personal entrenado en reanimación cardiopulmonar avanzada y con equipo de desfibrilación disponible, dado el riesgo, infrecuente pero real, de desencadenar arritmias ventriculares malignas (taquicardia ventricular polimórfica o fibrilación ventricular). La monitorización electrocardiográfica continua debe prolongarse después de finalizar la infusión, ya que el patrón tipo 1 puede aparecer de forma diferida, incluso cuando los intervalos QRS y QTc han comenzado a normalizarse. La prueba se considera positiva si aparece un patrón tipo 1 durante o después de la administración del fármaco. La prueba está contraindicada en pacientes que ya presentan un patrón tipo 1 espontáneo, puesto que el diagnóstico ya está establecido [6].
 5. **Estudio genético.** Se recomienda la secuenciación del gen *SCN5A* en pacientes índice para confirmar la base molecular y facilitar el cribado familiar.
 6. **Decisión clínica final.** La decisión sobre estratificación de riesgo y tratamiento (seguimiento, modificación del estilo de vida, evitación de fármacos arritmogénicos, valoración de desfibrilador automático implantable) es siempre clínica, multifactorial y realizada por especialistas.

Este circuito subraya por qué el sistema desarrollado en este TFG se plantea exclusivamente como herramienta de triaje. Una predicción positiva del modelo no equivale a un diagnóstico de síndrome de Brugada. Equivale a una señal que sugiere priorizar la revisión del trazado por un especialista y, si procede, iniciar el circuito diagnóstico descrito. La decisión de realizar una prueba farmacológica, su interpretación y las consecuencias clínicas permanecen bajo responsabilidad médica [6].



(a) ECG con morfología tipo 1 en V1 y V2.



(b) Patrones tipo 1, 2 y 3 usados como referencia visual.

Figura 2.1. Ejemplos clínicos de morfología Brugada. Izquierda: CardioNetworks/ECGpedia, CC BY-SA 3.0 [8]. Derecha: figura de Napolitano y Priori, reutilizada bajo CC BY 2.0 [9].

La relación con el bloqueo de rama derecha requiere una precisión adicional. El trazado tipo 1 puede recordar visualmente a una alteración terminal del QRS. Sin embargo, el mecanismo y los criterios no son equivalentes. La onda J del patrón de Brugada se concentra en las derivaciones precordiales derechas y no necesita la onda S lateral recíproca que forma parte del bloqueo de rama derecha [10]. En este TFG, RBBB se utiliza como una etiqueta morfológica auxiliar y no como requisito clínico para Brugada.

La familia generadora BRUGADA introduce una elevación inicial del segmento ST, una caída progresiva y una onda T negativa. Después de generar la señal, los tres validadores independientes determinan qué hallazgos están presentes. La familia de origen se conserva como metadato, mientras que la tarea predictiva utiliza únicamente las etiquetas observables. Esta separación es importante: el simulador crea un caso visual para probar modelos, no una reproducción diagnóstica del síndrome.




Figura 2.2. Representación esquemática de los hallazgos visuales que motivan el triaje de patrón Brugada.

Tabla 2.1. Relación entre el concepto clínico y la aproximación operativa del proyecto

Hallazgo	Interpretación clínica resumida	Aproximación utilizada en el conjunto sintético
RBBB	Trastorno de conducción que requiere duración y morfología compatibles en varias derivaciones	Dos máximos positivos en la región ventricular, una depresión intermedia y actividad terminal tardía y ancha
Elevación ST	Desplazamiento del punto J y del segmento ST cuya relevancia depende de derivación y contexto	Media positiva en ventanas posteriores al QRS junto con actividad ventricular suficiente
Inversión T	Onda T negativa con significado dependiente de la derivación y de la secuencia de activación	Deflexión tardía negativa con profundidad, posición y duración mínimas
Brugada tipo 1	Patrón descendente en precordiales derechas que debe interpretarse dentro de criterios clínicos	Familia generadora que combina elevación inicial, descenso del ST y T negativa. No se utiliza como etiqueta diagnóstica

2.4 La señal y la imagen como representaciones

Una señal digital conserva muestras de amplitud ordenadas en el tiempo. Esta representación permite medir intervalos, aplicar filtros y comparar derivaciones con una escala conocida. La imagen es el resultado de transformar esas muestras mediante un proceso de renderizado. Contiene la forma visible del trazado, pero también incorpora decisiones de presentación.

El renderizado establece el tamaño del lienzo, la cuadrícula, el grosor de la línea, los márgenes y la disposición de las derivaciones. Una red puede utilizar cualquiera de esos elementos si están correlacionados con la etiqueta. Por ello un conjunto de imágenes debe controlar que la clase no pueda deducirse a partir de una marca, un recorte o una diferencia de resolución.

La imagen posee una ventaja práctica cuando la señal original no está disponible. Sangha y colaboradores demostraron que un modelo multietiqueta podía analizar ECG renderizados y mantener un rendimiento alto en registros externos y trazados impresos [15]. Gliner y colaboradores mostraron además que una CNN puede trabajar con fotografías de ECG, aunque la diferencia de formato requiere estrategias específicas de adaptación [17].

La alternativa consiste en digitalizar primero la imagen. El trabajo de Wu y colaboradores desarrolló una herramienta automática para segmentar trazados impresos y reconstruir las

señales [16]. La digitalización permite reutilizar modelos temporales, pero introduce errores cuando las derivaciones se solapan o la calidad del documento es baja. El análisis directo de imagen y la digitalización no son soluciones excluyentes. Responden a compromisos distintos.

Esta doble naturaleza del ECG, señal temporal e imagen, es precisamente lo que hace relevante la comparación entre CNN y VLM. Una CNN entrenada con pocos ejemplos necesita extraer toda la información visual de los píxeles disponibles. Un modelo de visión y lenguaje puede complementar la información visual con conocimiento previo adquirido durante su preentrenamiento sobre colecciones masivas de imágenes y texto médico. La pregunta es si ese conocimiento previo compensa la escasez de datos etiquetados.

Tabla 2.2. Comparación entre la señal temporal y la imagen electrocardiográfica

Aspecto	Señal temporal	Imagen
Información primaria	Muestras de amplitud con frecuencia conocida	Geometría visible después del renderizado
Medición de intervalos	Directa si se conoce la frecuencia de muestreo	Depende de escala, resolución y posibles transformaciones
Disponibilidad histórica	Limitada cuando solo se conserva el documento	Frecuente en informes, PDF, papel y fotografías
Variabilidad técnica	Filtros, fabricantes y frecuencia de muestreo	Incluye además cuadrícula, color, perspectiva, recorte y compresión
Modelos habituales	Convoluciones unidimensionales, recurrentes y transformadores	CNN, transformadores visuales y modelos de visión y lenguaje
Riesgo principal	Dependencia del dispositivo y del preprocesado temporal	Aprendizaje de rasgos de estilo que no pertenecen a la fisiología

2.5 Datos sintéticos y modelos gaussianos

Los datos sintéticos permiten controlar factores que resultan difíciles de aislar en una colección clínica. Es posible generar clases equilibradas, conocer los parámetros que originan cada señal y repetir exactamente el proceso. También se evita utilizar información de pacientes durante las primeras fases del desarrollo.

Un modelo sintético no elimina el problema de los datos. Lo transforma. La validez depende de que las reglas de generación representen los rasgos que se quieren estudiar y de que no introduzcan atajos visuales. Una morfología demasiado regular puede producir un conjunto fácil para una red y poco informativo sobre el comportamiento en registros reales.

La representación mediante ondas gaussianas cuenta con precedentes en el procesa-

miento de ECG. Sayadi y colaboradores describieron un modelo dinámico basado en ondas gaussianas para generar señales y realizar filtrado bayesiano [18]. En el presente proyecto se adopta una variante más simple y directamente controlable. Cada componente se define como

$$g_i(t) = a_i \exp \left(-\frac{(t - \mu_i)^2}{2\sigma_i^2} \right), \quad (2.1)$$

donde a_i controla la amplitud, μ_i determina la posición temporal y σ_i regula la anchura. El latido completo se obtiene mediante

$$x(t) = \sum_{i=1}^M g_i(t). \quad (2.2)$$

La suma incluye componentes para P, Q, R, S, R prima, punto J, segmento ST y onda T. Los parámetros se muestrean dentro de intervalos dependientes de la familia generadora. Después se aplican relaciones temporales para mantener un orden coherente. Finalmente, un validador decide si la señal satisface las condiciones mínimas de la familia solicitada.

Este procedimiento es un muestreo con rechazo. Si la señal no supera el validador se descarta y se genera otra. La estrategia mejora la consistencia interna, aunque también puede concentrar las muestras cerca de las regiones que aceptan las reglas. La tasa de aceptación y la distribución de parámetros deben analizarse como parte del control de calidad.

Los simuladores de mayor fidelidad utilizan modelos electrofisiológicos y geometrías cardíacas completas. MedalCare XL, por ejemplo, ofrece miles de ECG sintéticos de doce derivaciones obtenidos mediante simulaciones electrofisiológicas [19]. Ese enfoque persigue realismo fisiológico y requiere un coste computacional mayor. El simulador de este TFG persigue interpretabilidad y control local. No son alternativas equivalentes.

2.6 Clasificación multietiqueta

En clasificación multiclase cada ejemplo se asigna a una categoría exclusiva. En clasificación multietiqueta, una muestra se asocia con un subconjunto de etiquetas. Esta formulación es adecuada cuando los hallazgos pueden coexistir [31].

Sea L el número de etiquetas. Para una imagen x , la referencia se representa mediante un vector

$$\mathbf{y} = (y_1, \dots, y_L), \quad y_j \in \{0, 1\}. \quad (2.3)$$

Una red convolucional produce un logit z_j por etiqueta. La función sigmoide transfor-

ma cada logit en una probabilidad independiente

$$\hat{p}_j = \frac{1}{1 + \exp(-z_j)}. \quad (2.4)$$

La pérdida habitual es la entropía cruzada binaria

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{L} \sum_{j=1}^L [y_j \log(\hat{p}_j) + (1 - y_j) \log(1 - \hat{p}_j)]. \quad (2.5)$$

La independencia de las salidas no significa que las etiquetas sean estadísticamente independientes. La red puede aprender representaciones compartidas y aprovechar coocurrencias. Sin embargo, una coocurrencia excesiva puede crear atajos. Si todas las ondas T negativas aparecen siempre junto con elevación del ST, el modelo puede predecir una etiqueta a partir de la otra sin observar la región correcta.

La decisión binaria requiere un umbral. El valor 0,5 es una referencia simple, pero no tiene por qué ser óptimo para todas las etiquetas. Los umbrales deben fijarse con el conjunto de validación y conservarse para el test. Ajustarlos con el conjunto de prueba produciría una estimación optimista.

En los modelos de visión y lenguaje la salida no es una probabilidad sigmoide. El sistema genera texto o un objeto estructurado. La evaluación necesita convertir esa respuesta a un vector binario y registrar de forma separada las respuestas que no cumplen el esquema. Esta diferencia forma parte del protocolo y no debe ocultarse durante la comparación.

2.7 Redes neuronales convolucionales

Una convolución aplica un conjunto de filtros compartidos sobre regiones locales de una imagen. Las primeras capas detectan transiciones y contornos. Las capas posteriores combinan esas respuestas para construir patrones de mayor escala. En una imagen de ECG, la red puede aprender inclinaciones, picos, valles y relaciones entre regiones temporales.

El uso de pesos compartidos aporta cierta tolerancia a desplazamientos pequeños. Sin embargo, el ECG no es completamente invariante a la posición. Una deflexión negativa tiene un significado diferente si aparece dentro del QRS o en la región de la onda T. La arquitectura debe conservar suficiente información espacial y el preprocesado debe alinear los latidos.

En este trabajo la referencia convolucional cerrada es una ResNet18 preentrenada. Las conexiones residuales facilitan la optimización de redes profundas al aprender transformaciones relativas a la entrada de cada bloque [28]. El uso de pesos de ImageNet no garantiza una ventaja en ECG, pero aporta filtros visuales iniciales útiles para contornos, trazos y texturas cuando el número de ejemplos etiquetados es pequeño.

La evaluación debe comprobar si esa transferencia visual se mantiene fuera del simulador. Un resultado alto en imágenes sintéticas puede reflejar que la red aprendió reglas de renderizado, mientras que un resultado más bajo en datos reales puede revelar ruido, variabilidad clínica o diferencias en la definición de etiqueta. Los resultados de este TFG confirman que la CNN aprende bien en sintético pero falla en datos reales, lo que motiva la exploración de alternativas que no dependan exclusivamente del entrenamiento supervisado con pocos ejemplos.

2.8 Modelos de visión y lenguaje

Un modelo de visión y lenguaje (VLM) combina una representación visual con un modelo generativo de texto. La imagen se transforma en vectores que el componente lingüístico puede atender durante la generación. La salida puede adoptar la forma de una respuesta libre, una explicación o una estructura con campos definidos. Esta arquitectura introduce una capacidad fundamentalmente nueva respecto a las CNN: el modelo no solo procesa imágenes, sino que integra conocimiento visual y textual adquirido durante un preentrenamiento masivo.

Flamingo mostró que un modelo multimodal entrenado con secuencias intercaladas de imagen y texto podía adaptarse a tareas mediante ejemplos incluidos en el contexto [23]. Este paradigma evita actualizar los pesos para cada tarea. Las demostraciones especifican la relación entre entrada y salida durante la inferencia, eliminando la necesidad de un conjunto de entrenamiento propio.

Esta propiedad es especialmente relevante para el problema de este TFG. Cuando solo se dispone de pocos ejemplos etiquetados de un fenómeno raro como el patrón de Brugada, el entrenamiento supervisado de una CNN puede resultar insuficiente, como demuestran los resultados experimentales. Un VLM, en cambio, puede aprovechar su conocimiento visual previo, que incluye trazados, diagramas médicos, texto clínico y relaciones entre morfología y diagnóstico, para interpretar nuevas imágenes sin necesidad de ajustar sus parámetros. La hipótesis central del TFG es que este conocimiento previo puede compensar la escasez de datos etiquetados.

Gemma 4 admite texto e imagen y permite ajustar el número de tokens visuales dedicados a cada imagen [26]. Un presupuesto visual mayor conserva más detalle, aunque incrementa el coste. Esta decisión es relevante para ECG porque los cambios morfológicos pueden ocupar una región pequeña del lienzo. La posibilidad de ejecución local facilita experimentos reproducibles y reduce la necesidad de enviar imágenes a un servicio externo.

MedGemma 1.5 es un modelo multimodal médico basado en Gemma 3. Su entrenamiento incluye radiología, histopatología, dermatología, fondo de ojo, documentos y regis-

tros clínicos [27]. La documentación oficial no presenta el ECG como modalidad principal de entrenamiento. También indica que el modelo debe adaptarse y validarse antes de cualquier uso específico. La comparación entre Gemma 4 (modelo generalista de última generación) y MedGemma (modelo con adaptación médica sobre una base anterior) permitirá evaluar si el preentrenamiento médico específico aporta ventaja adicional en un dominio no cubierto explícitamente.

2.9 Aprendizaje multimodal en contexto

El aprendizaje en contexto (ICL) es la estrategia central propuesta en este TFG como alternativa al entrenamiento supervisado. En ICL se proporciona una secuencia de demostraciones

$$\mathcal{D}_K = \{(x_1, y_1), \dots, (x_K, y_K)\} \quad (2.6)$$

antes de la consulta objetivo x^* . El modelo genera una estimación condicionada por la instrucción y por las demostraciones

$$\hat{y}^* = f_{\theta}(x^*, \mathcal{D}_K, \text{instrucción}), \quad (2.7)$$

sin modificar los parámetros θ . Esta diferencia con el entrenamiento supervisado es fundamental. Los mismos K ejemplos etiquetados que una CNN utilizaría para actualizar millones de pesos, un VLM los recibe como contexto dentro del prompt. Los pesos del modelo permanecen fijos y el aprendizaje se produce de forma implícita durante la generación.

Esta formulación convierte al número de ejemplos K en la variable de comparación natural entre ambos enfoques. Con un mismo presupuesto de K ejemplos etiquetados, la CNN debe aprender a distinguir patrones visuales; el VLM solo necesita que esos ejemplos le muestren qué significa cada clase. La pregunta experimental es directa: ¿a partir de qué valor de K compensa entrenar un modelo específico y en qué rango resulta más razonable aprovechar el conocimiento previo del VLM?

El número de ejemplos no determina por sí solo la calidad del contexto. Importan la selección, la diversidad, el orden y la coherencia entre la imagen y la etiqueta. Qin y colaboradores identificaron la recuperación multimodal, el orden interno de cada demostración y la posición de la instrucción como factores relevantes [25].

Chen y colaboradores observaron que varios modelos podían depender más del texto que de la información visual contenida en las demostraciones [24]. Esta observación justifica los controles del proyecto. En el control de respuestas permutadas se conservan las imágenes y se destruye la asociación correcta con la etiqueta. En el control sin imágenes se mantiene

la estructura textual y se elimina la evidencia visual de las demostraciones.

Si un modelo mejora solo con demostraciones correctas y pierde esa mejora en ambos controles, existe evidencia de que utiliza la correspondencia multimodal. Si mantiene el rendimiento con respuestas permutadas, puede estar ignorando las demostraciones o explotando la distribución de clases. Si funciona sin las imágenes de apoyo, la mejora puede proceder del formato de respuesta o de la descripción textual.

2.10 Explicabilidad y fidelidad

Los mapas de activación de clase permiten visualizar qué regiones de una imagen influyen en una salida. Grad CAM utiliza los gradientes de una clase para ponderar los mapas de activación de una capa convolucional [29]. En una tarea de ECG, una explicación razonable debería destacar regiones distintas para QRS, segmento ST y onda T.

Un mapa visual no demuestra causalidad clínica. La resolución suele ser inferior a la imagen de entrada y el resultado depende de la capa seleccionada. También puede señalar una región amplia aunque el modelo utilice un artefacto local. Su función en este proyecto será detectar comportamientos incompatibles con la tarea, no certificar una explicación.

Las explicaciones generadas por un modelo de visión y lenguaje plantean un problema diferente. El texto puede describir correctamente la morfología aunque esa descripción no haya causado la predicción. La plausibilidad lingüística y la fidelidad del razonamiento son propiedades distintas. La evaluación principal utilizará respuestas estructuradas. Las justificaciones se analizarán como un artefacto cualitativo separado.

2.11 Cambio de dominio y adaptación

El dominio sintético y el dominio real difieren en fisiología, adquisición y presentación. El simulador genera un único latido alineado, con una cuadrícula uniforme y sin variabilidad entre pacientes. Un ECG real contiene ruido, deriva de línea base, diferencias de frecuencia cardíaca, trazos superpuestos, anotaciones y múltiples derivaciones.

Una red puede obtener un rendimiento elevado en sintético y fallar en real si aprende características exclusivas del renderizado. Este fenómeno es un cambio de dominio. La adaptación intenta aprender representaciones útiles para la tarea y poco informativas sobre el origen de la muestra.

El entrenamiento adversarial de dominio introduce un clasificador que intenta distinguir muestras fuente y objetivo. El extractor recibe una señal de gradiente invertida para reducir esa capacidad de discriminación [30]. Gliner y colaboradores aplicaron este principio a imágenes de ECG capturadas con teléfono y mostraron que datos objetivo sin etiqueta podían mejorar la transferencia [17].

La adaptación no sustituye la evaluación externa. Alinear distribuciones puede ocultar diferencias relevantes si las prevalencias o las relaciones entre etiquetas cambian. El protocolo deberá comparar el rendimiento antes y después, conservar un conjunto real independiente y analizar cada etiqueta. Los resultados de este TFG muestran que incluso con técnicas de adaptación de dominio, la CNN no supera de forma robusta el dominio real con pocos datos, lo que refuerza la necesidad de explorar enfoques que no dependan exclusivamente del entrenamiento supervisado.

2.12 Implicaciones para el diseño experimental

Los fundamentos anteriores determinan varias decisiones de diseño que sitúan la comparación CNN frente a VLM/ICL en el centro del trabajo.

La primera decisión es que las etiquetas se describirán como hallazgos morfológicos. La segunda es que la familia BRUGADA no se convertirá en un diagnóstico automático, sino en una señal de triaje que remite al circuito clínico descrito anteriormente. La tercera, y más importante para la pregunta de investigación, es que CNN y modelos de visión y lenguaje recibirán exactamente la misma imagen objetivo y el mismo presupuesto de ejemplos K . La diferencia estará en cómo usan esos ejemplos: la CNN para actualizar pesos; el VLM como demostraciones en contexto.

La separación por pacientes no puede evaluarse en el conjunto sintético porque cada imagen se genera de forma independiente. En datos reales será obligatoria para impedir que registros de una misma persona aparezcan en entrenamiento y test. También será necesario preservar la escala o documentar cualquier normalización.

El rendimiento se analizará por etiqueta porque cada hallazgo ocupa una región distinta. La coincidencia exacta medirá si se recupera el conjunto completo. La sensibilidad y la especificidad mostrarán qué tipo de error domina. La medida F1 resumirá el equilibrio entre precisión y sensibilidad. Estas métricas serán idénticas para CNN y VLM/ICL, garantizando una comparación justa.

Finalmente, cualquier conclusión sobre utilidad clínica quedará condicionada a una evaluación real. El dominio sintético responde preguntas sobre aprendibilidad, sensibilidad al contexto y comportamiento relativo de los modelos. No permite estimar por sí solo la seguridad de un sistema médico. La lectura clínica de los resultados debe interpretarse siempre dentro del circuito de triaje: priorización de revisión seguida de circuito diagnóstico completo cuando proceda.

CAPÍTULO 3

Trabajos relacionados

3.1 Alcance de la revisión

La revisión se centra en trabajos que ayudan a responder la pregunta experimental del TFG. Se consideran cinco líneas. La primera estudia el diagnóstico automático a partir de señales de ECG. La segunda utiliza el trazado como imagen. La tercera genera datos sintéticos. La cuarta desarrolla modelos multimodales para imágenes electrocardiográficas. La quinta analiza aprendizaje en contexto con demostraciones visuales. Las dos últimas líneas reciben mayor atención porque constituyen la dirección experimental principal del proyecto.

La búsqueda bibliográfica se actualizó hasta el 22 de junio de 2026. Se priorizaron artículos revisados por pares, conjuntos publicados con documentación técnica, guías clínicas y tarjetas oficiales de modelo. Los resultados no se comparan como si procedieran del mismo banco de pruebas. Las bases de datos, las etiquetas y las métricas difieren entre estudios.

Esta precaución es necesaria porque una exactitud alta en una tarea binaria no puede compararse directamente con una clasificación multietiqueta. Tampoco es equivalente evaluar imágenes renderizadas desde señales limpias que fotografías de documentos clínicos. La revisión se utiliza para identificar decisiones de diseño y huecos metodológicos.

3.2 Aprendizaje profundo sobre señales electrocardiográficas

El análisis automático moderno se desarrolló principalmente sobre señales temporales. Las convoluciones unidimensionales permiten aprender filtros directamente sobre las muestras y evitan diseñar manualmente todas las características. Las redes profundas amplían el campo receptivo hasta integrar información distribuida a lo largo de varios segundos.

Ribeiro y colaboradores entrenaron una red profunda con más de dos millones de ECG de doce derivaciones procedentes de una red brasileña de telemedicina [11]. El sistema reconocía seis alteraciones y fue comparado con médicos en un subconjunto anotado. El trabajo mostró que una gran colección clínica puede sostener un clasificador temporal de alto rendimiento.

Su escala también señala una limitación para enfermedades poco frecuentes. Reunir mi-

lones de registros con etiquetas fiables no es una estrategia disponible para todos los problemas. Además, las etiquetas de rutina pueden reflejar criterios locales, versiones de software y variabilidad entre observadores.

PTB XL proporcionó un punto de referencia abierto con 21 837 ECG de doce derivaciones y 71 enunciados potencialmente multietiqueta [12]. Sus particiones recomendadas facilitan comparaciones reproducibles. MIMIC IV ECG amplió la escala hasta aproximadamente 800 000 registros vinculables con información clínica [13]. Estos recursos resultan valiosos para preentrenamiento y validación, aunque no garantizan una cantidad suficiente de cada condición rara.

La literatura sobre señal establece dos referencias para el presente trabajo. Primero, una arquitectura supervisada puede aprender morfología electrocardiográfica cuando dispone de datos adecuados. Segundo, el rendimiento depende de la correspondencia entre el dominio de entrenamiento y la población objetivo. El simulador se utiliza para estudiar el régimen anterior a una gran colección clínica, no para competir con sistemas entrenados sobre millones de registros.

3.3 Análisis directo de imágenes de ECG

El análisis de imagen aborda situaciones en las que el trazado está disponible como documento. Gliner y colaboradores compararon redes que recibían señales digitales y redes que recibían imágenes de doce derivaciones [14]. Su estudio incluyó ocho condiciones para el modelo temporal y una evaluación visual centrada en fibrilación auricular. También aplicó transformaciones que imitaban capturas con teléfono.

Sangha y colaboradores desarrollaron una CNN multietiqueta a partir de 2 228 236 registros brasileños convertidos en imagen [15]. El modelo predijo seis etiquetas clínicas y se evaluó en una cohorte externa alemana y en ECG impresos. El estudio demostró que la representación visual puede generalizar cuando el entrenamiento incorpora escala, diversidad y variación de formato.

La principal diferencia con este TFG es la disponibilidad de datos. Sangha y colaboradores estudian aprendizaje supervisado a gran escala. El presente trabajo pregunta qué ocurre antes de alcanzar esa escala y compara el entrenamiento de una CNN con el uso inmediato de demostraciones en un modelo abierto.

La imagen puede analizarse directamente o convertirse de nuevo a señal. Wu y colaboradores desarrollaron un sistema automático de digitalización y evaluaron la correlación entre la señal reconstruida y la original [16]. Los resultados fueron altos en formatos favorables y disminuyeron cuando había solapamiento entre derivaciones. Esta variabilidad muestra que la digitalización añade sus propios fallos.

El trabajo de Gliner y colaboradores de 2023 se centra en la transferencia desde imágenes limpias a fotografías y formatos no observados [17]. Su arquitectura adversarial utiliza muestras objetivo sin etiqueta para reducir la dependencia del estilo de adquisición. Esta línea es directamente relevante para la futura transición del simulador a datos reales.

3.4 Datos sintéticos para ECG

La generación sintética aparece en varios niveles de fidelidad. Los modelos gaussianos representan ondas mediante funciones paramétricas. Su principal ventaja es la interpretabilidad. Cada cambio puede relacionarse con amplitud, posición o anchura. Sayadi y colaboradores emplearon un modelo de este tipo dentro de un sistema dinámico para generación y filtrado [18].

Los modelos electrofisiológicos simulan la propagación eléctrica sobre geometrías cardíacas. MedalCare XL contiene 16 900 ECG sintéticos de doce derivaciones para un grupo sano y siete patologías [19]. La colección aporta señales con una base mecánica y permite estudiar condiciones difíciles de equilibrar en datos clínicos.

También existen modelos generativos aprendidos. Los modelos de difusión condicionados pueden producir señales asociadas a enunciados diagnósticos [20]. Su flexibilidad es mayor que la de un simulador manual, pero la relación entre cada parámetro y la morfología final resulta menos directa. Además, la calidad debe evaluarse mediante diversidad, fidelidad clínica y utilidad para tareas posteriores.

El simulador del proyecto ocupa un punto deliberadamente simple. No intenta reproducir un torso, un corazón tridimensional o una distribución clínica completa. Genera un latido para estudiar tres hallazgos localizados. Esta decisión reduce el realismo y mejora la capacidad de auditar las reglas.

La literatura sintética también advierte de un riesgo. Un conjunto generado puede amplificar los supuestos del modelo de simulación. Si la variabilidad no incluye ruido, escalas y formas intermedias, el clasificador aprenderá una frontera más limpia que la que existe en práctica clínica. La evaluación real sigue siendo necesaria.

3.5 Conjuntos que integran señal, imagen y texto

Los modelos multimodales necesitan datos alineados. Una imagen sin informe permite clasificación supervisada, pero no ofrece una relación rica entre morfología y lenguaje. Un informe sin trazado tampoco permite comprobar si la explicación se apoya en evidencia visual.

MEETI se publicó en 2026 como una extensión de MIMIC IV ECG [22]. El recurso sincroniza señales, imágenes renderizadas, parámetros por latido e interpretaciones textuales.

Cubre hasta 784 680 registros de 160 597 pacientes. Las imágenes se generan con una escala estándar y las interpretaciones detalladas se producen mediante un modelo de lenguaje a partir de informes y parámetros.

MEETI reduce la barrera de entrada para estudiar alineamiento multimodal a gran escala. También requiere una lectura crítica. Parte del texto es generado por un modelo y no constituye una nueva anotación clínica independiente. El recurso resulta adecuado para pre-entrenamiento, recuperación y generación de informes, pero la evaluación diagnóstica debe conservar etiquetas y conjuntos de referencia validados.

El proyecto no utiliza por ahora MEETI porque su tarea se limita a un latido sintético y tres hallazgos. Sin embargo, este conjunto ofrece una ruta futura para ampliar la representación hacia doce derivaciones y para comparar imagen, señal y texto sobre los mismos registros.

3.6 Modelos multimodales especializados en ECG

Los modelos generalistas de visión y lenguaje han sido entrenados principalmente con imágenes naturales, documentos y contenido web. Un trazado electrocardiográfico posee una estructura diferente. La información se codifica en deflexiones delgadas, relaciones temporales y comparaciones entre derivaciones. Esta distancia de dominio puede limitar la interpretación directa y motiva dos aproximaciones complementarias: adaptar un modelo de gran tamaño al dominio médico, o aprovechar las capacidades de razonamiento visual de un modelo generalista sin modificar sus pesos. Ambas vías se exploran en este TFG.

Liu y colaboradores introdujeron ECGInstruct, PULSE y ECGBench [21]. ECGInstruct contiene más de un millón de pares de imagen y texto que cubren reconocimiento de características, ritmo, morfología y generación de informes. PULSE es un modelo de siete mil millones de parámetros adaptado a ECG. ECGBench evalúa cuatro tareas en nueve conjuntos e incluye imágenes sintéticas y reales.

Los autores informan que PULSE supera a modelos multimodales generalistas en su banco de pruebas [21]. Este resultado apoya la idea de que el conocimiento visual específico importa. Al mismo tiempo, PULSE se ha entrenado con una colección masiva de instrucciones. Su existencia confirma que la adaptación al dominio mejora el rendimiento, pero no responde a la misma pregunta que este TFG. El presente proyecto investiga qué rendimiento se puede obtener *sin ajuste* de pesos, utilizando un modelo generalista abierto cuando solo existen unos pocos ejemplos de una condición rara como Brugada.

PULSE constituye una referencia futura importante. Si se incorpora al protocolo, permitiría separar tres niveles de especialización. El primero sería una CNN entrenada de forma supervisada con pocas muestras. El segundo sería un modelo generalista mediante aprendiza-

je en contexto. El tercero sería un modelo multimodal ya adaptado a ECG. La comparación entre estos tres niveles mediría el valor incremental de cada etapa de especialización para una tarea de baja prevalencia.

La aparición de PULSE modifica el estado del arte, pero no elimina la pregunta de investigación. Un modelo especializado puede no estar disponible para una modalidad rara, una definición local o un nuevo protocolo de anotación. El aprendizaje en contexto sigue siendo relevante durante las fases tempranas de formulación y recogida de datos, especialmente cuando el coste de entrenamiento especializado es prohibitivo y se necesita una evaluación rápida de viabilidad.

3.7 Aprendizaje multimodal en contexto

El aprendizaje en contexto (*in-context learning*, ICL) representa un cambio de paradigma respecto al ciclo clásico de entrenamiento supervisado. En lugar de modificar los pesos de una red mediante descenso por gradiente, ICL inyecta los ejemplos directamente en la ventana de contexto del modelo durante la inferencia. Cada demostración consiste en una imagen y su etiqueta o descripción textual. El modelo produce una predicción para la imagen de consulta sin que sus pesos hayan cambiado. Esta propiedad es especialmente valiosa cuando los datos disponibles se reducen a unas pocas decenas de muestras, situación habitual en condiciones cardíacas de baja prevalencia como el síndrome de Brugada.

Flamingo estableció la arquitectura de referencia para esta capacidad. El modelo recibe secuencias intercaladas de imágenes y texto y resuelve tareas con demostraciones de ejemplo [23]. Flamingo demostró que un modelo preentrenado de gran escala puede adaptarse a tareas nuevas durante la inferencia cuando se le proporcionan ejemplos visuales y textuales relevantes. Este resultado impulsó el uso de modelos multimodales como sistemas flexibles que no requieren un ciclo de ajuste dedicado para cada tarea.

Sin embargo, los estudios posteriores demuestran que esta capacidad es frágil y que la contribución de cada componente de las demostraciones no es homogénea. Chen y colaboradores evaluaron si los modelos utilizaban realmente la parte visual de las demostraciones [24]. Encontraron una dependencia dominante del contenido textual en varios bancos de pruebas estándar. La selección de ejemplos basada en similitud visual seguía aportando valor marginal, pero la imagen dentro de la demostración podía tener menos influencia de la esperada. Este hallazgo plantea una pregunta directa para el presente trabajo: cuando las demostraciones contienen imágenes de ECG, ¿el modelo las procesa visualmente o se apoya solo en las descripciones textuales?

Qin y colaboradores estudiaron la selección, el orden y la construcción de los ejemplos [25]. Sus resultados muestran que la recuperación multimodal, la posición de la instrucción

dentro del contexto y la diversidad de las demostraciones afectan al rendimiento de forma significativa. Esto impide tratar K como la única variable relevante. Dos contextos con el mismo número de ejemplos pueden contener información muy diferente y producir resultados dispares.

Estas observaciones han influido directamente en el diseño experimental del repositorio. Cada valor positivo de K se repite con tres semillas para cuantificar la variabilidad asociada a la selección de ejemplos. Las variantes con respuestas permutadas sirven como control para detectar si el modelo está memorizando la correspondencia etiqueta-posición en lugar de razonar visualmente. Las variantes sin imagen miden la contribución del canal visual. Las instrucciones breves y las descripciones morfológicas permiten comparar el efecto del conocimiento textual explícito frente al razonamiento visual implícito. En conjunto, estos controles permiten atribuir el rendimiento a cada componente del contexto y evitar conclusiones espurias sobre la capacidad visual del modelo.

Además, la aplicación de ICL a dominios médicos especializados plantea retos adicionales que la literatura general no ha abordado en profundidad. La morfología de un ECG carece de los objetos semánticos familiares que abundan en los bancos naturales. El modelo debe interpretar deflexiones de pocos milímetros, elevaciones del segmento ST y relaciones temporales entre ondas. No es evidente que la representación visual preentrenada sobre fotografías y documentos sea suficiente para capturar estas diferencias sutiles. El presente trabajo es, hasta donde sabemos, uno de los primeros en aplicar ICL multimodal a imágenes de ECG de un solo latido con condiciones raras.

3.8 Gemma 4 y MedGemma

Gemma 4 es una familia abierta y multimodal publicada por Google DeepMind en 2026. Sus variantes admiten texto e imagen, contexto extenso y resolución visual variable [26]. El presupuesto de tokens visuales permite estudiar un compromiso entre detalle y coste. La posibilidad de ejecución local facilita experimentos reproducibles y reduce la necesidad de enviar imágenes a un servicio externo.

El proyecto selecciona Gemma 4 como modelo generalista principal para la rama VLM/ICL. Esta elección responde a criterios prácticos y metodológicos. En primer lugar, Gemma 4 ofrece pesos abiertos, lo cual permite una reproducibilidad completa y evita la dependencia de un servicio propietario cuyo comportamiento puede cambiar entre versiones. En segundo lugar, su ventana de contexto admite varias imágenes simultáneas, requisito imprescindible para implementar demostraciones de tipo *few-shot* con K ejemplos visuales. En tercer lugar, la compatibilidad con servidores de inferencia locales permite ejecutar cientos de evaluaciones sin coste por petición.

La elección de Gemma 4 no se justifica mediante una afirmación previa de superioridad en ECG. No existen, hasta donde sabemos, estudios publicados que evalúen este modelo sobre trazados electrocardiográficos. El rendimiento deberá establecerse mediante los experimentos del capítulo 9. Precisamente esta ausencia de evaluación previa refuerza la motivación del TFG: determinar si un modelo generalista abierto puede interpretar imágenes de ECG sin ajuste cuando se le proporcionan unas pocas demostraciones.

MedGemma 1.5 se incluye como referencia médica complementaria. El modelo ha recibido adaptación con diferentes modalidades clínicas, incluyendo radiología y dermatología [27]. Sin embargo, su tarjeta no presenta el ECG como una modalidad central y exige validación específica. La comparación entre Gemma 4 y MedGemma permitirá responder a una pregunta relevante: ¿el preentrenamiento médico general aporta una ventaja sobre un modelo generalista más reciente cuando la tarea consiste en interpretar un trazado de ECG de un solo latido? Si la ventaja es nula o marginal, se concluirá que la adaptación médica general no transfiere automáticamente al dominio electrocardiográfico, lo cual reforzaría la relevancia de modelos especializados como PULSE.

Las versiones exactas deberán registrarse porque Gemma 4 y MedGemma pertenecen a generaciones base distintas. También deben conservarse la resolución, el presupuesto visual, la plantilla de conversación y la configuración de inferencia. Sin esa información la comparación no sería reproducible. El protocolo del repositorio registra automáticamente estos metadatos en cada ejecución experimental.

3.9 Síntesis comparativa

La tabla 3.1 resume los trabajos más relacionados. Las cifras indican la escala del estudio original y no deben interpretarse como tamaños directamente comparables. Algunas colecciones contienen señales, otras imágenes renderizadas y otras pares multimodales.

Tabla 3.1. Síntesis de trabajos relacionados

Trabajo	Entrada	Escala	Aportación	Relación con este TFG
Ribeiro et al. [11]	Señal de doce derivaciones	Más de dos millones de ECG	Clasificación profunda de seis alteraciones	Referencia supervisada a gran escala
Wagner et al. [12]	Señal de doce derivaciones	21 837 ECG	Conjunto abierto multietiqueta con particiones recomendadas	Ejemplo de recurso real para transferencia futura
Gliner et al. [14]	Señal e imagen	41 830 registros recopilados	Comparación entre entrada digital y visual con artefactos de captura	Evidencia de viabilidad del ECG como imagen
Sangha et al. [15]	Señal e imagen	2 228 236 ECG de entrenamiento	Diagnóstico multietiqueta con validación externa e impresa	Referencia visual supervisada a gran escala
Wu et al. [16]	Imagen de papel	515 registros de validación	Reconstrucción automática de señales desde documentos	Alternativa al análisis directo de imagen
Gliner et al. [17]	Imagen limpia y fotografía	79 226 imágenes etiquetadas y 39 613 imágenes objetivo sin etiqueta	Adaptación adversarial entre formatos	Base para la transferencia sintético real
Gillette et al. [19]	Señal sintética de doce derivaciones	16 900 ECG	Simulación electrofisiológica de ocho grupos	Contraste con el simulador paramétrico simple
Liu et al. [21]	Imagen y texto	Más de un millón de instrucciones	PULSE, ECGInstruct y ECGBench	Referencia especializada para modelos multimodales
Zhang et al. [22]	Señal, imagen, parámetros y texto	Hasta 784 680 registros	Recurso multimodal alineado basado en MIMIC IV ECG	Ruta de ampliación hacia datos clínicos multimodales

3.10 Hueco de investigación

La literatura revisada demuestra que el ECG puede analizarse como señal y como imagen con resultados clínicamente útiles, siempre que se disponga de una cantidad suficiente de datos etiquetados. Cuando la escala de entrenamiento se reduce a millones o cientos de miles de muestras, los modelos supervisados alcanzan un rendimiento competitivo con expertos. Sin embargo, para condiciones de baja prevalencia como el síndrome de Brugada, que puede representar menos del uno por ciento de un archivo clínico, ninguno de los trabajos revisados aborda la situación en la que el presupuesto total de ejemplos etiquetados se limita a unas pocas decenas.

La rama CNN de este TFG documenta precisamente este régimen. Los resultados del capítulo experimental muestran que una red convolucional entrenada con muy pocas muestras alcanza un rendimiento limitado y pierde capacidad diagnóstica de forma severa al transferirse a un dominio real. Este fracaso no es un defecto del diseño, sino la consecuencia esperable de un entrenamiento supervisado sin datos suficientes. La rama CNN sirve, por tanto, como línea base que establece el coste de la especialización cuando los datos son escasos.

Frente a esta limitación, los modelos de visión y lenguaje abren una vía alternativa. En lugar de modificar pesos mediante descenso por gradiente, un VLM recibe los mismos K ejemplos como demostraciones dentro de su ventana de contexto y produce una predicción sin entrenamiento. Esta aproximación posee tres ventajas potenciales en el régimen de pocos datos. Primera, no requiere un ciclo de entrenamiento y, por tanto, elimina el riesgo de sobreajuste a un conjunto diminuto. Segunda, el modelo puede integrar conocimiento morfológico previo adquirido durante su preentrenamiento masivo. Tercera, el coste computacional de la inferencia es predecible y no depende del número de épocas.

Hasta donde sabemos, ningún trabajo publicado ha realizado la comparación directa que propone este TFG: dado un presupuesto fijo de K imágenes de ECG etiquetadas con una condición rara, ¿es más eficaz utilizar esas K muestras para entrenar una CNN desde cero o para construir un contexto de demostraciones en un VLM abierto? Los trabajos de Ribeiro et al. [11] y Sangha et al. [15] estudian el entrenamiento supervisado a gran escala. Los trabajos de Alayrac et al. [23], Chen et al. [24] y Qin et al. [25] estudian el aprendizaje en contexto multimodal sobre tareas naturales. Liu et al. [21] especializan un modelo multimodal con más de un millón de instrucciones. Ninguna de estas líneas responde a la comparación planteada con el mismo presupuesto K sobre imágenes de ECG y, específicamente, sobre una condición rara.

El TFG aborda ese hueco mediante un diseño experimental que impone un presupuesto común de ejemplos a ambas ramas. La CNN utiliza las K muestras para modificar sus pesos. Gemma 4 y MedGemma las utilizan dentro del contexto de inferencia. Los controles de imagen eliminada y etiquetas permutadas permiten comprobar si el modelo multimodal aprovecha genuinamente la correspondencia visual. El simulador proporciona una tarea conocida y auditable antes de introducir la variabilidad del dominio clínico.

La contribución esperada no es una nueva arquitectura ni un nuevo modelo entrenado. Es una caracterización experimental del régimen de uso. La rama CNN, ya cerrada en esta memoria, responde a la primera mitad de la pregunta: qué ocurre cuando se entrena un modelo visual específico con muy pocos ejemplos y se intenta transferirlo a un dominio real. Los resultados muestran que el entrenamiento con datos insuficientes produce modelos frágiles. La rama VLM/ICL deberá completar la segunda mitad: comprobar si el mismo presupuesto K , usado como contexto en lugar de como entrenamiento, mejora la relación entre rendimiento, coste y trazabilidad. Si la rama VLM supera a la CNN en este régimen, se establecerá evidencia de que, para condiciones raras del ECG, el aprendizaje en contexto con un modelo abierto es una alternativa más eficaz que el entrenamiento supervisado tradicional con datos escasos.

CAPÍTULO 4

Diseño experimental

La pregunta central de este TFG es si un modelo de visión y lenguaje (VLM) con aprendizaje en contexto (ICL) puede compensar la escasez de datos etiquetados en la detección de sospecha de patrón Brugada a partir de imágenes de ECG, un escenario en el que el entrenamiento supervisado convencional tropieza. Para responderla, el diseño experimental se organiza en dos brazos complementarios. El primero —una CNN ResNet18 entrenada con presupuestos reducidos— no es el objetivo final, sino el brazo que establece la línea base y proporciona la evidencia empírica de que el enfoque supervisado clásico resulta insuficiente cuando las etiquetas son escasas. El segundo brazo —un VLM abierto que recibe los mismos ejemplos como demostraciones dentro del prompt— constituye la solución propuesta y el eje principal de la comparación.

Desde el punto de vista clínico, el sistema se concibe como herramienta de triaje, no como diagnóstico autónomo. Cualquier predicción positiva del modelo coloca al paciente dentro del circuito clínico de Brugada: una alerta prioriza la revisión experta del ECG, que puede conducir al reposicionamiento de las derivaciones V1/V2, y, en los pacientes seleccionados, a la provocación farmacológica con ajmalina o flecainida. La decisión diagnóstica definitiva recae siempre en el especialista. El modelo actúa, por tanto, como filtro de priorización que reduce el tiempo hasta la evaluación experta, sin sustituir ningún paso del protocolo.

4.1 Pregunta experimental

La pregunta experimental completa puede formularse así: *¿puede un VLM con ICL, aprovechando su conocimiento multimodal preexistente, alcanzar un rendimiento diagnóstico útil con los mismos pocos ejemplos con los que una CNN supervisada fracasa?*

Esta formulación asigna a cada brazo un papel claro:

1. **Brazo CNN (línea base).** La CNN se entrena con presupuestos progresivos ($K = 2, \dots, 32$) primero sobre datos sintéticos, después sobre datos clínicos reales y, finalmente, con técnicas de adaptación de dominio. Su función es *demostrar* que el aprendizaje supervisado con pocos datos —incluso reforzado con preentrenamiento, aumento de datos y alineación de dominios— no alcanza un rendimiento suficiente en el esce-

nario real. El resultado negativo o insuficiente de este brazo no es un fracaso del TFG: es la evidencia que justifica la transición hacia el paradigma VLM/ICL.

2. **Brazo VLM/ICL (solución propuesta).** El VLM recibe las mismas imágenes y los mismos presupuestos K , pero los ejemplos se introducen como demostraciones en contexto dentro del prompt, sin modificar los pesos del modelo. La hipótesis es que el conocimiento visual y lingüístico adquirido durante el preentrenamiento a gran escala puede compensar la falta de datos supervisados específicos y ofrecer un rendimiento clínicamente útil donde la CNN no lo consigue.

La comparación entre ambos brazos se realiza sobre las mismas particiones de pacientes, los mismos valores de K y la misma métrica principal —exactitud equilibrada— para garantizar que la diferencia observada procede exclusivamente del paradigma de aprendizaje y no de cambios en el protocolo de evaluación.

4.2 Canalización experimental

La figura 4.1 resume la canalización completa. Las imágenes sintéticas y reales se convierten al mismo formato visual de entrada. La ruta CNN entrena modelos con presupuestos reducidos, evalúa por paciente, agrega predicciones por derivación y produce tablas, curvas, matrices de confusión y mapas Grad-CAM. La ruta VLM reutiliza las mismas imágenes y los mismos presupuestos K , pero introduce los ejemplos como demostraciones dentro del prompt y obtiene la predicción sin ajuste de pesos. Ambas rutas desembocan en el mismo módulo de evaluación, lo que permite una comparación directa y justa.




Figura 4.1. Canalización experimental: la CNN establece la línea base supervisada y el VLM/ICL constituye el comparador central propuesto.

4.3 Orientación clínica: triaje, no diagnóstico

El modelo no emite un diagnóstico de síndrome de Brugada, sino una señal de sospecha que prioriza la revisión clínica. En la práctica asistencial, una predicción positiva activa el siguiente circuito:

1. **Revisión experta del ECG.** El cardiólogo examina el trazado completo para valorar la morfología del segmento ST en las derivaciones precordiales derechas.
2. **Reposicionamiento de derivaciones.** Cuando la sospecha se mantiene, se repite el registro con V1 y V2 colocadas en posiciones superiores (segundo o tercer espacio intercostal), maniobra que aumenta la sensibilidad para detectar el patrón tipo 1.
3. **Provocación farmacológica.** En los pacientes seleccionados por el clínico, se administra ajmalina o flecainida bajo monitorización para desenmascarar un patrón de Brugada tipo 1 oculto.
4. **Decisión clínica.** El diagnóstico definitivo y las decisiones terapéuticas —seguimiento, estudio genético, implantación de desfibrilador— corresponden al equipo médico, nunca al modelo.

Este encuadre tiene implicaciones directas sobre las métricas. Dado que el modelo es un filtro de priorización, un falso negativo (paciente con Brugada no alertado) tiene mayor coste que un falso positivo (control enviado a revisión). Sin embargo, un exceso de falsos positivos sobrecarga el circuito clínico y reduce la confianza de los usuarios. La exactitud equilibrada captura ambos aspectos al ponderar sensibilidad y especificidad por igual, y se complementa con la inspección de la curva ROC para evaluar el compromiso operativo.

4.4 Unidades de análisis

La unidad de separación es siempre el paciente. En el conjunto sintético, cada paciente simulado contiene tres imágenes correspondientes a V1, V2 y V3. En Brugada HUCA, cada paciente clínico aporta las ventanas renderizadas de esas derivaciones precordiales derechas. El modelo produce una probabilidad por imagen y la decisión de paciente se obtiene promediando las probabilidades de sus derivaciones antes de aplicar el umbral.


Tabla 4.1. Conjuntos utilizados en los experimentos cerrados.

Conjunto	Pacientes	Imágenes	Positivos	Negativos	Tarea
Sintético QRS/ST	100	300	20	80	Detección derivada de patrón Brugada operativo: RBBB, elevación ST e inversión T presentes
Brugada HUCA	317	951	116	201	Caso Brugada confirmado frente a control, excluyendo categorías limítrofes o no equivalentes

La diferencia entre ambas tareas es deliberada y debe conservarse al interpretar los resultados. En el simulador se evalúa composición morfológica derivada de reglas. En HUCA se evalúa una etiqueta clínica binaria disponible en los metadatos. Por tanto, el salto sintético-real no mide únicamente cambio de renderizado, sino también un cambio de definición de etiqueta.

4.5 Presupuestos de pocos ejemplos

Los presupuestos de entrenamiento son $K = \{2, 4, 8, 16, 32\}$. Para cada K positivo se ejecutan tres semillas: 42, 123 y 2026. La selección de ejemplos se realiza dentro de cada pliegue, sin utilizar el paciente reservado para test. El objetivo no es maximizar rendimiento con todos los datos, sino medir cómo evoluciona cada estrategia —supervisada y en contexto— cuando las etiquetas son escasas.



LOOCV por paciente, tres semillas por K positivo y agregación por probabilidad media de $V1/V2/V3$.

Figura 4.2. Validación leave-one-out por paciente y selección de presupuestos K .

En cada ejecución se conserva el identificador de pliegue, la semilla, los pacientes usados como ejemplos, las predicciones por imagen y las métricas agregadas. El informe de auditoría final verifica 1500 predicciones de paciente en el simulador y 4755 predicciones de

paciente en HUCA para la CNN base.

4.6 Modelo CNN evaluado

El modelo supervisado es ResNet18 con pesos iniciales de ImageNet y una cabeza binaria. Aunque el simulador original contiene tres hallazgos morfológicos, la campaña cerrada utiliza una etiqueta derivada de patrón Brugada operativo: positiva cuando las condiciones necesarias están simultáneamente presentes y negativa cuando el paciente simulado es normal o incompleto. Esta reducción facilita la comparación con HUCA, donde la etiqueta disponible es binaria.

El entrenamiento utiliza `BCEWithLogitsLoss`, ponderación automática de la clase positiva cuando procede, AdamW y selección interna de umbral sobre el subconjunto de validación del pliegue. La métrica principal es la exactitud equilibrada porque la prevalencia positiva es desigual y porque interesa medir sensibilidad y especificidad de forma simétrica.

La función de este brazo dentro del diseño es doble: por un lado, establece la referencia numérica contra la que se comparará el VLM; por otro, permite cuantificar el grado de deterioro que introduce la escasez de datos en un enfoque supervisado estándar.

4.7 Adaptación de dominio


La rama de adaptación de dominio se ejecuta como extensión del brazo CNN. Su propósito es agotar las opciones de mejora dentro del paradigma supervisado antes de declarar su insuficiencia. Los métodos evaluados son:

- **SSL**: preentrenamiento autosupervisado sobre imágenes sin etiqueta antes del ajuste supervisado.
- **CORAL**: penalización para acercar covarianzas de características entre origen sintético y destino real.
- **MMD**: penalización de discrepancia entre distribuciones de características de ambos dominios.
- **DANN**: aprendizaje adversario con inversión de gradiente para reducir información específica del dominio [30].

Estas variantes se evalúan en $K = 16$ y $K = 32$, los presupuestos con mayor interés tras observar la curva del modelo base. La comparación se realiza contra la CNN HUCA sin adaptación en los mismos valores de K . Si ninguna de estas variantes recupera un rendimiento suficiente, el hallazgo refuerza la necesidad de abandonar la familia supervisada y probar un

paradigma fundamentalmente distinto —el VLM con ICL—, en lugar de seguir añadiendo regularización a la CNN.

Adaptacion de dominio sin etiquetas QRS/ST reales



La adaptacion usa el dominio real como distribucion visual, no como fuente de etiquetas morfologicas. Por eso sigue siendo un experimento de transferencia y triaje, no una prueba diagnostica autonoma.

Figura 4.3. Métodos de adaptación de dominio revisados y ejecutados sobre la rama experimental.

4.8 Métricas

Se reportan exactitud, exactitud equilibrada, F1, precisión, sensibilidad, especificidad, área ROC y precisión media. Las tablas principales muestran la media y la desviación estándar sobre tres semillas. Además, para cada configuración se guardan matrices de confusión agregadas, curvas ROC/PR y predicciones por paciente.

La exactitud equilibrada se define como:

$$BA = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right).$$

Esta métrica es especialmente importante en el contexto de triaje: un modelo puede obtener sensibilidad moderada a costa de marcar demasiados controles como positivos. En una herramienta de priorización, ese comportamiento solo es tolerable si se declara como alerta preliminar y se acompaña del circuito de revisión clínica descrito anteriormente. En la comparación con VLM/ICL se emplea el mismo criterio principal para garantizar que el cambio de paradigma de aprendizaje no implique un cambio en la regla de evaluación.

4.9 Estado de cierre

La tabla 4.2 resume la matriz de evidencias del documento. El brazo CNN y la adaptación de dominio aportan valores numéricos completos. El brazo VLM/ICL aporta especificación completa de modelos, prompts, controles, contrato JSON y tablas de salida; sus celdas numéricas se reservan para la ejecución de inferencias. Así, la memoria no trata VLM como

una nota lateral, sino como el segundo brazo de la comparación.

Tabla 4.2. Estado de los bloques experimentales al cierre de la memoria.

Bloque	Estado	Evidencia disponible
Simulador QRS/ST	Completo	Datos, pliegues LOOCV, entrenamiento CNN, tablas, curvas, matriz de confusión y Grad-CAM
Brugada HUCA	Completo	Datos procesados, pliegues por paciente, entrenamiento CNN, comparación sintético-real y Grad-CAM
Adaptación de dominio	Completo	SSL, CORAL, MMD y DANN ejecutados para $K = 16$ y $K = 32$, con comparación agregada
VLM e ICL (brazo principal)	Especificado	Modelos, mensajes, controles, contrato JSON, agregación por paciente y tablas de resultados definidos; valores numéricos marcados como <i>por ejecutar</i> en el capítulo 9
Auditoría final	Completa para CNN	<code>final_cnn_package_ready</code> : OK; esquema de auditoría VLM definido para ejecución conjunta

Esta separación evita inventar valores y, al mismo tiempo, mantiene completo el diseño comparativo. Las conclusiones numéricas actuales proceden de la CNN y de la adaptación de dominio; el capítulo 9 fija la estructura exacta con la que se incorporarán Gemma 4 y MedGemma para determinar si el aprendizaje en contexto ofrece una alternativa viable donde el entrenamiento supervisado con pocos datos ha demostrado ser insuficiente.

CAPÍTULO 5

Simulador y conjunto de datos sintético

5.1 Objetivo del dominio sintético

La disponibilidad de datos sintéticos permite estudiar una pregunta metodológica sin esperar a reunir una cohorte clínica extensa. En este trabajo el simulador actúa como un laboratorio controlado. Cada beat se construye a partir de componentes interpretables, se valida mediante reglas explícitas y se transforma en una imagen que puede entregarse tanto a una CNN como a un modelo de visión y lenguaje.

El objetivo no es reproducir toda la fisiología cardíaca. Un simulador clínicamente exhaustivo tendría que modelar varias derivaciones, cambios de frecuencia, interacción entre ciclos, conducción auricular y ventricular, ruido de adquisición, variación anatómica y efectos del dispositivo. El sistema implementado reduce el problema a un único beat de apariencia precordial derecha. Esta simplificación permite controlar tres hallazgos visuales que intervienen en la motivación del proyecto.

El uso de datos sintéticos cumple cuatro funciones:

1. Generar etiquetas sin depender de anotación manual para cada imagen.
2. Separar la forma de una onda de factores externos como fabricante, hospital o estilo de documento.
3. Construir presupuestos de ejemplos con tamaños exactos y semillas conocidas.
4. Reservar una familia generadora compuesta para estudiar transferencia.

La contrapartida es una brecha inevitable entre el dominio sintético y el real. El simulador puede demostrar que una tarea controlada es aprendible. No puede demostrar que el mismo rendimiento se mantenga en un ECG clínico. Esa distinción se conserva en toda la memoria.

5.2 Representación matemática

Cada beat se define como una suma de diez átomos gaussianos. Para el átomo i , la amplitud a_i , el centro temporal μ_i y la anchura σ_i determinan la función

$$g_i(t) = a_i \exp \left(-\frac{(t - \mu_i)^2}{2\sigma_i^2} \right). \quad (5.1)$$

La señal completa es

$$x(t) = \sum_{i=1}^{10} g_i(t). \quad (5.2)$$

El signo de a_i controla la dirección de la deflexión. El valor absoluto de a_i controla su magnitud. El parámetro μ_i desplaza el componente sobre el eje temporal y σ_i modifica su extensión. La suma permite formar transiciones suaves sin introducir discontinuidades.

La elección de gaussianas se inspira en modelos sintéticos previos que representan ondas electrocardiográficas mediante componentes paramétricos [18]. El presente simulador es más sencillo que un modelo dinámico electrofisiológico. Su ventaja es la capacidad de relacionar cada modificación con una región visual concreta.

Tabla 5.1. Átomos utilizados para construir un beat

Átomo	Región principal	Función dentro del generador
P	Onda P	Añade una deflexión auricular positiva anterior al QRS
Q	Inicio del QRS	Permite una pequeña deflexión negativa, aunque la configuración actual la mantiene anulada
R	QRS inicial	Produce el primer máximo positivo ventricular
S	QRS central	Forma la deflexión negativa posterior a R
R_prime	QRS terminal	Introduce un segundo máximo positivo y permite una forma RSR prima
J_elev	Punto J	Controla la transición entre el final del QRS y el segmento ST
ST1	ST inicial	Modela elevación temprana y la parte descendente de una forma cóncava
ST2	ST tardío	Controla la continuidad hacia la onda T
T1	Onda T principal	Define la polaridad y la magnitud principal de la repolarización
T2	Cola de la onda T	Suaviza y prolonga la repolarización




Figura 5.1. Construcción de un beat mediante átomos gaussianos y suma resultante.

5.3 Muestreo temporal

La configuración final utiliza una frecuencia de 500 Hz y una duración de 900 ms. El número de muestras se calcula como

$$N = \text{round} \left(\frac{D}{1000} f_s \right), \quad (5.3)$$

donde D es la duración en milisegundos y f_s la frecuencia de muestreo. Con los valores finales se obtienen 450 muestras. El vector temporal es

$$t_n = \frac{1000n}{f_s}, \quad n \in \{0, \dots, N - 1\}. \quad (5.4)$$

Los rangos de la repolarización se definieron sobre una duración de referencia de 900 ms. Cuando cambia la duración del beat, los centros posteriores a 390 ms se adaptan mediante

$$\mu_i^{(D)} = 390 + \left(\mu_i^{(900)} - 390 \right) \frac{D - 390}{900 - 390}. \quad (5.5)$$

Las anchuras de los componentes tardíos se escalan por el mismo factor, con un mínimo que impide gaussianas degeneradas. Los componentes anteriores al punto de pivote no se desplazan. De este modo el QRS conserva su posición mientras que ST y T se comprimen o expanden para ocupar la duración disponible.

5.4 Rangos de parámetros

La generación comienza con un andamiaje compartido. Cada átomo dispone de intervalos para a , μ y σ . Después se aplican sustituciones específicas de la familia. El muestreo dentro de cada intervalo es uniforme. La distribución final no es uniforme porque las reglas morfológicas y los validadores rechazan parte de las propuestas.

Los rangos no deben interpretarse como límites clínicos. Son parámetros de un generador visual. Por ejemplo, el átomo R_{prime} tiene amplitud casi nula en la familia normal y puede alcanzar valores mayores en RBBB. Los átomos J_{elev} , ST1 y ST2 permanecen cerca de cero en una señal normal y se desplazan hacia amplitudes positivas en la familia de elevación del ST.

Separar rangos y validadores responde a dos responsabilidades distintas. Los rangos hacen probable una morfología. Los validadores determinan si la señal terminada satisface la definición operativa. Si ambos elementos se mezclaran, cualquier cambio visual podría alterar de manera silenciosa el significado de las etiquetas.

5.5 Familias generadoras

El simulador contiene cinco familias de origen. Una familia selecciona rangos de muestreo y reglas de coherencia, pero no determina directamente el vector objetivo.

5.5.1 Familia normal

La familia NORMAL reduce la amplitud de R prima, mantiene la región J y ST próxima a la línea base y fuerza ondas T positivas. También exige que la señal no satisfaga ninguno de los tres validadores de hallazgos. Esta exclusión explícita es necesaria porque una señal generada con rangos normales podría producir por azar una combinación que superase un umbral patológico.

5.5.2 Morfología RBBB

La familia RBBB favorece una segunda deflexión positiva posterior a S. La posición de R prima se obliga a aparecer al menos 24 ms después del centro de S. Su amplitud no puede quedar por debajo del 80 por ciento de la amplitud de R dentro de los límites permitidos. También se amplía su anchura respecto a la primera R.

El resultado busca una forma RSR prima visible. No reproduce todos los criterios clínicos de bloqueo completo de rama derecha, que dependen de la duración global del QRS y de la distribución entre derivaciones [3]. Por ello la etiqueta se denomina morfología compatible en el texto interpretativo.

5.5.3 Elevación de ST

La familia ST_ELEVATION utiliza amplitudes positivas en el punto J y en los dos componentes del ST. La primera sección del ST se ensancha para evitar un pico estrecho que pudiera confundirse con una deflexión del QRS. El validador exige además actividad ventricular positiva y negativa suficiente, con el fin de descartar señales planas elevadas.

5.5.4 Inversión de T

La familia T_WAVE_INVERSION hace negativas las dos componentes de T y las separa de la región ST. También puede producir una R prima moderada y una elevación pequeña de J. Esta elección permite coocurrencias con RBBB y ST. El validador exige que la deflexión negativa sea tardía, suficientemente profunda y mantenida.

5.5.5 Familia Brugada

La familia BRUGADA implementa únicamente una forma coved o tipo 1 esquemática. Combina elevación de J, ST inicial positivo, descenso posterior e inversión de T. La amplitud de R prima es menor que en la familia RBBB pura, pero puede mantener una alteración terminal del QRS.

El nombre de la familia no se incorpora al vector objetivo. Una señal aceptada por el validador interno de Brugada se vuelve a evaluar mediante los validadores independientes de RBBB, elevación de ST e inversión de T. Por tanto puede recibir una combinación parcial de hallazgos. Esta decisión convierte la familia en una prueba de composición y evita utilizar una etiqueta clínica que el simulador no puede justificar.

Tabla 5.2. Relación entre familias generadoras y rasgos favorecidos

Familia	Modificación dominante	Interpretación experimental
NORMAL	ST próximo a cero, T positiva y R prima mínima	Referencia sin hallazgos operativos
RBBB	Segundo máximo positivo tardío y ancho	Componente terminal del QRS
ST elevado	Punto J y ST positivos	Componente de elevación posterior al QRS
Inversión de T	Repolarización tardía negativa	Componente de inversión de T
BRUGADA	J elevado, ST descendente y T negativa	Familia compuesta reservable para transferencia

5.6 Reglas de coherencia morfológica

El muestreo independiente de los átomos puede producir órdenes temporales incoherentes. Para reducir este problema se aplican reglas deterministas antes de sumar las gaussianas. Q debe preceder a R. S debe aparecer después de R y ser más ancha. J se sitúa después de S. Los dos componentes del ST se ordenan tras J. T1 y T2 ocupan la región final.

Estas reglas no garantizan fisiología. Garantizan una geometría mínima para que ca-

da parámetro conserve una interpretación. Las reglas específicas de una familia refuerzan relaciones adicionales, como la posición tardía de R prima o el signo negativo de T.

Modificar una regla puede tener efectos indirectos. Mover T1 cambia el resultado del validador de inversión y también puede alterar la media tardía del ST. Por eso cada cambio debe acompañarse de una nueva generación de ejemplos, un análisis de frecuencias y una comprobación de aceptación.

5.7 Muestreo con rechazo

El procedimiento de generación utiliza muestreo con rechazo. Para una familia c , el algoritmo sigue los siguientes pasos:

1. Combinar los rangos base con los rangos específicos de c .
2. Adaptar los componentes tardíos a la duración solicitada.
3. Muestrear los parámetros de los diez átomos.
4. Aplicar las reglas de orden y coherencia.
5. Sumar los átomos sobre el vector temporal.
6. Evaluar el validador correspondiente a c .
7. Aceptar la señal si supera las reglas o volver al paso de muestreo.

El límite por defecto es de 400 intentos. Si no se obtiene una señal válida, el generador lanza un error e incluye las últimas métricas calculadas. El número de intento se almacena en los metadatos de cada muestra. Esta variable permite detectar rangos mal alineados con los validadores.

Sea q_c la probabilidad de aceptación de una propuesta de la familia c . El número esperado de intentos antes de una aceptación es aproximadamente

$$\mathbb{E}[A_c] = \frac{1}{q_c}. \quad (5.6)$$

Una familia que requiere muchos intentos puede seguir generando imágenes correctas, pero revela que gran parte de su espacio paramétrico no satisface la definición operativa. Las tasas de aceptación deben registrarse cuando se cierre la versión final del simulador.

5.8 Validadores y semántica de las etiquetas

Los validadores operan sobre ventanas temporales de la señal terminada. Las ventanas posteriores a 390 ms se adaptan mediante la ecuación 5.5. Las amplitudes se expresan en mV y las duraciones en ms.

Tabla 5.3. Criterios operativos de los validadores sintéticos

Validador	Condiciones necesarias
RBBB	Dos máximos positivos entre 240 y 470 ms, separación mínima de 28 ms, primer máximo superior a 0,12 mV, segundo máximo superior a 0,20 mV, mínimo intermedio inferior a $-0,05$ mV, segundo máximo posterior a 345 ms y anchura terminal superior a 38 ms por encima de 0,10 mV
Elevación de ST	Máximo del QRS superior a 0,28 mV, mínimo del QRS inferior a $-0,14$ mV, media de J superior a 0,09 mV y media del ST superior a 0,09 mV
Inversión de T	Máximo del QRS superior a 0,22 mV, máximo de R prima superior a 0,08 mV, media del ST superior a $-0,03$ mV, mínimo de T inferior a $-0,12$ mV, mínimo posterior al umbral temporal equivalente a 640 ms y más de 45 ms por debajo de $-0,05$ mV
Normal	Máximo del QRS superior a 0,22 mV, mínimo inferior a $-0,10$ mV, media de ST entre $-0,04$ y 0,05 mV, máximo de T superior a 0,12 mV, R prima inferior a 0,10 mV y rechazo de los tres hallazgos
Brugada	Máximo del QRS superior a 0,18 mV, mínimo inferior a $-0,16$ mV, media de J superior a 0,09 mV, media de ST superior a 0,08 mV, ST temprano al menos 0,03 mV por encima del ST tardío y mínimo de T inferior a $-0,08$ mV

Los umbrales se diseñaron para separar morfologías del simulador. No deben trasladarse a un ECG real ni compararse de forma directa con criterios clínicos. Un ECG real requiere calibración, derivaciones identificadas, velocidad de papel conocida y valoración del contexto. Los estándares clínicos revisados en el capítulo 2 se utilizan para orientar la forma general, no para validar pacientes.

Las tres etiquetas finales se calculan de forma independiente. Para una señal aceptada, se ejecutan los validadores de RBBB, ST y TWI y se construye un vector binario. Este paso puede producir coocurrencias que no coinciden con la familia. La etiqueta final es una propiedad de la señal, no una copia del mecanismo que la generó.

5.9 Renderizado de las señales

Cada beat se representa sobre un lienzo cuadrado. La configuración final guarda imágenes de 896 por 896 píxeles a 130 puntos por pulgada. El eje horizontal utiliza una cuadrícula menor cada 40 ms y una cuadrícula mayor cada 200 ms. El eje vertical utiliza divisiones menores de 0,1 mV y mayores de 0,5 mV. La señal se dibuja en negro con un grosor de dos puntos y la cuadrícula en rosa con dos intensidades.

El renderizado conserva títulos de ejes y valores numéricos. Estos elementos aportan información de escala, pero también pueden transformarse en atajos si los límites cambian entre muestras. Por ese motivo, los límites horizontal y vertical se fijan para todas las imágenes.

nes de la campaña final. La inspección visual verifica que ninguna familia posee un encuadre, margen o patrón de marcas propio.

No se aplicarán reflejos horizontales. Invertir el eje temporal cambiaría el orden fisiológico de las ondas. Tampoco se aplicarán reflejos verticales, ya que intercambiarían elevación y depresión. Las transformaciones visuales admisibles deben conservar la semántica, como pequeñas variaciones de grosor, contraste, desplazamiento y escala dentro de límites conocidos.

Ejemplos sintéticos por familia generadora




Figura 5.2. Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador.

5.10 Construcción del conjunto de datos

El constructor crea primero un ejemplo de verificación por familia. Después genera el número solicitado de beats y asigna una semilla independiente a cada muestra. Finalmente crea las particiones y guarda las imágenes.

Cada fila del manifiesto contiene:

- ruta relativa de la imagen
- nombre de la partición

- familia generadora
- semilla de la muestra
- número de intento de aceptación
- subtipo cuando corresponde
- índice interno
- tres columnas binarias de etiquetas

Además se genera un esquema de etiquetas y un resumen con frecuencias por partición, familia, etiqueta y combinación. Los manifiestos CSV permiten entrenar modelos visuales sin depender de la estructura de carpetas. Los ficheros JSON conservan información para auditoría y generación de informes.

Tabla 5.4. Configuración final del conjunto sintético QRS/ST

Elemento	Total	Organización	Finalidad
Pacientes simulados	100	20 por familia fuente	Construir una cohorte equilibrada por mecanismo generador
Imágenes	300	Copia del beat central en V1, V2 y V3	Evaluar el mismo contrato visual que en HUCA
Pliegues LOOCV	100	Un paciente reservado por pliegue	Medir rendimiento agregado por paciente
Presupuestos K	5	2, 4, 8, 16 y 32 ejemplos	Estudiar aprendizaje supervisado con pocos datos

5.11 Comprobación de integración

La configuración final se ejecutó para generar 100 pacientes sintéticos, 300 imágenes, pliegues LOOCV y resúmenes de etiquetas. El conjunto contiene 20 pacientes con los tres hallazgos presentes y 80 pacientes normales o incompletos. Las combinaciones observadas incluyen NORMAL, RBBB, RBBB+ST, RBBB+ST+TWI, RBBB+TWI y TWI.

Esta comprobación no se limita a una prueba de humo: es el conjunto utilizado en la campaña CNN sintética. Su función es demostrar que la ruta de generación, aceptación, partición y escritura es operativa y que el conjunto final conserva variabilidad suficiente para estudiar la curva por K .

La inspección visual mostró que las familias pueden compartir etiquetas. Una muestra de elevación del ST puede satisfacer además el validador RBBB. Una muestra generada como inversión de T puede presentar una segunda deflexión positiva terminal. Este comportamiento confirma que el problema no es una clasificación encubierta de cinco carpetas.

5.12 Control de calidad del simulador

La validación del conjunto sintético se organiza en cuatro niveles.

5.12.1 Nivel estructural

Se comprueba que cada señal tiene 450 muestras, que sus valores son finitos y que las imágenes tienen dimensiones constantes. Los manifiestos deben contener todas las rutas y no puede haber duplicados entre pliegues de evaluación.

5.12.2 Nivel semántico

Se recalculan las etiquetas directamente desde la señal cuando esta se conserva. Los valores de los validadores se comparan con las columnas del manifiesto. La familia normal debe tener el vector vacío. La familia Brugada debe superar su regla interna aunque su vector final pueda contener una combinación parcial.

5.12.3 Nivel distribucional

Se analizan las frecuencias de cada etiqueta y de cada combinación. Un balance perfecto por familia no implica balance por etiqueta. Si una combinación domina el conjunto, la macro F_1 puede ocultar que el modelo utiliza coocurrencias. Se revisarán matrices entre familia y etiqueta, distribuciones de intentos y rangos de amplitud.

5.12.4 Nivel visual

Se generan paneles sin intervención del modelo. La revisión busca ondas truncadas, escalas diferentes, textos que revelen la clase, cuadrículas inconsistentes, trazos fuera del lienzo y formas que no se correspondan con sus métricas. Una muestra que pasa reglas numéricas pero resulta visualmente inverosímil debe motivar una revisión del generador.




Figura 5.3. Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV.

5.13 Riesgos de atajos visuales

Un modelo puede obtener resultados altos sin aprender la morfología pretendida. Entre los atajos posibles se encuentran límites automáticos del eje, diferencias de antialiasing, márgenes asociados a la amplitud, densidad de cuadrícula, nombres de fichero y estructura de carpetas.

Para reducir estos riesgos, las imágenes se cargarán desde el manifiesto y la familia no se entregará al modelo. Los límites visuales serán constantes. Los nombres de fichero solo contendrán un contador. La evaluación incluirá recortes de la zona de trazado y versiones sin texto de ejes como análisis de sensibilidad. Si el rendimiento cae de forma drástica al retirar elementos no fisiológicos, se investigará el origen antes de interpretar los resultados.

También se comprobará la atención espacial de las CNN mediante Grad CAM [29]. La finalidad no es demostrar causalidad, sino detectar si las regiones activas se concentran en QRS, ST y T o en elementos periféricos.

5.14 Limitaciones del simulador

El simulador representa un beat aislado y una geometría semejante a una derivación precordial. No modela doce derivaciones ni una transformación eléctrica común entre ellas. No incluye variabilidad entre beats, arritmias, intervalos dependientes de frecuencia, ruido muscular, deriva de línea base, interferencia de red, pérdida de electrodos ni compresión de documentos.

La forma de cada onda se construye con gaussianas. Esta elección produce curvas suaves y puede simplificar bordes que en un ECG real son más irregulares. Los validadores se basan en ventanas y umbrales creados para este dominio. Una señal clínica no debe procesarse con ellos como si fueran reglas diagnósticas.

La familia Brugada es una aproximación a una morfología coved. No representa la heterogeneidad del síndrome, la variación entre derivaciones ni la posibilidad de patrones intermitentes. Su uso se limita a estudiar composición visual de los tres hallazgos.

Estas limitaciones no invalidan el laboratorio sintético. Delimitan qué afirmaciones puede sostener. El dominio permite comparar eficiencia de ejemplos bajo condiciones controladas. La validez clínica dependerá de la evaluación externa descrita en el capítulo de datos reales.

CAPÍTULO 6

Modelos

Este capítulo describe las dos familias de modelos que articulan la comparación metodológica del TFG. Por un lado, una CNN supervisada constituye la línea base convencional: un modelo que requiere entrenamiento explícito y cuyos resultados ponen de manifiesto las limitaciones del aprendizaje con pocas muestras. Por otro lado, los modelos de visión y lenguaje (VLM) representan la propuesta central de este trabajo: una vía alternativa para explotar los mismos pocos ejemplos etiquetados sin modificar ningún peso, aprovechando conocimiento visual y lingüístico adquirido durante el preentrenamiento a gran escala. La comparación entre ambas familias no es una competición abstracta, sino una evaluación de regímenes: cuándo conviene entrenar y cuándo conviene usar demostraciones en contexto.

6.1 Entrada común

Todos los modelos trabajan con imágenes de ECG. En la CNN, cada imagen corresponde a una derivación precordial derecha renderizada y redimensionada a 224 por 224 píxeles. En la línea VLM, la misma imagen se incluye en un mensaje multimodal junto con instrucciones textuales y, cuando se emplea aprendizaje en contexto, ejemplos demostrativos. La comparación solo tiene sentido porque ambos enfoques reciben la misma evidencia visual y se evalúan por paciente con las mismas métricas.




Figura 6.1. Recorridos de entrada y evaluación: la CNN actualiza pesos con los K ejemplos etiquetados; el VLM los recibe como demostraciones en el prompt sin modificar parámetros.

6.2 Dos formas de usar K

El presupuesto K —el número de pacientes etiquetados de los que se dispone— es el eje central de todo el TFG. Sin embargo, su significado operativo cambia radicalmente según la familia de modelos que lo consume. Comprender esta diferencia es imprescindible para interpretar cualquier resultado posterior.

6.2.1 CNN: K como conjunto de entrenamiento

En un modelo supervisado como la CNN, los K pacientes etiquetados se utilizan para calcular una pérdida y propagar gradientes que actualizan los pesos de la red. El aprendizaje ocurre durante el entrenamiento: tras las épocas de ajuste, los pesos quedan fijados y la inferencia posterior se limita a aplicar la función aprendida a nuevas imágenes. El coste computacional del aprendizaje se concentra en la fase de entrenamiento; cada nueva predicción es rápida y barata.

Cuando K es pequeño, este mecanismo presenta limitaciones conocidas:

- **Alta varianza.** Con pocos ejemplos, la selección concreta de los K pacientes influye de forma desproporcionada en el modelo resultante. Cambiar un solo paciente del conjunto de entrenamiento puede producir un clasificador sustancialmente diferente.
- **Sobreajuste.** La red tiene millones de parámetros y solo unas decenas o centenas de imágenes para ajustarlos. Sin una regularización cuidadosa, los pesos memorizan los ejemplos de entrenamiento en lugar de capturar la estructura general de la tarea.

- **Atajos visuales.** El modelo puede aprender a distinguir artefactos de adquisición, diferencias de calibración o formato del trazado en lugar de patrones morfológicos clínicamente relevantes. Este problema es especialmente grave cuando el entrenamiento se realiza con datos sintéticos y la evaluación con datos clínicos.

6.2.2 VLM: K como demostraciones en contexto

En un VLM con aprendizaje en contexto (*in-context learning*, ICL), los K pacientes etiquetados no se utilizan para modificar pesos. En su lugar, se insertan como demostraciones dentro del prompt que recibe el modelo: cada demostración consiste en una imagen de ECG y la etiqueta correcta asociada. Los pesos del modelo permanecen completamente fijos durante todo el proceso. El “aprendizaje” ocurre de forma implícita: el modelo usa las demostraciones para inferir el formato de la tarea, la correspondencia entre patrones visuales y etiquetas, y la distribución esperada de la respuesta.

Este mecanismo presenta ventajas complementarias a las limitaciones de la CNN:

- **Sin sobreajuste a los ejemplos.** Al no actualizar parámetros, no existe riesgo de memorizar los K ejemplos. El rendimiento depende de la capacidad del modelo preentrenado para generalizar a partir de la estructura del prompt.
- **Conocimiento visual previo.** Un VLM preentrenado a gran escala ha observado millones de imágenes y textos durante su formación. Este conocimiento previo puede compensar la escasez de datos específicos del dominio, siempre que el dominio no sea completamente ajeno a la distribución de preentrenamiento.
- **Flexibilidad de K .** Aumentar o reducir K solo requiere modificar el prompt, sin reen entrenar ni desplegar un nuevo modelo. Esto permite explorar el efecto de K de forma inmediata.

Sin embargo, el ICL introduce sus propios riesgos:

- **Dependencia del prompt.** El orden de las demostraciones, la redacción de las instrucciones y el formato de la respuesta solicitada pueden influir en la predicción tanto o más que el contenido visual.
- **Ignorancia de la imagen.** El modelo puede basar su respuesta en patrones textuales, en la frecuencia relativa de etiquetas dentro del prompt o en sesgos de su preentrenamiento, sin analizar realmente la morfología del ECG.
- **Respuestas inválidas.** A diferencia de una CNN, cuya salida es siempre un logit numérico, un VLM puede generar texto libre que no se ajuste al formato esperado, produciendo predicciones no utilizables.

6.2.3 Síntesis: la misma evidencia, mecanismos opuestos

La tabla 6.1 resume las diferencias operativas. Ambos métodos reciben exactamente los mismos K pacientes etiquetados y se evalúan sobre el mismo conjunto de test. Lo que difiere es el mecanismo por el cual esos ejemplos se traducen en una predicción. Esta diferencia es la motivación de todo el estudio comparativo.

Tabla 6.1. Uso del presupuesto K según la familia de modelos.

Dimensión	CNN supervisada	VLM con ICL
Papel de K	Conjunto de entrenamiento	Demostraciones en el prompt
Actualización de pesos	Sí (gradiente)	No
Dónde ocurre el aprendizaje	Durante el entrenamiento	Durante la generación
Coste por cambio de K	Reentrenamiento completo	Edición del prompt
Riesgo con K pequeño	Sobreajuste, alta varianza	Prompt ruidoso, sesgo textual
Escalabilidad de K	Sin límite práctico	Limitada por ventana de contexto

La pregunta central no es cuál de los dos mecanismos es “mejor” en abstracto, sino a partir de qué K el entrenamiento supervisado se vuelve viable y fiable, y por debajo de qué K el aprendizaje en contexto ofrece una señal útil que el entrenamiento no puede igualar.

6.3 CNN ResNet18

El modelo supervisado ejecutado es una ResNet18 de `torchvision` con pesos iniciales `DEFAULT`. La cabeza de clasificación se sustituye por una salida binaria. En los experimentos sintéticos, la etiqueta positiva indica que el paciente simulado cumple simultáneamente los hallazgos operativos asociados al patrón Brugada derivado. En HUCA, la etiqueta positiva indica caso Brugada confirmado frente a control.

La pérdida es `BCEWithLogitsLoss`. Cuando el pliegue lo requiere, la clase positiva se pondera automáticamente a partir de los ejemplos de entrenamiento. El optimizador es AdamW, con tasa de aprendizaje 3×10^{-4} , lote de 32 imágenes y 20 épocas máximas. La selección de umbral se realiza en validación interna mediante exactitud equilibrada derivada por paciente; si no hay validación suficiente, se conserva el umbral 0,5.

Tabla 6.2. Configuración CNN utilizada en las campañas finales.

Propiedad	Valor
Arquitectura	ResNet18 con cabeza binaria
Inicialización	Pesos DEFAULT de Torchvision para ResNet18
Entrada	RGB, 224 por 224 píxeles
Pérdida	BCEWithLogitsLoss, loss_pos_weight=auto
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Épocas máximas	20
Tamaño de lote	32
Presupuestos	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026
Umbral	Seleccionado por validación con exactitud equilibrada por paciente
Agregación	Media de probabilidades de V1, V2 y V3 antes del umbral

6.4 Validación por paciente

El entrenamiento y la evaluación se organizan mediante validación leave-one-out. En cada pliegue se reserva un paciente completo y se entrena con un subconjunto de K pacientes del resto. Esto evita que imágenes de un mismo paciente aparezcan simultáneamente en entrenamiento y test. En HUCA esta restricción es indispensable porque las tres derivaciones de un paciente comparten adquisición, calibración y contexto clínico.

El informe de cada ejecución guarda:

- configuración de entrenamiento;
- pacientes seleccionados como ejemplos;
- probabilidades por imagen;
- predicción agregada por paciente;
- umbral elegido;
- matriz de confusión y métricas;
- paneles Grad CAM para inspección cualitativa.

6.5 Grad CAM

Grad CAM se utiliza como diagnóstico cualitativo, no como explicación clínica suficiente [29]. El mapa indica regiones que influyen en el logit del modelo, pero no prueba que la red haya aprendido un criterio médico correcto. En esta memoria se usa para comprobar si las activaciones se concentran en zonas plausibles del trazado y para detectar errores en los que una atención visual razonable termina en una decisión equivocada.




Figura 6.2. Ejemplo Grad CAM del modelo CNN sobre el conjunto sintético.

6.6 Adaptación de dominio

La adaptación de dominio se entrena con el conjunto sintético como origen etiquetado y HUCA como destino no etiquetado durante el ajuste. La evaluación final sigue realizándose sobre HUCA por paciente. Se revisan cuatro variantes:

- **SSL.** Preentrenamiento SimCLR durante tres épocas sobre imágenes del dominio destino y posterior ajuste supervisado. En el código se reproduce con `METHOD=ssl`, que internamente llama al pipeline con `domain_adaptation=none` y

`ssl_pretrain_epochs=3.`

- **CORAL.** Penalización de covarianzas para aproximar la estructura de características de origen y destino.
- **MMD.** Penalización de discrepancia de medias en kernel con escalas 0,5, 1,0, 2,0 y 4,0.
- **DANN.** Clasificador de dominio adversario con inversión de gradiente [30].

Las pérdidas de adaptación se ponderan con 0,1 y se activan de forma progresiva durante el entrenamiento. Esta rama responde a una pregunta concreta: si la CNN falla por cambio de dominio visual, alinear representaciones debería recuperar parte del rendimiento. Los resultados muestran que la mejora existe, pero es demasiado pequeña para cerrar el problema. Esta constatación refuerza la motivación para explorar un enfoque radicalmente distinto —los VLM— que no depende de alinear distribuciones visuales, sino de aprovechar conocimiento multimodal preexistente.

6.7 Modelos de visión y lenguaje

6.7.1 Motivación: por qué un VLM para pocos datos

Las secciones anteriores describen el rendimiento de la CNN y sus variantes de adaptación de dominio. Los resultados empíricos muestran que, cuando K es pequeño, el entrenamiento supervisado presenta limitaciones estructurales: alta varianza entre semillas, dependencia de la selección concreta de pacientes y dificultad para transferir desde el dominio sintético al clínico. La adaptación de dominio mitiga parcialmente el desajuste distribucional, pero no resuelve el problema fundamental: con pocos ejemplos, el gradiente no dispone de evidencia suficiente para ajustar millones de parámetros de forma fiable.

Los modelos de visión y lenguaje ofrecen una aproximación complementaria. Un VLM preentrenado a gran escala ha internalizado representaciones visuales ricas y conocimiento biomédico textual durante su fase de preentrenamiento. En lugar de aprender desde cero a partir de K ejemplos, el VLM utiliza esos ejemplos como demostraciones que especifican la tarea dentro de un conocimiento preexistente. La hipótesis es que este conocimiento previo puede compensar la escasez de datos etiquetados específicos del dominio, especialmente para valores de K en los que la CNN es inestable.

Esta hipótesis no se asume como verdadera: se diseña un marco experimental que permita confirmarla o refutarla. Los controles descritos en la sección 6.8 son los instrumentos para verificar que cualquier rendimiento observado se debe efectivamente al análisis visual y no a artefactos del prompt.

6.7.2 Gemma 4: modelo generalista de código abierto

El modelo VLM generalista seleccionado es Gemma 4. La elección se fundamenta en tres propiedades:

- **Pesos abiertos.** A diferencia de modelos propietarios accesibles solo mediante API, los pesos de Gemma 4 están disponibles públicamente. Esto permite la inferencia local, la reproducibilidad completa de los experimentos y la independencia de servicios externos cuyas condiciones de uso pueden cambiar.
- **Contexto multimodal con múltiples imágenes.** Gemma 4 acepta mensajes que combinen texto e imágenes de forma intercalada, lo que permite construir prompts de ICL que incluyan varias demostraciones imagen-etiqueta seguidas de la imagen de consulta. Esta capacidad es imprescindible para el aprendizaje en contexto multimodal con $K > 1$.
- **Inferencia local mediante vLLM.** El modelo se despliega localmente utilizando el *framework* de inferencia vLLM, que permite servir modelos de gran tamaño con gestión eficiente de memoria GPU, batching continuo y cuantización cuando es necesario. Esto elimina la dependencia de servicios en la nube y permite controlar completamente el entorno de ejecución.

6.7.3 MedGemma: adaptación al dominio médico

MedGemma es una variante de Gemma adaptada al dominio biomédico mediante entrenamiento adicional con datos médicos. Su inclusión permite responder a una pregunta específica: ¿mejora el rendimiento en ECG cuando el VLM ha sido expuesto a imágenes y textos médicos durante su preentrenamiento, aunque no necesariamente a ECG?

La comparación Gemma 4 *versus* MedGemma aísla el efecto del dominio de preentrenamiento. Si MedGemma supera a Gemma 4 de forma consistente, esto indicaría que el conocimiento biomédico previo —terminología, patrones visuales de imágenes clínicas, razonamiento diagnóstico— se transfiere al dominio electrocardiográfico. Si el rendimiento es similar, sugeriría que el conocimiento relevante para la tarea ya está capturado en el preentrenamiento generalista, o que las imágenes de ECG son suficientemente distintas de las imágenes médicas convencionales como para que la especialización no aporte ventaja.

6.7.4 Pipeline de inferencia VLM

La canalización de inferencia VLM sigue una estructura reproducible (figura 6.3):

1. **Selección de demostraciones.** Se eligen K pacientes etiquetados del conjunto dispo-

nible. La selección sigue el mismo protocolo que en la CNN para garantizar comparabilidad.

2. **Construcción del prompt multimodal.** Se compone un mensaje que incluye: instrucciones de sistema que definen la tarea y el formato de respuesta, las K demostraciones (imagen + etiqueta) y la imagen de consulta.
3. **Generación.** El modelo VLM procesa el prompt y genera una respuesta textual.
4. **Validación JSON.** La respuesta se analiza sintácticamente como JSON. Se verifica que contenga los campos requeridos (predicción binaria, confianza opcional) y que los valores sean válidos.
5. **Gestión de fallos.** Las respuestas que no superan la validación se registran como predicciones inválidas. La tasa de respuestas inválidas es una métrica de calidad del pipeline.

La respuesta esperada es un objeto JSON estructurado. No se solicita explicación libre obligatoria. Esta decisión es deliberada: un formato cerrado reduce la ambigüedad en la evaluación y permite comparar directamente con la salida numérica de la CNN. Si el VLM genera texto fuera del formato esperado, la predicción se marca como inválida en lugar de intentar interpretarla heurísticamente.




Figura 6.3. Canalización VLM/ICL: selección de demostraciones, construcción del prompt multimodal, generación local, validación JSON y controles de ablación.

6.8 Controles previstos para VLM

Un VLM puede obtener rendimiento aparentemente bueno por razones ajenas al análisis visual. Puede explotar la frecuencia relativa de etiquetas en las demostraciones, copiar

patrones textuales del prompt o basarse en sesgos de su preentrenamiento sin examinar la imagen. Para distinguir aprendizaje multimodal real de artefactos, se diseñan tres condiciones experimentales de control:

- **Normal.** Cada demostración incluye la imagen del ECG y la etiqueta correcta asociada. Esta es la condición completa que se espera que maximice el rendimiento si el modelo efectivamente utiliza la correspondencia imagen-etiqueta.
- **Respuestas permutadas.** Las imágenes de las demostraciones se mantienen inalteradas, pero las etiquetas se barajan aleatoriamente, rompiendo la correspondencia imagen-etiqueta. Este control mide si el modelo depende realmente de la relación entre cada imagen específica y su diagnóstico, o si basta con ver imágenes y etiquetas —en cualquier combinación— para producir predicciones similares.

Si el rendimiento *no cae* con respuestas permutadas, significa que el modelo no está aprendiendo de la correspondencia imagen-etiqueta, sino de otros aspectos del prompt: la proporción de etiquetas positivas, el formato general, o sesgos textuales. En ese caso, cualquier rendimiento observado en la condición normal no puede atribuirse a aprendizaje en contexto genuino.

- **Demostraciones sin imagen.** El prompt conserva las instrucciones textuales y las etiquetas de cada demostración, pero se eliminan las imágenes de ejemplo. Solo la imagen de consulta permanece. Este control aísla la contribución de la evidencia visual de las demostraciones.

Si el rendimiento *se mantiene* sin las imágenes de ejemplo, el modelo está basando sus decisiones en la estructura textual del prompt y no en el contenido visual de las demostraciones. Esto indicaría que el ICL multimodal, en la práctica, no está aprovechando las imágenes de referencia.

La interpretación conjunta de las tres condiciones permite clasificar el comportamiento del VLM:

- Si Normal > Permutadas > Sin imagen: el modelo utiliza tanto las imágenes como la correspondencia con las etiquetas. Es el escenario más favorable.
- Si Normal $\approx$ Permutadas > Sin imagen: el modelo usa las imágenes pero ignora la correspondencia con las etiquetas.
- Si Normal $\approx$ Permutadas $\approx$ Sin imagen: el modelo ignora las demostraciones por completo y responde basándose solo en la imagen de consulta y las instrucciones.
- Si cualquier control supera a Normal: hay indicios de inestabilidad o de que las demostraciones introducen ruido en lugar de información.

6.9 Criterio de comparación

La métrica principal de comparación entre métodos es la exactitud equilibrada (*balanced accuracy*) agregada por paciente. Esta métrica es apropiada para el problema porque el conjunto de datos es pequeño y presenta desbalance de clases; la exactitud equilibrada pondera por igual ambas clases independientemente de su prevalencia. Como métricas complementarias se reportan F1, sensibilidad, especificidad, área bajo la curva ROC y precisión media (AP).

Sin embargo, la comparación no se reduce a determinar cuál método obtiene mayor exactitud equilibrada en un único punto. El análisis se estructura como una **curva de decisión** en función de K :

- **Zona de K muy bajo** ($K = 2, 4$). El entrenamiento supervisado dispone de tan pocos ejemplos que la CNN es altamente inestable: gran varianza entre semillas, sensibilidad extrema a qué pacientes se seleccionan, y riesgo elevado de sobreajuste o de aprender atajos. En esta zona, el ICL puede ofrecer una señal más estable porque no depende de la convergencia de un optimizador con datos insuficientes.
- **Zona de transición** ($K = 8, 16$). A medida que aumenta K , la CNN dispone de más evidencia para generalizar. La pregunta clave es: ¿a partir de qué K el entrenamiento supervisado iguala o supera consistentemente al ICL? Este punto de cruce —si existe— define el umbral práctico por encima del cual merece la pena invertir en entrenamiento.
- **Zona de K suficiente** ($K = 32$ y más). Con datos suficientes, el entrenamiento supervisado debería dominar porque puede ajustar representaciones específicas para la tarea. El ICL, limitado por la ventana de contexto y por la ausencia de actualización de pesos, tiene un techo de rendimiento que el entrenamiento puede superar.

Además de la exactitud, la comparación incluye dimensiones operativas que condicionan la viabilidad en un entorno clínico real:

- **Coste de entrenamiento.** La CNN requiere un proceso de entrenamiento por cada configuración de K y semilla. El VLM no requiere entrenamiento.
- **Coste por inferencia.** La inferencia de una CNN es rápida y ligera. La inferencia de un VLM con contexto multimodal extenso es significativamente más costosa en tiempo y memoria GPU.
- **Tasa de respuestas inválidas.** La CNN siempre produce una salida numérica válida. El VLM puede generar respuestas que no se ajustan al formato JSON esperado, reduciendo la cobertura efectiva.

-
- **Latencia.** Para aplicaciones de triaje en tiempo real, la diferencia de latencia entre una pasada forward de CNN y una generación autoregresiva de VLM puede ser determinante.
 - **Requisitos de hardware.** Una ResNet18 cabe en cualquier GPU moderna. Un VLM de varios miles de millones de parámetros requiere hardware especializado o cuantización agresiva.

La lectura final no será “CNN contra VLM” como veredicto único. Será un mapa de decisión: para un presupuesto de etiquetado dado, un coste computacional aceptable y un nivel de robustez requerido, ¿conviene invertir en entrenamiento supervisado o utilizar aprendizaje en contexto como herramienta de triaje preliminar? La base cuantitativa de CNN y adaptación de dominio establecida en este trabajo proporciona el punto de referencia sobre el cual se evalúa la alternativa VLM.

CAPÍTULO 7

Resultados en el conjunto sintético

El primer bloque de resultados establece si una CNN puede aprender la tarea en un entorno controlado. Este paso es necesario antes de evaluar el modelo sobre datos reales y, sobre todo, antes de comparar con VLM/ICL. Si la CNN no logra aprender siquiera en un dominio sintético limpio, la comparación con VLM carecería de una línea base interpretable. El conjunto sintético contiene 100 pacientes simulados y 300 imágenes, con tres derivaciones por paciente. La etiqueta positiva corresponde a la presencia simultánea de los hallazgos operativos que definen el patrón Brugada derivado en el simulador. Hay 20 pacientes positivos y 80 normales o incompletos.

7.1 Curva por presupuesto

La tabla 7.1 muestra la media y la desviación estándar sobre tres semillas. La tendencia es clara: con $K = 2$ y $K = 4$ el modelo ya supera el azar en exactitud equilibrada, pero aún produce muchos falsos positivos. A partir de $K = 16$ aparece una mejora sustancial y con $K = 32$ se obtiene el mejor punto de la campaña.

Tabla 7.1. Resultados CNN ResNet18 sobre el conjunto sintético QRS/ST.

K	BA	F1	Sens.	Esp.	ROC AUC
2	$0,625 \pm 0,022$	0,401	0,650	0,600	0,520
4	$0,631 \pm 0,042$	0,407	0,617	0,646	0,566
8	$0,685 \pm 0,023$	0,468	0,683	0,688	0,629
16	$0,773 \pm 0,013$	0,569	0,800	0,746	0,755
32	$0,848 \pm 0,030$	0,673	0,883	0,812	0,857




Figura 7.1. Exactitud equilibrada de la CNN sobre el conjunto sintético según el presupuesto K .

El incremento entre $K = 8$ y $K = 16$ es el cambio más importante de la curva. El modelo pasa de una exactitud equilibrada media de 0,685 a 0,773, lo que indica que ocho ejemplos todavía no cubren suficientemente la variabilidad de combinaciones morfológicas. Con $K = 32$, la sensibilidad alcanza 0,883 y la especificidad 0,812, una combinación razonable para una tarea controlada de alerta morfológica.

Este resultado demuestra que la formulación visual es viable y que la CNN puede extraer información de las imágenes. Sin embargo, como se verá en el capítulo siguiente, este aprendizaje no se traslada al dominio real.

7.2 Matriz de confusión

La matriz agregada de $K = 32$ resume el mejor punto sintético. En las tres semillas se acumulan 53 verdaderos positivos, 195 verdaderos negativos, 45 falsos positivos y 7 falsos negativos. El error dominante sigue siendo marcar como positivos algunos pacientes incompletos, aunque el número de falsos negativos es bajo.




Figura 7.2. Matriz de confusión agregada del conjunto sintético para $K = 32$.

En un contexto de triaje, esta distribución de errores sería preferible a la situación inversa: el modelo tiende a avisar de más antes que a omitir positivos. Sin embargo, el conjunto sintético no representa pacientes reales y sus etiquetas proceden de reglas internas; por tanto, este resultado solo demuestra aprendizaje de la tarea simulada.

7.3 Inspección cualitativa

El panel Grad CAM de la figura 7.3 muestra que el modelo atiende a regiones del complejo QRS, el punto J y la repolarización. La inspección es coherente con la definición de la etiqueta, pero no sustituye a una validación clínica. Grad CAM ayuda a detectar fallos obvios de atención; no certifica que la red razone como un especialista.




Figura 7.3. Ejemplo Grad CAM del modelo sintético.

7.4 Conclusión del dominio sintético

El dominio sintético confirma tres hechos. Primero, el renderizado contiene información visual suficiente para entrenar una CNN con pocos ejemplos. Segundo, el presupuesto importa: por debajo de $K = 16$ el comportamiento es útil pero irregular; con $K = 32$ el modelo mejora simultáneamente sensibilidad, especificidad, F1 y área ROC. Tercero, este buen rendimiento no puede trasladarse de forma directa a clínica porque las imágenes sintéticas son más limpias y las etiquetas están definidas por el propio generador.

Este resultado no cierra la comparación con VLM/ICL. Establece que la CNN *puede* aprender cuando las condiciones están controladas. La pregunta siguiente es si ese aprendizaje se mantiene en datos reales o si la CNN, incluso con adaptación de dominio, falla al enfrentarse a la variabilidad clínica. Si falla, la comparación con VLM/ICL queda no solo justificada, sino motivada empíricamente.

CAPÍTULO 8

Evaluación con Brugada HUCA

El segundo bloque de resultados utiliza Brugada HUCA, un conjunto de ECG clínicos reales asociado al síndrome de Brugada [38]. La finalidad de este capítulo es medir cuánto se degrada la CNN al abandonar el simulador y evaluar si la adaptación de dominio recupera parte de esa pérdida. Los resultados de este capítulo son decisivos para la motivación del TFG: si una CNN entrenada y adaptada con pocos ejemplos no supera el azar en el dominio real, queda demostrada empíricamente la insuficiencia del enfoque supervisado clásico y, con ello, la necesidad de explorar si el conocimiento multimodal de los VLM puede compensar la escasez de datos.

8.1 Cohorte final

El procesado parte de 363 pacientes. Se excluyen 46 casos con patrón basal limítrofe que no deben mezclarse como positivos o negativos en la tarea principal. La cohorte final contiene 317 pacientes: 116 casos Brugada confirmados y 201 controles. Para cada paciente se generan tres imágenes, una por V1, V2 y V3, lo que produce 951 imágenes.

Tabla 8.1. Cohorte Brugada HUCA utilizada en la evaluación CNN.

Grupo	Pacientes	Imágenes
Brugada confirmado	116	348
Control	201	603
Excluido por patrón basal limítrofe	46	—
Total evaluado	317	951


La etiqueta real disponible no es equivalente a las tres etiquetas morfológicas del simulador. HUCA no contiene anotaciones independientes de RBBB, elevación ST e inversión T para cada imagen. Por ello, el experimento real se formula como caso Brugada confirmado frente a control y sus conclusiones se limitan a triaje de esa variable clínica. Es importante recordar que en la práctica asistencial, un resultado positivo del modelo no equivale a un diag-

nóstico: señala que el trazado debería ser revisado por un especialista y, si procede, iniciar el circuito diagnóstico que puede incluir prueba farmacológica con bloqueantes del canal de sodio [6].

8.2 Preprocesamiento

La preparación selecciona las derivaciones precordiales derechas, detecta un latido central y recorta una ventana de 300 ms antes de R y 600 ms después de R. La salida conserva el identificador de paciente, derivación, etiqueta clínica, ruta de imagen y plan de pliegues LOOCV. El objetivo es obtener una representación visual comparable a la sintética sin borrar la variabilidad propia del ECG real.

Preparacion de Brugada-HUCA



La etiqueta QRS/ST real no se inventa: HUCA aporta `clinical_brugada` para evaluar la regla final derivada.

Esto separa el detector morfológico entrenado en sintético de la referencia clínica usada para triaje y auditoría patient-level.

Figura 8.1. Canalización de preprocesamiento de Brugada HUCA para V1, V2 y V3.

La separación por paciente es obligatoria. Si V1, V2 y V3 de un mismo paciente se repartieran entre entrenamiento y test, el modelo podría aprovechar características de adquisición o escala en lugar de aprender rasgos clínicamente relevantes.

8.3 Resultados CNN base

La tabla 8.2 resume la CNN base entrenada y evaluada sobre HUCA. A diferencia del dominio sintético, aumentar K no produce una mejora monótonica. El mejor punto de exactitud equilibrada aparece con $K = 16$, pero solo alcanza 0,516. Con $K = 32$ la exactitud equilibrada baja a 0,499. Estos valores son esencialmente indistinguibles del azar.

Tabla 8.2. Resultados CNN ResNet18 sobre Brugada HUCA.

K	BA	F1	Sens.	Esp.	ROC AUC
2	$0,509 \pm 0,010$	0,484	0,693	0,325	0,525
4	$0,509 \pm 0,023$	0,493	0,730	0,289	0,495
8	$0,490 \pm 0,018$	0,469	0,672	0,308	0,496
16	$0,516 \pm 0,023$	0,480	0,658	0,375	0,569
32	$0,499 \pm 0,012$	0,466	0,644	0,355	0,491




Figura 8.2. Exactitud equilibrada de la CNN base sobre Brugada HUCA.

La sensibilidad es moderada, pero la especificidad es baja. En el mejor punto $K = 16$, la matriz agregada de tres semillas contiene 229 verdaderos positivos, 226 verdaderos negativos, 377 falsos positivos y 119 falsos negativos. El modelo tiende a sobredetectar casos Brugada, lo que podría ser tolerable únicamente como alerta preliminar extremadamente conservadora, pero no como herramienta de descarte ni de diagnóstico.




Figura 8.3. Matriz de confusión agregada de Brugada HUCA para $K = 16$.

Este resultado es el hallazgo más importante de la rama CNN: con tan pocos datos, el entrenamiento supervisado de una ResNet18, incluso con pesos preentrenados de ImageNet, no consigue extraer señal útil de ECGs clínicos reales de Brugada. La red aprende en el simulador porque las imágenes son limpias y las etiquetas derivan de reglas controladas. En el dominio real, la variabilidad clínica, el ruido de adquisición y la complejidad del fenotipo superan la capacidad del modelo.

8.4 Brecha sintético-real

La comparación directa muestra una brecha de dominio marcada. En el simulador la exactitud equilibrada aumenta hasta 0,848 con $K = 32$. En HUCA, el modelo se mantiene alrededor de 0,50. Esto indica que la señal visual aprendida en condiciones controladas no se transfiere de forma directa a la variabilidad clínica.




Figura 8.4. Comparación de exactitud equilibrada entre el conjunto sintético y Brugada HUCA.




Figura 8.5. Comparación de F1 entre el conjunto sintético y Brugada HUCA.

La brecha tiene varias causas plausibles: ruido y variabilidad de adquisición, diferencias de escala, presencia de múltiples fenotipos, etiqueta clínica no reducible a una sola ventana de ECG y ausencia de anotaciones morfológicas finas en HUCA. El resultado no invalida el simulador; delimita su alcance y confirma que el problema de pocos datos no se resuelve con un simulador más limpio.

8.5 Adaptación de dominio

La rama de adaptación de dominio entrena con imágenes sintéticas etiquetadas y utiliza HUCA como dominio destino no etiquetado. Se ejecutan cuatro variantes: SSL, CORAL, MMD y DANN. La tabla 8.3 compara cada método con la línea base en $K = 16$ y $K = 32$.

Tabla 8.3. Comparación de adaptación de dominio sobre Brugada HUCA.

Método	K	BA	F1	Sens.	Esp.
Base	16	$0,516 \pm 0,023$	0,480	0,658	0,375
SSL	16	$0,477 \pm 0,027$	0,458	0,658	0,297
CORAL	16	$0,524 \pm 0,008$	0,481	0,641	0,408
MMD	16	$0,516 \pm 0,019$	0,474	0,635	0,396
DANN	16	$0,515 \pm 0,019$	0,470	0,621	0,410
Base	32	$0,499 \pm 0,012$	0,466	0,644	0,355
SSL	32	$0,503 \pm 0,014$	0,476	0,672	0,333
CORAL	32	$0,528 \pm 0,013$	0,480	0,632	0,423
MMD	32	$0,549 \pm 0,029$	0,498	0,649	0,448
DANN	32	$0,509 \pm 0,028$	0,472	0,644	0,375




Figura 8.6. Exactitud equilibrada de las variantes de adaptación de dominio.




Figura 8.7. F1 de las variantes de adaptación de dominio.

La mejor configuración es MMD con $K = 32$, con BA 0,549 y especificidad 0,448. La mejora frente a la línea base de $K = 32$ es de 0,049 puntos de exactitud equilibrada. Es una señal positiva para la adaptación, pero todavía insuficiente para considerar el sistema clínicamente robusto. Incluso con la mejor técnica de adaptación, la CNN no supera el umbral que permitiría un uso práctico como herramienta de triaje.

8.6 Inspección cualitativa

El Grad CAM real confirma que las activaciones pueden localizarse sobre regiones del trazado, pero también muestra la dificultad de interpretar modelos entrenados con pocos ejemplos sobre datos clínicos heterogéneos. La atención visual no compensa la falta de especificidad ni resuelve la diferencia entre etiqueta clínica y morfología observable.




Figura 8.8. Ejemplo Grad CAM del modelo CNN sobre Brugada HUCA.

8.7 Conclusión en datos reales: evidencia que motiva la comparación con VLM

La conclusión de HUCA es clara y constituye la evidencia empírica central de la rama CNN. La red convolucional, incluso con pesos preentrenados y técnicas de adaptación de dominio, no logra un rendimiento robusto en datos reales de Brugada con tan pocos ejemplos etiquetados. La exactitud equilibrada se mantiene cerca del azar y la especificidad es demasiado baja para cualquier uso práctico más allá de investigación exploratoria.

Este resultado no es un punto final. Es el punto de partida para la comparación con VLM/ICL. La CNN demuestra qué no funciona: entrenar un modelo visual específico con $K \leq 32$ ejemplos en un dominio clínicamente complejo como el síndrome de Brugada. La siguiente fase debe determinar si un modelo de visión y lenguaje, que aporta conocimiento visual y médico previo adquirido durante un preentrenamiento masivo, puede ofrecer una mejor relación entre rendimiento, coste y cantidad de datos etiquetados cuando recibe esos mismos K ejemplos como demostraciones en contexto en lugar de como conjunto de entrenamiento.

CAPÍTULO 9

Evaluación VLM/ICL

Este capítulo desarrolla el segundo brazo del estudio: modelos de visión y lenguaje con aprendizaje en contexto. Su papel dentro del TFG tiene el mismo peso metodológico que la rama CNN. La diferencia es que aquí los valores numéricos de resultados se dejan como celdas reservadas para ejecución, mientras que el diseño experimental, las condiciones, los controles, el contrato de salida y las tablas de comparación quedan definidos por completo.

9.1 Objetivo del brazo VLM

La rama CNN ha establecido la línea base supervisada: con $K \leq 32$, ResNet18 aprende en el simulador, pero no alcanza rendimiento robusto sobre Brugada HUCA. El brazo VLM/ICL evalúa la hipótesis complementaria: si los ejemplos etiquetados son demasiado escasos para actualizar pesos de forma fiable, quizá puedan ser más útiles como demostraciones dentro del contexto de un modelo multimodal preentrenado.

La comparación se formula con la misma entrada visual, los mismos pacientes, los mismos presupuestos K , la misma separación leave-one-out y las mismas métricas por paciente. La diferencia experimental es una sola: la CNN usa los ejemplos para entrenar; el VLM los usa para condicionar la inferencia.

9.2 Modelos evaluados

El protocolo contempla dos modelos abiertos:

- **Gemma 4.** Modelo multimodal generalista con entrada de texto e imagen [26]. Actúa como referencia abierta no especializada. Su papel es medir cuánto puede aportar un VLM general con contexto visual y textual amplio.
- **MedGemma 1.5.** Modelo multimodal médico basado en la familia Gemma y adaptado con modalidades clínicas [27]. Actúa como referencia médica. Su papel es medir si el preentrenamiento biomédico general aporta ventaja en ECG, aun cuando el ECG no figure como modalidad principal de su tarjeta.

Ambos modelos se sirven localmente mediante vLLM siempre que el hardware lo permita. Esta decisión evita depender de APIs externas y permite registrar versión de pesos, plantilla de conversación, resolución visual, temperatura y parámetros de generación.

9.3 Presupuestos y demostraciones

Los presupuestos son $K = \{0, 2, 4, 8, 16, 32\}$. El caso $K = 0$ mide comportamiento *zero-shot*: el modelo recibe instrucciones y la imagen objetivo, pero ninguna demostración etiquetada. Los valores positivos de K miden aprendizaje en contexto con ejemplos imagen-respuesta.

Para que la comparación con la CNN sea directa, las demostraciones se seleccionan a nivel de paciente y nunca incluyen el paciente reservado para test. Cuando un paciente aporta varias derivaciones, la demostración conserva la misma lógica de agregación que el resto del estudio: V1, V2 y V3 son evidencia visual del mismo paciente, no muestras independientes para filtrar entre entrenamiento y prueba.

9.4 Contrato de salida

La salida esperada es JSON estricto con los mismos hallazgos morfológicos que utiliza la CNN. Para cada imagen V1, V2 o V3, la respuesta mínima es:

```
1 {  
2   "RBBB": true,  
3   "ST_ELEVATION": true,  
4   "T_WAVE_INVERSION": true  
5 }
```

La etiqueta clínica de paciente se deriva después mediante la misma regla AND usada en el resto del TFG: solo se marca sospecha Brugada si los tres hallazgos están presentes tras agregar las derivaciones. Opcionalmente puede añadirse una confianza discreta en versiones posteriores, pero la evaluación principal solo usa las tres claves booleanas anteriores.

El análisis principal no interpreta texto libre. Una respuesta no parseable, con claves ausentes, tipos incorrectos o valores fuera del esquema, se registra como fallo de formato. Esta tasa de fallos se reporta junto con las métricas clínicas porque forma parte del comportamiento real de un VLM.

9.5 Condiciones experimentales

La tabla 9.1 fija las condiciones de la campaña. Las tres primeras condiciones miden rendimiento; las dos últimas son controles de causalidad multimodal.

Tabla 9.1. Condiciones experimentales VLM/ICL.

Condición	K	Propósito
Zero-shot	0	Medir conocimiento previo sin demostraciones.
ICL normal	2, 4, 8, 16, 32	Medir aprendizaje en contexto con pares imagen-etiqueta correctos.
ICL balanceado	2, 4, 8, 16, 32	Mantener proporción positiva/negativa controlada cuando el pliegue lo permita.
Etiquetas permutadas	8, 16, 32	Romper la correspondencia imagen-etiqueta para detectar uso espurio del contexto.
Sin imagen de apoyo	8, 16, 32	Mantener etiquetas de demostración, pero retirar las imágenes de apoyo.

9.6 Agregación por paciente

Cada predicción se obtiene por imagen y se agrega a nivel de paciente para conservar la misma unidad de evaluación que en la CNN. Si el modelo produce una respuesta válida para V1, V2 y V3, se calcula una decisión de paciente por voto mayoritario o por media de probabilidades si se activa la confianza numérica. Si alguna derivación produce JSON inválido, se conserva el fallo en la auditoría. El análisis principal contabiliza los fallos como errores; un análisis secundario puede informar métricas sobre respuestas válidas, pero nunca sustituye al análisis principal.

9.7 Scripts y artefactos de ejecución

La campaña VLM/ICL queda implementada en dos wrappers reproducibles. `scripts/run/validate_vlm_loocv.sh` valida particiones, prompts, imágenes, modelos configurados y volumen previsto de inferencias sin cargar pesos ni llamar a red. `scripts/run/run_vlm_loocv.sh` ejecuta la campaña completa y genera, para cada modelo, condición, K y semilla, predicciones por muestra en `outputs/vlm_loocv/`. Los resúmenes agregados se escriben en `reports/loocv/vlm/`: manifiesto de campaña, métricas por ejecución, métricas por modelo-condición- K , matrices de confusión y gráficas de exactitud equilibrada y F1. Cuando existan inferencias auditadas, `scripts/run/build_loocv_comparison.sh` reconstruye la comparación CNN frente a VLM.

9.8 Tablas de resultados preparadas

Las tablas siguientes forman parte del documento aunque las celdas numéricas VLM estén reservadas. Esto evita que la rama VLM aparezca como una nota futura: el experimento está especificado, sus salidas están definidas y solo falta rellenar los valores tras ejecutar las inferencias. En estas tablas, — indica valor por ejecutar.

Tabla 9.2. Resultados VLM/ICL previstos para Gemma 4 sobre Brugada HUCA.

K	BA	F1	Sens.	Esp.	JSON inválido	Latencia media
0	—	—	—	—	—	—
2	—	—	—	—	—	—
4	—	—	—	—	—	—
8	—	—	—	—	—	—
16	—	—	—	—	—	—
32	—	—	—	—	—	—

Tabla 9.3. Resultados VLM/ICL previstos para MedGemma 1.5 sobre Brugada HUCA.

K	BA	F1	Sens.	Esp.	JSON inválido	Latencia media
0	—	—	—	—	—	—
2	—	—	—	—	—	—
4	—	—	—	—	—	—
8	—	—	—	—	—	—
16	—	—	—	—	—	—
32	—	—	—	—	—	—

Tabla 9.4. Controles VLM/ICL previstos para verificar uso multimodal real.

Modelo	Condición	K	BA	Caída frente a normal	Lectura
Gemma 4	Etiquetas permutadas	16	—	—	—
Gemma 4	Sin imagen de apoyo	16	—	—	—
MedGemma 1.5	Etiquetas permutadas	16	—	—	—
MedGemma 1.5	Sin imagen de apoyo	16	—	—	—
Gemma 4	Etiquetas permutadas	32	—	—	—
Gemma 4	Sin imagen de apoyo	32	—	—	—
MedGemma 1.5	Etiquetas permutadas	32	—	—	—
MedGemma 1.5	Sin imagen de apoyo	32	—	—	—

9.9 Comparación final prevista

La comparación final se leerá como una curva de decisión. La CNN ya aporta los valores de referencia. Las celdas VLM se rellenarán tras ejecutar las inferencias con la misma auditoría.

Tabla 9.5. Matriz de decisión CNN frente a VLM/ICL.

K	CNN HUCA base BA	Mejor BA	CNN+DA	Mejor VLM BA	Lectura esperada
2	0,509	—	—	—	Régimen extremo.
4	0,509	—	—	—	CNN inestable.
8	0,490	—	—	—	Transición inicial.
16	0,516	0,524 (CORAL)	—	—	Ref. CORAL.
32	0,499	0,549 (MMD)	—	—	Ref. MMD.

9.10 Figuras de resultados reservadas




Figura 9.1. Figura prevista para la comparación final de exactitud equilibrada entre CNN y VLM/ICL.




Figura 9.2. Figura prevista para matrices de confusión de Gemma 4 y MedGemma 1.5.

9.11 Criterio de lectura

Si un VLM supera de forma consistente a la CNN en K bajo, la conclusión será que el conocimiento multimodal previo aporta valor en la zona donde entrenar pesos no compensa. Si la CNN alcanza o supera al VLM cuando K aumenta, aparecerá un punto de cruce práctico: por debajo conviene ICL; por encima conviene entrenamiento supervisado. Si ninguno de los dos enfoques supera un rendimiento aceptable, el resultado también será informativo: indicará que la tarea requiere más datos, mejores anotaciones morfológicas o modelos específicamente preentrenados en ECG.

En todos los casos, la lectura clínica se mantiene constante. La salida del modelo solo prioriza revisión experta dentro del circuito de Brugada; no confirma ni descarta el síndrome.

CAPÍTULO 10

Discusión

El resultado central de la rama CNN no es un sistema que funcione ni un sistema que falle sin más. El resultado central es una evidencia negativa cuantificada: los modelos de visión tradicionales, incluso con adaptación de dominio, no resuelven la detección de Brugada cuando solo se dispone de unos pocos ejemplos etiquetados. En el simulador la exactitud equilibrada alcanza 0,848 con $K = 32$; en Brugada HUCA la línea base oscila en torno a 0,50 y la mejor adaptación de dominio, MMD con $K = 32$, solo llega a 0,549. Esta evidencia negativa no invalida el proyecto. Al contrario, constituye la piedra angular de la comparación: establece por qué debe investigarse si el conocimiento multimodal preentrenado de los VLM puede compensar la escasez de datos que la CNN no supera.

10.1 Qué demuestra el simulador

El simulador demuestra que la formulación como imagen es viable para una CNN. La red aprende rasgos relacionados con QRS, punto J, segmento ST y onda T, y mejora de forma monótonica al aumentar el presupuesto de ejemplos. El salto entre $K = 8$ y $K = 16$ sugiere que la tarea necesita una cobertura mínima de variabilidad morfológica; por debajo de ese rango, la selección concreta de los ejemplos pesa demasiado sobre el resultado.

Sin embargo, el simulador no demuestra capacidad diagnóstica. Sus etiquetas se generan con reglas internas, las imágenes son limpias y las familias morfológicas están más separadas que en la práctica clínica. El valor del simulador es estrictamente experimental: permite validar código, métricas, agregación por paciente y sensibilidad al número de ejemplos antes de confrontar datos reales.

10.2 Qué demuestra HUCA

HUCA introduce la dificultad que faltaba en el simulador. La etiqueta es clínica, los registros son heterogéneos y una ventana individual de V1, V2 o V3 no contiene por sí sola todo el proceso diagnóstico. El rendimiento obtenido indica que la CNN capta parte de la señal positiva, pero con una especificidad demasiado baja: en el mejor caso de la línea base ($K = 16$), la especificidad es de 0,375 y la exactitud equilibrada de 0,516.

Lo que HUCA demuestra de forma inequívoca es que entrenar un modelo visual específico con pocos ejemplos no es suficiente para esta tarea clínica. Este es un resultado necesario antes de proponer alternativas: sin haber cuantificado primero la insuficiencia de la vía convencional, cualquier apelación a modelos más grandes carecería de justificación empírica.

10.3 Por qué no basta la adaptación de dominio

La brecha sintético-real tiene dos componentes. El primero es visual: el ECG real contiene ruido, variabilidad de escala, diferencias de adquisición y trazados menos regulares. El segundo es semántico: la etiqueta sintética deriva de una composición de hallazgos morfológicos, mientras que HUCA aporta una etiqueta clínica binaria que integra historia, seguimiento y confirmación especializada. Aunque ambas tareas están relacionadas con Brugada, no son idénticas.

La adaptación de dominio mejora parcialmente este escenario. CORAL y MMD aumentan la especificidad en $K = 32$, y MMD obtiene el mejor resultado global con una exactitud equilibrada de 0,549 [30]. Aun así, la mejora es modesta: 0,049 puntos sobre la línea base. Esto indica que alinear representaciones visuales entre dominios no compensa cuando la etiqueta cambia de naturaleza, cuando faltan anotaciones morfológicas finas en el dominio real y, sobre todo, cuando el número de ejemplos etiquetados es tan reducido.

Este resultado es importante para la argumentación del proyecto en su conjunto. Si la dificultad residiera únicamente en diferencias de estilo visual, una buena adaptación debería cerrar la brecha de forma sustancial. El hecho de que no lo haga apunta a un problema más profundo: la CNN parte de cero en cuanto a conocimiento clínico y debe aprender simultáneamente qué es Brugada, cómo se refleja visualmente y cómo distinguirlo de otras morfologías, todo ello con unos pocos ejemplos. Esta carga es excesiva para un modelo que no dispone de conocimiento previo relevante.

10.4 Pocos datos y decisión de modelo

El estudio confirma que K importa, pero no de la misma forma en todos los dominios. En el simulador, más ejemplos casi siempre ayudan. En HUCA, aumentar de $K = 16$ a $K = 32$ no mejora la línea base e incluso la degrada ligeramente. Esto puede deberse a la variabilidad de la selección de ejemplos, al pequeño tamaño efectivo, a que los ejemplos añadidos no cubren subfenotipos relevantes o a que la arquitectura aprende atajos visuales no generalizables.

La pregunta útil no es si una CNN es “buena” o “mala”. La pregunta útil es en qué región del espacio de datos conviene entrenarla. Con cohortes grandes, diversas y bien eti-

quetadas, una CNN o un transformer visual especializado pueden ser la solución natural. Pero existe un umbral por debajo del cual el coste de ajustar pesos desde cero supera el beneficio que esos pocos ejemplos pueden aportar. Los resultados sugieren que, para Brugada HUCA, ese umbral no se cruza con $K \leq 32$.

La implicación es directa: si un modelo que aprende exclusivamente de los datos disponibles no logra superar el azar, tiene sentido preguntarse si un modelo que ya posee conocimiento visual y médico previo puede aprovechar esos mismos pocos ejemplos de una forma cualitativamente distinta.

10.5 Interpretabilidad

Grad CAM aporta una comprobación cualitativa útil: los mapas no se concentran de forma absurda en márgenes o ruido de fondo [29]. En varios ejemplos aparecen activaciones sobre zonas plausibles del complejo QRS y la repolarización. Pero la interpretabilidad visual no salva el rendimiento. Un mapa razonable puede acompañar a una clasificación incorrecta, y un mapa localizado no equivale a una justificación clínica.

En futuras versiones será necesario combinar Grad CAM con análisis por subgrupos, calibración, revisión de errores por especialista y anotaciones morfológicas independientes. Sin esas capas, la explicación se debe presentar como diagnóstico técnico del modelo, no como validación médica.

10.6 Relación con VLM e ICL

Esta sección es la más importante de la discusión porque conecta la evidencia negativa de la CNN con la hipótesis central del proyecto.

10.6.1 Por qué la CNN no basta y qué cambia con un VLM

La CNN entrenada sobre HUCA parte de pesos de ImageNet: filtros visuales genéricos aprendidos sobre objetos cotidianos. No posee ningún conocimiento previo sobre electrocardiografía, sobre la morfología del patrón de Brugada, sobre la fisiología del canal de sodio ni sobre criterios diagnósticos. Todo lo que la red sabe de Brugada debe aprenderlo de los K ejemplos etiquetados disponibles. Con $K \leq 32$, esa carga resulta imposible de cubrir.

Un modelo de lenguaje visual como Gemma 4 [26] o un modelo médico multimodal como MedGemma 1.5 [27] aportan dos formas de conocimiento previo que la CNN no tiene. La primera es conocimiento visual amplio: estos modelos han procesado millones de imágenes durante su preentrenamiento, incluidas representaciones gráficas, diagramas y, en el caso de MedGemma, imágenes médicas de múltiples modalidades. La segunda es conocimiento textual y conceptual: los VLM han sido entrenados con textos médicos, artículos, guías clíni-

cas y descripciones de patologías. Aunque ninguno de ellos presenta el ECG como modalidad principal de entrenamiento, la base de conocimiento que aportan es incomparablemente mayor que la de una ResNet18 con pesos de ImageNet.

Esta diferencia no es meramente cuantitativa. Es una diferencia de naturaleza. La CNN debe construir su comprensión de Brugada exclusivamente a partir de los ejemplos de entrenamiento. El VLM puede potencialmente reconocer que una imagen contiene un trazado de ECG, identificar derivaciones precordiales, detectar elevación del segmento ST y asociarla con conceptos clínicos que ya forman parte de su representación interna. La pregunta experimental es si ese conocimiento previo se traduce efectivamente en mejor rendimiento con pocos ejemplos, no si es teóricamente superior.

10.6.2 ICL frente a entrenamiento: dos paradigmas distintos

El aprendizaje en contexto (ICL) utiliza K ejemplos como demostraciones incluidas en el prompt, sin actualizar en ningún momento los pesos del modelo. Esto es fundamentalmente diferente del entrenamiento supervisado de la CNN, donde los K ejemplos se utilizan para ajustar millones de parámetros mediante retropropagación.

La diferencia tiene consecuencias directas en el régimen de pocos datos. Cuando se entrenan pesos, cada ejemplo debe contribuir a una actualización de gradiente que modifique el modelo de forma productiva. Con K muy pequeño, el riesgo de sobreajuste es alto, la cobertura de la variabilidad clínica es baja y los gradientes pueden ser ruidosos. ICL evita este problema: los ejemplos no actualizan pesos, sino que condicionan la distribución de probabilidad de la siguiente respuesta. El modelo utiliza las demostraciones como contexto para una tarea que resuelve aplicando su conocimiento previo, no como material para aprender de cero.

Esto no implica que ICL sea necesariamente superior. Un VLM puede ignorar detalles finos del ECG, depender más del texto del prompt que de la imagen, producir respuestas inválidas o ser incapaz de distinguir morfologías sutiles. Por eso la pipeline incluye controles de respuestas permutadas y demostraciones sin imagen, precisamente para detectar si el modelo usa realmente la información visual de las demostraciones o si responde por inercia textual [24, 25].

10.6.3 La pregunta correcta y el papel de la línea base CNN

La pregunta del proyecto no es si los VLM son “mejores” que las CNN en general. Los VLM no compiten con sistemas supervisados entrenados sobre millones de ECG etiquetados. La pregunta es mucho más específica: en el régimen de datos extremadamente escasos ($K \leq 32$ ejemplos etiquetados), ¿puede el conocimiento previo de un VLM compensar la imposibilidad de entrenar un modelo visual específico?

Para que esta pregunta tenga sentido científico, es imprescindible haber demostrado primero que la vía convencional falla. Eso es exactamente lo que establece la rama CNN. Sin esta evidencia negativa, la propuesta de usar VLM/ICL sería una elección arbitraria de tecnología. Con ella, se convierte en una hipótesis motivada por datos: sabemos que entrenar no funciona, luego probamos si explotar conocimiento previo sin entrenar puede funcionar.

La comparación prevista es justa y controlada: misma imagen, mismos presupuestos K , separación por paciente y mismas métricas. La única diferencia es cómo se utilizan los ejemplos: como material de entrenamiento o como demostraciones en contexto.

10.6.4 ¿A partir de qué K conviene entrenar frente a usar ICL?

Los resultados CNN sugieren que existe un umbral de viabilidad del entrenamiento supervisado. Con $K \leq 32$, la CNN no supera el azar en el dominio real. La literatura muestra que las CNN necesitan cientos o miles de ejemplos etiquetados para alcanzar rendimiento clínicamente relevante en ECG [15, 11].

Por debajo de ese umbral, ICL podría ser la estrategia más eficiente porque no necesita ajustar pesos y aprovecha conocimiento previo. Por encima de ese umbral, un modelo supervisado podría superar a ICL porque puede especializarse en los patrones específicos del dominio. La frontera exacta depende de la tarea, la complejidad morfológica, la calidad de las etiquetas y la capacidad del VLM para procesar imágenes de ECG.

Determinar esa frontera con datos es una de las contribuciones que la fase VLM/ICL puede aportar. Si los resultados VLM/ICL muestran un rendimiento que decrece al aumentar K mientras la CNN mejora, existirá un punto de cruce que defina cuándo renta cada estrategia. Si el VLM domina en todos los valores de K probados, significará que el umbral de viabilidad del entrenamiento es superior a 32 ejemplos para esta tarea. Ambos resultados serían informativos.

10.6.5 Gemma 4 y MedGemma: hipótesis diferenciadas

Gemma 4 es un modelo generalista multimodal con resolución visual variable [26]. Su presupuesto de tokens visuales permite estudiar si asignar más resolución a una imagen de ECG mejora la detección de cambios morfológicos sutiles. MedGemma 1.5 es un modelo con adaptación médica que incluye radiología, histopatología, dermatología y registros clínicos [27]. Su tarjeta no presenta el ECG como modalidad principal, lo que plantea una pregunta interesante: ¿es más útil un modelo generalista reciente con mejor arquitectura, o un modelo médico con conocimiento de dominio pero potencialmente menos potente en el procesamiento visual de ECG?

La respuesta no puede anticiparse. Lo que sí puede anticiparse es que ambos modelos

parten de una posición radicalmente diferente a la de la CNN: no necesitan aprender qué es un ECG, qué es Brugada, qué significa una elevación del segmento ST ni cómo se lee una derivación precordial. Esos conceptos ya forman parte, en mayor o menor medida, de su representación interna.

10.7 Implicaciones para triaje clínico

En el marco del síndrome de Brugada, la utilidad potencial de un modelo predictivo no es el diagnóstico. El diagnóstico de Brugada requiere un circuito clínico que ningún modelo automatizado puede reemplazar [6].

Un sistema de triaje basado en el modelo operaría de la siguiente forma. El algoritmo analiza la imagen del ECG y genera una puntuación de riesgo o una clasificación preliminar. Si el modelo señala un caso como sospechoso, ese paciente se prioriza para revisión experta del ECG completo de doce derivaciones. El especialista evalúa la morfología en las derivaciones precordiales derechas, considerando la presencia del patrón tipo 1, tipo 2 o tipo 3, y su relación con posibles variantes normales o fenocopias. Si la sospecha se mantiene pero el ECG basal no es diagnóstico, el protocolo clínico incluye la posibilidad de repetir el registro con reposicionamiento de V1 y V2 a espacios intercostales superiores, que pueden aumentar la sensibilidad para detectar el patrón [7].

En los casos seleccionados en los que la sospecha clínica persiste, el siguiente paso es la prueba farmacológica con bloqueantes del canal de sodio, como ajmalina o flecainida, administrada en un entorno monitorizado. Esta prueba intenta desenmascarar un patrón tipo 1 que el ECG basal no mostraba. La indicación depende de la valoración integral del paciente: síntomas, antecedentes familiares de muerte súbita, hallazgos electrocardiográficos previos y cuadro clínico [6]. La prueba no se utiliza como cribado indiscriminado, y su especificidad no es perfecta.

En este circuito, el modelo de aprendizaje automático ocupa un papel exclusivamente auxiliar: puede acelerar la identificación de candidatos para revisión, pero nunca sustituye al especialista ni decide sobre la indicación de la prueba farmacológica. Un falso positivo del modelo genera una revisión experta adicional; un falso negativo puede retrasar la entrada del paciente en el circuito. Con los rendimientos actuales de la CNN, el balance favorece un uso exclusivamente de investigación. La fase VLM/ICL medirá si ese balance puede mejorar lo suficiente para justificar un estudio piloto de triaje asistido.

10.8 Limitaciones

Las principales limitaciones son:

- El conjunto real procede de un único dominio clínico y necesita validación externa.
- La etiqueta HUCA disponible no separa hallazgos morfológicos individuales.
- El preprocesamiento reduce cada ECG a ventanas de V1, V2 y V3 alrededor de un latido central.
- Los presupuestos de entrenamiento son deliberadamente pequeños y pueden dejar subgrupos sin representación.
- No se ha realizado calibración clínica ni estimación formal de utilidad neta.
- El protocolo VLM/ICL queda especificado en el capítulo 9 con modelos, presupuestos, prompts, controles y tablas de salida. Las únicas piezas sin valores son las celdas numéricas que dependen de inferencias VLM auditadas.
- La evidencia negativa de la CNN se limita a ResNet18 con pesos de ImageNet. Otras arquitecturas o esquemas de preentrenamiento visual podrían obtener resultados diferentes, aunque la expectativa con $K \leq 32$ es baja.

10.9 Lectura final

La rama CNN produce un resultado negativo documentado y reproducible. El modelo no resuelve la detección de Brugada en datos clínicos con pocos ejemplos. La adaptación de dominio atenúa la brecha sintético-real, pero no la cierra. Este resultado no es un fracaso del proyecto; es el primer paso del argumento científico.

La estructura del razonamiento es la siguiente: si un modelo que debe aprender todo desde cero no funciona con pocos datos, ¿puede funcionar un modelo que ya sabe algo? La CNN establece el “no funciona”. La rama VLM/ICL ya queda planteada con el mismo diseño experimental para comprobar si el conocimiento previo convierte ese “no funciona” en un rendimiento útil. Independientemente del resultado, la comparación será informativa: si el VLM tampoco funciona, el problema residirá en la tarea misma con ese nivel de datos; si el VLM mejora, quedará cuantificado el valor del conocimiento previo en escenarios de extrema escasez.

La siguiente decisión experimental ya está planteada: ejecutar Gemma 4 y MedGemma con los mismos presupuestos, los mismos datos y las mismas métricas, y determinar, con datos, a partir de cuántos ejemplos renta entrenar un modelo visual específico y cuándo es preferible usar aprendizaje en contexto para triaje preliminar.

CAPÍTULO 11

Gestión, ética, privacidad y marco normativo

11.1 Planificación del proyecto

11.1.1 Alcance y carga de trabajo

El Trabajo de Fin de Grado tiene una carga de 12 créditos ECTS. El Real Decreto 1125/2003 establece una dedicación de entre 25 y 30 horas por crédito [41]. La planificación adopta el límite inferior de 25 horas y fija una referencia de 300 horas. Esta cifra no representa un registro automático del tiempo ya consumido, sino el presupuesto de esfuerzo utilizado para organizar el proyecto.

La tabla 11.1 distribuye la dedicación entre revisión, diseño, implementación, evaluación y documentación. La generación sintética y la infraestructura de experimentación reciben una fracción elevada porque condicionan tanto a las redes convolucionales como a los modelos de visión y lenguaje.

Tabla 11.1. Distribución prevista de la dedicación del proyecto.

Actividad	Horas
Revisión bibliográfica y clínica	28
Requisitos y protocolo experimental	20
Simulador y construcción de datos	48
Infraestructura VLM y diseño de mensajes	35
Implementación de redes convolucionales	35
Ejecución de experimentos sintéticos	42
Datos reales y adaptación de dominio	28
Análisis estadístico y visualización	20
Redacción de la memoria	34
Control de calidad y preparación de la defensa	10
Total	300

11.1.2 Fases y calendario

El proyecto se estructura entre octubre de 2025 y junio de 2026. Las fases se solapan de forma controlada. La revisión bibliográfica continúa durante el desarrollo, mientras que la redacción se inicia antes de cerrar los resultados para documentar decisiones que de otro modo podrían perderse.

Tabla 11.2. Calendario general del Trabajo de Fin de Grado.

Periodo	Actividades principales
Octubre y noviembre de 2025	Definición del problema, revisión clínica, análisis de trabajos relacionados y diseño inicial
Diciembre de 2025 y enero de 2026	Desarrollo del simulador, validadores y formatos de imagen
Febrero y marzo de 2026	Canalización VLM, mensajes, esquemas JSON y controles de aprendizaje en contexto
Abril de 2026	Diseño e integración de las redes convolucionales y pruebas de reproducibilidad
Mayo de 2026	Experimentos sintéticos, preparación de datos reales y adaptación de dominio
Junio de 2026	Análisis, cierre de la memoria, revisión integral y defensa




Figura 11.1. Plan temporal del proyecto y cierre de los experimentos principales.

Los hitos de control son la validación visual del simulador, la reproducción de una ejecución VLM, la integración de la CNN, el cierre de los pliegues de datos reales, la congelación de resultados y la generación de la versión final de la memoria. Cada hito debe producir un artefacto revisable.

11.2 Gestión de riesgos

La tabla 11.3 recoge los riesgos principales, su efecto y la respuesta prevista. La probabilidad se valora de forma cualitativa antes de cerrar los experimentos.

Tabla 11.3. Riesgos principales del proyecto.

Riesgo	Prioridad	Medida de respuesta
Retraso en la integración de la CNN	Alta	Definir primero una línea base mínima reproducible y separar mejoras opcionales
Acceso insuficiente a GPU	Alta	Ejecutar pruebas pequeñas, estimar coste antes del barrido y conservar reanudación por registro
Salidas VLM inválidas	Media	Forzar esquema JSON, validar cada respuesta y contabilizar los fallos
Fuga entre entrenamiento y prueba	Alta	Crear divisiones por paciente o semilla generativa antes del ajuste y guardar los identificadores
Diferencia excesiva entre dominios	Alta	Medir transferencia directa y añadir armonización, ajuste fino y adaptación como experimentos separados
Etiquetas reales no equivalentes	Alta	Separar diagnóstico y morfología y exigir anotación específica para la segunda tarea
Cambios de versión del modelo	Media	Registrar identificador exacto, fecha, revisión y parámetros de servicio
Resultados incompletos al cerrar la memoria	Alta	Mantener marcadores explícitos y no rellenar tablas con estimaciones no ejecutadas

Los riesgos se revisan al terminar cada bloque. Una desviación no se corrige ocultando el alcance pendiente, sino reduciendo de forma explícita los experimentos secundarios y protegiendo las comparaciones principales.

11.3 Recursos y estimación de coste

El desarrollo local requiere un equipo capaz de ejecutar Python, generar imágenes y compilar LaTeX. El servicio de un modelo abierto de visión y lenguaje requiere una GPU con memoria suficiente. La configuración preparada solicita una NVIDIA A6000 para Gemma 4 E4B. La disponibilidad real, la versión de vLLM y el modelo cargado deberán registrarse en cada ejecución.

No se asigna un importe ficticio al cómputo. El coste de una campaña se calculará mediante

$$C_{\text{computo}} = \sum_{j=1}^m h_j c_j, \quad (11.1)$$

donde h_j es el número de horas consumidas por el recurso j y c_j es su precio por

hora en la fecha de contratación. El informe final incluirá tiempo de GPU, tiempo de CPU, almacenamiento y, si se emplea un servicio propietario como control, número de tokens y tarifa vigente.

También se registrará el tiempo por muestra y el consumo máximo de memoria. Estas magnitudes permiten comparar métodos aunque el precio comercial cambie. El coste de personal no se monetiza, pero queda representado por la distribución de 300 horas.

11.4 Gestión de configuración y trazabilidad

El repositorio Git actúa como fuente de verdad del código, los mensajes y la memoria. Cada campaña experimental debe guardar:

- revisión del repositorio
- versiones de Python y dependencias
- identificador del modelo y revisión de pesos
- parámetros de generación, servicio y evaluación
- semillas y divisiones de datos
- mensaje de sistema, mensaje de tarea y esquema de respuesta
- predicciones sin procesar, métricas derivadas y registro de errores

Los resultados agregados no sustituyen a las predicciones. Conservar ambos niveles permite detectar errores de análisis y recalcular métricas sin repetir inferencias costosas. Los archivos generados deben ser inmutables o incorporar un identificador de ejecución que evite sobrescrituras accidentales.

Las dependencias de redes convolucionales ya están declaradas como extra opcional del proyecto mediante PyTorch y Torchvision. El entorno de servicio vLLM se gestiona por separado porque las inferencias VLM/ICL requieren trazabilidad específica de pesos, servidor, plantilla de conversación y contrato de salida. Antes de rellenar sus celdas numéricas será necesario registrar revisión de pesos, versión del servidor, plantilla de conversación y predicciones completas.

11.5 Principios éticos

11.5.1 Proporcionalidad y finalidad

La finalidad del trabajo es comparar métodos de reconocimiento de morfologías electrocardiográficas y estudiar su transferencia con pocos datos. No se pretende automatizar

decisiones asistenciales. El alcance se limita a investigación retrospectiva y desarrollo metodológico.

La proporcionalidad exige emplear la cantidad mínima de datos necesaria, evitar variables clínicas no relacionadas con los objetivos y escoger modelos cuya complejidad esté justificada por la pregunta experimental. La disponibilidad de una variable no constituye por sí sola una razón para utilizarla.

11.5.2 Riesgos para las personas

Aunque los datos estén anonimizados o seudonimizados, un error metodológico puede generar conclusiones engañosas sobre una población clínica poco numerosa. Los principales riesgos indirectos son la sobreestimación del rendimiento, el sesgo por selección, la ausencia de calibración, la confusión entre morfología y diagnóstico y la generalización fuera del centro de origen.

La mitigación incluye validación por paciente, intervalos de confianza, documentación de exclusiones, análisis por subgrupos cuando el tamaño lo permita y lenguaje prudente. No se presentará una mejora estadística como beneficio clínico sin un estudio diseñado para esa finalidad.

11.5.3 Intervención humana

Las anotaciones clínicas y la interpretación de discrepancias requieren supervisión experta. En un uso futuro, el sistema solo podría actuar como apoyo y sus resultados deberían mostrarse junto con la señal original, la calidad de entrada y una indicación de incertidumbre. La persona responsable de la decisión no debe quedar condicionada por una salida presentada como certeza.

11.6 Protección de datos

11.6.1 Marco general

Los datos de salud son una categoría especial en el artículo 9 del Reglamento General de Protección de Datos [42]. Su tratamiento exige una base jurídica adecuada y garantías reforzadas. Los principios del artículo 5 incluyen licitud, limitación de finalidad, minimización, exactitud, limitación del plazo de conservación, integridad, confidencialidad y responsabilidad proactiva.

La protección desde el diseño y por defecto, recogida en el artículo 25, implica que la arquitectura del proyecto debe reducir la exposición desde el inicio. El artículo 32 exige medidas de seguridad apropiadas al riesgo. Cuando un tratamiento pueda implicar un alto riesgo,

el artículo 35 prevé una evaluación de impacto. Para investigación científica, el artículo 89 requiere salvaguardias técnicas y organizativas.

En España, la Ley Orgánica 3/2018 completa este marco [43]. Su disposición adicional decimoséptima regula tratamientos de datos de salud con fines de investigación y contempla el uso de datos seudonimizados bajo condiciones específicas. Entre las garantías relevantes se encuentran la separación entre información clínica y datos que permitan reidentificar, el acceso restringido y la revisión ética. La Ley 14/2007 de Investigación biomédica añade principios de consentimiento, confidencialidad y control ético [44].

11.6.2 Aplicación al proyecto

Brugada HUCA se publica sin información identificativa y su documentación declara anonimización mediante Safe Harbor [38]. El proyecto conservará únicamente los campos necesarios para las tareas definidas. Los identificadores públicos se transformarán en claves internas cuando se creen derivados, evitando incorporarlos a nombres de figura destinados a difusión.

Las medidas mínimas son almacenamiento local controlado, permisos restringidos, cifrado del dispositivo, ausencia de datos clínicos en servicios no autorizados, copias de seguridad protegidas y registro de procedencia. Las claves de API no se incluyen en el repositorio ni en la memoria. Si se incorporan datos adicionales no anónimos, deberá revisarse la base jurídica y realizarse el análisis de impacto antes del tratamiento.

La guía de la Agencia Española de Protección de Datos sobre gestión del riesgo y evaluaciones de impacto ofrece una referencia práctica para esa revisión [45]. La evaluación no puede sustituirse por una declaración genérica de anonimización.

11.7 Licencias y reutilización

El código propio deberá publicar una licencia compatible con las dependencias y con los objetivos de difusión. Las imágenes sintéticas pueden regenerarse a partir del código y sus metadatos. Para datos externos se respetarán sus términos individuales.

Brugada HUCA utiliza CC BY SA 4.0. Toda redistribución de material derivado debe conservar atribución, indicar cambios y aplicar la licencia correspondiente. PTB XL y MI-MIC IV ECG tienen condiciones de acceso y reutilización propias que deben comprobarse en su versión concreta. No se copiarán datos clínicos dentro del repositorio público.

Los pesos de modelos de terceros también pueden imponer condiciones. El identificador comercial o técnico del modelo no basta. Deben conservarse la licencia, la revisión descargada y las restricciones de uso vigentes en la fecha del experimento.

11.8 Regulación de sistemas de inteligencia artificial

11.8.1 Reglamento europeo de inteligencia artificial

El Reglamento 2024/1689 establece las normas europeas en materia de inteligencia artificial [46]. Su artículo 2 contempla una exclusión para sistemas y modelos desarrollados y puestos en servicio específicamente con la única finalidad de investigación y desarrollo científicos antes de su comercialización o puesta en servicio. Esta exclusión es coherente con el alcance metodológico del TFG, pero no cubre automáticamente una prueba clínica en condiciones reales ni un producto desplegado.

Si el sistema se integrara en un producto sanitario, su clasificación dependería de la finalidad prevista y de su relación con la legislación sectorial. El artículo 6 vincula determinados productos sujetos a evaluación de conformidad por terceros con la categoría de alto riesgo.

A fecha de 22 de junio de 2026, el texto original prevé la aplicación general desde el 2 de agosto de 2026 y un calendario específico para sistemas asociados a productos regulados. El Consejo y el Parlamento anunciaron el 7 de mayo de 2026 un acuerdo político para desplazar determinadas obligaciones de alto riesgo al 2 de diciembre de 2027 y al 2 de agosto de 2028 [47]. Mientras el cambio no quede consolidado en el texto jurídico aplicable, cualquier proyecto de despliegue debe comprobar de nuevo las fechas y obligaciones vigentes. La memoria evita presentar un calendario legislativo en transición como si fuera definitivo.

11.8.2 Producto sanitario

El Reglamento 2017/745 establece que un programa puede ser producto sanitario cuando el fabricante le atribuye una finalidad médica específica [48]. La intención declarada, las funciones, los usuarios y el contexto de uso son determinantes. Un prototipo de investigación que clasifica imágenes para comparar algoritmos no adquiere por ello una autorización clínica.

Si se desarrollara una herramienta para apoyar diagnóstico, pronóstico o tratamiento, habría que analizar la cualificación y clasificación del programa, la gestión de riesgos, la evaluación clínica, el ciclo de vida y la vigilancia posterior. La guía MDCG 2019 11, revisada en junio de 2025, orienta la cualificación y clasificación del software [49]. La guía MDCG 2025 6 estudia la interacción entre el Reglamento de productos sanitarios y el Reglamento de Inteligencia Artificial [50].

Por tanto, la memoria y la interfaz deben incluir una limitación visible de uso. El sistema no está validado como producto sanitario y no debe utilizarse para diagnosticar, descartar enfermedad ni decidir tratamiento.

11.8.3 Espacio Europeo de Datos de Salud

El Reglamento 2025/327 crea el Espacio Europeo de Datos de Salud [51]. Su aplicación comienza de forma escalonada desde el 26 de marzo de 2027. Aunque no constituye la base jurídica inmediata de este trabajo, será relevante para futuros proyectos que reutilicen datos sanitarios a escala europea. Cualquier extensión deberá revisar sus reglas de acceso, finalidad secundaria y entornos seguros.

11.9 Equidad, robustez y transparencia

La base sintética no representa grupos demográficos. Por tanto, no permite medir diferencias de rendimiento por sexo, edad, origen o comorbilidad. La fase real deberá describir las variables disponibles y analizar subgrupos solo cuando exista tamaño suficiente y una razón clínica. La ausencia de un análisis no debe interpretarse como ausencia de sesgo.

El modelo puede aprender propiedades del renderizado, del equipo o del centro. Las pruebas de robustez incluirán cambios de resolución, cuadrícula, recorte, contraste y ruido dentro de límites plausibles. Una caída intensa ante transformaciones inocuas indicaría dependencia de señales espurias.

La transparencia se apoya en mensajes exactos, esquemas de respuesta, versiones, matrices de confusión, ejemplos de error y descripción de datos. Las explicaciones visuales como Grad CAM pueden ayudar a auditar una CNN [29], pero no demuestran causalidad ni corrección clínica.

11.10 Sostenibilidad

El impacto ambiental se reduce evitando barridos sin hipótesis, reutilizando predicciones, ejecutando primero pruebas pequeñas y deteniendo configuraciones claramente defectuosas según reglas previas. Se preferirán modelos abiertos de tamaño compatible con el objetivo experimental y se informará del tiempo de acelerador.

La comparación entre CNN y VLM debe considerar no solo la métrica, sino también coste de entrenamiento, coste por inferencia, latencia y posibilidad de despliegue local. Un incremento marginal de rendimiento puede no justificar un aumento grande de consumo.

11.11 Compromiso de uso responsable

El producto de este TFG es un prototipo de investigación reproducible. Sus resultados deberán leerse dentro del conjunto, las etiquetas y el protocolo empleados. No se autoriza su uso autónomo con pacientes. Cualquier evolución clínica necesitará validación externa, evaluación prospectiva, supervisión profesional, revisión ética y cumplimiento regulatorio

específico.

Esta limitación no reduce el valor del trabajo. Al contrario, delimita con precisión qué evidencia aporta y qué preguntas permanecen abiertas.

CAPÍTULO 12

Conclusiones

Este TFG entrega una canalización reproducible para estudiar el ECG como imagen en escenarios de pocos datos, con orientación exclusiva de triaje dentro del circuito clínico de Brugada (revisión experta $\rightarrow$ posible recolocación de V1/V2 $\rightarrow$ provocación farmacológica con ajmalina/flecainida $\rightarrow$ decisión clínica). La arquitectura experimental se plantea en dos ramas complementarias: CNN entrenadas con pocos ejemplos y modelos de visión y lenguaje (VLM) usados mediante aprendizaje en contexto (ICL). La evidencia cuantitativa cerrada corresponde a la primera rama —simulación, entrenamiento CNN, evaluación real, adaptación de dominio, Grad-CAM y auditoría final— y su contribución principal es precisamente demostrar los límites de este enfoque cuando los datos son escasos, estableciendo así el precedente empírico que fundamenta la segunda rama.

12.1 Conclusiones principales

La conclusión más importante de este trabajo es que, con el volumen de datos disponible en Brugada HUCA, entrenar una CNN específica no resulta suficiente para alcanzar un rendimiento robusto de triaje, ni siquiera con preentrenamiento visual estándar ni con adaptación de dominio. Este resultado no constituye un fallo, sino una contribución positiva: proporciona la evidencia empírica necesaria para justificar la exploración de VLM/ICL como alternativa central del trabajo. Si una CNN convencional no logra generalizar con pocos ejemplos etiquetados, la pregunta metodológica que guía esta investigación —cuándo conviene entrenar un modelo específico frente a recurrir al aprendizaje en contexto— puede ya responderse desde el lado CNN.

Las conclusiones que sustentan esta afirmación son las siguientes:

1. **La CNN aprende señal visual en el dominio sintético.** Con $K = 32$, ResNet18 alcanza una exactitud equilibrada de 0,848, sensibilidad de 0,883 y especificidad de 0,812. Esto valida el simulador como entorno controlado para morfologías QRS/ST y confirma que el protocolo de pocos ejemplos captura señal visual cuando la distribución está controlada.
2. **La transferencia a ECG clínicos reales es difícil.** En Brugada HUCA, la mejor línea

base obtiene 0,516 de exactitud equilibrada con $K = 16$. La sensibilidad es moderada, pero la especificidad baja impide utilizar el modelo como herramienta de descarte o diagnóstico. El resultado solo es compatible con investigación en triaje, siempre con revisión clínica posterior dentro del circuito de Brugada.

3. **La adaptación de dominio aporta una mejora limitada.** MMD con $K = 32$ mejora el mejor punto real hasta 0,549 de exactitud equilibrada y 0,448 de especificidad. La mejora confirma que alinear dominios puede aportar valor, pero no elimina la brecha entre simulador y HUCA.
4. **Estas tres evidencias configuran el precedente para VLM/ICL.** Si la ruta de entrenamiento específico —incluyendo adaptación de dominio— no produce un clasificador robusto con K ejemplos, la hipótesis natural es que un modelo VLM preentrenado con conocimiento médico amplio pueda aprovechar esos mismos K ejemplos como demostraciones en contexto, obteniendo una mejor relación entre rendimiento, coste computacional y cantidad de datos etiquetados. La comparación VLM/ICL constituye, por tanto, el eje central de la investigación y no una extensión opcional.

12.2 Objetivos alcanzados

Se han alcanzado los objetivos técnicos de la rama CNN:

- Generación y validación de un conjunto sintético QRS/ST con 100 pacientes y 300 imágenes.
- Construcción de Brugada HUCA procesado con 317 pacientes incluidos, 951 imágenes y 46 exclusiones documentadas.
- Ejecución completa de CNN ResNet18 para $K = \{2, 4, 8, 16, 32\}$ y tres semillas.
- Comparación sintético-real con métricas agregadas, gráficas y análisis de Grad-CAM.
- Revisión, corrección y ejecución de la rama de adaptación de dominio con MMD.
- Auditoría final con todos los experimentos CNN marcados como completos.
- Diseño y documentación de la pipeline VLM/ICL como comparador central, lista para su ejecución inmediata.

12.3 Respuesta a la pregunta de investigación

La pregunta de investigación plantea cuándo resulta más ventajoso entrenar un modelo visual específico frente a recurrir a modelos de visión y lenguaje con aprendizaje en contexto,

en un escenario clínico de pocos datos y orientado al triaje de sospecha de Brugada.

La respuesta obtenida hasta este punto es parcial pero sustantiva, y puede articularse en dos vertientes:

1. **Vertiente demostrada (CNN).** Con el volumen de datos disponible en Brugada HUCA, entrenar una CNN específica —incluso con adaptación de dominio— no produce un clasificador con rendimiento suficiente para triaje robusto. La CNN funciona bien en el simulador, pero la transferencia al dominio clínico real no alcanza un nivel operativo. Esta vertiente queda cerrada experimentalmente.
2. **Vertiente especificada (VLM/ICL).** La hipótesis ya queda formulada y operacionalizada: un VLM preentrenado con conocimiento visual y médico amplio —como Gemma 4 o MedGemma [26, 27]— podría aprovechar los mismos K ejemplos como demostraciones en contexto y obtener una mejor relación rendimiento/coste/datos etiquetados. Si esta hipótesis se confirma, la respuesta a la pregunta de investigación será que, en el régimen de pocos datos de Brugada, el aprendizaje en contexto supera al entrenamiento específico. Si no se confirma, el resultado será igualmente valioso, pues delimitará las condiciones bajo las cuales ninguna de las dos estrategias resulta viable sin más datos.

Es fundamental subrayar que, en ambos casos, la función del sistema es de triaje: priorizar la revisión dentro del circuito clínico de Brugada, nunca diagnosticar ni descartar la enfermedad de forma autónoma.

12.4 Trabajo futuro

12.4.1 Paso inmediato: ejecución de la rama VLM/ICL

El paso inmediato y prioritario es completar la rama VLM/ICL, que constituye el eje central de la comparación planteada en este trabajo. El plan de ejecución incluye:

- Evaluar **Gemma 4** y **MedGemma** [26, 27] con los mismos presupuestos $K = \{0, 2, 4, 8, 16, 32\}$ y las mismas particiones utilizadas en los experimentos CNN, garantizando una comparación directa.
- Conservar predicciones por muestra, validar la estructura JSON de salida, registrar versión de modelo y servidor, y aplicar la misma auditoría de completitud que se exigió a la rama CNN.
- Comparar CNN frente a VLM/ICL en las mismas métricas —exactitud equilibrada, sensibilidad, especificidad— para responder de forma definitiva a la pregunta de investigación.

- Analizar la interpretabilidad de las respuestas VLM/ICL frente a los mapas de Grad-CAM de la CNN.

12.4.2 Validación clínica ampliada

Más allá de la comparación CNN vs. VLM/ICL, la consolidación del sistema de triaje requiere:

- Obtener anotaciones morfológicas independientes en HUCA para evaluar la concordancia inter-observador.
- Evaluar la calibración de las probabilidades predichas, especialmente relevante en un contexto de triaje donde la priorización depende de umbrales clínicos.
- Revisar los errores del modelo con especialistas en el circuito de Brugada, identificando patrones de fallo sistemático.
- Explorar validación externa con datos de otros centros hospitalarios.
- Estudiar subgrupos clínicos (sexo, edad, patrón tipo 1 vs. tipo 2) para detectar sesgos o variaciones de rendimiento.

12.5 Cierre

Este trabajo cierra una base experimental honesta y reproducible. La CNN funciona bien en el simulador, funciona de manera limitada en Brugada HUCA y mejora solo modestamente con adaptación de dominio MMD. Lejos de ser un resultado negativo, esta evidencia constituye la contribución principal de la rama CNN: demuestra empíricamente que el entrenamiento específico con pocos datos no basta en este dominio clínico, estableciendo el precedente necesario para la comparación con VLM/ICL. El sistema, en cualquier caso, se concibe como herramienta de triaje dentro del circuito clínico de Brugada —priorizar la revisión experta, nunca sustituirla— y la ejecución de Gemma 4 y MedGemma con aprendizaje en contexto es el paso inmediato para completar la respuesta a la pregunta de investigación.

APÉNDICE A

Configuración experimental

Este apéndice resume la configuración necesaria para reproducir los experimentos cerrados. Los valores proceden de los scripts y artefactos generados en el repositorio, no de un plan prospectivo.

A.1 Entorno de software

El proyecto declara Python 3.12 o posterior y utiliza uv como gestor de entorno. Las dependencias directas y opcionales relevantes se recogen en la tabla A.1.

Tabla A.1. Dependencias principales declaradas por el proyecto.

Paquete	Versión mínima
Matplotlib	3.9
NumPy	2.0
OpenAI Python	2.35.1
pandas	2.2
Pillow	10.4
Pydantic	2.8
scikit-learn	1.5
tqdm	4.66
PyTorch, extra <code>cnn</code>	2.3
Torchvision, extra <code>cnn</code>	0.18
WFDB, extra <code>real-data</code>	4.1
pytest, extra <code>dev</code>	8.3
Ruff, extra <code>dev</code>	0.6

La memoria se compila con XeLaTeX a través del helper local de compilación. Los experimentos CNN se ejecutan con backend Matplotlib Agg para generar informes sin interfaz gráfica.

A.2 Conjunto sintético QRS/ST

Tabla A.2. Configuración del conjunto sintético final.

Propiedad	Valor
Fuente	<code>ecg_few.simulator</code>
Pacientes	100
Imágenes	300
Familias fuente	NORMAL, RBBB, ST_ELEVATION, T_WAVE_INVERSION, COMBINED_QRS_ST
Pacientes por familia	20
Derivaciones renderizadas	V1, V2 y V3
Frecuencia de muestreo	500 Hz
Duración del beat	900 ms
Resolución de guardado	130 ppp
Positivos derivados	20
Negativos o incompletos	80
Presupuestos	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026

La etiqueta positiva se obtiene cuando RBBB, elevación ST e inversión T están presentes simultáneamente. La agregación de paciente promedia las probabilidades de las derivaciones y después aplica el umbral seleccionado.

A.3 Brugada HUCA

Tabla A.3. Configuración del conjunto real procesado.

Propiedad	Valor
Fuente	Brugada HUCA 1.0.0
Pacientes brutos	363
Pacientes excluidos	46 por patrón basal limítrofe
Pacientes incluidos	317
Imágenes incluidas	951
Casos confirmados	116
Controles	201
Derivaciones	V1, V2 y V3
Ventana	300 ms antes de R y 600 ms después de R
Frecuencia de origen	100 Hz
Resolución de guardado	130 ppp
Separación	Leave-one-out por paciente

HUCA no contiene anotaciones independientes para las tres etiquetas morfológicas del simulador. La tarea real utiliza la etiqueta clínica `clinical_brugada`.

A.4 Configuración CNN

Tabla A.4. Hiperparámetros de la CNN final.

Propiedad	Valor
Arquitectura	ResNet18
Pesos iniciales	default de Torchvision
Entrada	RGB, 224 por 224
Salida	Un logit binario
Pérdida	BCEWithLogitsLoss con <code>loss_pos_weight=auto</code>
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Lote	32
Épocas máximas	20
Estrategia de umbral	<code>val_derived_balanced_accuracy</code>
Métrica principal	Exactitud equilibrada por paciente
Grad CAM	12 paneles en sintético y 6 en HUCA por ejecución agregada

A.5 Configuración de adaptación de dominio

Tabla A.5. Configuración de la rama de adaptación de dominio.

Propiedad	Valor
Origen etiquetado	<code>data/simulator_qrs</code>
Destino no etiquetado	<code>data/brugada_huca</code>
Métodos	SSL, CORAL, MMD y DANN
Presupuestos	$K = 16$ y $K = 32$
Semillas	42, 123 y 2026
Peso de adaptación	0,1
Escalas MMD	0,5, 1,0, 2,0 y 4,0
SSL	SimCLR durante 3 épocas, <code>ssl_pretrain_lr=0.0001</code>
Política de destino	Transductiva compartida, sin etiquetas destino en la pérdida supervisada

A.6 Configuración VLM/ICL

La línea VLM/ICL forma parte del diseño comparativo al mismo nivel que la CNN. La configuración queda congelada para que las inferencias usen la misma base experimental, las mismas particiones por paciente y los mismos presupuestos K :

- modelos abiertos: `google/gemma-4-E4B-it` y `google/medgemma-4b-it`, configurables mediante `VLM_MODELS`;
- servidor local compatible con API de vLLM/OpenAI, configurado con `VLM_API_BASE`;
- temperatura 0;
- salida JSON validada con las claves `RBBB`, `ST_ELEVATION` y `T_WAVE_INVERSION`;
- presupuestos $K = \{0, 2, 4, 8, 16, 32\}$;
- condiciones `zero_shot`, `normal`, `balanced`, `permuted` y `no_support_images`;
- salidas en `outputs/vlm_loocv/` y `reports/loocv/vlm/`.

El capítulo 9 ya incluye las tablas de salida, las condiciones experimentales y los criterios de comparación. Las celdas numéricas se rellenarán únicamente cuando existan predicciones por muestra, matrices de confusión y auditoría equivalente a la de CNN.

APÉNDICE B

Resultados completos

Este apéndice reúne las tablas de resultados agregadas utilizadas en los capítulos 7 y 8. Todas las cifras son medias sobre tres semillas salvo los recuentos, que acumulan las predicciones de las tres ejecuciones.

B.1 CNN en el conjunto sintético

Tabla B.1. Resultados completos de la CNN sobre el conjunto sintético.

K	Acc.	BA	F1	Prec.	Sens.	Esp.	AP
2	0,610	$0,625 \pm 0,022$	0,401	0,291	0,650	0,600	0,268
4	0,640	$0,631 \pm 0,042$	0,407	0,304	0,617	0,646	0,268
8	0,687	$0,685 \pm 0,023$	0,468	0,357	0,683	0,688	0,383
16	0,757	$0,773 \pm 0,013$	0,569	0,442	0,800	0,746	0,534
32	0,827	$0,848 \pm 0,030$	0,673	0,545	0,883	0,812	0,614

B.2 CNN en Brugada HUCA

Tabla B.2. Resultados completos de la CNN base sobre Brugada HUCA.

K	Acc.	BA	F1	Prec.	Sens.	Esp.	AP
2	0,460	$0,509 \pm 0,010$	0,484	0,372	0,693	0,325	0,404
4	0,450	$0,509 \pm 0,023$	0,493	0,373	0,730	0,289	0,388
8	0,442	$0,490 \pm 0,018$	0,469	0,360	0,672	0,308	0,383
16	0,478	$0,516 \pm 0,023$	0,480	0,379	0,658	0,375	0,478
32	0,461	$0,499 \pm 0,012$	0,466	0,366	0,644	0,355	0,423

B.3 Comparación de dominios

Tabla B.3. Exactitud equilibrada sintética frente a real.

K	Sintético BA	HUCA BA
2	0,625	0,509
4	0,631	0,509
8	0,685	0,490
16	0,773	0,516
32	0,848	0,499

B.4 Adaptación de dominio

Tabla B.4. Resultados completos de adaptación de dominio sobre Brugada HUCA.

Método	K	Acc.	BA	F1	Prec.	Sens.	Esp.
Base	16	0,478	0,516 $\pm$ 0,023	0,480	0,379	0,658	0,375
SSL	16	0,429	0,477 $\pm$ 0,027	0,458	0,351	0,658	0,297
CORAL	16	0,493	0,524 $\pm$ 0,008	0,481	0,384	0,641	0,408
MMD	16	0,484	0,516 $\pm$ 0,019	0,474	0,378	0,635	0,396
DANN	16	0,487	0,515 $\pm$ 0,019	0,470	0,378	0,621	0,410
Base	32	0,461	0,499 $\pm$ 0,012	0,466	0,366	0,644	0,355
SSL	32	0,457	0,503 $\pm$ 0,014	0,476	0,368	0,672	0,333
CORAL	32	0,499	0,528 $\pm$ 0,013	0,480	0,388	0,632	0,423
MMD	32	0,522	0,549 $\pm$ 0,029	0,498	0,404	0,649	0,448
DANN	32	0,473	0,509 $\pm$ 0,028	0,472	0,373	0,644	0,375

B.5 Artefactos

Los artefactos principales quedan en:

- reports/loocv/cnn_simulator_qrs/
- reports/loocv/cnn/
- reports/loocv/cnn_comparison/
- reports/loocv/cnn_domain_adaptation/

-
- `reports/loocv/audit/`
 - `outputs/cnn_simulator_qrs_loocv/`
 - `outputs/cnn_loocv/`
 - `outputs/cnn_domain_adaptation/`

La auditoría final marca como completos los conjuntos, los informes CNN, la comparación sintético-real y la adaptación de dominio. La línea VLM/ICL se documenta en el capítulo 9: sus tablas de salida están preparadas, pero las cifras no se mezclan con este apéndice hasta que existan inferencias auditadas por muestra. Su función dentro del TFG es comparar si el mismo presupuesto K usado como contexto puede superar la línea base CNN cerrada aquí.

APÉNDICE C

Mensajes y respuestas estructuradas

C.1 Criterio de conservación

Los mensajes forman parte de la configuración experimental. Una modificación de una palabra puede alterar la respuesta de un modelo de visión y lenguaje. Por esta razón se conservan los textos completos, su ruta y la revisión del repositorio. Los listados siguientes reproducen la versión utilizada para preparar la campaña.

C.2 Mensaje de sistema

Ruta: prompts/system/default.md

```
1 You are analyzing synthetic images of single ECG beats from a precordial-like
   lead.
2
3 This is a visual morphology classification task. It is not a patient diagnosis.
4
5 Use the waveform shown in the image as the only evidence. Follow the requested
   JSON schema exactly. Do not add explanations, markdown, or additional keys
   .
6
7 Relevant terminology:
8
9 - Q is the first negative deflection before any positive ventricular
   deflection.
10 - R is the first positive ventricular deflection.
11 - S is the negative deflection after R.
12 - R prime is a second positive deflection after S.
13 - The J point marks the transition from the end of the QRS complex to the ST
   segment.
14 - The T wave follows the ST segment and represents ventricular repolarization.
```

C.3 Tarea multietiqueta mínima

Ruta: prompts/multilabel/label_only.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Decide whether each visual morphology finding is present:
4
5 - RBBB
6 - ST_ELEVATION
7 - T_WAVE_INVERSION
8
9 Return only valid JSON with boolean values for exactly these keys:
10
11 {
12   "RBBB": true,
13   "ST_ELEVATION": false,
14   "T_WAVE_INVERSION": false
15 }
```

C.4 Tarea multietiqueta descrita

Ruta: prompts/multilabel/morphology_described.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Evaluate these visual morphology findings.
4
5 RBBB:
6
7 - Look for an RSR prime pattern with an initial positive R wave, a negative S
  wave, and a distinct second positive peak.
8 - The second positive peak should occur late in the QRS region.
9 - The terminal positive component should be visibly broad rather than a narrow
  isolated spike.
10
11 ST_ELEVATION:
12
13 - The ST region begins after the QRS complex at the J point and ends before
  the T wave.
14 - In the absence of elevation, this region remains close to the baseline.
15 - ST elevation is present when the trace remains visibly above the baseline
  after the QRS complex.
16 - The elevated region may be smooth, concave, convex, or coved.
17
18 T_WAVE_INVERSION:
```



```
19
20 - The T wave follows the ST region.
21 - An upright T wave forms a positive late deflection.
22 - T wave inversion is present when the late repolarization wave forms a
    sustained negative deflection below the baseline.
23
24 Return only valid JSON with boolean values for exactly these keys:
25
26 {
27   "RBBB": true,
28   "ST_ELEVATION": false,
29   "T_WAVE_INVERSION": false
30 }
```

C.5 Consultas binarias

C.5.1 RBBB

Ruta: prompts/binary/rbbb.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Finding: RBBB.
4
5 Operational visual definition:
6
7 - Look for an RSR prime pattern with an initial positive R wave, a negative S
    wave, and a distinct second positive peak.
8 - The second positive peak should occur late in the QRS region.
9 - The terminal positive component should be visibly broad rather than a narrow
    isolated spike.
10
11 Question: Is the RBBB morphology present?
12
13 Return only valid JSON:
14
15 {
16   "finding": "RBBB",
17   "present": true
18 }
19
20 Use `false` instead of `true` when the finding is absent.
```

C.5.2 Elevación de ST

Ruta: prompts/binary/st_elevation.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Finding: ST_ELEVATION.
4
5 Operational visual definition:
6
7 - The ST region begins after the QRS complex at the J point and ends before
  the T wave.
8 - In the absence of elevation, this region remains close to the baseline.
9 - ST elevation is present when the trace remains visibly above the baseline
  after the QRS complex.
10 - The elevated region may be smooth, concave, convex, or coved.
11
12 Question: Is ST_ELEVATION present?
13
14 Return only valid JSON:
15
16 {
17   "finding": "ST_ELEVATION",
18   "present": true
19 }
20
21 Use `false` instead of `true` when the finding is absent.
```

C.5.3 Inversión de la onda T

Ruta: prompts/binary/t_wave_inversion.md

```
1 Analyze this synthetic single-beat ECG image.
2
3 Finding: T_WAVE_INVERSION.
4
5 Operational visual definition:
6
7 - The T wave follows the ST region.
8 - An upright T wave forms a positive late deflection.
9 - T wave inversion is present when the late repolarization wave forms a
  sustained negative deflection below the baseline.
10
11 Question: Is T_WAVE_INVERSION present?
12
13 Return only valid JSON:
14
```

```
15 {  
16   "finding": "T_WAVE_INVERSION",  
17   "present": true  
18 }  
19  
20 Use `false` instead of `true` when the finding is absent.
```

C.6 Ejemplos de respuestas

Una respuesta multietiqueta válida contiene exactamente tres booleanos:

```
1 {  
2   "RBBB": true,  
3   "ST_ELEVATION": true,  
4   "T_WAVE_INVERSION": false  
5 }
```

El siguiente contenido es JSON válido, pero no cumple el contrato porque incorpora una clave adicional:

```
1 {  
2   "RBBB": true,  
3   "ST_ELEVATION": true,  
4   "T_WAVE_INVERSION": false,  
5   "explanation": "The trace is elevated."  
6 }
```

La respuesta siguiente tampoco es admisible porque utiliza cadenas en lugar de booleanos:

```
1 {  
2   "RBBB": "true",  
3   "ST_ELEVATION": "false",  
4   "T_WAVE_INVERSION": "false"  
5 }
```

En la tarea binaria, el nombre del hallazgo debe coincidir con la consulta. Una respuesta con **finding** distinto se registra como error aunque el booleano sea correcto.

C.7 Construcción del contexto

Para $K > 0$, cada demostración contiene el mensaje de tarea, una imagen y la respuesta correcta. Las demostraciones se seleccionan una vez por ejecución y se reutilizan para todas las imágenes objetivo. Los identificadores quedan almacenados en el fichero de predicciones.

El control de respuestas permutadas reasigna las soluciones entre demostraciones. El control de demostraciones sin imagen conserva el texto y la respuesta, pero retira la entrada visual de cada ejemplo. La imagen objetivo nunca se retira.

C.8 Análisis de la salida

El servidor recibe un esquema JSON cuando admite `json_schema`. El texto devuelto se valida de nuevo mediante modelos Pydantic. Se conservan el texto original, la predicción analizada, la latencia, el uso informado y cualquier excepción.

El análisis principal no elimina silenciosamente las respuestas fallidas. Una campaña puede calcular un análisis secundario sobre respuestas válidas, pero debe informar también la tasa de error y considerar los fallos como predicciones incorrectas en la comparación principal.

APÉNDICE D

Reproducción

Este apéndice describe el procedimiento utilizado para regenerar datos, entrenar las CNN, construir los informes y compilar la memoria. Los comandos se ejecutan desde la raíz del repositorio.

D.1 Preparación del entorno

```
1 uv sync --extra dev --extra cnn --extra real-data
2 uv run --no-sync python --version
```

Para las campañas CNN se recomienda fijar el backend de Matplotlib:

```
1 export MPLBACKEND=Agg
```

D.2 Generación de datos

El conjunto sintético QRS/ST se regenera con:

```
1 scripts/run/build_simulator_qrs_dataset.sh
```

El conjunto Brugada HUCA procesado se construye desde la descarga local de Physio-Net:

```
1 scripts/run/build_brugada_huca_dataset.sh
```

Los resultados esperados son:

- data/simulator_qrs: 100 pacientes, 300 imágenes y pliegues LOOCV;
- data/brugada_huca: 317 pacientes incluidos, 951 imágenes y 46 exclusiones documentadas.

D.3 Entrenamiento CNN

La campaña sintética se lanza con:

```
1 RESUME=0 scripts/run/run_cnn_simulator_qrs_loocv.sh
```

La campaña real HUCA se lanza con:

```
1 RESUME=0 scripts/run/run_cnn_loocv.sh
```

Ambos scripts usan por defecto $K = 2, 4, 8, 16, 32$, semillas 42, 123 y 2026, ResNet18, 20 épocas, lote 32 y selección de umbral por exactitud equilibrada de validación.

D.4 Adaptación de dominio

La rama de adaptación se ejecuta método a método:

```
1 METHOD=ssl RESUME=0 scripts/run/run_cnn_domain_adaptation_loocv.sh
2 METHOD=coral RESUME=0 scripts/run/run_cnn_domain_adaptation_loocv.sh
3 METHOD=mmd RESUME=0 scripts/run/run_cnn_domain_adaptation_loocv.sh
4 METHOD=dann RESUME=0 scripts/run/run_cnn_domain_adaptation_loocv.sh
```

El método `ssl` se reproduce como preentrenamiento SimCLR de tres épocas y ajuste supervisado sin pérdida adicional de adaptación. CORAL, MMD y DANN usan el peso de adaptación 0,1. La salida queda en `outputs/cnn_domain_adaptation/` y `reports/loocv/cnn_domain_adaptation/`.

D.5 Comparaciones e informes

La comparación sintético-real se reconstruye con:

```
1 scripts/run/build_loocv_comparison.sh
```

La comparación de adaptación de dominio se genera con:

```
1 uv run --no-sync python scripts/eval/compare_cnn_domain_adaptation_reports.py
```

La auditoría final se lanza con:

```
1 scripts/run/audit_loocv_results.sh
```

El cierre correcto debe incluir:

- `all_cnn_experiments_complete`: OK;
- `cnn_domain_adaptation_complete`: OK;
- `final_cnn_package_ready`: OK;
- `vlm_protocol_ready`: OK;
- `vlm_numeric_results`: por_ejecutar.

D.6 Ejecución VLM/ICL

La infraestructura VLM/ICL queda preparada como segundo brazo de la comparación. Antes de lanzar inferencias se valida el plan completo sin cargar modelos ni hacer llamadas de red:

```
1 VLM_RUNTIME=local_gpu \  
2 VLM_MODELS=google/gemma-4-E4B-it,google/medgemma-4b-it \  
3 scripts/run/validate_vlm_loocv.sh
```

La campaña completa contra un servidor vLLM compatible con la API de OpenAI se ejecuta con:

```
1 VLM_API_BASE=http://servidor:8000/v1 \  
2 VLM_MODELS=google/gemma-4-E4B-it,google/medgemma-4b-it \  
3 scripts/run/run_vlm_loocv.sh
```

Por defecto se ejecutan $K = \{0, 2, 4, 8, 16, 32\}$, semillas 42, 123 y 2026, y las condiciones `zero_shot`, `normal`, `balanced`, `permuted` y `no_support_images`. Los controles usan `CONTROL_K_VALUES=8,16,32`. Para probar la ruta de artefactos sin GPU ni API puede usarse:

```
1 VLM_RUNTIME=local_gpu \  
2 DRY_RUN_PREDICTIONS=negative \  
3 LIMIT_FOLDS=2 \  
4 K_VALUES=0,2 \  
5 CONTROL_K_VALUES=2 \  
6 MODELS=fake/gemma4,fake/medgemma \  
7 scripts/run/run_vlm_loocv.sh
```

Antes de incorporar resultados VLM al documento deben existir, como mínimo:

- `reports/loocv/vlm/vlm_campaign_manifest.json`;
- `reports/loocv/vlm/vlm_summary_by_seed.csv`;
- `reports/loocv/vlm/vlm_summary_by_k.csv`;
- `reports/loocv/vlm/vlm_summary_by_model_condition_k.csv`;
- matrices de confusión en el subdirectorio `confusion_by_model_condition_k/` del informe VLM;
- gráficas `balanced_accuracy_by_k.png` y `f1_by_k.png`;
- predicciones por muestra bajo `outputs/vlm_loocv/`, separadas por modelo, condición, K y semilla;

- auditoría con métricas VLM completas.

La comparación CNN frente a VLM se reconstruye, una vez existan inferencias, con:

```
1 VLM_CONDITION=normal scripts/run/build_loocv_comparison.sh
```

D.7 Compilación de la memoria

La memoria se compila desde el helper local de LaTeX:

```
1 python scripts/compile_latex.py D:/Python_D/ecg/ecg-few/thesis/thesis/main.tex  
   --compiler tectonic --json
```

Después de compilar, el PDF debe renderizarse a imágenes y revisarse visualmente para comprobar que las tablas, figuras, cabeceras, pies de página y referencias no presentan solapes ni elementos pendientes.

Bibliografía

- [1] Zeppenfeld, K. y colaboradores. 2022 ESC Guidelines for the management of patients with ventricular arrhythmias and the prevention of sudden cardiac death. *European Heart Journal*, 43(40), 3997–4126, 2022. <https://doi.org/10.1093/eurheartj/ehac262>.
- [2] Kligfield, P., Gettes, L. S., Bailey, J. J. y colaboradores. Recommendations for the standardization and interpretation of the electrocardiogram. Part I. The electrocardiogram and its technology. *Circulation*, 115(10), 1306–1324, 2007. <https://doi.org/10.1161/CIRCULATIONAHA.106.180200>.
- [3] Surawicz, B., Childers, R., Deal, B. J., Gettes, L. S. y colaboradores. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part III. Intraventricular conduction disturbances. *Circulation*, 119(10), e235–e240, 2009. <https://doi.org/10.1161/CIRCULATIONAHA.108.191095>.
- [4] Rautaharju, P. M., Surawicz, B. y Gettes, L. S. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part IV. The ST segment, T and U waves, and the QT interval. *Circulation*, 119(10), e241–e250, 2009. <https://doi.org/10.1161/CIRCULATIONAHA.108.191096>.
- [5] Sieira, J. y Brugada, P. The definition of the Brugada syndrome. *European Heart Journal*, 38(40), 3029–3034, 2017. <https://doi.org/10.1093/eurheartj/ehx490>.
- [6] Wilde, A. A. M., Semsarian, C., Marquez, M. F. y colaboradores. Use, misuse, and pitfalls of the drug challenge test in the diagnosis of the Brugada syndrome. *European Heart Journal*, 44(27), 2427–2439, 2023. <https://doi.org/10.1093/eurheartj/ehad295>.
- [7] BrugadaDrugs.org Advisory Board. Diagnostic drugs for Brugada syndrome. BrugadaDrugs.org, consultada el 28 de junio de 2026. https://www.brugadadrugs.org/druglist_diagnostic/.
- [8] CardioNetworks y ECGpedia. Brugada syndrome type1 example4. Wikimedia Commons, licencia CC BY-SA 3.0, consultada el 28 de junio de

2026. [https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_\(CardioNetworks_ECGpedia\).png](https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_(CardioNetworks_ECGpedia).png).
- [9] Napolitano, C. y Priori, S. G. Brugada syndrome. *Orphanet Journal of Rare Diseases*, 1, 35, 2006. <https://doi.org/10.1186/1750-1172-1-35>.
- [10] Corrado, D., Pelliccia, A., Heidbuchel, H. y colaboradores. Recommendations for interpretation of 12 lead electrocardiogram in the athlete. *European Heart Journal*, 31(2), 243–259, 2010. <https://doi.org/10.1093/eurheartj/ehp473>.
- [11] Ribeiro, A. H. y colaboradores. Automatic diagnosis of the 12 lead ECG using a deep neural network. *Nature Communications*, 11, 1760, 2020. <https://doi.org/10.1038/s41467-020-15432-4>.
- [12] Wagner, P., Strodthoff, N., Bousseljot, R. D. y colaboradores. PTB XL, a large publicly available electrocardiography dataset. *Scientific Data*, 7, 154, 2020. <https://doi.org/10.1038/s41597-020-0495-6>.
- [13] Gow, B., Pollard, T., Nathanson, L. A. y colaboradores. MIMIC IV ECG. Diagnostic Electrocardiogram Matched Subset. Version 1.0. PhysioNet, 2023. <https://doi.org/10.13026/4nqg-sb35>.
- [14] Gliner, V., Keidar, N., Makarov, V. y colaboradores. Automatic classification of healthy and disease conditions from images or digital standard 12 lead electrocardiograms. *Scientific Reports*, 10, 16331, 2020. <https://doi.org/10.1038/s41598-020-73060-w>.
- [15] Sangha, V. y colaboradores. Automated multilabel diagnosis on electrocardiographic images and signals. *Nature Communications*, 13, 1583, 2022. <https://doi.org/10.1038/s41467-022-29153-3>.
- [16] Wu, H., Patel, K. H. K., Li, X. y colaboradores. A fully automated paper ECG digitisation algorithm using deep learning. *Scientific Reports*, 12, 20963, 2022. <https://doi.org/10.1038/s41598-022-25284-1>.
- [17] Gliner, V., Makarov, V., Avetisyan, A. I., Schuster, A. y Yaniv, Y. Using domain adaptation for classification of healthy and disease conditions from mobile captured images of standard 12 lead electrocardiograms. *Scientific Reports*, 13, 14023, 2023. <https://doi.org/10.1038/s41598-023-40693-6>.
- [18] Sayadi, O., Shamsollahi, M. B. y Clifford, G. D. Synthetic ECG generation and Bayesian filtering using a Gaussian wave based dynamical model. *Physiological Measurement*, 31(10), 1309–1329, 2010. <https://doi.org/10.1088/0967-3334/31/10/005>.

-
- [19] Gillette, K. y colaboradores. MedalCare XL. 16 900 healthy and pathological synthetic 12 lead ECGs from electrophysiological simulations. *Scientific Data*, 10, 531, 2023. <https://doi.org/10.1038/s41597-023-02416-4>.
- [20] Lopez Alcaraz, J. M. y Strodthoff, N. Diffusion based conditional ECG generation with structured state space models. arXiv:2301.08227, 2023. <https://doi.org/10.48550/arXiv.2301.08227>.
- [21] Liu, R., Bai, Y., Yue, X. y Zhang, P. Teaching multimodal language models to comprehend 12 lead electrocardiographic images. *npj Digital Medicine*, 9, 349, 2026. <https://doi.org/10.1038/s41746-026-02551-3>.
- [22] Zhang, D., Lan, X., Geng, S. y colaboradores. MEETI. A multimodal ECG dataset from MIMIC IV ECG with signals, images, features and interpretations. *Scientific Data*, 13, 527, 2026. <https://doi.org/10.1038/s41597-026-06796-1>.
- [23] Alayrac, J. B., Donahue, J., Luc, P. y colaboradores. Flamingo. A visual language model for few shot learning. *Advances in Neural Information Processing Systems*, 35, 23716–23736, 2022. <https://arxiv.org/abs/2204.14198>.
- [24] Chen, S., Han, Z., He, B., Liu, J., Buckley, M., Qin, Y., Torr, P., Tresp, V. y Gu, J. Can multimodal large language models truly perform multimodal in context learning. *IEEE/CVF Winter Conference on Applications of Computer Vision*, 6000–6010, 2025. <https://doi.org/10.1109/WACV61041.2025.00585>.
- [25] Qin, L., Chen, Q., Fei, H., Chen, Z., Li, M. y Che, W. What factors affect multimodal in context learning. An in depth exploration. *Advances in Neural Information Processing Systems*, 37, 2024. <https://arxiv.org/abs/2410.20482>.
- [26] Google DeepMind. Gemma 4 model card. Google AI for Developers, 2026. https://ai.google.dev/gemma/docs/core/model_card_4.
- [27] Google Health AI Developer Foundations. MedGemma 1.5 model card. Google for Developers, 2026. <https://developers.google.com/health-ai-developer-foundations/medgemma/model-card>.
- [28] He, K., Zhang, X., Ren, S. y Sun, J. Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770–778, 2016. <https://doi.org/10.1109/CVPR.2016.90>.
- [29] Selvaraju, R. R. y colaboradores. Grad CAM. Visual explanations from deep networks via gradient based localization. *Proceedings of the IEEE International Conference on Computer Vision*, 618–626, 2017. <https://doi.org/10.1109/ICCV.2017.74>.

-
- [30] Ganin, Y. y colaboradores. Domain adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59), 1–35, 2016. <https://jmlr.org/papers/v17/15-239.html>.
- [31] Tsoumakas, G. y Katakis, I. Multi label classification. An overview. *International Journal of Data Warehousing and Mining*, 3(3), 1–13, 2007. <https://doi.org/10.4018/jdwm.2007070101>.
- [32] PyTorch Contributors. Reproducibility. PyTorch documentation, consultada el 22 de junio de 2026. <https://docs.pytorch.org/docs/stable/notes/randomness.html>.
- [33] PyTorch Contributors. BCEWithLogitsLoss. PyTorch documentation, consultada el 22 de junio de 2026. <https://docs.pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html>.
- [34] Torchvision Contributors. ResNet18 and pretrained weights. Torchvision documentation, consultada el 22 de junio de 2026. <https://docs.pytorch.org/vision/stable/models/generated/torchvision.models.resnet18.html>.
- [35] Loshchilov, I. y Hutter, F. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019. <https://arxiv.org/abs/1711.05101>.
- [36] vLLM Project. OpenAI compatible server. vLLM documentation, consultada el 22 de junio de 2026. https://docs.vllm.ai/en/latest/serving/online_serving/openai_compatible_server/.
- [37] vLLM Project. Gemma 4 usage guide. vLLM recipes, consultada el 22 de junio de 2026. <https://docs.vllm.ai/projects/recipes/en/latest/Google/Gemma4.html>.
- [38] Moris Lara, A., Álvarez López, M., Juliá del Prado, L. y colaboradores. Brugada HUCA. 12 Lead ECG Recordings from 76 Confirmed Brugada Syndrome Cases and 287 Controls. Version 1.0.0. PhysioNet, 2026. <https://doi.org/10.13026/5g9p-ya33>.
- [39] Collins, G. S., Moons, K. G. M., Dhiman, P. y colaboradores. TRIPOD+AI statement. Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378, 2024. <https://doi.org/10.1136/bmj-2023-078378>.
- [40] Moons, K. G. M., Damen, J. A. A. G., Kaul, T. y colaboradores. PROBAST+AI. An updated quality, risk of bias and applicability assessment tool for prediction models

- using regression or artificial intelligence methods. *BMJ*, 388, e082505, 2025. <https://doi.org/10.1136/bmj-2024-082505>.
- [41] España. Real Decreto 1125/2003, de 5 de septiembre, por el que se establece el sistema europeo de créditos y el sistema de calificaciones. *Boletín Oficial del Estado*, 2003. <https://www.boe.es/buscar/act.php?id=BOE-A-2003-17643>.
- [42] Unión Europea. Reglamento 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales. *Diario Oficial de la Unión Europea*, 2016. <https://eur-lex.europa.eu/eli/reg/2016/679/oj/spa>.
- [43] España. Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales. *Boletín Oficial del Estado*, 2018. <https://www.boe.es/buscar/act.php?id=BOE-A-2018-16673>.
- [44] España. Ley 14/2007, de 3 de julio, de Investigación biomédica. *Boletín Oficial del Estado*, 2007. <https://www.boe.es/buscar/act.php?id=BOE-A-2007-12945>.
- [45] Agencia Española de Protección de Datos. Gestión del riesgo y evaluación de impacto en tratamientos de datos personales. AEPD, 2021. Documento oficial de la AEPD.
- [46] Unión Europea. Reglamento 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial. *Diario Oficial de la Unión Europea*, 2024. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/spa>.
- [47] Consejo de la Unión Europea. AI Act. Council and Parliament strike a deal on rules for high risk AI and streamlining of implementation. Comunicado de prensa, 7 de mayo de 2026. Comunicado oficial del Consejo.
- [48] Unión Europea. Reglamento 2017/745 sobre los productos sanitarios. *Diario Oficial de la Unión Europea*, 2017. <https://eur-lex.europa.eu/eli/reg/2017/745/oj/spa>.
- [49] Medical Device Coordination Group. Guidance on Qualification and Classification of Software in Regulation 2017/745 and Regulation 2017/746. MDCG 2019 11 revision 1. Comisión Europea, junio de 2025. https://health.ec.europa.eu/document/download/b45335c5-1679-4c71-a91c-2915bf7c4f00_en.
- [50] Medical Device Coordination Group. Frequently Asked Questions on the Interplay between the Medical Devices Regulation and the Artificial Intelligence Act. MDCG 2025 6. Comisión Europea, 2025. https://health.ec.europa.eu/document/download/d1c9c10f-3bd2-4eb5-8512-2b9cd18a3fc2_en.

-
- [51] Unión Europea. Reglamento 2025/327 relativo al Espacio Europeo de Datos de Salud. *Diario Oficial de la Unión Europea*, 2025. <https://eur-lex.europa.eu/eli/reg/2025/327/oj/spa>.