



ESCUELA POLITÉCNICA DE INGENIERÍA DE GIJÓN

GRADO EN CIENCIA E INGENIERÍA DE DATOS

ÁREA DE CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

TÍTULO DEL TRABAJO

Análisis de ECGs con grandes modelos de lenguaje: aplicación a enfermedades raras

D. ALEJANDRO MORIS LARA

TUTOR: D. Nahuel Costa Cortez

Resumen

Este Trabajo de Fin de Grado estudia el análisis automático de electrocardiogramas cuando el dato disponible no es la señal digital original, sino una imagen del trazado. Esta situación es frecuente en la práctica clínica, donde los ECG circulan como papel escaneado, PDF o captura integrada en la historia electrónica. La mayoría de sistemas automáticos trabajan con la señal temporal, usando convoluciones unidimensionales, modelos recurrentes o arquitecturas de atención. Este trabajo explora la vía menos habitual: analizar directamente la imagen del ECG cuando solo hay pocos ejemplos etiquetados.

El caso de estudio es la sospecha de síndrome de Brugada, una canalopatía hereditaria asociada a muerte súbita. El sistema se plantea solo como apoyo al triaje: una predicción positiva prioriza la revisión por especialistas, pero no confirma ni descarta el diagnóstico. La formulación morfológica se centra en morfología compatible con bloqueo de rama derecha, elevación del segmento ST e inversión de la onda T, porque son rasgos visibles asociados al patrón de Brugada en derivaciones precordiales derechas.

La evaluación combina un simulador QRS/ST, que genera imágenes de V1, V2 y V3 con etiquetas derivadas de reglas observables, y una cohorte de ECG reales cedida por el Hospital Universitario Central de Asturias (HUCA), compuesta por 317 pacientes y 951 imágenes con etiqueta clínica binaria. Los experimentos se organizan por paciente mediante validación leave-one-out, presupuestos $K = \{2, 4, 8, 16, 32\}$ y tres semillas.

La línea base supervisada utiliza ResNet18. En el simulador alcanza una exactitud equilibrada de 0,848 para $K = 32$, con sensibilidad 0,883 y especificidad 0,812. En la cohorte cedida por el HUCA, el rendimiento se aproxima al azar: la mejor exactitud equilibrada del modelo base es 0,516 con $K = 16$. La especificidad se mantiene demasiado baja para un sistema de triaje fiable.

Estos resultados delimitan el alcance de entrenar una CNN con pocos datos reales y motivan la comparación con modelos de visión y lenguaje mediante aprendizaje en contexto. El protocolo VLM/ICL se define con Gemma 4 y MedGemma, usando las mismas imágenes, particiones y presupuestos K , como extensión reproducible del marco de evaluación.

Palabras clave: electrocardiograma como imagen, síndrome de Brugada, pocos datos, redes neuronales convolucionales, modelos de visión y lenguaje, aprendizaje en contexto, triaje clínico.

Abstract

This Bachelor's Thesis studies automatic ECG analysis when the available input is not the original digital signal but an image of the trace. This setting is common in clinical workflows, where ECGs are exchanged as scanned paper, PDF files or screenshots embedded in electronic health records. Most automatic ECG systems work on temporal signals, using one-dimensional convolutions, recurrent models or attention-based architectures. This work instead evaluates whether the rendered ECG image can be used directly when only a few labelled examples are available.

The case study is suspected Brugada syndrome, an inherited channelopathy associated with sudden cardiac death. The proposed system is restricted to triage support: a positive prediction prioritizes expert review but does not confirm or rule out the diagnosis. The morphological formulation focuses on right bundle branch block-like morphology, ST-segment elevation and T-wave inversion because these are visible features associated with the Brugada pattern in the right precordial leads.

Evaluation combines a QRS/ST simulator, which generates V1, V2 and V3 images with rule-derived labels, and a real ECG cohort ceded by the Hospital Universitario Central de Asturias (HUCA), containing 317 patients and 951 images with a binary clinical label. Experiments are performed at patient level using leave-one-out cross-validation, budgets $K = \{2, 4, 8, 16, 32\}$ and three seeds.

The supervised baseline is a ResNet18 model. On the simulator, it reaches balanced accuracy 0.848 at $K = 32$, with sensitivity 0.883 and specificity 0.812. On the cohort provided by the HUCA, performance remains close to chance: the best baseline balanced accuracy is 0.516 at $K = 16$. Specificity remains too low for reliable triage.

These results define the limits of training a CNN with very few real examples and motivate comparison with vision-language models through in-context learning. The VLM/ICL protocol is specified for Gemma 4 and MedGemma using the same images, patient splits and K budgets, as a reproducible extension of the evaluation framework.

Keywords: ECG image analysis, Brugada syndrome, limited labeled data, convolutional neural networks, vision-language models, in-context learning, clinical triage.

Índice general

Resumen	I
Abstract	II
1. Introducción	1
1.1. Motivación clínica	1
1.1.1. Circuito clínico de confirmación	2
1.1.2. Papel del sistema propuesto	2
1.2. Motivación metodológica	3
1.3. Pregunta de investigación	3
1.4. Hipótesis	4
1.5. Objetivos	4
1.6. Contribuciones	5
1.7. Alcance	5
1.8. Estructura de la memoria	6
2. Fundamentos clínicos y técnicos	7
2.1. Origen y representación del electrocardiograma	7
2.2. Morfología básica de un latido	7
2.3. Hallazgos morfológicos utilizados en el proyecto	8
2.3.1. Morfología compatible con bloqueo de rama derecha	8
2.3.2. Elevación del segmento ST	9
2.3.3. Inversión de la onda T	9
2.3.4. Síndrome de Brugada: caso motivador y circuito diagnóstico	10
2.4. La señal y la imagen como representaciones	13
2.5. Datos sintéticos y modelos gaussianos	14
2.6. Clasificación multietiqueta	15
2.7. Redes neuronales convolucionales	16
2.8. Modelos de visión y lenguaje	17
2.9. Aprendizaje multimodal en contexto	18
2.10. Explicabilidad y fidelidad	19
2.11. Cambio de dominio	19
2.12. Implicaciones para el diseño experimental	20

3. Trabajos relacionados	21
3.1. Alcance de la revisión	21
3.2. Aprendizaje profundo sobre señales electrocardiográficas	21
3.3. Análisis directo de imágenes de ECG	22
3.4. Datos sintéticos para ECG	23
3.5. Conjuntos que integran señal, imagen y texto	23
3.6. Modelos multimodales especializados en ECG	24
3.7. Aprendizaje multimodal en contexto	25
3.8. Gemma 4 y MedGemma	26
3.9. Síntesis comparativa	27
3.10. Hueco de investigación	28
4. Diseño experimental	30
4.1. Pregunta experimental	30
4.2. Canalización experimental	31
4.3. Orientación clínica: triaje, no diagnóstico	31
4.4. Unidades de análisis	32
4.5. Presupuestos de pocos ejemplos	33
4.6. Modelo CNN evaluado	33
4.7. Comprobación complementaria	34
4.8. Métricas	34
4.9. Alcance experimental	34
5. Simulador y conjunto de datos sintético	36
5.1. Objetivo del dominio sintético	36
5.2. Representación matemática	36
5.3. Muestreo temporal	38
5.4. Rangos de parámetros	39
5.5. Familias generadoras	39
5.5.1. Familia normal	39
5.5.2. Morfología RBBB	39
5.5.3. Elevación de ST	40
5.5.4. Inversión de T	40
5.5.5. Familia Brugada	40
5.6. Reglas de coherencia morfológica	41
5.7. Muestreo con rechazo	41
5.8. Validadores y semántica de las etiquetas	42
5.9. Renderizado de las señales	42
5.10. Construcción del conjunto de datos	43

5.11.	Comprobación de integración	44
5.12.	Control de calidad del simulador	45
5.12.1.	Nivel estructural	45
5.12.2.	Nivel semántico	45
5.12.3.	Nivel distribucional	45
5.12.4.	Nivel visual	45
5.13.	Riesgos de atajos visuales	46
5.14.	Limitaciones del simulador	46
6.	Modelos	48
6.1.	Entrada común	48
6.2.	Dos formas de usar K	49
6.2.1.	CNN: K como conjunto de entrenamiento	49
6.2.2.	VLM: K como demostraciones en contexto	50
6.2.3.	Síntesis: la misma evidencia, mecanismos opuestos	51
6.3.	CNN ResNet18	51
6.4.	Validación por paciente	52
6.5.	Grad CAM	53
6.6.	Comprobación sintético-real	54
6.7.	Modelos de visión y lenguaje	54
6.7.1.	Motivación: por qué un VLM para pocos datos	55
6.7.2.	Gemma 4: modelo generalista de código abierto	55
6.7.3.	MedGemma: adaptación al dominio médico	56
6.7.4.	Pipeline de inferencia VLM	56
6.8.	Controles previstos para VLM	57
6.9.	Criterio de comparación	58
7.	Resultados en el conjunto sintético	60
7.1.	Curva por presupuesto	60
7.2.	Matriz de confusión	61
7.3.	Inspección cualitativa	62
7.4.	Conclusión del dominio sintético	63
8.	Evaluación sobre datos reales	64
8.1.	Cohorte final	64
8.2.	Preprocesamiento	65
8.3.	Resultados CNN base	65
8.4.	Brecha sintético-real	67
8.5.	Inspección cualitativa	69

8.6.	Lectura de la evaluación real	69
9.	Evaluación VLM/ICL	71
9.1.	Objetivo de la línea VLM/ICL	71
9.2.	Modelos evaluados	71
9.3.	Presupuestos y demostraciones	72
9.4.	Formato de salida	72
9.5.	Condiciones experimentales	73
9.6.	Agregación por paciente	73
9.7.	Trazabilidad de la evaluación	74
9.8.	Variables de reporte	74
9.9.	Matriz metodológica	74
9.10.	Criterio de lectura	75
10.	Gestión, ética, privacidad y marco normativo	76
10.1.	Gestión de riesgos	76
10.2.	Gestión de configuración y trazabilidad	77
10.3.	Principios éticos	77
10.3.1.	Proporcionalidad y finalidad	77
10.3.2.	Riesgos para las personas	78
10.3.3.	Intervención humana	78
10.4.	Protección de datos	78
10.4.1.	Marco general	78
10.4.2.	Aplicación al proyecto	79
10.5.	Licencias y reutilización	79
10.6.	Regulación de sistemas de inteligencia artificial	79
10.6.1.	Reglamento europeo de inteligencia artificial	80
10.6.2.	Producto sanitario	80
10.6.3.	Espacio Europeo de Datos de Salud	80
10.7.	Equidad, robustez y transparencia	81
10.8.	Sostenibilidad	81
10.9.	Compromiso de uso responsable	81
11.	Conclusiones	82
11.1.	Conclusión principal	82
11.2.	Trabajo futuro	82
A.	Configuración experimental	83
A.1.	Entorno de software	83

A.2.	Conjunto sintético QRS/ST	84
A.3.	Datos cedidos por el HUCA	85
A.4.	Configuración CNN	86
A.5.	Configuración de adaptación de dominio	86
A.6.	Configuración VLM/ICL	87
B.	Resultados completos	88
B.1.	CNN en el conjunto sintético	88
B.2.	CNN en la cohorte cedida por el HUCA	88
B.3.	Comparación de dominios	89
B.4.	Adaptación de dominio	89
B.5.	Trazabilidad de resultados	89
C.	Mensajes y respuestas estructuradas	91
C.1.	Criterio de conservación	91
C.2.	Mensaje de sistema	91
C.3.	Tarea multietiqueta mínima	91
C.4.	Tarea multietiqueta descrita	92
C.5.	Consultas binarias	93
C.5.1.	RBBB	93
C.5.2.	Elevación de ST	94
C.5.3.	Inversión de la onda T	94
C.6.	Ejemplos de respuestas	95
C.7.	Construcción del contexto	95
C.8.	Análisis de la salida	96
D.	Reproducción	97
D.1.	Entorno	97
D.2.	Datos	97
D.3.	Línea CNN	97
D.4.	Adaptación de dominio	98
D.5.	Línea VLM/ICL	98
D.6.	Auditoría y compilación	98
	Bibliografía	99

Índice de figuras

2.1. Ejemplos clínicos de morfología Brugada. Izquierda: ECGpedia, CC BY-SA 3.0 [8]. Derecha: Napolitano y Priori, CC BY 2.0 [9].	12
2.2. Representación esquemática de los hallazgos visuales que motivan el triaje de patrón Brugada.	12
2.3. Esquema de aprendizaje en contexto multimodal: los ejemplos etiquetados se incorporan al prompt como demostraciones y la imagen de consulta se predice sin actualizar los pesos del VLM.	18
4.1. Flujo experimental: la CNN establece la línea base supervisada y el VLM/ICL constituye el comparador central propuesto.	31
4.2. Validación leave-one-out por paciente y selección de presupuestos K	33
5.1. Generador gaussiano de un beat sintético. Los parámetros de cada átomo fijan su amplitud, posición y anchura antes de sumar las regiones P, QRS, ST y T.	38
5.2. Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador.	43
5.3. Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV.	46
6.1. Recorridos de entrada y evaluación: la CNN actualiza pesos con los K ejemplos etiquetados; el VLM los recibe como demostraciones en el prompt sin modificar parámetros.	49
6.2. Uso supervisado de los K ejemplos en la línea CNN: las muestras de entrenamiento actualizan los pesos de ResNet18 y la muestra reservada produce una predicción binaria junto con su mapa Grad-CAM.	52
6.3. Ejemplo Grad CAM del modelo CNN sobre el conjunto sintético.	54
6.4. Flujo VLM/ICL: selección de demostraciones, construcción del prompt multimodal, generación local, validación JSON y controles de ablación.	57
7.1. Exactitud equilibrada de la CNN sobre el conjunto sintético según el presupuesto K	61
7.2. Matriz de confusión agregada del conjunto sintético para $K = 32$	62
7.3. Ejemplo Grad CAM del modelo sintético.	63

8.1.	Preprocesamiento de los ECG cedidos por el HUCA para V1, V2 y V3. . .	65
8.2.	Exactitud equilibrada de la CNN base sobre los datos cedidos por el HUCA.	66
8.3.	Matriz de confusión agregada de la cohorte cedida por el HUCA para $K = 16$.	67
8.4.	Comparación de exactitud equilibrada entre el conjunto sintético y la cohorte cedida por el HUCA.	68
8.5.	Comparación de F1 entre el conjunto sintético y la cohorte cedida por el HUCA.	68
8.6.	Ejemplo Grad CAM del modelo CNN sobre los datos cedidos por el HUCA.	69

Índice de tablas

2.1. Relación entre el concepto clínico y la traducción experimental utilizada en el proyecto	13
2.2. Comparación entre la señal temporal y la imagen electrocardiográfica . . .	14
3.1. Síntesis de trabajos relacionados	28
4.1. Conjuntos utilizados en los experimentos cerrados.	32
4.2. Alcance de los bloques experimentales.	35
5.1. Átomos utilizados para construir un beat	37
5.2. Relación entre familias generadoras y rasgos favorecidos	40
5.3. Criterios de los validadores sintéticos	42
5.4. Configuración final del conjunto sintético QRS/ST	44
6.1. Uso del presupuesto K según la familia de modelos.	51
6.2. Configuración CNN utilizada en las campañas finales.	52
7.1. Resultados CNN ResNet18 sobre el conjunto sintético QRS/ST.	60
8.1. Cohorte cedida por el HUCA utilizada en la evaluación CNN.	64
8.2. Resultados CNN ResNet18 sobre los datos cedidos por el HUCA.	66
9.1. Condiciones experimentales VLM/ICL.	73
9.2. Campos de reporte para una campaña VLM/ICL.	74
9.3. Matriz metodológica para comparar CNN y VLM/ICL.	75
10.1. Riesgos principales del proyecto.	76
A.1. Dependencias principales declaradas por el proyecto.	83
A.2. Configuración del conjunto sintético final.	84
A.3. Configuración del conjunto real procesado.	85
A.4. Hiperparámetros de la CNN final.	86
A.5. Configuración de la línea de adaptación de dominio.	86
A.6. Configuración resumida de la línea VLM/ICL.	87
B.1. Resultados completos de la CNN sobre el conjunto sintético.	88

B.2. Resultados completos de la CNN base sobre los datos cedidos por el HUCA.	88
B.3. Exactitud equilibrada sintética frente a real.	89
B.4. Resultados completos de adaptación de dominio sobre los datos cedidos por el HUCA.	89

1 Introducción

El electrocardiograma es una señal temporal, pero en la práctica clínica también circula como imagen: papel térmico, PDF, captura de pantalla o trazado incrustado en una historia electrónica. Esta segunda forma de representación no es marginal. Con frecuencia es la única disponible para revisión retrospectiva, intercambio entre servicios o análisis documental. Aun así, la mayoría de sistemas automáticos de ECG se han diseñado sobre la señal digital, con modelos recurrentes, convoluciones unidimensionales o arquitecturas basadas en atención. Este TFG explora una vía menos habitual: analizar directamente el trazado renderizado como imagen.

La pregunta aparece en un contexto de pocos datos etiquetados. Si solo se dispone de un número reducido de ECG confirmados, entrenar un modelo visual específico puede llevar a sobreajuste o a una generalización pobre. Una alternativa reciente consiste en usar modelos de visión y lenguaje (VLM) mediante aprendizaje en contexto (ICL), incorporando los ejemplos etiquetados en el prompt durante la inferencia y sin modificar los pesos del modelo. El objetivo del trabajo es comparar ambas formas de usar el mismo presupuesto de ejemplos: entrenamiento supervisado de una CNN frente a demostraciones en contexto para un VLM.

Un antecedente directo es el trabajo de Camba et al. [26], que estudia si los VLM con ICL pueden detectar anomalías en ECG tratados como imagen en escenarios con pocos datos. Esta memoria toma esa pregunta como punto de partida y la lleva a una comparación controlada frente a una CNN, con separación por paciente, presupuestos K comunes y evaluación específica para sospecha de Brugada.

El caso clínico elegido es la sospecha de síndrome de Brugada, una canalopatía hereditaria infrecuente asociada a muerte súbita cardíaca. El trabajo no plantea un sistema diagnóstico autónomo. Su alcance es el triaje: priorizar trazados que puedan requerir revisión temprana por especialistas. La formulación morfológica se centra en tres rasgos visibles asociados al patrón de Brugada en derivaciones precordiales derechas: morfología compatible con bloqueo de rama derecha (RBBB), elevación del segmento ST e inversión de la onda T.

1.1.- MOTIVACIÓN CLÍNICA

El síndrome de Brugada es un trastorno arrítmico hereditario relacionado con alteraciones de los canales de sodio cardíacos. Predispone a fibrilación ventricular y muerte súbita, especialmente en varones jóvenes durante el reposo o el sueño [1, 6]. Su prevalencia estimada se

sitúa entre 1:2 000 y 1:5 000, aunque probablemente esté infradiagnosticado porque muchos portadores permanecen asintomáticos.

El patrón electrocardiográfico tipo 1 se caracteriza por elevación del segmento ST de morfología convexa (*coved*) de al menos 2 mm en una derivación precordial derecha, seguida de onda T negativa [6]. Los patrones tipo 2 y tipo 3, de morfología en silla de montar, no son diagnósticos por sí solos. Además, existen fenocopias producidas por fiebre, alteraciones electrolíticas, isquemia o fármacos, que pueden imitar el trazado y deben excluirse antes de confirmar la enfermedad [5].

La dificultad aumenta porque el patrón tipo 1 puede ser intermitente. Un ECG basal normal no descarta el síndrome, y un trazado sospechoso debe interpretarse dentro del contexto clínico. Esta variabilidad convierte el problema en un buen caso de estudio para métodos de apoyo, siempre que su papel se limite a priorizar revisión y no a sustituir el juicio clínico.

1.1.1.- Circuito clínico de confirmación

Ante una sospecha de Brugada, el circuito asistencial sigue una secuencia de complejidad creciente:

1. **ECG estándar de 12 derivaciones.** Se revisan especialmente V1 y V2 en busca de patrones sugestivos.
2. **Revisión por especialista.** Un cardiólogo o electrofisiólogo valora el trazado, la historia clínica y los antecedentes familiares.
3. **Reposicionamiento de V1/V2.** Si la sospecha persiste, se registra un nuevo ECG colocando V1 y V2 en espacios intercostales superiores para aumentar la sensibilidad [5].
4. **Prueba farmacológica.** En pacientes seleccionados se administra un bloqueante del canal de sodio, como ajmalina o flecainida, en un entorno monitorizado con capacidad de reanimación [7].
5. **Decisión clínica.** El diagnóstico y las decisiones terapéuticas, incluido el seguimiento o la posible indicación de desfibrilador automático implantable, corresponden al equipo médico.

1.1.2.- Papel del sistema propuesto

El sistema desarrollado se sitúa antes de la confirmación diagnóstica. Su salida solo indica que un trazado merece revisión prioritaria. No diagnostica síndrome de Brugada, no descarta pacientes, no reemplaza la prueba farmacológica y no emite recomendaciones terapéuticas.

Esta restricción es importante por dos motivos. Primero, la baja prevalencia hace que un

sistema automático opere con una probabilidad pretest reducida. Segundo, un falso negativo puede retrasar la revisión de un paciente relevante, mientras que un exceso de falsos positivos puede saturar el circuito clínico. Por ello, las métricas se interpretan siempre como métricas de triaje y no como rendimiento diagnóstico definitivo.

1.2.- MOTIVACIÓN METODOLÓGICA

Los modelos profundos han mostrado resultados destacados en análisis de ECG cuando disponen de grandes cohortes y etiquetas consistentes [11, 15]. Sin embargo, esa condición rara vez se cumple en enfermedades de baja prevalencia. En Brugada, la obtención de ejemplos confirmados exige revisión especializada, documentación clínica y, en muchos casos, prueba farmacológica. El coste de anotación y la baja frecuencia del evento limitan el tamaño de los conjuntos disponibles.

El trabajo compara dos estrategias bajo el mismo presupuesto de ejemplos etiquetados:

1. **CNN entrenada de forma supervisada.** Una ResNet18 utiliza los K pacientes disponibles para actualizar sus pesos mediante descenso de gradiente. Este enfoque proporciona una línea base visual específica para la tarea.
2. **VLM con aprendizaje en contexto.** Gemma 4 y MedGemma [27, 28] mantienen sus pesos fijos. Los K ejemplos se introducen en el prompt como pares imagen-respuesta y condicionan la predicción de la muestra de test.

La comparación no enfrenta simplemente dos arquitecturas. Contrasta dos formas de explotar pocos datos: aprender parámetros a partir de ellos o usarlos como evidencia contextual durante la inferencia. Esta diferencia es especialmente relevante cuando el número de ejemplos es demasiado pequeño para cubrir la variabilidad clínica.

1.3.- PREGUNTA DE INVESTIGACIÓN

La pregunta central del trabajo es:

Dado un conjunto reducido de imágenes de ECG etiquetadas y una tarea de triaje de sospecha de Brugada, ¿cuándo resulta preferible entrenar una CNN específica y cuándo conviene utilizar un VLM con aprendizaje en contexto?

La pregunta se descompone en cuatro subpreguntas:

1. ¿Puede una CNN aprender rasgos visuales útiles en un simulador QRS/ST controlado con presupuestos K pequeños?

2. ¿Se mantiene ese aprendizaje al evaluar sobre datos reales cedidos por el HUCA, donde la etiqueta es clínica y la variabilidad del trazado es real?
3. ¿Aporta el ICL una ventaja cuando los mismos ejemplos se usan como demostraciones en lugar de como conjunto de entrenamiento?
4. ¿Existe un umbral de K a partir del cual el entrenamiento supervisado iguala o supera al uso en contexto?

1.4.- HIPÓTESIS

El estudio parte de las siguientes hipótesis de trabajo:

1. El simulador QRS/ST contiene señal visual suficiente para que una CNN aprenda por encima del azar.
2. Al pasar a los datos reales cedidos por el HUCA, la CNN perderá rendimiento por la variabilidad clínica, el ruido de adquisición y la diferencia entre etiqueta morfológica sintética y etiqueta clínica real.
3. En régimen de pocos ejemplos, un VLM puede aprovechar mejor los mismos K casos si se presentan como demostraciones en contexto.
4. La comparación será especialmente informativa en K bajo, donde actualizar millones de pesos con pocos pacientes resulta más frágil.

1.5.- OBJETIVOS

El objetivo general es construir una canalización experimental reproducible para comparar CNN e ICL multimodal en triaje de sospecha de Brugada a partir de ECG como imagen.

Los objetivos específicos son:

1. Generar un conjunto sintético QRS/ST con imágenes de V1, V2 y V3 y etiquetas derivadas de reglas morfológicas.
2. Construir una cohorte procesada a partir de los ECG cedidos por el HUCA, separada por paciente y con exclusiones documentadas.
3. Entrenar ResNet18 mediante validación leave-one-out para $K = \{2, 4, 8, 16, 32\}$ y tres semillas.

4. Medir exactitud equilibrada, F1, sensibilidad, especificidad, área ROC, precisión media y matrices de confusión.
5. Definir la evaluación VLM/ICL con modelos abiertos, prompts estructurados, controles y validación de formato de salida.
6. Preparar una matriz de comparación común para CNN e ICL, de modo que los resultados VLM verificables se incorporen sin cambiar el protocolo.

1.6.- CONTRIBUCIONES

Las contribuciones del trabajo son:

- Un simulador revisado de trazados QRS/ST con 100 pacientes y 300 imágenes.
- Un preprocesado de los ECG cedidos por el HUCA con 317 pacientes, 951 imágenes y 46 exclusiones documentadas.
- Resultados completos de la línea CNN en dominio sintético y en datos reales, incluyendo curvas de aprendizaje, matrices de confusión y mapas Grad-CAM.
- Un protocolo VLM/ICL preparado para Gemma 4 y MedGemma, con los mismos pacientes, presupuestos K , métricas y controles que la línea CNN.
- Una formulación de ECG como imagen para una condición rara, orientada a triaje clínico y no a diagnóstico autónomo.

1.7.- ALCANCE

El trabajo no valida un producto sanitario. Tampoco estima utilidad clínica prospectiva ni sustituye la revisión por especialista. La etiqueta sintética procede de reglas internas sobre tres hallazgos morfológicos, mientras que la etiqueta de la cohorte cedida por el HUCA representa caso Brugada confirmado frente a control. Ambas tareas están relacionadas, pero no son equivalentes.

El análisis cuantitativo de la memoria se centra en la línea CNN. El protocolo VLM/ICL se define con las mismas particiones, métricas y controles, como extensión reproducible de la comparación.

1.8.- ESTRUCTURA DE LA MEMORIA

El capítulo 2 presenta los fundamentos clínicos y técnicos. El capítulo 3 revisa trabajos sobre ECG como señal, ECG como imagen, datos sintéticos y aprendizaje en contexto. El capítulo 4 fija el diseño experimental. El capítulo 5 describe el simulador QRS/ST. El capítulo 6 detalla las configuraciones CNN y VLM. Los capítulos 7 y 8 recogen la evaluación sintética y la evaluación sobre datos reales. El capítulo 9 define el protocolo VLM/ICL. El capítulo 11 recoge el cierre del alcance evaluado.

2 Fundamentos clínicos y técnicos

2.1.- ORIGEN Y REPRESENTACIÓN DEL ELECTROCARDIOGRAMA

El electrocardiograma registra diferencias de potencial producidas por la actividad eléctrica del corazón. La señal observada en cada derivación no corresponde a una estructura anatómica aislada. Es la proyección de un proceso eléctrico tridimensional sobre un eje definido por la posición de los electrodos. Por esta razón una misma activación puede generar deflexiones distintas según la derivación desde la que se observe.

El ECG convencional utiliza doce derivaciones obtenidas a partir de diez electrodos. Las derivaciones I, II, III, aVR, aVL y aVF describen la actividad en el plano frontal. Las derivaciones V1 a V6 ofrecen una perspectiva precordial en el plano horizontal. La colocación de los electrodos, la ganancia, la velocidad de registro y el filtrado influyen en la apariencia final. Las recomendaciones de estandarización insisten en conservar estos parámetros porque una modificación técnica puede alterar amplitudes, duraciones y relaciones espaciales que después se utilizan durante la interpretación [2].

La representación clínica habitual utiliza una velocidad de 25 mm por segundo y una ganancia de 10 mm por mV. Con esa convención, un milímetro horizontal equivale a 40 ms y un milímetro vertical equivale a 0,1 mV. Estas equivalencias permiten estimar intervalos y amplitudes directamente sobre el papel. Cuando el trazado se transforma en una imagen digital, la relación física deja de estar garantizada si la imagen se redimensiona, se recorta o se fotografía sin una referencia de escala.

El presente trabajo no intenta reconstruir el vector cardíaco completo. La unidad experimental es una imagen de un latido sintético semejante a una ventana precordial derecha. Esta simplificación permite controlar el complejo QRS, el segmento ST y la onda T. También impide aplicar de forma literal criterios que requieren comparar varias derivaciones. La memoria distinguirá por tanto entre la definición clínica de un hallazgo y la aproximación visual utilizada por el simulador.

2.2.- MORFOLOGÍA BÁSICA DE UN LATIDO

Un latido normal puede describirse mediante una secuencia de ondas y segmentos. La onda P refleja la despolarización auricular. El intervalo PR incluye la propagación desde las

aurículas hasta el sistema de conducción ventricular. El complejo QRS representa la despolarización ventricular. El punto J marca la transición entre el final del QRS y el comienzo del segmento ST. La onda T se relaciona con la repolarización ventricular.

Las letras Q, R y S no designan posiciones anatómicas fijas. La onda Q es la primera deflexión negativa anterior a una deflexión positiva. La onda R es la primera deflexión positiva del complejo ventricular. La onda S es una deflexión negativa posterior a una onda R. Si aparece una segunda deflexión positiva, se denomina R prima. Esta nomenclatura describe la geometría de la señal y no establece por sí sola un diagnóstico.

El segmento ST se evalúa con respecto a una referencia isoeléctrica. En un registro real, esa referencia puede aproximarse mediante el segmento TP o el segmento PR según el contexto. La elevación o depresión no se interpreta de forma independiente. Importan la derivación, la magnitud, la morfología, la distribución espacial y el cuadro clínico. Las recomendaciones de la AHA, el ACCF y la HRS separan de forma explícita la descripción del segmento ST, la onda T y el intervalo QT porque cada elemento aporta información diferente [4].

La onda T también depende de la derivación. Una deflexión negativa puede ser fisiológica en algunas posiciones y patológica en otras. Su significado cambia según la edad, el sexo, la secuencia de activación ventricular, los cambios del segmento ST y la presencia de otras alteraciones. El proyecto no intenta resolver esta interpretación completa. La etiqueta de inversión de T indica únicamente que la región tardía del latido sintético presenta una deflexión negativa que satisface las reglas del conjunto.

2.3.- HALLAZGOS MORFOLÓGICOS UTILIZADOS EN EL PROYECTO

2.3.1.- Morfología compatible con bloqueo de rama derecha

El bloqueo de rama derecha es una alteración de la conducción intraventricular. En su forma completa se caracteriza por una duración del QRS igual o superior a 120 ms y por una morfología terminal compatible en las derivaciones apropiadas. Las recomendaciones de estandarización describen patrones como rsR prima o rSR prima en V1 o V2, junto con una onda S ensanchada en derivaciones laterales [3].

La segunda deflexión positiva en las derivaciones precordiales derechas aparece por la activación tardía del ventrículo derecho. No obstante, una forma semejante a rsR prima en una sola derivación no basta para diagnosticar un bloqueo completo. También deben considerarse la duración global del QRS, la morfología en I y V6, la posición de los electrodos y otras causas de retraso terminal.

El simulador solo representa una ventana semejante a una derivación precordial. Por ello

la etiqueta RBBB se entiende como *morfología compatible con bloqueo de rama derecha*. El validador busca dos máximos positivos separados por una deflexión negativa, exige que el segundo máximo aparezca en una posición tardía y comprueba una anchura terminal mínima. Esta regla captura una forma visual útil para el experimento, pero no reproduce el criterio clínico completo.

2.3.2.- Elevación del segmento ST

El segmento ST comienza en el punto J y termina con el inicio de la onda T. Su desplazamiento se mide con respecto a una referencia isoeléctrica. La magnitud clínicamente relevante depende de la derivación, del sexo, de la edad y de la situación diagnóstica. Además, una elevación puede aparecer en contextos diferentes, entre ellos isquemia aguda, pericarditis, repolarización precoz, alteraciones de conducción y síndromes de onda J.

La etiqueta sintética ST_ELEVATION no representa ninguna etiología concreta. El validador exige actividad ventricular suficiente y comprueba que la amplitud media alrededor del punto J y durante el segmento ST sea positiva. Se trata de una definición geométrica diseñada para separar imágenes, no de un umbral clínico expresado en milímetros.

Esta distinción evita una inferencia incorrecta. El modelo aprende a reconocer una región elevada después del QRS. No aprende por ese hecho a diferenciar un patrón de Brugada, un infarto agudo u otra causa. Esa diferenciación requeriría varias derivaciones, contexto clínico y un conjunto de etiquetas mucho más amplio.

2.3.3.- Inversión de la onda T

La onda T refleja la repolarización ventricular y suele aparecer después del segmento ST. Su polaridad normal varía entre derivaciones. También puede modificarse como consecuencia secundaria de una secuencia anómala de despolarización. Por ejemplo, una alteración de conducción puede producir cambios discordantes del segmento ST y de la onda T.

En el conjunto sintético, la inversión se define mediante una deflexión tardía negativa. El validador comprueba la profundidad mínima, la posición temporal del mínimo y la duración de la región situada por debajo de un nivel negativo. La regla incluye además condiciones sobre el QRS y el segmento ST para evitar que una oscilación temprana se confunda con una onda T.

La etiqueta T_WAVE_INVERSION expresa por tanto una propiedad visual localizada. No determina si la inversión es primaria, secundaria, fisiológica o patológica. Esta limitación deberá conservarse cuando el modelo se evalúe con datos reales.

2.3.4.- Síndrome de Brugada: caso motivador y circuito diagnóstico

El síndrome de Brugada es una canalopatía hereditaria del canal de sodio, frecuentemente asociada a mutaciones en el gen *SCN5A*, que predispone a fibrilación ventricular y muerte súbita cardíaca. Su prevalencia se estima entre 1 y 5 por cada 10 000 personas, con predominio en varones adultos jóvenes, aunque puede manifestarse a cualquier edad. A pesar de su baja prevalencia, su asociación con arritmias malignas lo convierte en un problema clínico relevante [5].

El elemento electrocardiográfico central es el patrón tipo 1, también denominado patrón *coved*: una elevación descendente del segmento ST de al menos 2 mm en las derivaciones precordiales derechas V1 o V2, seguida de una onda T negativa. Este patrón es el único considerado diagnóstico según las guías vigentes [1]. Los patrones tipo 2 y tipo 3, descritos históricamente, ya no se consideran suficientes por sí solos para establecer el diagnóstico.

La definición ha evolucionado con el tiempo. Los criterios actuales aceptan que el patrón tipo 1, ya sea espontáneo o inducido, es suficiente para el diagnóstico de síndrome de Brugada en ausencia de otras causas que lo expliquen [1]. No obstante, el contexto clínico es fundamental: síntomas como síncope inexplicado, respiración agónica nocturna, antecedentes familiares de muerte súbita o arritmias ventriculares documentadas refuerzan la sospecha y orientan la estratificación del riesgo.

Circuito diagnóstico clínico


El diagnóstico del síndrome de Brugada sigue un circuito clínico estructurado que no puede reducirse al reconocimiento automático de un patrón en una imagen:

1. **ECG basal de 12 derivaciones.** La evaluación comienza con un ECG estándar. Si el trazado muestra un patrón tipo 1 espontáneo en V1 o V2, el diagnóstico se puede establecer tras excluir fenocopias y otras causas de elevación del ST.
2. **Recolocación de derivaciones precordiales.** Cuando el ECG basal es sospechoso pero no concluyente, las guías recomiendan registrar V1 y V2 en espacios intercostales superiores (segundo o tercero en lugar del cuarto estándar). Esta maniobra aumenta la sensibilidad para detectar el patrón tipo 1, porque la posición más alta acerca el electrodo al tracto de salida del ventrículo derecho [7].
3. **Valoración clínica integral.** Se evalúan síntomas actuales y pasados, historia familiar de muerte súbita o síndrome de Brugada confirmado, exposición a fármacos o situaciones que puedan provocar fenocopias (fiebre, trastornos electrolíticos, isquemia) y comorbilidades.
4. **Prueba farmacológica con bloqueantes del canal de sodio.** En pacientes seleccionados con sospecha persistente y ECG basal no diagnóstico, se realiza una prueba de pro-


vocación farmacológica. Los fármacos empleados son bloqueantes del canal de sodio de clase I: ajmalina (la más utilizada, administrada por vía intravenosa a dosis aproximada de 1 mg/kg durante 10 minutos), flecainida, procainamida o pilsicainida según la disponibilidad local [6]. La prueba se administra en un entorno monitorizado con personal entrenado en reanimación cardiopulmonar avanzada y con equipo de desfibrilación disponible, dado el riesgo, infrecuente pero real, de desencadenar arritmias ventriculares malignas (taquicardia ventricular polimórfica o fibrilación ventricular). La monitorización electrocardiográfica continua debe prolongarse después de finalizar la infusión, ya que el patrón tipo 1 puede aparecer de forma diferida, incluso cuando los intervalos QRS y QTc han comenzado a normalizarse. La prueba se considera positiva si aparece un patrón tipo 1 durante o después de la administración del fármaco. La prueba está contraindicada en pacientes que ya presentan un patrón tipo 1 espontáneo, puesto que el diagnóstico ya está establecido [6].

5. **Estudio genético.** Se recomienda la secuenciación del gen *SCN5A* en pacientes índice para confirmar la base molecular y facilitar el cribado familiar.
6. **Decisión clínica final.** La decisión sobre estratificación de riesgo y tratamiento (seguimiento, modificación del estilo de vida, evitación de fármacos arritmogénicos, valoración de desfibrilador automático implantable) es siempre clínica, multifactorial y realizada por especialistas.

Este circuito subraya por qué el sistema desarrollado en este TFG se plantea exclusivamente como herramienta de triaje. Una predicción positiva del modelo no equivale a un diagnóstico de síndrome de Brugada. Equivale a una señal que sugiere priorizar la revisión del trazado por un especialista y, si procede, iniciar el circuito diagnóstico descrito. La decisión de realizar una prueba farmacológica, su interpretación y las consecuencias clínicas permanecen bajo responsabilidad médica [6].



(a) ECG con morfología tipo 1 en V1 y V2.



(b) Patrones tipo 1–3.

Figura 2.1.- Ejemplos clínicos de morfología Brugada. Izquierda: ECGpedia, CC BY-SA 3.0 [8]. Derecha: Napolitano y Priori, CC BY 2.0 [9].

La relación con el bloqueo de rama derecha requiere una precisión adicional. El trazado tipo 1 puede recordar visualmente a una alteración terminal del QRS. Sin embargo, el mecanismo y los criterios no son equivalentes. La onda J del patrón de Brugada se concentra en las derivaciones precordiales derechas y no necesita la onda S lateral recíproca que forma parte del bloqueo de rama derecha [10]. En este TFG, RBBB se utiliza como una etiqueta morfológica auxiliar y no como requisito clínico para Brugada.

La familia generadora BRUGADA introduce una elevación inicial del segmento ST, una caída progresiva y una onda T negativa. Después de generar la señal, los tres validadores independientes determinan qué hallazgos están presentes. La familia de origen se conserva como metadato, mientras que la tarea predictiva utiliza únicamente las etiquetas observables. Esta separación es importante: el simulador crea un caso visual para probar modelos, no una reproducción diagnóstica del síndrome.




Figura 2.2.- Representación esquemática de los hallazgos visuales que motivan el triaje de patrón Brugada.

Hallazgo	Interpretación clínica resumida	Criterio utilizado en el conjunto sintético
RBBB	Trastorno de conducción que requiere duración y morfología compatibles en varias derivaciones	Dos máximos positivos en la región ventricular, una depresión intermedia y actividad terminal tardía y ancha
Elevación ST	Desplazamiento del punto J y del segmento ST cuya relevancia depende de derivación y contexto	Media positiva en ventanas posteriores al QRS junto con actividad ventricular suficiente
Inversión T	Onda T negativa con significado dependiente de la derivación y de la secuencia de activación	Deflexión tardía negativa con profundidad, posición y duración mínimas
Brugada tipo 1	Patrón descendente en precordiales derechas que debe interpretarse dentro de criterios clínicos	Familia generadora que combina elevación inicial, descenso del ST y T negativa. No se utiliza como etiqueta diagnóstica

Tabla 2.1.- Relación entre el concepto clínico y la traducción experimental utilizada en el proyecto

2.4.- LA SEÑAL Y LA IMAGEN COMO REPRESENTACIONES

Una señal digital conserva muestras de amplitud ordenadas en el tiempo. Esta representación permite medir intervalos, aplicar filtros y comparar derivaciones con una escala conocida. La imagen es el resultado de transformar esas muestras mediante un proceso de renderizado. Contiene la forma visible del trazado, pero también incorpora decisiones de presentación.

El renderizado establece el tamaño del lienzo, la cuadrícula, el grosor de la línea, los márgenes y la disposición de las derivaciones. Una red puede utilizar cualquiera de esos elementos si están correlacionados con la etiqueta. Por ello un conjunto de imágenes debe controlar que la clase no pueda deducirse a partir de una marca, un recorte o una diferencia de resolución.

La imagen posee una ventaja práctica cuando la señal original no está disponible. Sangha y colaboradores demostraron que un modelo multietiqueta podía analizar ECG renderizados y mantener un rendimiento alto en registros externos y trazados impresos [15]. Gliner y colaboradores mostraron además que una CNN puede trabajar con fotografías de ECG, aunque la diferencia de formato requiere estrategias específicas de adaptación [17].

La alternativa consiste en digitalizar primero la imagen. El trabajo de Wu y colaboradores desarrolló una herramienta automática para segmentar trazados impresos y reconstruir las

señales [16]. La digitalización permite reutilizar modelos temporales, pero introduce errores cuando las derivaciones se solapan o la calidad del documento es baja. El análisis directo de imagen y la digitalización no son soluciones excluyentes. Responden a compromisos distintos.

Esta doble naturaleza del ECG, señal temporal e imagen, es precisamente lo que hace relevante la comparación entre CNN y VLM. Una CNN entrenada con pocos ejemplos necesita extraer toda la información visual de los píxeles disponibles. Un modelo de visión y lenguaje puede complementar la imagen con conocimiento adquirido durante su preentrenamiento sobre colecciones masivas de imágenes y texto médico. La pregunta es si ese punto de partida mejora el uso de pocos ejemplos etiquetados.

Aspecto	Señal temporal	Imagen
Información primaria	Muestras de amplitud con frecuencia conocida	Geometría visible después del renderizado
Medición de intervalos	Directa si se conoce la frecuencia de muestreo	Depende de escala, resolución y posibles transformaciones
Disponibilidad histórica	Limitada cuando solo se conserva el documento	Frecuente en informes, PDF, papel y fotografías
Variabilidad técnica	Filtros, fabricantes y frecuencia de muestreo	Incluye además cuadrícula, color, perspectiva, recorte y compresión
Modelos habituales	Convoluciones unidimensionales, recurrentes y transformadores	CNN, transformadores visuales y modelos de visión y lenguaje
Riesgo principal	Dependencia del dispositivo y del preprocesado temporal	Aprendizaje de rasgos de estilo que no pertenecen a la fisiología

Tabla 2.2.- Comparación entre la señal temporal y la imagen electrocardiográfica

2.5.- DATOS SINTÉTICOS Y MODELOS GAUSSIANOS

Los datos sintéticos permiten controlar factores que resultan difíciles de aislar en una colección clínica. Es posible generar clases equilibradas, conocer los parámetros que originan cada señal y repetir exactamente el proceso. También se evita utilizar información de pacientes durante las primeras fases del desarrollo.

Un modelo sintético no elimina el problema de los datos. Lo transforma. La validez depende de que las reglas de generación representen los rasgos que se quieren estudiar y de que no introduzcan atajos visuales. Una morfología demasiado regular puede producir un conjunto fácil para una red y poco informativo sobre el comportamiento en registros reales.

La representación mediante ondas gaussianas cuenta con precedentes en el procesamiento

de ECG. Sayadi y colaboradores describieron un modelo dinámico basado en ondas gaussianas para generar señales y realizar filtrado bayesiano [18]. En el presente proyecto se adopta una variante más simple y directamente controlable. Cada componente se define como

$$g_i(t) = a_i \exp \left(-\frac{(t - \mu_i)^2}{2\sigma_i^2} \right), \quad (2.1)$$

donde a_i controla la amplitud, μ_i determina la posición temporal y σ_i regula la anchura. El latido completo se obtiene mediante

$$x(t) = \sum_{i=1}^M g_i(t). \quad (2.2)$$

La suma incluye componentes para P, Q, R, S, R prima, punto J, segmento ST y onda T. Los parámetros se muestrean dentro de intervalos dependientes de la familia generadora. Después se aplican relaciones temporales para mantener un orden coherente. Finalmente, un validador decide si la señal satisface las condiciones mínimas de la familia solicitada.

Este procedimiento es un muestreo con rechazo. Si la señal no supera el validador se descarta y se genera otra. La estrategia mejora la consistencia interna, aunque también puede concentrar las muestras cerca de las regiones que aceptan las reglas. La tasa de aceptación y la distribución de parámetros deben analizarse como parte del control de calidad.

Los simuladores de mayor fidelidad utilizan modelos electrofisiológicos y geometrías cardíacas completas. MedalCare XL, por ejemplo, ofrece miles de ECG sintéticos de doce derivaciones obtenidos mediante simulaciones electrofisiológicas [19]. Ese enfoque persigue realismo fisiológico y requiere un coste computacional mayor. El simulador de este TFG persigue interpretabilidad y control local. No son alternativas equivalentes.

2.6.- CLASIFICACIÓN MULTITIQUETA

En clasificación multiclase cada ejemplo se asigna a una categoría exclusiva. En clasificación multitiqueta, una muestra se asocia con un subconjunto de etiquetas. Esta formulación es adecuada cuando los hallazgos pueden coexistir [32].

Sea L el número de etiquetas. Para una imagen x , la referencia se representa mediante un vector

$$\mathbf{y} = (y_1, \dots, y_L), \quad y_j \in \{0, 1\}. \quad (2.3)$$

Una red convolucional produce un logit z_j por etiqueta. La función sigmoide transforma cada logit en una probabilidad independiente

$$\hat{p}_j = \frac{1}{1 + \exp(-z_j)}. \quad (2.4)$$

La pérdida habitual es la entropía cruzada binaria

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{L} \sum_{j=1}^L [y_j \log(\hat{p}_j) + (1 - y_j) \log(1 - \hat{p}_j)]. \quad (2.5)$$

La independencia de las salidas no significa que las etiquetas sean estadísticamente independientes. La red puede aprender representaciones compartidas y aprovechar coocurrencias. Sin embargo, una coocurrencia excesiva puede crear atajos. Si todas las ondas T negativas aparecen siempre junto con elevación del ST, el modelo puede predecir una etiqueta a partir de la otra sin observar la región correcta.

La decisión binaria requiere un umbral. El valor 0,5 es una referencia simple, pero no tiene por qué ser óptimo para todas las etiquetas. Los umbrales deben fijarse con el conjunto de validación y conservarse para el test. Ajustarlos con el conjunto de prueba produciría una estimación optimista.

En los modelos de visión y lenguaje la salida no es una probabilidad sigmoide. El sistema genera texto o un objeto estructurado. La evaluación necesita convertir esa respuesta a un vector binario y registrar de forma separada las respuestas que no cumplen el esquema. Esta diferencia forma parte del protocolo y no debe ocultarse durante la comparación.

2.7.- REDES NEURONALES CONVOLUCIONALES

Una convolución aplica un conjunto de filtros compartidos sobre regiones locales de una imagen. Las primeras capas detectan transiciones y contornos. Las capas posteriores combinan esas respuestas para construir patrones de mayor escala. En una imagen de ECG, la red puede aprender inclinaciones, picos, valles y relaciones entre regiones temporales.

El uso de pesos compartidos aporta cierta tolerancia a desplazamientos pequeños. Sin embargo, el ECG no es completamente invariante a la posición. Una deflexión negativa tiene un significado diferente si aparece dentro del QRS o en la región de la onda T. La arquitectura debe conservar suficiente información espacial y el preprocesado debe alinear los latidos.

En este trabajo la referencia convolucional cerrada es una ResNet18 preentrenada. Las conexiones residuales facilitan la optimización de redes profundas al aprender transformaciones relativas a la entrada de cada bloque [29]. El uso de pesos de ImageNet no garantiza una ventaja en ECG, pero aporta filtros visuales iniciales útiles para contornos, trazos y texturas cuando el número de ejemplos etiquetados es pequeño.

La evaluación debe comprobar si esa transferencia visual se mantiene fuera del simulador.

Un resultado alto en imágenes sintéticas puede reflejar que la red aprendió reglas de renderizado, mientras que un resultado más bajo en datos reales puede revelar ruido, variabilidad clínica o diferencias en la definición de etiqueta. Los resultados de este TFG confirman que la CNN aprende bien en sintético pero falla en datos reales, lo que motiva la exploración de alternativas que no dependan exclusivamente del entrenamiento supervisado con pocos ejemplos.

2.8.- MODELOS DE VISIÓN Y LENGUAJE

Un modelo de visión y lenguaje (VLM) combina una representación visual con un modelo generativo de texto. La imagen se transforma en vectores que el componente lingüístico puede atender durante la generación. La salida puede adoptar la forma de una respuesta libre, una explicación o una estructura con campos definidos. Esta arquitectura introduce una capacidad fundamentalmente nueva respecto a las CNN: el modelo no solo procesa imágenes, sino que integra conocimiento visual y textual adquirido durante un preentrenamiento masivo.

Flamingo mostró que un modelo multimodal entrenado con secuencias intercaladas de imagen y texto podía adaptarse a tareas mediante ejemplos incluidos en el contexto [23]. Este paradigma evita actualizar los pesos para cada tarea. Las demostraciones especifican la relación entre entrada y salida durante la inferencia, eliminando la necesidad de un conjunto de entrenamiento propio.

Esta propiedad es especialmente relevante para el problema de este TFG. Cuando solo se dispone de pocos ejemplos etiquetados de un fenómeno raro como el patrón de Brugada, el entrenamiento supervisado de una CNN puede resultar insuficiente, como muestran los resultados experimentales. Un VLM, en cambio, parte de representaciones visuales y textuales adquiridas durante su preentrenamiento, que pueden incluir trazados, diagramas médicos, texto clínico y relaciones entre morfología y diagnóstico. La hipótesis central del TFG es que ese punto de partida puede ser útil cuando el conjunto etiquetado es pequeño.

Gemma 4 admite texto e imagen y permite ajustar el número de tokens visuales dedicados a cada imagen [27]. Un presupuesto visual mayor conserva más detalle, aunque incrementa el coste. Esta decisión es relevante para ECG porque los cambios morfológicos pueden ocupar una región pequeña del lienzo. La posibilidad de ejecución local facilita experimentos reproducibles y reduce la necesidad de enviar imágenes a un servicio externo.

MedGemma 1.5 es un modelo multimodal médico basado en Gemma 3. Su entrenamiento incluye radiología, histopatología, dermatología, fondo de ojo, documentos y registros clínicos [28]. La documentación oficial no sitúa el ECG entre sus modalidades principales de entrenamiento. También indica que el modelo debe adaptarse y validarse antes de cualquier uso específico. La comparación entre Gemma 4 (modelo generalista de última generación)

y MedGemma (modelo con adaptación médica sobre una base anterior) permitirá evaluar si el preentrenamiento médico específico aporta ventaja adicional en un dominio no cubierto explícitamente.

2.9.- APRENDIZAJE MULTIMODAL EN CONTEXTO

El aprendizaje en contexto (ICL) es la estrategia central propuesta en este TFG como alternativa al entrenamiento supervisado. En ICL se proporciona una secuencia de demostraciones

$$\mathcal{D}_K = \{(x_1, y_1), \dots, (x_K, y_K)\} \quad (2.6)$$

antes de la consulta objetivo x^* . El modelo genera una estimación condicionada por la instrucción y por las demostraciones

$$\hat{y}^* = f_{\theta}(x^*, \mathcal{D}_K, \text{instrucción}), \quad (2.7)$$

sin modificar los parámetros θ . Esta diferencia con el entrenamiento supervisado es fundamental. Los mismos K ejemplos etiquetados que una CNN utilizaría para actualizar millones de pesos, un VLM los recibe como contexto dentro del prompt. Los pesos del modelo permanecen fijos y el aprendizaje se produce de forma implícita durante la generación.




Figura 2.3.- Esquema de aprendizaje en contexto multimodal: los ejemplos etiquetados se incorporan al prompt como demostraciones y la imagen de consulta se predice sin actualizar los pesos del VLM.

Esta formulación convierte al número de ejemplos K en la variable de comparación natural entre ambos enfoques. Con un mismo presupuesto de K ejemplos etiquetados, la CNN debe aprender a distinguir patrones visuales; el VLM recibe esos ejemplos como guía de la tarea. La pregunta experimental es directa: ¿a partir de qué valor de K merece la pena entrenar un modelo específico y en qué rango resulta más razonable usar ICL?

El número de ejemplos no determina por sí solo la calidad del contexto. Importan la selección, la diversidad, el orden y la coherencia entre la imagen y la etiqueta. Qin y colaboradores identificaron la recuperación multimodal, el orden interno de cada demostración y la posición de la instrucción como factores relevantes [25].

Chen y colaboradores observaron que varios modelos podían depender más del texto que de la información visual contenida en las demostraciones [24]. Esta observación justifica los controles del proyecto. En el control de respuestas permutadas se conservan las imágenes y se destruye la asociación correcta con la etiqueta. En el control sin imágenes se mantiene la estructura textual y se elimina la evidencia visual de las demostraciones.

Si un modelo mejora solo con demostraciones correctas y pierde esa mejora en ambos controles, existe evidencia de que utiliza la correspondencia multimodal. Si mantiene el rendimiento con respuestas permutadas, puede estar ignorando las demostraciones o explotando la distribución de clases. Si funciona sin las imágenes de apoyo, la mejora puede proceder del formato de respuesta o de la descripción textual.

2.10.- EXPLICABILIDAD Y FIDELIDAD

Los mapas de activación de clase permiten visualizar qué regiones de una imagen influyen en una salida. Grad CAM utiliza los gradientes de una clase para ponderar los mapas de activación de una capa convolucional [30]. En una tarea de ECG, una explicación razonable debería destacar regiones distintas para QRS, segmento ST y onda T.

Un mapa visual no demuestra causalidad clínica. La resolución suele ser inferior a la imagen de entrada y el resultado depende de la capa seleccionada. También puede señalar una región amplia aunque el modelo utilice un artefacto local. Su función en este proyecto será detectar comportamientos incompatibles con la tarea, no certificar una explicación.

Las explicaciones generadas por un modelo de visión y lenguaje plantean un problema diferente. El texto puede describir correctamente la morfología aunque esa descripción no haya causado la predicción. La plausibilidad lingüística y la fidelidad del razonamiento son propiedades distintas. La evaluación principal utilizará respuestas estructuradas. Las justificaciones se analizarán como un artefacto cualitativo separado.

2.11.- CAMBIO DE DOMINIO

El dominio sintético y el dominio real difieren en fisiología, adquisición y presentación. El simulador genera un único latido alineado, con una cuadrícula uniforme y sin variabilidad entre pacientes. Un ECG real contiene ruido, deriva de línea base, diferencias de frecuencia

cardíaca, trazos superpuestos, anotaciones y múltiples derivaciones.

Una red puede obtener un rendimiento elevado en sintético y fallar en real si aprende características exclusivas del renderizado. Este fenómeno es relevante en este TFG porque la pregunta principal no es solo si una CNN aprende en un escenario controlado, sino si esa señal visual conserva valor cuando se enfrenta a ECG clínicos reales. La comprobación complementaria de este salto se presenta al final de la evaluación sobre datos reales.

2.12.- IMPLICACIONES PARA EL DISEÑO EXPERIMENTAL

Los fundamentos anteriores determinan varias decisiones de diseño que sitúan la comparación CNN frente a VLM/ICL en el centro del trabajo.

La primera decisión es que las etiquetas se describirán como hallazgos morfológicos. La segunda es que la familia BRUGADA no se convertirá en un diagnóstico automático, sino en una señal de triaje que remite al circuito clínico descrito anteriormente. La tercera, y más importante para la pregunta de investigación, es que CNN y modelos de visión y lenguaje recibirán exactamente la misma imagen objetivo y el mismo presupuesto de ejemplos K . La diferencia estará en cómo usan esos ejemplos: la CNN para actualizar pesos; el VLM como demostraciones en contexto.

La separación por pacientes no puede evaluarse en el conjunto sintético porque cada imagen se genera de forma independiente. En datos reales será obligatoria para impedir que registros de una misma persona aparezcan en entrenamiento y test. También será necesario preservar la escala o documentar cualquier normalización.

El rendimiento se analizará por etiqueta porque cada hallazgo ocupa una región distinta. La coincidencia exacta medirá si se recupera el conjunto completo. La sensibilidad y la especificidad mostrarán qué tipo de error domina. La medida F1 resumirá el equilibrio entre precisión y sensibilidad. Estas métricas serán idénticas para CNN y VLM/ICL, garantizando una comparación justa.

Finalmente, cualquier conclusión sobre utilidad clínica quedará condicionada a una evaluación real. El dominio sintético responde preguntas sobre aprendibilidad, sensibilidad al contexto y comportamiento relativo de los modelos. No permite estimar por sí solo la seguridad de un sistema médico. La lectura clínica de los resultados debe interpretarse siempre dentro del circuito de triaje: priorización de revisión seguida de circuito diagnóstico completo cuando proceda.

3 Trabajos relacionados

3.1.- ALCANCE DE LA REVISIÓN

La revisión se centra en trabajos que ayudan a responder la pregunta experimental del TFG. Se consideran cinco líneas. La primera estudia el diagnóstico automático a partir de señales de ECG. La segunda utiliza el trazado como imagen. La tercera genera datos sintéticos. La cuarta desarrolla modelos multimodales para imágenes electrocardiográficas. La quinta analiza aprendizaje en contexto con demostraciones visuales. Las dos últimas líneas reciben mayor atención porque constituyen la dirección experimental principal del proyecto.

La revisión prioriza artículos revisados por pares, conjuntos publicados con documentación técnica, guías clínicas y documentación oficial de modelos. Los resultados no se comparan como si procedieran del mismo banco de pruebas. Las bases de datos, las etiquetas y las métricas difieren entre estudios.

Esta precaución es necesaria porque una exactitud alta en una tarea binaria no puede compararse directamente con una clasificación multietiqueta. Tampoco es equivalente evaluar imágenes renderizadas desde señales limpias que fotografías de documentos clínicos. La revisión se utiliza para identificar decisiones de diseño y huecos metodológicos.

3.2.- APRENDIZAJE PROFUNDO SOBRE SEÑALES ELECTROCARDIOGRÁFICAS

El análisis automático moderno se desarrolló principalmente sobre señales temporales. Las convoluciones unidimensionales permiten aprender filtros directamente sobre las muestras y evitan diseñar manualmente todas las características. Las redes profundas amplían el campo receptivo hasta integrar información distribuida a lo largo de varios segundos.

Ribeiro y colaboradores entrenaron una red profunda con más de dos millones de ECG de doce derivaciones procedentes de una red brasileña de telemedicina [11]. El sistema reconocía seis alteraciones y fue comparado con médicos en un subconjunto anotado. El trabajo mostró que una gran colección clínica puede sostener un clasificador temporal de alto rendimiento.

Su escala también señala una limitación para enfermedades poco frecuentes. Reunir millones de registros con etiquetas fiables no es una estrategia disponible para todos los problemas. Además, las etiquetas de rutina pueden reflejar criterios locales, versiones de software y variabilidad entre observadores.

PTB XL proporcionó un punto de referencia abierto con 21 837 ECG de doce derivaciones y 71 enunciados potencialmente multietiqueta [12]. Sus particiones recomendadas facilitan comparaciones reproducibles. MIMIC IV ECG amplió la escala hasta aproximadamente 800 000 registros vinculables con información clínica [13]. Estos recursos resultan valiosos para preentrenamiento y validación, aunque no garantizan una cantidad suficiente de cada condición rara.

La literatura sobre señal establece dos referencias para el presente trabajo. Primero, una arquitectura supervisada puede aprender morfología electrocardiográfica cuando dispone de datos adecuados. Segundo, el rendimiento depende de la correspondencia entre el dominio de entrenamiento y la población objetivo. El simulador se utiliza para estudiar el régimen anterior a una gran colección clínica, no para competir con sistemas entrenados sobre millones de registros.

3.3.- ANÁLISIS DIRECTO DE IMÁGENES DE ECG

El análisis de imagen aborda situaciones en las que el trazado está disponible como documento. Gliner y colaboradores compararon redes que recibían señales digitales y redes que recibían imágenes de doce derivaciones [14]. Su estudio incluyó ocho condiciones para el modelo temporal y una evaluación visual centrada en fibrilación auricular. También aplicó transformaciones que imitaban capturas con teléfono.

Sangha y colaboradores desarrollaron una CNN multietiqueta a partir de 2 228 236 registros brasileños convertidos en imagen [15]. El modelo predijo seis etiquetas clínicas y se evaluó en una cohorte externa alemana y en ECG impresos. El estudio demostró que la representación visual puede generalizar cuando el entrenamiento incorpora escala, diversidad y variación de formato.

La principal diferencia con este TFG es la disponibilidad de datos. Sangha y colaboradores estudian aprendizaje supervisado a gran escala. El presente trabajo pregunta qué ocurre antes de alcanzar esa escala y compara el entrenamiento de una CNN con el uso inmediato de demostraciones en un modelo abierto.

La imagen puede analizarse directamente o convertirse de nuevo a señal. Wu y colaboradores desarrollaron un sistema automático de digitalización y evaluaron la correlación entre la señal reconstruida y la original [16]. Los resultados fueron altos en formatos favorables y disminuyeron cuando había solapamiento entre derivaciones. Esta variabilidad muestra que la digitalización añade sus propios fallos.

El trabajo de Gliner y colaboradores de 2023 se centra en la transferencia desde imágenes limpias a fotografías y formatos no observados [17]. Su arquitectura adversarial utiliza muestras objetivo sin etiqueta para reducir la dependencia del estilo de adquisición. Esta línea es

directamente relevante para la futura transición del simulador a datos reales.

3.4.- DATOS SINTÉTICOS PARA ECG

La generación sintética aparece en varios niveles de fidelidad. Los modelos gaussianos representan ondas mediante funciones paramétricas. Su principal ventaja es la interpretabilidad. Cada cambio puede relacionarse con amplitud, posición o anchura. Sayadi y colaboradores emplearon un modelo de este tipo dentro de un sistema dinámico para generación y filtrado [18].

Los modelos electrofisiológicos simulan la propagación eléctrica sobre geometrías cardíacas. MedalCare XL contiene 16 900 ECG sintéticos de doce derivaciones para un grupo sano y siete patologías [19]. La colección aporta señales con una base mecanística y permite estudiar condiciones difíciles de equilibrar en datos clínicos.

También existen modelos generativos aprendidos. Los modelos de difusión condicionados pueden producir señales asociadas a enunciados diagnósticos [20]. Su flexibilidad es mayor que la de un simulador manual, pero la relación entre cada parámetro y la morfología final resulta menos directa. Además, la calidad debe evaluarse mediante diversidad, fidelidad clínica y utilidad para tareas posteriores.

El simulador del proyecto se mantiene en una versión simple. No intenta reproducir un torso, un corazón tridimensional o una distribución clínica completa. Genera un latido para estudiar tres hallazgos localizados. Esta decisión reduce el realismo y mejora la capacidad de auditar las reglas.

La literatura sintética también advierte de un riesgo. Un conjunto generado puede amplificar los supuestos del modelo de simulación. Si la variabilidad no incluye ruido, escalas y formas intermedias, el clasificador aprenderá una frontera más limpia que la que existe en práctica clínica. La evaluación real sigue siendo necesaria.

3.5.- CONJUNTOS QUE INTEGRAN SEÑAL, IMAGEN Y TEXTO

Los modelos multimodales necesitan datos alineados. Una imagen sin informe permite clasificación supervisada, pero no ofrece una relación rica entre morfología y lenguaje. Un informe sin trazado tampoco permite comprobar si la explicación se apoya en evidencia visual.

MEETI se publicó en 2026 como una extensión de MIMIC IV ECG [22]. El recurso sincroniza señales, imágenes renderizadas, parámetros por latido e interpretaciones textuales. Cubre hasta 784 680 registros de 160 597 pacientes. Las imágenes se generan con una escala

estándar y las interpretaciones detalladas se producen mediante un modelo de lenguaje a partir de informes y parámetros.

MEETI reduce la barrera de entrada para estudiar alineamiento multimodal a gran escala. También requiere una lectura crítica. Parte del texto es generado por un modelo y no constituye una nueva anotación clínica independiente. El recurso resulta adecuado para pre-entrenamiento, recuperación y generación de informes, pero la evaluación diagnóstica debe conservar etiquetas y conjuntos de referencia validados.

MEETI no forma parte de los experimentos de esta memoria porque la tarea se limita a un latido sintético y tres hallazgos. Sin embargo, el conjunto ofrece una ruta de ampliación hacia doce derivaciones y permite comparar imagen, señal y texto sobre los mismos registros.

3.6.- MODELOS MULTIMODALES ESPECIALIZADOS EN ECG

Los modelos generalistas de visión y lenguaje han sido entrenados principalmente con imágenes naturales, documentos y contenido web. Un trazado electrocardiográfico posee una estructura diferente. La información se codifica en deflexiones delgadas, relaciones temporales y comparaciones entre derivaciones. Esta distancia de dominio puede limitar la interpretación directa y motiva dos aproximaciones complementarias: adaptar un modelo de gran tamaño al dominio médico, o aprovechar las capacidades de razonamiento visual de un modelo generalista sin modificar sus pesos. Ambas vías se exploran en este TFG.

Liu y colaboradores introdujeron ECGInstruct, PULSE y ECGBench [21]. ECGInstruct contiene más de un millón de pares de imagen y texto que cubren reconocimiento de características, ritmo, morfología y generación de informes. PULSE es un modelo de siete mil millones de parámetros adaptado a ECG. ECGBench evalúa cuatro tareas en nueve conjuntos e incluye imágenes sintéticas y reales.

Los autores informan que PULSE supera a modelos multimodales generalistas en su banco de pruebas [21]. Este resultado apoya la idea de que el conocimiento visual específico importa. Al mismo tiempo, PULSE se ha entrenado con una colección masiva de instrucciones. Su existencia confirma que la adaptación al dominio mejora el rendimiento, pero no responde a la misma pregunta que este TFG. El presente proyecto investiga qué rendimiento se puede obtener *sin ajuste* de pesos, utilizando un modelo generalista abierto cuando solo existen unos pocos ejemplos de una condición rara como Brugada.

PULSE marca un nivel adicional de especialización. Su incorporación al protocolo permitiría separar tres niveles: una CNN entrenada de forma supervisada con pocas muestras, un modelo generalista mediante aprendizaje en contexto y un modelo multimodal ya adaptado a ECG. La comparación entre estos niveles mediría el valor incremental de cada etapa de especialización para una tarea de baja prevalencia.

La aparición de PULSE modifica el estado del arte, pero no elimina la pregunta de investigación. Un modelo especializado puede no estar disponible para una modalidad rara, una definición local o un nuevo protocolo de anotación. El aprendizaje en contexto sigue siendo relevante durante las fases tempranas de formulación y recogida de datos, especialmente cuando el coste de entrenamiento especializado es prohibitivo y se necesita una evaluación rápida de viabilidad.

3.7.- APRENDIZAJE MULTIMODAL EN CONTEXTO

El aprendizaje en contexto (*in-context learning*, ICL) modifica el ciclo habitual de entrenamiento supervisado. En lugar de ajustar los pesos de una red mediante descenso por gradiente, los ejemplos se colocan en la ventana de contexto del modelo durante la inferencia. Cada demostración consiste en una imagen y su etiqueta o descripción textual. El modelo produce una predicción para la imagen de consulta sin que sus pesos hayan cambiado. Esta propiedad es especialmente valiosa cuando los datos disponibles se reducen a unas pocas decenas de muestras, situación habitual en condiciones cardíacas de baja prevalencia como el síndrome de Brugada.

Flamingo estableció la arquitectura de referencia para esta capacidad. El modelo recibe secuencias intercaladas de imágenes y texto y resuelve tareas con demostraciones de ejemplo [23]. Flamingo demostró que un modelo preentrenado de gran escala puede adaptarse a tareas nuevas durante la inferencia cuando se le proporcionan ejemplos visuales y textuales relevantes. Este resultado impulsó el uso de modelos multimodales como sistemas flexibles que no requieren un ciclo de ajuste dedicado para cada tarea.

Sin embargo, los estudios posteriores demuestran que esta capacidad es frágil y que la contribución de cada componente de las demostraciones no es homogénea. Chen y colaboradores evaluaron si los modelos utilizaban realmente la parte visual de las demostraciones [24]. Encontraron una dependencia dominante del contenido textual en varios bancos de pruebas estándar. La selección de ejemplos basada en similitud visual seguía aportando valor marginal, pero la imagen dentro de la demostración podía tener menos influencia de la esperada. Este hallazgo plantea una pregunta directa para el presente trabajo: cuando las demostraciones contienen imágenes de ECG, ¿el modelo las procesa visualmente o se apoya solo en las descripciones textuales?

Qin y colaboradores estudiaron la selección, el orden y la construcción de los ejemplos [25]. Sus resultados muestran que la recuperación multimodal, la posición de la instrucción dentro del contexto y la diversidad de las demostraciones afectan al rendimiento de forma significativa. Esto impide tratar K como la única variable relevante. Dos contextos con el mismo número de ejemplos pueden contener información muy diferente y producir resultados

disparos.

Estas observaciones han influido directamente en el diseño experimental del repositorio. Cada valor positivo de K se repite con tres semillas para cuantificar la variabilidad asociada a la selección de ejemplos. Las variantes con respuestas permutadas sirven como control para detectar si el modelo está memorizando la correspondencia etiqueta-posición en lugar de razonar visualmente. Las variantes sin imagen miden la contribución del canal visual. Las instrucciones breves y las descripciones morfológicas permiten comparar el efecto del conocimiento textual explícito frente al razonamiento visual implícito. En conjunto, estos controles permiten atribuir el rendimiento a cada componente del contexto y evitar conclusiones espurias sobre la capacidad visual del modelo.

Además, la aplicación de ICL a dominios médicos especializados plantea retos adicionales que la literatura general no ha abordado en profundidad. La morfología de un ECG carece de los objetos semánticos familiares que abundan en los bancos naturales. El modelo debe interpretar deflexiones de pocos milímetros, elevaciones del segmento ST y relaciones temporales entre ondas. No es evidente que la representación visual preentrenada sobre fotografías y documentos sea suficiente para capturar estas diferencias sutiles. El presente trabajo es, hasta donde sabemos, uno de los primeros en aplicar ICL multimodal a imágenes de ECG de un solo latido con condiciones raras.

3.8.- GEMMA 4 Y MEDGEMMA

Gemma 4 es una familia abierta y multimodal publicada por Google DeepMind en 2026. Sus variantes admiten texto e imagen, contexto extenso y resolución visual variable [27]. El presupuesto de tokens visuales permite estudiar un compromiso entre detalle y coste. La posibilidad de ejecución local facilita experimentos reproducibles y reduce la necesidad de enviar imágenes a un servicio externo.

El proyecto selecciona Gemma 4 como modelo generalista principal para la línea VLM/ICL. Esta elección responde a criterios prácticos y metodológicos. En primer lugar, Gemma 4 ofrece pesos abiertos, lo cual permite una reproducibilidad completa y evita la dependencia de un servicio propietario cuyo comportamiento puede cambiar entre versiones. En segundo lugar, su ventana de contexto admite varias imágenes simultáneas, requisito imprescindible para implementar demostraciones de tipo *few-shot* con K ejemplos visuales. En tercer lugar, la compatibilidad con servidores de inferencia locales permite ejecutar cientos de evaluaciones sin coste por petición.

La elección de Gemma 4 no se justifica mediante una afirmación previa de superioridad en ECG. No existen, hasta donde sabemos, estudios publicados que evalúen este modelo sobre trazados electrocardiográficos. El rendimiento deberá establecerse mediante los experimen-

tos del capítulo 9. Precisamente esta ausencia de evaluación previa refuerza la motivación del TFG: determinar si un modelo generalista abierto puede interpretar imágenes de ECG sin ajuste cuando se le proporcionan unas pocas demostraciones.

MedGemma 1.5 se incluye como referencia médica complementaria. El modelo ha recibido adaptación con diferentes modalidades clínicas, incluyendo radiología y dermatología [28]. La documentación disponible no sitúa el ECG entre sus modalidades principales, por lo que su uso en este dominio requiere validación específica. La comparación entre Gemma 4 y MedGemma permitirá responder a una pregunta relevante: ¿el preentrenamiento médico general aporta una ventaja sobre un modelo generalista más reciente cuando la tarea consiste en interpretar un trazado de ECG de un solo latido? Si la ventaja es nula o marginal, se concluirá que la adaptación médica general no transfiere automáticamente al dominio electrocardiográfico, lo cual reforzaría la relevancia de modelos especializados como PULSE.

La comparación exige registrar versiones exactas porque Gemma 4 y MedGemma pertenecen a generaciones base distintas. También deben conservarse la resolución, el presupuesto visual, la plantilla de conversación y la configuración de inferencia. Sin esa información la comparación no sería reproducible. El protocolo del repositorio registra automáticamente estos metadatos en cada ejecución experimental.

3.9.- SÍNTESIS COMPARATIVA

La tabla 3.1 resume los trabajos más relacionados. Las cifras indican la escala del estudio original y no deben interpretarse como tamaños directamente comparables. Algunas colecciones contienen señales, otras imágenes renderizadas y otras pares multimodales.

Trabajo	Entrada	Escala	Aportación	Relación con este TFG
Ribeiro et al. [11]	Señal de doce derivaciones	Más de dos millones de ECG	Clasificación profunda de seis alteraciones	Referencia supervisada a gran escala
Wagner et al. [12]	Señal de doce derivaciones	21 837 ECG	Conjunto abierto multietiqueta con particiones recomendadas	Ejemplo de recurso real para transferencia futura
Gliner et al. [14]	Señal e imagen	41 830 registros recopilados	Comparación entre entrada digital y visual con artefactos de captura	Evidencia de viabilidad del ECG como imagen
Sangha et al. [15]	Señal e imagen	2 228 236 ECG de entrenamiento	Diagnóstico multietiqueta con validación externa e impresa	Referencia visual supervisada a gran escala
Wu et al. [16]	Imagen de papel	515 registros de validación	Reconstrucción automática de señales desde documentos	Alternativa al análisis directo de imagen
Gliner et al. [17]	Imagen limpia y fotografía	79 226 imágenes etiquetadas y 39 613 imágenes objetivo sin etiqueta	Adaptación adversarial entre formatos	Base para la transferencia sintético real
Gillette et al. [19]	Señal sintética de doce derivaciones	16 900 ECG	Simulación electrofisiológica de ocho grupos	Contraste con el simulador paramétrico simple
Liu et al. [21]	Imagen y texto	Más de un millón de instrucciones	PULSE, ECGInstruct y ECGBench	Referencia especializada para modelos multimodales
Zhang et al. [22]	Señal, imagen, parámetros y texto	Hasta 784 680 registros	Recurso multimodal alineado basado en MIMIC IV ECG	Ruta de ampliación hacia datos clínicos multimodales

Tabla 3.1.- Síntesis de trabajos relacionados

3.10.- HUECO DE INVESTIGACIÓN

La literatura revisada demuestra que el ECG puede analizarse como señal y como imagen con resultados clínicamente útiles, siempre que se disponga de una cantidad suficiente de datos etiquetados. Cuando la escala de entrenamiento se reduce a millones o cientos de miles de muestras, los modelos supervisados alcanzan un rendimiento competitivo con expertos. Sin embargo, para condiciones de baja prevalencia como el síndrome de Brugada, que puede representar menos del uno por ciento de un archivo clínico, ninguno de los trabajos revisados aborda la situación en la que el presupuesto total de ejemplos etiquetados se limita a unas pocas decenas.

La línea CNN de este TFG documenta precisamente esta situación. Los resultados del capítulo experimental muestran que una red convolucional entrenada con muy pocas muestras alcanza un rendimiento limitado y pierde capacidad diagnóstica al transferirse a un dominio real. Este resultado no es un defecto del diseño, sino la consecuencia esperable de un entrenamiento supervisado sin datos suficientes. La línea CNN sirve, por tanto, como base para

medir el coste de la especialización cuando los datos son escasos.

Frente a esta limitación, los modelos de visión y lenguaje abren una vía alternativa. En lugar de modificar pesos mediante descenso por gradiente, un VLM recibe los mismos K ejemplos como demostraciones dentro de su ventana de contexto y produce una predicción sin entrenamiento. Esta aproximación posee tres ventajas potenciales en el régimen de pocos datos. Primera, no requiere un ciclo de entrenamiento y, por tanto, elimina el riesgo de sobreajuste a un conjunto diminuto. Segunda, el modelo puede integrar conocimiento morfológico previo adquirido durante su preentrenamiento masivo. Tercera, el coste computacional de la inferencia es predecible y no depende del número de épocas.

Hasta donde sabemos, ningún trabajo publicado ha realizado la comparación directa que propone este TFG: dado un presupuesto fijo de K imágenes de ECG etiquetadas con una condición rara, ¿es más eficaz utilizar esas K muestras para entrenar una CNN desde cero o para construir un contexto de demostraciones en un VLM abierto? Los trabajos de Ribeiro et al. [11] y Sangha et al. [15] estudian el entrenamiento supervisado a gran escala. Los trabajos de Alayrac et al. [23], Chen et al. [24] y Qin et al. [25] estudian el aprendizaje en contexto multimodal sobre tareas naturales. Liu et al. [21] especializan un modelo multimodal con más de un millón de instrucciones. Ninguna de estas líneas responde a la comparación planteada con el mismo presupuesto K sobre imágenes de ECG y, específicamente, sobre una condición rara.

El TFG aborda ese hueco mediante un diseño experimental que impone un presupuesto común de ejemplos a ambos enfoques. La CNN utiliza las K muestras para modificar sus pesos. Gemma 4 y MedGemma las utilizan dentro del contexto de inferencia. Los controles de imagen eliminada y etiquetas permutadas permiten comprobar si el modelo multimodal aprovecha de verdad la correspondencia visual. El simulador proporciona una tarea conocida y verificable antes de introducir la variabilidad del dominio clínico.

La contribución metodológica no es una nueva arquitectura ni un nuevo modelo entrenado. Es una caracterización experimental del modo de uso. La línea CNN responde a la primera mitad de la pregunta: qué ocurre cuando se entrena un modelo visual específico con muy pocos ejemplos y se intenta transferirlo a un dominio real. Los resultados muestran que el entrenamiento con datos insuficientes produce modelos frágiles. La línea VLM/ICL fija la segunda mitad de la comparación: comprobar, con el mismo presupuesto K , si usar los ejemplos como contexto mejora la relación entre rendimiento, coste y trazabilidad frente a usarlos como entrenamiento.

4 Diseño experimental

La pregunta central de este TFG es si un modelo de visión y lenguaje (VLM) con aprendizaje en contexto (ICL) puede aprovechar mejor que una CNN un número reducido de ECG etiquetados. Para responderla, el diseño experimental se organiza en dos líneas comparables. Una usa una ResNet18 entrenada con presupuestos reducidos. La otra usa un VLM abierto que recibe los mismos ejemplos como demostraciones dentro del prompt. Ambos métodos trabajan con ECG renderizados como imagen y se evalúan por paciente.

Desde el punto de vista clínico, el sistema se concibe como herramienta de triaje, no como diagnóstico autónomo. Cualquier predicción positiva del modelo coloca al paciente dentro del circuito clínico de Brugada: una alerta prioriza la revisión experta del ECG, que puede conducir al reposicionamiento de las derivaciones V1/V2, y, en los pacientes seleccionados, a la provocación farmacológica con ajmalina o flecainida. La decisión diagnóstica definitiva recae siempre en el especialista. El modelo actúa, por tanto, como filtro de priorización que reduce el tiempo hasta la evaluación experta, sin sustituir ningún paso del protocolo.

4.1.- PREGUNTA EXPERIMENTAL

La pregunta experimental completa puede formularse así: *¿puede un VLM con ICL mejorar el uso de pocos ejemplos etiquetados respecto a una CNN entrenada de forma supervisada sobre las mismas imágenes?*

Esta formulación asigna a cada línea un papel claro:

1. **Línea CNN.** La CNN se entrena con presupuestos progresivos ($K = 2, \dots, 32$) sobre datos sintéticos y sobre datos clínicos reales. Este enfoque establece la referencia supervisada con la que se comparará el uso de ICL.
2. **Línea VLM/ICL.** El VLM recibe las mismas imágenes y los mismos presupuestos K , pero los ejemplos se introducen como demostraciones en contexto dentro del prompt, sin modificar los pesos del modelo. La hipótesis es que el conocimiento visual y lingüístico adquirido durante el preentrenamiento puede ser útil cuando los datos específicos son escasos.

La comparación entre ambas líneas se realiza sobre las mismas particiones de pacientes, los mismos valores de K y la misma métrica principal, exactitud equilibrada, para que la diferencia observada proceda del paradigma de aprendizaje y no de cambios en el protocolo

de evaluación.

4.2.- CANALIZACIÓN EXPERIMENTAL

La figura 4.1 resume el flujo experimental. Las imágenes sintéticas y reales se convierten al mismo formato visual de entrada. La ruta CNN entrena modelos con presupuestos reducidos, evalúa por paciente, agrega predicciones por derivación y produce tablas, curvas, matrices de confusión y mapas Grad-CAM. La ruta VLM reutiliza las mismas imágenes y los mismos presupuestos K , pero introduce los ejemplos como demostraciones dentro del prompt y obtiene la predicción sin ajuste de pesos. Ambas rutas desembocan en el mismo módulo de evaluación, lo que permite una comparación directa.




Figura 4.1.- Flujo experimental: la CNN establece la línea base supervisada y el VLM/ICL constituye el comparador central propuesto.

4.3.- ORIENTACIÓN CLÍNICA: TRIAJE, NO DIAGNÓSTICO

El modelo no emite un diagnóstico de síndrome de Brugada, sino una señal de sospecha que prioriza la revisión clínica. En la práctica asistencial, una predicción positiva activa el siguiente circuito:

1. **Revisión experta del ECG.** El cardiólogo examina el trazado completo para valorar la morfología del segmento ST en las derivaciones precordiales derechas.
2. **Reposicionamiento de derivaciones.** Cuando la sospecha se mantiene, se repite el

registro con V1 y V2 colocadas en posiciones superiores (segundo o tercer espacio intercostal), maniobra que aumenta la sensibilidad para detectar el patrón tipo 1.

3. **Provocación farmacológica.** En los pacientes seleccionados por el clínico, se administra ajmalina o flecainida bajo monitorización para desenmascarar un patrón de Brugada tipo 1 oculto.
4. **Decisión clínica.** El diagnóstico definitivo y las decisiones terapéuticas, como seguimiento, estudio genético o implantación de desfibrilador, corresponden al equipo médico, nunca al modelo.

Este encuadre tiene implicaciones directas sobre las métricas. Dado que el modelo es un filtro de priorización, un falso negativo (paciente con Brugada no alertado) tiene mayor coste que un falso positivo (control enviado a revisión). Sin embargo, un exceso de falsos positivos sobrecarga el circuito clínico y reduce la confianza de los usuarios. La exactitud equilibrada captura ambos aspectos al ponderar sensibilidad y especificidad por igual, y se complementa con la inspección de la curva ROC para evaluar el equilibrio entre ambos errores.

4.4.- UNIDADES DE ANÁLISIS

La unidad de separación es siempre el paciente. En el conjunto sintético, cada paciente simulado contiene tres imágenes correspondientes a V1, V2 y V3. En los datos cedidos por el HUCA, cada paciente clínico aporta las ventanas renderizadas de esas derivaciones precordiales derechas. El modelo produce una probabilidad por imagen y la decisión de paciente se obtiene promediando las probabilidades de sus derivaciones antes de aplicar el umbral.

Conjunto	Pacientes	Imágenes	Positivos	Negativos	Tarea
Sintético QRS/ST	100	300	20	80	Detección derivada de patrón Brugada: RBBB, elevación ST e inversión T presentes
Cohorte HUCA	317	951	116	201	Caso Brugada confirmado frente a control, excluyendo categorías limítrofes o no equivalentes

Tabla 4.1.- Conjuntos utilizados en los experimentos cerrados.

La diferencia entre ambas tareas debe conservarse al interpretar los resultados. En el simulador se evalúa composición morfológica derivada de reglas. En los datos cedidos por

el HUCA se evalúa una etiqueta clínica binaria disponible en los metadatos. Por tanto, el salto sintético-real no mide únicamente cambio de renderizado, sino también un cambio de definición de etiqueta.

4.5.- PRESUPUESTOS DE POCOS EJEMPLOS

Los presupuestos de entrenamiento son $K = \{2, 4, 8, 16, 32\}$. Para cada K positivo se ejecutan tres semillas: 42, 123 y 2026. La selección de ejemplos se realiza dentro de cada pliegue, sin utilizar el paciente reservado para test. El objetivo no es maximizar rendimiento con todos los datos, sino medir cómo evoluciona cada estrategia, supervisada y en contexto, cuando las etiquetas son escasas.



LOOCV por paciente, tres semillas por K positivo y agregación por probabilidad media de $V1/V2/V3$.

Figura 4.2.- Validación leave-one-out por paciente y selección de presupuestos K .

En cada ejecución se conserva el identificador de pliegue, la semilla, los pacientes usados como ejemplos, las predicciones por imagen y las métricas agregadas. El informe de auditoría final verifica 1500 predicciones de paciente en el simulador y 4755 predicciones de paciente en los datos cedidos por el HUCA para la CNN base.

4.6.- MODELO CNN EVALUADO

El modelo supervisado es ResNet18 con pesos iniciales de ImageNet y una cabeza binaria. Aunque el simulador original contiene tres hallazgos morfológicos, la campaña cerrada utiliza una etiqueta derivada de patrón Brugada: positiva cuando RBBB, elevación ST e inversión de T están simultáneamente presentes, y negativa cuando el paciente simulado es normal o incompleto. Esta reducción facilita la comparación con la cohorte cedida por el HUCA, donde la etiqueta disponible es binaria.

El entrenamiento utiliza BCEWithLogitsLoss, ponderación automática de la clase positiva cuando procede, AdamW y selección interna de umbral sobre el subconjunto de validación

del pliegue. La métrica principal es la exactitud equilibrada porque la prevalencia positiva es desigual y porque interesa medir sensibilidad y especificidad de forma simétrica.

La función de esta línea dentro del diseño es doble: por un lado, establece la referencia numérica contra la que se comparará el VLM; por otro, permite cuantificar el deterioro que introduce la escasez de datos en un enfoque supervisado estándar.

4.7.- COMPROBACIÓN COMPLEMENTARIA

Además de la línea base, la evaluación CNN incluye una comprobación del salto entre imágenes sintéticas y datos reales. Su función es valorar si parte de la pérdida de rendimiento procede del cambio de distribución visual. Esta comprobación se interpreta al final de la evaluación sobre datos reales y no condiciona la definición principal de la tarea VLM/ICL.

4.8.- MÉTRICAS

Se reportan exactitud, exactitud equilibrada, F1, precisión, sensibilidad, especificidad, área ROC y precisión media. Las tablas principales muestran la media y la desviación estándar sobre tres semillas. Además, para cada configuración se guardan matrices de confusión agregadas, curvas ROC/PR y predicciones por paciente.

La exactitud equilibrada se define como:

$$BA = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right).$$

Esta métrica es especialmente importante en el contexto de triaje: un modelo puede obtener sensibilidad moderada a costa de marcar demasiados controles como positivos. En una herramienta de priorización, ese comportamiento solo es tolerable si se declara como alerta preliminar y se acompaña del circuito de revisión clínica descrito anteriormente. En la comparación con VLM/ICL se emplea el mismo criterio principal para garantizar que el cambio de paradigma de aprendizaje no implique un cambio en la regla de evaluación.

4.9.- ALCANCE EXPERIMENTAL

La tabla 4.2 distingue los bloques con resultados medidos de los bloques definidos como protocolo. La línea CNN y la comprobación complementaria aportan valores numéricos completos. La línea VLM/ICL aporta especificación de modelos, mensajes, controles, esquema

JSON y criterios de reporte.

Bloque	Estado	Evidencia disponible
Simulador QRS/ST	Completo	Datos, pliegues LOOCV, entrenamiento CNN, tablas, curvas, matriz de confusión y Grad-CAM
Datos reales	Completo	Cohorte HUCA procesada, pliegues por paciente, entrenamiento CNN, comparación sintético-real y Grad-CAM
Comparación sintético-real	Completo	Curvas y tablas que comparan el rendimiento de la CNN en el simulador y en la cohorte real
VLM e ICL	Protocolo definido	Modelos, mensajes, controles, esquema JSON, agregación por paciente y criterios de reporte
Auditoría final	Completa para los bloques con resultados	Predicciones por paciente, matrices y métricas agregadas verificadas; protocolo VLM definido con las mismas unidades de análisis

Tabla 4.2.- Alcance de los bloques experimentales.

Esta separación mantiene completo el diseño comparativo sin mezclar resultados medidos y protocolo. Las conclusiones numéricas proceden de la CNN y de la comprobación complementaria; el capítulo 9 fija la estructura de lectura para Gemma 4 y MedGemma.

5 Simulador y conjunto de datos sintético

5.1.- OBJETIVO DEL DOMINIO SINTÉTICO

La disponibilidad de datos sintéticos permite estudiar una pregunta metodológica sin esperar a reunir una cohorte clínica extensa. En este trabajo el simulador actúa como un laboratorio controlado. Cada beat se construye a partir de componentes interpretables, se valida mediante reglas explícitas y se transforma en una imagen que puede entregarse tanto a una CNN como a un modelo de visión y lenguaje.

El objetivo no es reproducir toda la fisiología cardíaca. Un simulador clínicamente exhaustivo tendría que modelar varias derivaciones, cambios de frecuencia, interacción entre ciclos, conducción auricular y ventricular, ruido de adquisición, variación anatómica y efectos del dispositivo. El sistema implementado reduce el problema a un único beat de apariencia precordial derecha. Esta simplificación permite controlar tres hallazgos visuales que intervienen en la motivación del proyecto.

El uso de datos sintéticos cumple cuatro funciones:

1. Generar etiquetas sin depender de anotación manual para cada imagen.
2. Separar la forma de una onda de factores externos como fabricante, hospital o estilo de documento.
3. Construir presupuestos de ejemplos con tamaños exactos y semillas conocidas.
4. Reservar una familia generadora compuesta para estudiar transferencia.

La contrapartida es una brecha inevitable entre el dominio sintético y el real. El simulador puede demostrar que una tarea controlada es aprendible. No puede demostrar que el mismo rendimiento se mantenga en un ECG clínico. Esa distinción se conserva en toda la memoria.

5.2.- REPRESENTACIÓN MATEMÁTICA

Cada beat se define como una suma de diez átomos gaussianos. Para el átomo i , la amplitud a_i , el centro temporal μ_i y la anchura σ_i determinan la función

$$g_i(t) = a_i \exp \left(-\frac{(t - \mu_i)^2}{2\sigma_i^2} \right). \quad (5.1)$$

La señal completa es

$$x(t) = \sum_{i=1}^{10} g_i(t). \quad (5.2)$$

El signo de a_i controla la dirección de la deflexión. El valor absoluto de a_i controla su magnitud. El parámetro μ_i desplaza el componente sobre el eje temporal y σ_i modifica su extensión. La suma permite formar transiciones suaves sin introducir discontinuidades.

La elección de gaussianas se inspira en modelos sintéticos previos que representan ondas electrocardiográficas mediante componentes paramétricos [18]. El presente simulador es más sencillo que un modelo dinámico electrofisiológico. Su ventaja es la capacidad de relacionar cada modificación con una región visual concreta.

Átomo	Región principal	Función dentro del generador
P	Onda P	Añade una deflexión auricular positiva anterior al QRS
Q	Inicio del QRS	Permite una pequeña deflexión negativa, aunque la configuración actual la mantiene anulada
R	QRS inicial	Produce el primer máximo positivo ventricular
S	QRS central	Forma la deflexión negativa posterior a R
R_prime	QRS terminal	Introduce un segundo máximo positivo y permite una forma RSR prima
J_elev	Punto J	Controla la transición entre el final del QRS y el segmento ST
ST1	ST inicial	Modela elevación temprana y la parte descendente de una forma cóncava
ST2	ST tardío	Controla la continuidad hacia la onda T
T1	Onda T principal	Define la polaridad y la magnitud principal de la repolarización
T2	Cola de la onda T	Suaviza y prolonga la repolarización

Tabla 5.1.- Átomos utilizados para construir un beat




Figura 5.1.- Generador gaussiano de un beat sintético. Los parámetros de cada átomo fijan su amplitud, posición y anchura antes de sumar las regiones P, QRS, ST y T.

5.3.- MUESTREO TEMPORAL

La configuración final utiliza una frecuencia de 500 Hz y una duración de 900 ms. El número de muestras se calcula como

$$N = \text{round} \left(\frac{D}{1000} f_s \right), \quad (5.3)$$

donde D es la duración en milisegundos y f_s la frecuencia de muestreo. Con los valores finales se obtienen 450 muestras. El vector temporal es

$$t_n = \frac{1000n}{f_s}, \quad n \in \{0, \dots, N-1\}. \quad (5.4)$$

Los rangos de la repolarización se definieron sobre una duración de referencia de 900 ms. Cuando cambia la duración del beat, los centros posteriores a 390 ms se adaptan mediante

$$\mu_i^{(D)} = 390 + \left(\mu_i^{(900)} - 390 \right) \frac{D - 390}{900 - 390}. \quad (5.5)$$

Las anchuras de los componentes tardíos se escalan por el mismo factor, con un mínimo que impide gaussianas degeneradas. Los componentes anteriores al punto de pivote no se desplazan. De este modo el QRS conserva su posición mientras que ST y T se comprimen o expanden para ocupar la duración disponible.

5.4.- RANGOS DE PARÁMETROS

La generación comienza con un andamiaje compartido. Cada átomo dispone de intervalos para a , μ y σ . Después se aplican sustituciones específicas de la familia. El muestreo dentro de cada intervalo es uniforme. La distribución final no es uniforme porque las reglas morfológicas y los validadores rechazan parte de las propuestas.

Los rangos no deben interpretarse como límites clínicos. Son parámetros de un generador visual. Por ejemplo, el átomo R_prime tiene amplitud casi nula en la familia normal y puede alcanzar valores mayores en RBBB. Los átomos J_elev , ST1 y ST2 permanecen cerca de cero en una señal normal y se desplazan hacia amplitudes positivas en la familia de elevación del ST.

Separar rangos y validadores responde a dos responsabilidades distintas. Los rangos hacen probable una morfología. Los validadores determinan si la señal terminada satisface la definición de cada etiqueta. Si ambos elementos se mezclaran, cualquier cambio visual podría alterar de manera silenciosa el significado de las etiquetas.

5.5.- FAMILIAS GENERADORAS

El simulador contiene cinco familias de origen. Una familia selecciona rangos de muestreo y reglas de coherencia, pero no determina directamente el vector objetivo.

5.5.1.- Familia normal

La familia NORMAL reduce la amplitud de R prima, mantiene la región J y ST próxima a la línea base y fuerza ondas T positivas. También exige que la señal no satisfaga ninguno de los tres validadores de hallazgos. Esta exclusión explícita es necesaria porque una señal generada con rangos normales podría producir por azar una combinación que superase un umbral patológico.

5.5.2.- Morfología RBBB

La familia RBBB favorece una segunda deflexión positiva posterior a S. La posición de R prima se obliga a aparecer al menos 24 ms después del centro de S. Su amplitud no puede quedar por debajo del 80 por ciento de la amplitud de R dentro de los límites permitidos. También se amplía su anchura respecto a la primera R.

El resultado busca una forma RSR prima visible. No reproduce todos los criterios clínicos de bloqueo completo de rama derecha, que dependen de la duración global del QRS y de la distribución entre derivaciones [3]. Por ello la etiqueta se denomina morfología compatible

en el texto interpretativo.

5.5.3.- Elevación de ST

La familia ST_ELEVATION utiliza amplitudes positivas en el punto J y en los dos componentes del ST. La primera sección del ST se ensancha para evitar un pico estrecho que pudiera confundirse con una deflexión del QRS. El validador exige además actividad ventricular positiva y negativa suficiente, con el fin de descartar señales planas elevadas.

5.5.4.- Inversión de T

La familia T_WAVE_INVERSION hace negativas las dos componentes de T y las separa de la región ST. También puede producir una R prima moderada y una elevación pequeña de J. Esta elección permite coocurrencias con RBBB y ST. El validador exige que la deflexión negativa sea tardía, suficientemente profunda y mantenida.

5.5.5.- Familia Brugada

La familia BRUGADA implementa únicamente una forma coved o tipo 1 esquemática. Combina elevación de J, ST inicial positivo, descenso posterior e inversión de T. La amplitud de R prima es menor que en la familia RBBB pura, pero puede mantener una alteración terminal del QRS.

El nombre de la familia no se incorpora al vector objetivo. Una señal aceptada por el validador interno de Brugada se vuelve a evaluar mediante los validadores independientes de RBBB, elevación de ST e inversión de T. Por tanto puede recibir una combinación parcial de hallazgos. Esta decisión convierte la familia en una prueba de composición y evita utilizar una etiqueta clínica que el simulador no puede justificar.

Familia	Modificación dominante	Interpretación experimental
NORMAL	ST próximo a cero, T positiva y R prima mínima	Referencia sin hallazgos del conjunto
RBBB	Segundo máximo positivo tardío y ancho	Componente terminal del QRS
ST elevado	Punto J y ST positivos	Componente de elevación posterior al QRS
Inversión de T	Repolarización tardía negativa	Componente de inversión de T
BRUGADA	J elevado, ST descendente y T negativa	Familia compuesta reservable para transferencia

Tabla 5.2.- Relación entre familias generadoras y rasgos favorecidos

5.6.- REGLAS DE COHERENCIA MORFOLÓGICA

El muestreo independiente de los átomos puede producir órdenes temporales incoherentes. Para reducir este problema se aplican reglas deterministas antes de sumar las gaussianas. Q debe preceder a R. S debe aparecer después de R y ser más ancha. J se sitúa después de S. Los dos componentes del ST se ordenan tras J. T1 y T2 ocupan la región final.

Estas reglas no garantizan fisiología. Garantizan una geometría mínima para que cada parámetro conserve una interpretación. Las reglas específicas de una familia refuerzan relaciones adicionales, como la posición tardía de R prima o el signo negativo de T.

Modificar una regla puede tener efectos indirectos. Mover T1 cambia el resultado del validador de inversión y también puede alterar la media tardía del ST. Por eso cada cambio debe acompañarse de una nueva generación de ejemplos, un análisis de frecuencias y una comprobación de aceptación.

5.7.- MUESTREO CON RECHAZO

El procedimiento de generación utiliza muestreo con rechazo. Para una familia c , el algoritmo sigue los siguientes pasos:

1. Combinar los rangos base con los rangos específicos de c .
2. Adaptar los componentes tardíos a la duración solicitada.
3. Muestrear los parámetros de los diez átomos.
4. Aplicar las reglas de orden y coherencia.
5. Sumar los átomos sobre el vector temporal.
6. Evaluar el validador correspondiente a c .
7. Aceptar la señal si supera las reglas o volver al paso de muestreo.

El límite por defecto es de 400 intentos. Si no se obtiene una señal válida, el generador lanza un error e incluye las últimas métricas calculadas. El número de intento se almacena en los metadatos de cada muestra. Esta variable permite detectar rangos mal alineados con los validadores.

Sea q_c la probabilidad de aceptación de una propuesta de la familia c . El número esperado de intentos antes de una aceptación es aproximadamente

$$\mathbb{E}[A_c] = \frac{1}{q_c}. \quad (5.6)$$

Una familia que requiere muchos intentos puede seguir generando imágenes correctas, pero revela que gran parte de su espacio paramétrico no satisface la definición de la etiqueta. Las tasas de aceptación deben registrarse cuando se cierre la versión final del simulador.

5.8.- VALIDADORES Y SEMÁNTICA DE LAS ETIQUETAS

Los validadores operan sobre ventanas temporales de la señal terminada. Las ventanas posteriores a 390 ms se adaptan mediante la ecuación 5.5. Las amplitudes se expresan en mV y las duraciones en ms.

Validador	Condiciones necesarias
RBBB	Dos máximos positivos entre 240 y 470 ms, separación mínima de 28 ms, primer máximo superior a 0,12 mV, segundo máximo superior a 0,20 mV, mínimo intermedio inferior a $-0,05$ mV, segundo máximo posterior a 345 ms y anchura terminal superior a 38 ms por encima de 0,10 mV
Elevación de ST	Máximo del QRS superior a 0,28 mV, mínimo del QRS inferior a $-0,14$ mV, media de J superior a 0,09 mV y media del ST superior a 0,09 mV
Inversión de T	Máximo del QRS superior a 0,22 mV, máximo de R prima superior a 0,08 mV, media del ST superior a $-0,03$ mV, mínimo de T inferior a $-0,12$ mV, mínimo posterior al umbral temporal equivalente a 640 ms y más de 45 ms por debajo de $-0,05$ mV
Normal	Máximo del QRS superior a 0,22 mV, mínimo inferior a $-0,10$ mV, media de ST entre $-0,04$ y 0,05 mV, máximo de T superior a 0,12 mV, R prima inferior a 0,10 mV y rechazo de los tres hallazgos
Brugada	Máximo del QRS superior a 0,18 mV, mínimo inferior a $-0,16$ mV, media de J superior a 0,09 mV, media de ST superior a 0,08 mV, ST temprano al menos 0,03 mV por encima del ST tardío y mínimo de T inferior a $-0,08$ mV

Tabla 5.3.- Criterios de los validadores sintéticos

Los umbrales se diseñaron para separar morfologías del simulador. No deben trasladarse a un ECG real ni compararse de forma directa con criterios clínicos. Un ECG real requiere calibración, derivaciones identificadas, velocidad de papel conocida y valoración del contexto. Los estándares clínicos revisados en el capítulo 2 se utilizan para orientar la forma general, no para validar pacientes.

Las tres etiquetas finales se calculan de forma independiente. Para una señal aceptada, se ejecutan los validadores de RBBB, ST y TWI y se construye un vector binario. Este paso puede producir coocurrencias que no coinciden con la familia. La etiqueta final es una propiedad de la señal, no una copia del mecanismo que la generó.

5.9.- RENDERIZADO DE LAS SEÑALES

Cada beat se representa sobre un lienzo cuadrado. La configuración final guarda imágenes de 896 por 896 píxeles a 130 puntos por pulgada. El eje horizontal utiliza una cuadrícula

menor cada 40 ms y una cuadrícula mayor cada 200 ms. El eje vertical utiliza divisiones menores de 0,1 mV y mayores de 0,5 mV. La señal se dibuja en negro con un grosor de dos puntos y la cuadrícula en rosa con dos intensidades.

El renderizado conserva títulos de ejes y valores numéricos. Estos elementos aportan información de escala, pero también pueden transformarse en atajos si los límites cambian entre muestras. Por ese motivo, los límites horizontal y vertical se fijan para todas las imágenes de la campaña final. La inspección visual verifica que ninguna familia posea un encuadre, margen o patrón de marcas propio.

No se aplicarán reflejos horizontales. Invertir el eje temporal cambiaría el orden fisiológico de las ondas. Tampoco se aplicarán reflejos verticales, ya que intercambiarían elevación y depresión. Las transformaciones visuales admisibles deben conservar la semántica, como pequeñas variaciones de grosor, contraste, desplazamiento y escala dentro de límites conocidos.




Figura 5.2.- Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador.

5.10.- CONSTRUCCIÓN DEL CONJUNTO DE DATOS

El constructor crea primero un ejemplo de verificación por familia. Después genera el número solicitado de beats y asigna una semilla independiente a cada muestra. Finalmente

crea las particiones y guarda las imágenes.

Cada fila del manifiesto contiene:

- ruta relativa de la imagen
- nombre de la partición
- familia generadora
- semilla de la muestra
- número de intento de aceptación
- subtipo cuando corresponde
- índice interno
- tres columnas binarias de etiquetas

Además se genera un esquema de etiquetas y un resumen con frecuencias por partición, familia, etiqueta y combinación. Los manifiestos CSV permiten entrenar modelos visuales sin depender de la estructura de carpetas. Los ficheros JSON conservan información para auditoría y generación de informes.

Elemento	Total	Organización	Finalidad
Pacientes simulados	100	20 por familia fuente	Construir una cohorte equilibrada por mecanismo generador
Imágenes	300	Beat central en V1, V2 y V3	Mismo formato visual que los datos reales
Pliegues LOOCV	100	Un paciente reservado por pliegue	Medir rendimiento agregado por paciente
Presupuestos K	5	2, 4, 8, 16 y 32 ejemplos	Estudiar aprendizaje supervisado con pocos datos

Tabla 5.4.- Configuración final del conjunto sintético QRS/ST

5.11.- COMPROBACIÓN DE INTEGRACIÓN

La configuración final se ejecutó para generar 100 pacientes sintéticos, 300 imágenes, pliegues LOOCV y resúmenes de etiquetas. El conjunto contiene 20 pacientes con los tres hallazgos presentes y 80 pacientes normales o incompletos. Las combinaciones observadas incluyen NORMAL, RBBB, RBBB+ST, RBBB+ST+TWI, RBBB+TWI y TWI.

Esta comprobación no se limita a una prueba de humo: es el conjunto utilizado en la campaña CNN sintética. Su objetivo es verificar que la ruta de generación, aceptación, partición y escritura funciona correctamente y que el conjunto final conserva variabilidad suficiente para estudiar la curva por K .

La inspección visual mostró que las familias pueden compartir etiquetas. Una muestra de elevación del ST puede satisfacer además el validador RBBB. Una muestra generada como inversión de T puede presentar una segunda deflexión positiva terminal. Este comportamiento confirma que el problema no es una clasificación encubierta de cinco carpetas.

5.12.- CONTROL DE CALIDAD DEL SIMULADOR

La validación del conjunto sintético se organiza en cuatro niveles.

5.12.1.- Nivel estructural

Se comprueba que cada señal tiene 450 muestras, que sus valores son finitos y que las imágenes tienen dimensiones constantes. Los manifiestos deben contener todas las rutas y no puede haber duplicados entre pliegues de evaluación.

5.12.2.- Nivel semántico

Se recalculan las etiquetas directamente desde la señal cuando esta se conserva. Los valores de los validadores se comparan con las columnas del manifiesto. La familia normal debe tener el vector vacío. La familia Brugada debe superar su regla interna aunque su vector final pueda contener una combinación parcial.

5.12.3.- Nivel distribucional

Se analizan las frecuencias de cada etiqueta y de cada combinación. Un balance perfecto por familia no implica balance por etiqueta. Si una combinación domina el conjunto, la macro F_1 puede ocultar que el modelo utiliza coocurrencias. Se revisarán matrices entre familia y etiqueta, distribuciones de intentos y rangos de amplitud.

5.12.4.- Nivel visual

Se generan paneles sin intervención del modelo. La revisión busca ondas truncadas, escalas diferentes, textos que revelen la clase, cuadrículas inconsistentes, trazos fuera del lienzo y formas que no se correspondan con sus métricas. Una muestra que pasa reglas numéricas pero resulta visualmente inverosímil debe motivar una revisión del generador.




Figura 5.3.- Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV.

5.13.- RIESGOS DE ATAÑOS VISUALES

Un modelo puede obtener resultados altos sin aprender la morfología pretendida. Entre los atajos posibles se encuentran límites automáticos del eje, diferencias de antialiasing, márgenes asociados a la amplitud, densidad de cuadrícula, nombres de fichero y estructura de carpetas.

Para reducir estos riesgos, las imágenes se cargarán desde el manifiesto y la familia no se entregará al modelo. Los límites visuales serán constantes. Los nombres de fichero solo contendrán un contador. La evaluación incluirá recortes de la zona de trazado y versiones sin texto de ejes como análisis de sensibilidad. Si el rendimiento cae de forma drástica al retirar elementos no fisiológicos, se investigará el origen antes de interpretar los resultados.

También se comprobará la atención espacial de las CNN mediante Grad CAM [30]. La finalidad no es demostrar causalidad, sino detectar si las regiones activas se concentran en QRS, ST y T o en elementos periféricos.

5.14.- LIMITACIONES DEL SIMULADOR

El simulador representa un beat aislado y una geometría semejante a una derivación precordial. No modela doce derivaciones ni una transformación eléctrica común entre ellas. No incluye variabilidad entre beats, arritmias, intervalos dependientes de frecuencia, ruido muscular, deriva de línea base, interferencia de red, pérdida de electrodos ni compresión de documentos.

La forma de cada onda se construye con gaussianas. Esta elección produce curvas suaves y puede simplificar bordes que en un ECG real son más irregulares. Los validadores se basan

en ventanas y umbrales creados para este dominio. Una señal clínica no debe procesarse con ellos como si fueran reglas diagnósticas.

La familia Brugada es una aproximación a una morfología coved. No representa la heterogeneidad del síndrome, la variación entre derivaciones ni la posibilidad de patrones intermitentes. Su uso se limita a estudiar composición visual de los tres hallazgos.

Estas limitaciones no invalidan el laboratorio sintético. Delimitan qué afirmaciones puede sostener. El dominio permite comparar eficiencia de ejemplos bajo condiciones controladas. La validez clínica dependerá de la evaluación externa descrita en el capítulo de datos reales.

6 Modelos

Este capítulo describe las dos familias de modelos que articulan la comparación metodológica del TFG. Por un lado, una CNN supervisada constituye la línea base convencional: un modelo que requiere entrenamiento explícito y cuyos resultados ponen de manifiesto las limitaciones del aprendizaje con pocas muestras. Por otro lado, los modelos de visión y lenguaje (VLM) representan la propuesta central de este trabajo: una vía alternativa para explotar los mismos pocos ejemplos etiquetados sin modificar ningún peso, aprovechando conocimiento visual y lingüístico adquirido durante el preentrenamiento a gran escala. La comparación entre ambas familias no es una competición abstracta, sino una evaluación de regímenes: cuándo conviene entrenar y cuándo conviene usar demostraciones en contexto.

6.1.- ENTRADA COMÚN

Todos los modelos trabajan con imágenes de ECG. En la CNN, cada imagen corresponde a una derivación precordial derecha renderizada y redimensionada a 224 por 224 píxeles. En la línea VLM, la misma imagen se incluye en un mensaje multimodal junto con instrucciones textuales y, cuando se emplea aprendizaje en contexto, ejemplos demostrativos. La comparación solo tiene sentido porque ambos enfoques reciben la misma evidencia visual y se evalúan por paciente con las mismas métricas.




Figura 6.1.- Recorridos de entrada y evaluación: la CNN actualiza pesos con los K ejemplos etiquetados; el VLM los recibe como demostraciones en el prompt sin modificar parámetros.

6.2.- DOS FORMAS DE USAR K

El presupuesto K , entendido como el número de pacientes etiquetados disponibles, organiza la comparación del TFG. Sin embargo, su uso cambia de forma marcada según la familia de modelos que lo consume. Comprender esta diferencia es imprescindible para interpretar cualquier resultado posterior.

6.2.1.- CNN: K como conjunto de entrenamiento

En un modelo supervisado como la CNN, los K pacientes etiquetados se utilizan para calcular una pérdida y propagar gradientes que actualizan los pesos de la red. El aprendizaje ocurre durante el entrenamiento: tras las épocas de ajuste, los pesos quedan fijados y la inferencia posterior se limita a aplicar la función aprendida a nuevas imágenes. El coste computacional del aprendizaje se concentra en la fase de entrenamiento; cada nueva predicción es rápida y barata.

Cuando K es pequeño, este mecanismo presenta limitaciones conocidas:

- **Alta varianza.** Con pocos ejemplos, la selección concreta de los K pacientes influye de forma desproporcionada en el modelo resultante. Cambiar un solo paciente del conjunto de entrenamiento puede producir un clasificador sustancialmente diferente.
- **Sobreajuste.** La red tiene millones de parámetros y solo unas decenas o centenas de imágenes para ajustarlos. Sin una regularización cuidadosa, los pesos memorizan los

ejemplos de entrenamiento en lugar de capturar la estructura general de la tarea.

- **Atajos visuales.** El modelo puede aprender a distinguir artefactos de adquisición, diferencias de calibración o formato del trazado en lugar de patrones morfológicos clínicamente relevantes. Este problema es especialmente grave cuando el entrenamiento se realiza con datos sintéticos y la evaluación con datos clínicos.

6.2.2.- VLM: K como demostraciones en contexto

En un VLM con aprendizaje en contexto (*in-context learning*, ICL), los K pacientes etiquetados no se utilizan para modificar pesos. En su lugar, se insertan como demostraciones dentro del prompt que recibe el modelo: cada demostración consiste en una imagen de ECG y la etiqueta correcta asociada. Los pesos del modelo permanecen completamente fijos durante todo el proceso. El “aprendizaje” ocurre de forma implícita: el modelo usa las demostraciones para inferir el formato de la tarea, la correspondencia entre patrones visuales y etiquetas, y la distribución esperada de la respuesta.

Este mecanismo presenta ventajas complementarias a las limitaciones de la CNN:

- **Sin sobreajuste a los ejemplos.** Al no actualizar parámetros, no existe riesgo de memorizar los K ejemplos. El rendimiento depende de la capacidad del modelo preentrenado para generalizar a partir de la estructura del prompt.
- **Punto de partida visual y textual.** Un VLM preentrenado a gran escala ha observado millones de imágenes y textos durante su formación. Ese preentrenamiento puede ser útil cuando hay pocos datos específicos del dominio, siempre que el ECG no quede completamente fuera de la distribución aprendida.
- **Flexibilidad de K .** Aumentar o reducir K solo requiere modificar el prompt, sin reentrenar ni desplegar un nuevo modelo. Esto permite explorar el efecto de K de forma inmediata.

Sin embargo, el ICL introduce sus propios riesgos:

- **Dependencia del prompt.** El orden de las demostraciones, la redacción de las instrucciones y el formato de la respuesta solicitada pueden influir en la predicción tanto o más que el contenido visual.
- **Ignorancia de la imagen.** El modelo puede basar su respuesta en patrones textuales, en la frecuencia relativa de etiquetas dentro del prompt o en sesgos de su preentrenamiento, sin analizar realmente la morfología del ECG.
- **Respuestas inválidas.** A diferencia de una CNN, cuya salida es siempre un logit numérico, un VLM puede generar texto libre que no se ajuste al formato esperado, produciendo

predicciones no utilizables.

6.2.3.- Síntesis: la misma evidencia, mecanismos opuestos

La tabla 6.1 resume las diferencias prácticas. Ambos métodos reciben exactamente los mismos K pacientes etiquetados y se evalúan sobre el mismo conjunto de test. Lo que difiere es el mecanismo por el cual esos ejemplos se traducen en una predicción. Esta diferencia es la motivación del estudio comparativo.

Dimensión	CNN supervisada	VLM con ICL
Papel de K	Conjunto de entrenamiento	Demostraciones en el prompt
Actualización de pesos	Sí (gradiente)	No
Dónde ocurre el aprendizaje	Durante el entrenamiento	Durante la generación
Coste por cambio de K	Reentrenamiento completo	Edición del prompt
Riesgo con K pequeño	Sobreajuste, alta varianza	Prompt ruidoso, sesgo textual
Escalabilidad de K	Sin límite práctico	Limitada por ventana de contexto

Tabla 6.1.- Uso del presupuesto K según la familia de modelos.

La pregunta central no es cuál de los dos mecanismos es “mejor” en abstracto, sino a partir de qué K el entrenamiento supervisado se vuelve viable y fiable, y por debajo de qué K el aprendizaje en contexto ofrece una señal útil que el entrenamiento no puede igualar.

6.3.- CNN RESNET18

El modelo supervisado ejecutado es una ResNet18 de torchvision con pesos iniciales DEFAULT [35]. La cabeza de clasificación se sustituye por una salida binaria. En los experimentos sintéticos, la etiqueta positiva indica que el paciente simulado cumple simultáneamente los tres hallazgos asociados al patrón Brugada derivado: RBBB, elevación ST e inversión de T. En la cohorte cedida por el HUCA, la etiqueta positiva indica caso Brugada confirmado frente a control.

La pérdida es BCEWithLogitsLoss [34]. Cuando el pliegue lo requiere, la clase positiva se pondera automáticamente a partir de los ejemplos de entrenamiento. El optimizador es AdamW [36], con tasa de aprendizaje 3×10^{-4} , lote de 32 imágenes y 20 épocas máximas. La selección de umbral se realiza en validación interna mediante exactitud equilibrada derivada por paciente; si no hay validación suficiente, se conserva el umbral 0,5.




Figura 6.2.- Uso supervisado de los K ejemplos en la línea CNN: las muestras de entrenamiento actualizan los pesos de ResNet18 y la muestra reservada produce una predicción binaria junto con su mapa Grad-CAM.

Propiedad	Valor
Arquitectura	ResNet18 con cabeza binaria
Inicialización	Pesos DEFAULT de Torchvision para ResNet18
Entrada	RGB, 224 por 224 píxeles
Pérdida	BCEWithLogitsLoss, loss_pos_weight=auto
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Épocas máximas	20
Tamaño de lote	32
Presupuestos	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026
Umbral	Seleccionado por validación con exactitud equilibrada por paciente
Agregación	Media de probabilidades de V1, V2 y V3 antes del umbral

Tabla 6.2.- Configuración CNN utilizada en las campañas finales.

6.4.- VALIDACIÓN POR PACIENTE

El entrenamiento y la evaluación se organizan mediante validación leave-one-out. En cada pliegue se reserva un paciente completo y se entrena con un subconjunto de K pacientes del resto. Esto evita que imágenes de un mismo paciente aparezcan simultáneamente en entrenamiento y test. En los datos cedidos por el HUCA esta restricción es indispensable porque las tres derivaciones de un paciente comparten adquisición, calibración y contexto clínico.

El informe de cada ejecución guarda:

- configuración de entrenamiento;
- pacientes seleccionados como ejemplos;
- probabilidades por imagen;
- predicción agregada por paciente;
- umbral elegido;
- matriz de confusión y métricas;
- paneles Grad CAM para inspección cualitativa.

6.5.- GRAD CAM

Grad CAM se utiliza como diagnóstico cualitativo, no como explicación clínica suficiente [30]. El mapa indica regiones que influyen en el logit del modelo, pero no prueba que la red haya aprendido un criterio médico correcto. En esta memoria se usa para comprobar si las activaciones se concentran en zonas plausibles del trazado y para detectar errores en los que una atención visual razonable termina en una decisión equivocada.




Figura 6.3.- Ejemplo Grad CAM del modelo CNN sobre el conjunto sintético.

6.6.- COMPROBACIÓN SINTÉTICO-REAL

La comparación entre el simulador y los datos reales se cierra al final de la evaluación CNN. Allí se revisa si parte de la pérdida de rendimiento procede de un cambio de distribución visual entre imágenes sintéticas y ECG clínicos reales. Esta comprobación se mantiene separada del diseño principal de VLM/ICL: sirve para medir el alcance de la CNN antes de comparar su uso de K ejemplos con el aprendizaje en contexto.

6.7.- MODELOS DE VISIÓN Y LENGUAJE

6.7.1.- Motivación: por qué un VLM para pocos datos

Las secciones anteriores describen el rendimiento de la CNN y su pérdida de robustez al pasar del simulador a los datos reales. Los resultados empíricos muestran que, cuando K es pequeño, el entrenamiento supervisado presenta limitaciones estructurales: alta varianza entre semillas, dependencia de la selección concreta de pacientes y dificultad para transferir desde el dominio sintético al clínico. Con pocos ejemplos, el gradiente no dispone de evidencia suficiente para ajustar millones de parámetros de forma fiable.

Los modelos de visión y lenguaje ofrecen una vía complementaria. Un VLM preentrenado a gran escala dispone de representaciones visuales y textuales aprendidas antes de ver el conjunto del proyecto. En lugar de aprender desde cero a partir de K ejemplos, usa esos ejemplos como demostraciones que especifican la tarea. La hipótesis es que este mecanismo puede ser más estable que el entrenamiento supervisado para valores de K en los que la CNN depende demasiado de la selección concreta de pacientes.

Esta hipótesis no se asume como verdadera: se diseña un marco experimental que permita confirmarla o refutarla. Los controles descritos en la sección 6.8 son los instrumentos para verificar que cualquier rendimiento observado se debe efectivamente al análisis visual y no a artefactos del prompt.

6.7.2.- Gemma 4: modelo generalista de código abierto

El modelo VLM generalista seleccionado es Gemma 4. La elección se fundamenta en tres propiedades:

- **Pesos abiertos.** A diferencia de modelos propietarios accesibles solo mediante API, los pesos de Gemma 4 están disponibles públicamente. Esto permite la inferencia local, la reproducibilidad completa de los experimentos y la independencia de servicios externos cuyas condiciones de uso pueden cambiar.
- **Contexto multimodal con múltiples imágenes.** Gemma 4 acepta mensajes que combinen texto e imágenes de forma intercalada, lo que permite construir prompts de ICL que incluyan varias demostraciones imagen-etiqueta seguidas de la imagen de consulta. Esta capacidad es imprescindible para el aprendizaje en contexto multimodal con $K > 1$.
- **Inferencia local mediante vLLM.** El modelo se despliega localmente utilizando el *framework* de inferencia vLLM y su servidor compatible con OpenAI [37]. La guía específica de Gemma 4 documenta la ejecución multimodal de esta familia en vLLM [38]. Esto elimina la dependencia de servicios en la nube y permite controlar completamente el entorno de ejecución.

6.7.3.- MedGemma: adaptación al dominio médico

MedGemma es una variante de Gemma adaptada al dominio biomédico mediante entrenamiento adicional con datos médicos. Su inclusión permite responder a una pregunta específica: ¿mejora el rendimiento en ECG cuando el VLM ha sido expuesto a imágenes y textos médicos durante su preentrenamiento, aunque no necesariamente a ECG?

La comparación Gemma 4 *versus* MedGemma aísla el efecto del dominio de preentrenamiento. Si MedGemma supera a Gemma 4 en varios presupuestos K , esto indicaría que el preentrenamiento biomédico se transfiere al dominio electrocardiográfico. Si el rendimiento es similar, sugeriría que el conocimiento relevante para la tarea ya está capturado en el preentrenamiento generalista, o que las imágenes de ECG son suficientemente distintas de las imágenes médicas convencionales como para que la especialización no aporte ventaja.

6.7.4.- Pipeline de inferencia VLM

El flujo de inferencia VLM sigue una estructura reproducible (figura 6.4):

1. **Selección de demostraciones.** Se eligen K pacientes etiquetados del conjunto disponible. La selección sigue el mismo protocolo que en la CNN para garantizar comparabilidad.
2. **Construcción del prompt multimodal.** Se compone un mensaje que incluye: instrucciones de sistema que definen la tarea y el formato de respuesta, las K demostraciones (imagen + etiqueta) y la imagen de consulta.
3. **Generación.** El modelo VLM procesa el prompt y genera una respuesta textual.
4. **Validación JSON.** La respuesta se analiza sintácticamente como JSON. Se verifica que contenga los campos requeridos (predicción binaria, confianza opcional) y que los valores sean válidos.
5. **Gestión de fallos.** Las respuestas que no superan la validación se registran como predicciones inválidas. La tasa de respuestas inválidas es una métrica de calidad del flujo.

La respuesta esperada es un objeto JSON estructurado. No se solicita explicación libre obligatoria. Un formato cerrado reduce la ambigüedad en la evaluación y permite comparar directamente con la salida numérica de la CNN. Si el VLM genera texto fuera del formato esperado, la predicción se marca como inválida en lugar de intentar interpretarla heurísticamente.

Pipeline VLM/ICL para comparación con CNN




Figura 6.4.- Flujo VLM/ICL: selección de demostraciones, construcción del prompt multimodal, generación local, validación JSON y controles de ablación.

6.8.- CONTROLES PREVISTOS PARA VLM

Un VLM puede obtener rendimiento aparentemente bueno por razones ajenas al análisis visual. Puede explotar la frecuencia relativa de etiquetas en las demostraciones, copiar patrones textuales del prompt o basarse en sesgos de su preentrenamiento sin examinar la imagen. Para distinguir aprendizaje multimodal real de artefactos, se diseñan tres condiciones experimentales de control:

- **Normal.** Cada demostración incluye la imagen del ECG y la etiqueta correcta asociada. Esta es la condición completa que se espera que maximice el rendimiento si el modelo efectivamente utiliza la correspondencia imagen-etiqueta.
- **Respuestas permutadas.** Las imágenes de las demostraciones se mantienen inalteradas, pero las etiquetas se barajan aleatoriamente, rompiendo la correspondencia imagen-etiqueta. Este control mide si el modelo depende realmente de la relación entre cada imagen específica y su diagnóstico, o si basta con ver imágenes y etiquetas en cualquier combinación para producir predicciones similares.

Si el rendimiento *no cae* con respuestas permutadas, significa que el modelo no está aprendiendo de la correspondencia imagen-etiqueta, sino de otros aspectos del prompt: la proporción de etiquetas positivas, el formato general, o sesgos textuales. En ese caso, cualquier rendimiento observado en la condición normal no puede atribuirse a aprendizaje en contexto genuino.

- **Demostraciones sin imagen.** El prompt conserva las instrucciones textuales y las etiquetas de cada demostración, pero se eliminan las imágenes de ejemplo. Solo la imagen de consulta permanece. Este control aísla la contribución de la evidencia visual de las demostraciones.

Si el rendimiento *se mantiene* sin las imágenes de ejemplo, el modelo está basando sus decisiones en la estructura textual del prompt y no en el contenido visual de las demostraciones. Esto indicaría que el ICL multimodal, en la práctica, no está aprovechando las imágenes de referencia.

La interpretación conjunta de las tres condiciones permite clasificar el comportamiento del VLM:

- Si Normal supera a Permutadas y Permutadas supera a Sin imagen: el modelo utiliza tanto las imágenes como la correspondencia con las etiquetas. Es el escenario más favorable.
- Si Normal y Permutadas son similares, pero ambas superan a Sin imagen: el modelo usa las imágenes pero ignora la correspondencia con las etiquetas.
- Si las tres condiciones son similares: el modelo ignora las demostraciones por completo y responde basándose solo en la imagen de consulta y las instrucciones.
- Si cualquier control supera a Normal: hay indicios de inestabilidad o de que las demostraciones introducen ruido en lugar de información.

6.9.- CRITERIO DE COMPARACIÓN

La métrica principal de comparación entre métodos es la exactitud equilibrada (*balanced accuracy*) agregada por paciente. Esta métrica es apropiada para el problema porque el conjunto de datos es pequeño y presenta desbalance de clases; la exactitud equilibrada pondera por igual ambas clases independientemente de su prevalencia. Como métricas complementarias se reportan F1, sensibilidad, especificidad, área bajo la curva ROC y precisión media (AP).

Sin embargo, la comparación no se reduce a determinar cuál método obtiene mayor exactitud equilibrada en un único punto. El análisis se estructura como una **curva de decisión** en función de K :

- **Zona de K muy bajo** ($K = 2, 4$). El entrenamiento supervisado dispone de tan pocos ejemplos que la CNN es altamente inestable: gran varianza entre semillas, sensibilidad extrema a qué pacientes se seleccionan, y riesgo elevado de sobreajuste o de aprender

atajos. En esta zona, el ICL puede ofrecer una señal más estable porque no depende de la convergencia de un optimizador con datos insuficientes.

- **Zona de transición** ($K = 8, 16$). A medida que aumenta K , la CNN dispone de más evidencia para generalizar. La pregunta clave es: ¿a partir de qué K el entrenamiento supervisado iguala o supera consistentemente al ICL? Si aparece un punto de cruce, definirá el umbral práctico por encima del cual merece la pena invertir en entrenamiento.
- **Zona de K suficiente** ($K = 32$ y más). Con datos suficientes, el entrenamiento supervisado debería dominar porque puede ajustar representaciones específicas para la tarea. El ICL, limitado por la ventana de contexto y por la ausencia de actualización de pesos, tiene un techo de rendimiento que el entrenamiento puede superar.

Además de la exactitud, la comparación incluye dimensiones prácticas que condicionan la viabilidad en un entorno clínico real:

- **Coste de entrenamiento.** La CNN requiere un proceso de entrenamiento por cada configuración de K y semilla. El VLM no requiere entrenamiento.
- **Coste por inferencia.** La inferencia de una CNN es rápida y ligera. La inferencia de un VLM con contexto multimodal extenso es significativamente más costosa en tiempo y memoria GPU.
- **Tasa de respuestas inválidas.** La CNN siempre produce una salida numérica válida. El VLM puede generar respuestas que no se ajustan al formato JSON esperado, reduciendo la cobertura efectiva.
- **Latencia.** Para aplicaciones de triaje en tiempo real, la diferencia de latencia entre una pasada forward de CNN y una generación autoregresiva de VLM puede ser determinante.
- **Requisitos de hardware.** Una ResNet18 cabe en cualquier GPU moderna. Un VLM de varios miles de millones de parámetros requiere hardware especializado o cuantización agresiva.

La lectura final no será “CNN contra VLM” como veredicto único. Será un mapa de decisión: para un presupuesto de etiquetado dado, un coste computacional aceptable y un nivel de robustez requerido, ¿conviene invertir en entrenamiento supervisado o utilizar aprendizaje en contexto como herramienta de triaje preliminar? La base cuantitativa de CNN establecida en este trabajo proporciona el punto de referencia sobre el cual se evalúa la alternativa VLM.

7 Resultados en el conjunto sintético

El primer bloque de resultados establece si una CNN puede aprender la tarea en un entorno controlado. Este paso es necesario antes de evaluar el modelo sobre datos reales y antes de comparar con VLM/ICL. Si la CNN no logra aprender siquiera en un dominio sintético limpio, la comparación con VLM carecería de una línea base interpretable. El conjunto sintético contiene 100 pacientes simulados y 300 imágenes, con tres derivaciones por paciente. La etiqueta positiva corresponde a la presencia simultánea de RBBB, elevación ST e inversión de T en el simulador. Hay 20 pacientes positivos y 80 normales o incompletos.

7.1.- CURVA POR PRESUPUESTO

La tabla 7.1 muestra la media y la desviación estándar sobre tres semillas. La tendencia es clara: con $K = 2$ y $K = 4$ el modelo ya supera el azar en exactitud equilibrada, pero aún produce muchos falsos positivos. A partir de $K = 16$ aparece una mejora sustancial y con $K = 32$ se obtiene el mejor punto de la campaña.

K	BA	F1	Sens.	Esp.	ROC AUC
2	$0,625 \pm 0,022$	0,401	0,650	0,600	0,520
4	$0,631 \pm 0,042$	0,407	0,617	0,646	0,566
8	$0,685 \pm 0,023$	0,468	0,683	0,688	0,629
16	$0,773 \pm 0,013$	0,569	0,800	0,746	0,755
32	$0,848 \pm 0,030$	0,673	0,883	0,812	0,857

Tabla 7.1.- Resultados CNN ResNet18 sobre el conjunto sintético QRS/ST.




Figura 7.1.- Exactitud equilibrada de la CNN sobre el conjunto sintético según el presupuesto K .

El incremento entre $K = 8$ y $K = 16$ es el cambio más importante de la curva. El modelo pasa de una exactitud equilibrada media de 0,685 a 0,773, lo que indica que ocho ejemplos todavía no cubren suficientemente la variabilidad de combinaciones morfológicas. Con $K = 32$, la sensibilidad alcanza 0,883 y la especificidad 0,812, una combinación razonable para una tarea controlada de alerta morfológica.

Este resultado demuestra que la formulación visual es viable y que la CNN puede extraer información de las imágenes. Sin embargo, como se verá en el capítulo siguiente, este aprendizaje no se traslada al dominio real.

7.2.- MATRIZ DE CONFUSIÓN

La matriz agregada de $K = 32$ resume el mejor punto sintético. En las tres semillas se acumulan 53 verdaderos positivos, 195 verdaderos negativos, 45 falsos positivos y 7 falsos negativos. El error dominante sigue siendo marcar como positivos algunos pacientes incompletos, aunque el número de falsos negativos es bajo.




Figura 7.2.- Matriz de confusión agregada del conjunto sintético para $K = 32$.

En un contexto de triaje, esta distribución de errores sería preferible a la situación inversa: el modelo tiende a avisar de más antes que a omitir positivos. Sin embargo, el conjunto sintético no representa pacientes reales y sus etiquetas proceden de reglas internas; por tanto, este resultado solo demuestra aprendizaje de la tarea simulada.

7.3.- INSPECCIÓN CUALITATIVA

El panel Grad CAM de la figura 7.3 muestra que el modelo atiende a regiones del complejo QRS, el punto J y la repolarización. La inspección es coherente con la definición de la etiqueta, pero no sustituye a una validación clínica. Grad CAM ayuda a detectar fallos obvios de atención; no certifica que la red razone como un especialista.




Figura 7.3.- Ejemplo Grad CAM del modelo sintético.

7.4.- CONCLUSIÓN DEL DOMINIO SINTÉTICO

El dominio sintético confirma tres hechos. Primero, el renderizado contiene información visual suficiente para entrenar una CNN con pocos ejemplos. Segundo, el presupuesto importa: por debajo de $K = 16$ el comportamiento es útil pero irregular; con $K = 32$ el modelo mejora simultáneamente sensibilidad, especificidad, F1 y área ROC. Tercero, este buen rendimiento no puede trasladarse de forma directa a clínica porque las imágenes sintéticas son más limpias y las etiquetas están definidas por el propio generador.

Este resultado no cierra la comparación con VLM/ICL. Establece que la CNN *puede* aprender cuando las condiciones están controladas. La pregunta siguiente es si ese aprendizaje se mantiene en datos reales o si la CNN falla al enfrentarse a la variabilidad clínica. Si falla, la comparación con VLM/ICL se apoya en los propios datos.

8 Evaluación sobre datos reales

El segundo bloque de resultados utiliza ECG clínicos reales cedidos por el Hospital Universitario Central de Asturias (HUCA) dentro del recurso Brugada HUCA [39]. La anotación procede de la recogida paciente a paciente y de la revisión manual especializada. La finalidad es medir cómo se comporta la CNN cuando abandona el simulador y se evalúa sobre trazados clínicos reales. Este paso es necesario porque un buen resultado sintético no garantiza utilidad en un dominio con ruido de adquisición, variabilidad clínica y una etiqueta definida a nivel de paciente.

8.1.- COHORTE FINAL

El procesado parte de 363 pacientes. Se excluyen 46 casos con patrón basal limítrofe que no deben mezclarse como positivos o negativos en la tarea principal. La cohorte final contiene 317 pacientes: 116 casos Brugada confirmados y 201 controles. Para cada paciente se generan tres imágenes, una por V1, V2 y V3, lo que produce 951 imágenes.

Grupo	Pacientes	Imágenes
Brugada confirmado	116	348
Control	201	603
Excluido por patrón basal limítrofe	46	–
Total evaluado	317	951


Tabla 8.1.- Cohorte cedida por el HUCA utilizada en la evaluación CNN.

La etiqueta real disponible no es equivalente a las tres etiquetas morfológicas del simulador. Los datos cedidos por el HUCA no contienen anotaciones independientes de RBBB, elevación ST e inversión T para cada imagen. Por ello, el experimento real se formula como caso Brugada confirmado frente a control y sus conclusiones se limitan a triaje de esa variable clínica. Es importante recordar que en la práctica asistencial, un resultado positivo del modelo no equivale a un diagnóstico: señala que el trazado debería ser revisado por un especialista y, si procede, iniciar el circuito diagnóstico que puede incluir prueba farmacológica con bloqueantes del canal de sodio [6].

8.2.- PREPROCESAMIENTO

La preparación selecciona las derivaciones precordiales derechas, detecta un latido central y recorta una ventana de 300 ms antes de R y 600 ms después de R. La salida conserva el identificador de paciente, derivación, etiqueta clínica, ruta de imagen y plan de pliegues LOOCV. El objetivo es obtener una representación visual comparable a la sintética sin borrar la variabilidad propia del ECG real.

Preparacion de Brugada-HUCA



La etiqueta QRS/ST real no se inventa: HUCA aporta `clinical_brugada` para evaluar la regla final derivada.

Esto separa el detector morfológico entrenado en sintético de la referencia clínica usada para triaje y auditoría patient-level.

Figura 8.1.- Preprocesamiento de los ECG cedidos por el HUCA para V1, V2 y V3.

La separación por paciente es obligatoria. Si V1, V2 y V3 de un mismo paciente se repartieran entre entrenamiento y test, el modelo podría aprovechar características de adquisición o escala en lugar de aprender rasgos clínicamente relevantes.

8.3.- RESULTADOS CNN BASE

La tabla 8.2 resume la CNN base entrenada y evaluada sobre la cohorte cedida por el HUCA. A diferencia del dominio sintético, aumentar K no produce una mejora monotonía. El mejor punto de exactitud equilibrada aparece con $K = 16$, pero solo alcanza 0,516. Con $K = 32$ la exactitud equilibrada baja a 0,499. Estos valores son esencialmente indistinguibles del azar.

K	BA	F1	Sens.	Esp.	ROC AUC
2	$0,509 \pm 0,010$	0,484	0,693	0,325	0,525
4	$0,509 \pm 0,023$	0,493	0,730	0,289	0,495
8	$0,490 \pm 0,018$	0,469	0,672	0,308	0,496
16	$0,516 \pm 0,023$	0,480	0,658	0,375	0,569
32	$0,499 \pm 0,012$	0,466	0,644	0,355	0,491

Tabla 8.2.- Resultados CNN ResNet18 sobre los datos cedidos por el HUCA.




Figura 8.2.- Exactitud equilibrada de la CNN base sobre los datos cedidos por el HUCA.

La sensibilidad es moderada, pero la especificidad es baja. En el mejor punto $K = 16$, la matriz agregada de tres semillas contiene 229 verdaderos positivos, 226 verdaderos negativos, 377 falsos positivos y 119 falsos negativos. El modelo tiende a sobredetectar casos Brugada, lo que podría ser tolerable únicamente como alerta preliminar extremadamente conservadora, pero no como herramienta de descarte ni de diagnóstico.




Figura 8.3.- Matriz de confusión agregada de la cohorte cedida por el HUCA para $K = 16$.

Este resultado es el hallazgo más importante de la línea CNN: con tan pocos datos, el entrenamiento supervisado de una ResNet18, incluso con pesos preentrenados de ImageNet, no consigue extraer señal útil de ECG clínicos reales de Brugada. La red aprende en el simulador porque las imágenes son limpias y las etiquetas derivan de reglas controladas. En el dominio real, la variabilidad clínica, el ruido de adquisición y la complejidad del fenotipo superan la capacidad del modelo.

8.4.- BRECHA SINTÉTICO-REAL

La comparación directa muestra una brecha de dominio marcada. En el simulador la exactitud equilibrada aumenta hasta 0,848 con $K = 32$. En los datos cedidos por el HUCA, el modelo se mantiene alrededor de 0,50. Esto indica que la señal visual aprendida en condiciones controladas no se transfiere de forma directa a la variabilidad clínica.




Figura 8.4.- Comparación de exactitud equilibrada entre el conjunto sintético y la cohorte cedida por el HUCA.




Figura 8.5.- Comparación de F1 entre el conjunto sintético y la cohorte cedida por el HUCA.

La brecha tiene varias causas plausibles: ruido y variabilidad de adquisición, diferencias de escala, presencia de múltiples fenotipos, etiqueta clínica no reducible a una sola ventana de ECG y ausencia de anotaciones morfológicas finas en la cohorte real. El resultado no invalida el simulador; delimita su alcance y confirma que el problema de pocos datos no se resuelve con un simulador más limpio.

8.5.- INSPECCIÓN CUALITATIVA

El Grad CAM real confirma que las activaciones pueden localizarse sobre regiones del trazado, pero también muestra la dificultad de interpretar modelos entrenados con pocos ejemplos sobre datos clínicos heterogéneos. La atención visual no corrige por sí sola la falta de especificidad ni resuelve la diferencia entre etiqueta clínica y morfología observable.




Figura 8.6.- Ejemplo Grad CAM del modelo CNN sobre los datos cedidos por el HUCA.

8.6.- LECTURA DE LA EVALUACIÓN REAL

La evaluación sobre los datos cedidos por el HUCA delimita el alcance de la línea CNN. La red convolucional, incluso con pesos preentrenados, no logra un rendimiento fiable en datos reales de Brugada con tan pocos ejemplos etiquetados. La exactitud equilibrada se mantiene cerca del azar y la especificidad es demasiado baja para cualquier uso práctico más allá de investigación exploratoria.

Este resultado marca la referencia que debe superar o matizar la línea VLM/ICL. La siguiente fase debe determinar si un modelo de visión y lenguaje, con conocimiento visual y médico adquirido durante el preentrenamiento, ofrece una mejor relación entre rendimiento, coste y cantidad de datos etiquetados cuando recibe esos mismos K ejemplos como demostraciones en contexto en lugar de como conjunto de entrenamiento.

9 Evaluación VLM/ICL

Este capítulo define la línea VLM/ICL del estudio: modelos de visión y lenguaje con aprendizaje en contexto. El capítulo fija el diseño experimental, las condiciones, los controles, el formato de salida y la lectura comparativa.

9.1.- OBJETIVO DE LA LÍNEA VLM/ICL

La línea CNN ha establecido la base supervisada: con $K \leq 32$, ResNet18 aprende en el simulador, pero no alcanza un rendimiento fiable sobre los datos cedidos por el HUCA. El protocolo VLM/ICL evalúa la hipótesis complementaria: si los ejemplos etiquetados son demasiado escasos para actualizar pesos de forma fiable, quizá puedan ser más útiles como demostraciones dentro del contexto de un modelo multimodal preentrenado.

La comparación se formula con la misma entrada visual, los mismos pacientes, los mismos presupuestos K , la misma separación leave-one-out y las mismas métricas por paciente. La diferencia experimental es una sola: la CNN usa los ejemplos para entrenar; el VLM los usa para condicionar la inferencia.

9.2.- MODELOS EVALUADOS

El protocolo contempla dos modelos abiertos:

- **Gemma 4.** Modelo multimodal generalista con entrada de texto e imagen [27]. Actúa como referencia abierta no especializada. Su papel es medir cuánto puede aportar un VLM general con contexto visual y textual amplio.
- **MedGemma 1.5.** Modelo multimodal médico basado en la familia Gemma y adaptado con modalidades clínicas [28]. Actúa como referencia médica. Su papel es medir si el preentrenamiento biomédico general aporta ventaja en ECG, aun cuando la documentación del modelo no identifique el ECG como modalidad principal.

Ambos modelos se sirven localmente mediante vLLM siempre que el hardware lo permita. Esta decisión evita depender de APIs externas y permite registrar versión de pesos, plantilla de conversación, resolución visual, temperatura y parámetros de generación.

9.3.- PRESUPUESTOS Y DEMOSTRACIONES

Los presupuestos son $K = \{0, 2, 4, 8, 16, 32\}$. El caso $K = 0$ mide comportamiento *zero-shot*: el modelo recibe instrucciones y la imagen objetivo, pero ninguna demostración etiquetada. Los valores positivos de K miden aprendizaje en contexto con ejemplos imagen-respuesta.

Para que la comparación con la CNN sea directa, las demostraciones se seleccionan a nivel de paciente y nunca incluyen el paciente reservado para test. Cuando un paciente aporta varias derivaciones, la demostración conserva la misma lógica de agregación que el resto del estudio: V1, V2 y V3 son evidencia visual del mismo paciente, no muestras independientes para filtrar entre entrenamiento y prueba.

El esquema general de esta construcción se resume en la figura 2.3. En este capítulo se concreta cómo se seleccionan las demostraciones, qué campos debe producir el modelo y cómo se agregan las respuestas por paciente.

9.4.- FORMATO DE SALIDA

El formato depende de la tarea VLM. En la tarea morfológica, el JSON estricto contiene los mismos hallazgos que utiliza la CNN. Para cada imagen V1, V2 o V3, la respuesta mínima es:

```

1 {
2   "RBBB": true,
3   "ST_ELEVATION": true,
4   "T_WAVE_INVERSION": true
5 }
```

La etiqueta clínica de paciente se deriva después mediante la misma regla AND usada en el resto del TFG: solo se marca sospecha Brugada si los tres hallazgos están presentes tras agregar las derivaciones. Esta tarea permite estudiar transferencia desde demostraciones morfológicas sintéticas hacia la cohorte del HUCA.

La segunda tarea es clínica directa. En ella el VLM recibe una única derivación fija del paciente, por defecto V2, y responde:

```

1 {
2   "clinical_brugada": true
3 }
```

La tarea clínica directa usa K pacientes reales de la cohorte cedida por el HUCA como demostraciones en contexto y predice otro paciente de esa misma cohorte. Para $K \geq 2$, la selección de contexto fuerza ejemplos normales y Brugada siempre que el pliegue lo permita.

La derivación se fija de antemano, por defecto V2, de modo que ambos modelos ven exactamente las mismas imágenes. Con ello se mide si el VLM aprovecha pocos ejemplos clínicos reales sin actualizar pesos, una pregunta complementaria a la transferencia morfológica desde simulador.

El análisis principal no interpreta texto libre. Una respuesta que no pueda analizarse como JSON, con claves ausentes, tipos incorrectos o valores fuera del esquema, se registra como fallo de formato. Esta tasa de fallos se reporta junto con las métricas clínicas porque forma parte del comportamiento real de un VLM.

9.5.- CONDICIONES EXPERIMENTALES

La tabla 9.1 fija las condiciones de la campaña. Las tres primeras condiciones miden rendimiento; las dos últimas son controles de causalidad multimodal.

Condición	K	Propósito
Zero-shot	0	Medir conocimiento previo sin demostraciones.
ICL normal	2, 4, 8, 16, 32	Medir aprendizaje en contexto con pares imagen-etiqueta correctos.
ICL balanceado	2, 4, 8, 16, 32	Mantener proporción positiva/negativa controlada cuando el pliegue lo permita.
Etiquetas permutadas	8, 16, 32	Romper la correspondencia imagen-etiqueta para detectar uso espurio del contexto.
Sin imagen de apoyo	8, 16, 32	Mantener etiquetas de demostración, pero retirar las imágenes de apoyo.

Tabla 9.1.- Condiciones experimentales VLM/ICL.

9.6.- AGREGACIÓN POR PACIENTE

En la tarea morfológica, cada predicción se obtiene por imagen y se agrega a nivel de paciente para conservar la misma unidad de evaluación que en la CNN. Si el modelo produce una respuesta válida para V1, V2 y V3, se calcula una decisión de paciente por voto mayoritario o por media de probabilidades si se activa la confianza numérica. En la tarea clínica directa, la consulta contiene una sola imagen del paciente; la salida `clinical_brugada` se evalúa directamente contra la referencia clínica de la cohorte. Si alguna respuesta produce JSON inválido, se conserva el fallo en la auditoría. El análisis principal contabiliza los fallos

como errores; un análisis secundario puede informar métricas sobre respuestas válidas, pero nunca sustituye al análisis principal.

9.7.- TRAZABILIDAD DE LA EVALUACIÓN

La evaluación VLM/ICL conserva la misma separación por paciente que la línea CNN. Para cada condición se registran el modelo, la tarea, el presupuesto K , la semilla, las imágenes de consulta, las demostraciones incluidas, la respuesta estructurada y la validez del formato. Esta información permite reconstruir métricas por paciente, matrices de confusión y comparaciones por presupuesto sin mezclar dominios ni pacientes.

9.8.- VARIABLES DE REPORTE

El reporte VLM/ICL conserva las métricas de la línea CNN y añade campos específicos de los modelos generativos. La tabla 9.2 resume qué debe quedar asociado a cada combinación de modelo, condición, presupuesto K y semilla.

Campo	Unidad	Función
Exactitud equilibrada	Paciente	Métrica principal, comparable con la línea CNN.
F1, sensibilidad y especificidad	Paciente	Lectura clínica complementaria del equilibrio entre falsos positivos y falsos negativos.
JSON inválido	Respuesta	Medida de cumplimiento del formato solicitado.
Latencia media	Consulta	Estimación de coste operativo por predicción.
Condición de control	Campaña	Identificación de zero-shot, ICL normal, ICL balanceado, etiquetas permutadas o demostraciones sin imagen.
Evidencia de contexto	Pliegue	Pacientes y derivaciones incluidos como demostraciones para reconstruir la inferencia.

Tabla 9.2.- Campos de reporte para una campaña VLM/ICL.

9.9.- MATRIZ METODOLÓGICA

La comparación entre CNN y VLM/ICL se define como una curva por presupuesto K , con la misma unidad de análisis y la misma métrica principal. La tabla 9.3 resume las diferencias

que deben mantenerse explícitas al leer los resultados.

Elemento	CNN	VLM/ICL
Uso de K	Entrenamiento supervisado de la capa y la red.	Demostraciones en contexto dentro del prompt.
Parámetros del modelo	Se actualizan durante el entrenamiento.	Permanecen fijos durante la inferencia.
Unidad de test	Paciente reservado en leave-one-out.	Paciente reservado en leave-one-out.
Entrada visual	Imágenes V1, V2 y V3 agregadas por paciente.	Misma imagen objetivo y, según tarea, demostraciones visuales.
Métrica principal	Exactitud equilibrada por paciente.	Exactitud equilibrada por paciente.
Controles	Semillas y selección de pacientes.	Semillas, etiquetas permutadas y demostraciones sin imagen.

Tabla 9.3.- Matriz metodológica para comparar CNN y VLM/ICL.

9.10.- CRITERIO DE LECTURA

La hipótesis principal es que ICL será más competitivo en K bajo, donde entrenar pesos con pocos pacientes resulta frágil. Si el VLM supera a la CNN en esa zona, el resultado apoyará el uso de demostraciones en contexto para tareas raras con pocas etiquetas. Si la CNN alcanza o supera al VLM cuando K aumenta, aparecerá un punto de cruce práctico: por debajo conviene ICL; por encima conviene entrenamiento supervisado. Si ninguno de los dos enfoques supera un rendimiento aceptable, el resultado también será informativo, porque indicará que la tarea requiere más datos, mejores anotaciones morfológicas o modelos específicamente preentrenados en ECG.

En todos los casos, la lectura clínica se mantiene constante. La salida del modelo solo prioriza revisión experta dentro del circuito de Brugada; no confirma ni descarta el síndrome.

10 Gestión, ética, privacidad y marco normativo

10.1.- GESTIÓN DE RIESGOS

La tabla 10.1 recoge los riesgos principales, su efecto y la respuesta prevista. La probabilidad se valora de forma cualitativa antes de cerrar los experimentos.

Riesgo	Prioridad	Medida de respuesta
Retraso en la integración de la CNN	Alta	Definir primero una línea base mínima reproducible y separar mejoras opcionales
Acceso insuficiente a GPU	Alta	Ejecutar pruebas pequeñas, estimar coste antes del barrido y conservar reanudación por registro
Salidas VLM inválidas	Media	Forzar esquema JSON, validar cada respuesta y contabilizar los fallos
Fuga entre entrenamiento y prueba	Alta	Crear divisiones por paciente o semilla generativa antes del ajuste y guardar los identificadores
Diferencia excesiva entre dominios	Alta	Medir transferencia directa y añadir armonización, ajuste fino y adaptación como experimentos separados
Etiquetas reales no equivalentes	Alta	Separar diagnóstico y morfología y exigir anotación específica para la segunda tarea
Cambios de versión del modelo	Media	Registrar identificador exacto, revisión y parámetros de servicio
Alcance de la línea VLM	Alta	Separar protocolo y resultados medidos, sin sustituir predicciones por estimaciones

Tabla 10.1.- Riesgos principales del proyecto.

Los riesgos se revisan al terminar cada bloque. Una desviación no se corrige ocultando el alcance real, sino reduciendo de forma explícita los experimentos secundarios y protegiendo las comparaciones principales.

10.2.- GESTIÓN DE CONFIGURACIÓN Y TRAZABILIDAD

El repositorio Git actúa como fuente de verdad del código, los mensajes y la memoria. Cada campaña experimental debe guardar:

- revisión del repositorio
- versiones de Python y dependencias
- identificador del modelo y revisión de pesos
- parámetros de generación, servicio y evaluación
- semillas y divisiones de datos
- mensaje de sistema, mensaje de tarea y esquema de respuesta
- predicciones sin procesar, métricas derivadas y registro de errores

Los resultados agregados no sustituyen a las predicciones. Conservar ambos niveles permite detectar errores de análisis y recalcular métricas sin repetir inferencias costosas. Los archivos generados deben ser inmutables o incorporar un identificador de ejecución que evite sobrescrituras accidentales.

Las dependencias de redes convolucionales ya están declaradas como extra opcional del proyecto mediante PyTorch y Torchvision. El entorno de servicio vLLM se gestiona por separado porque las inferencias VLM/ICL requieren trazabilidad específica de pesos, servidor, plantilla de conversación y esquema de salida. La comparación VLM/ICL exige registrar revisión de pesos, versión del servidor, plantilla de conversación y predicciones completas.

10.3.- PRINCIPIOS ÉTICOS

10.3.1.- Proporcionalidad y finalidad

La finalidad del trabajo es comparar métodos de reconocimiento de morfologías electrocardiográficas y estudiar su transferencia con pocos datos. No se pretende automatizar decisiones asistenciales. El alcance se limita a investigación retrospectiva y desarrollo metodológico.

La proporcionalidad exige emplear la cantidad mínima de datos necesaria, evitar variables clínicas no relacionadas con los objetivos y escoger modelos cuya complejidad esté justificada por la pregunta experimental. La disponibilidad de una variable no constituye por sí sola una razón para utilizarla.

10.3.2.- Riesgos para las personas

Aunque los datos estén anonimizados o seudonimizados, un error metodológico puede generar conclusiones engañosas sobre una población clínica poco numerosa. Los principales riesgos indirectos son la sobreestimación del rendimiento, el sesgo por selección, la ausencia de calibración, la confusión entre morfología y diagnóstico y la generalización fuera del centro de origen.

La mitigación incluye validación por paciente, intervalos de confianza, documentación de exclusiones, análisis por subgrupos cuando el tamaño lo permita y lenguaje prudente. No se presentará una mejora estadística como beneficio clínico sin un estudio diseñado para esa finalidad.

10.3.3.- Intervención humana

Las anotaciones clínicas y la interpretación de discrepancias requieren supervisión experta. En un uso futuro, el sistema solo podría actuar como apoyo y sus resultados deberían mostrarse junto con la señal original, la calidad de entrada y una indicación de incertidumbre. La persona responsable de la decisión no debe quedar condicionada por una salida presentada como certeza.

10.4.- PROTECCIÓN DE DATOS

10.4.1.- Marco general

Los datos de salud son una categoría especial en el artículo 9 del Reglamento General de Protección de Datos [42]. Su tratamiento exige una base jurídica adecuada y garantías reforzadas. Los principios del artículo 5 incluyen licitud, limitación de finalidad, minimización, exactitud, limitación del plazo de conservación, integridad, confidencialidad y responsabilidad proactiva.

La protección desde el diseño y por defecto, recogida en el artículo 25, implica que la arquitectura del proyecto debe reducir la exposición desde el inicio. El artículo 32 exige medidas de seguridad apropiadas al riesgo. Cuando un tratamiento pueda implicar un alto riesgo, el artículo 35 prevé una evaluación de impacto. Para investigación científica, el artículo 89 requiere salvaguardias técnicas y organizativas.

En España, la Ley Orgánica 3/2018 completa este marco [43]. Su disposición adicional decimoséptima regula tratamientos de datos de salud con fines de investigación y contempla el uso de datos seudonimizados bajo condiciones específicas. Entre las garantías relevantes se encuentran la separación entre información clínica y datos que permitan reidentificar, el

acceso restringido y la revisión ética. La Ley 14/2007 de Investigación biomédica añade principios de consentimiento, confidencialidad y control ético [44].

10.4.2.- Aplicación al proyecto

Brugada HUCA se publica sin información identificativa y su documentación declara anonimización mediante Safe Harbor [39]. El proyecto conservará únicamente los campos necesarios para las tareas definidas. Los identificadores públicos se transformarán en claves internas cuando se creen derivados, evitando incorporarlos a nombres de figura destinados a difusión.

Las medidas mínimas son almacenamiento local controlado, permisos restringidos, cifrado del dispositivo, ausencia de datos clínicos en servicios no autorizados, copias de seguridad protegidas y registro de procedencia. Las claves de API no se incluyen en el repositorio ni en la memoria. Si se incorporan datos adicionales no anónimos, deberá revisarse la base jurídica y realizarse el análisis de impacto antes del tratamiento.

La guía de la Agencia Española de Protección de Datos sobre gestión del riesgo y evaluaciones de impacto ofrece una referencia práctica para esa revisión [45]. La evaluación no puede sustituirse por una declaración genérica de anonimización.

10.5.- LICENCIAS Y REUTILIZACIÓN

El código propio deberá publicar una licencia compatible con las dependencias y con los objetivos de difusión. Las imágenes sintéticas pueden regenerarse a partir del código y sus metadatos. Para datos externos se respetarán sus términos individuales.

Brugada HUCA utiliza CC BY SA 4.0. Toda redistribución de material derivado debe conservar atribución, indicar cambios y aplicar la licencia correspondiente. PTB XL y MIMIC IV ECG tienen condiciones de acceso y reutilización propias que deben comprobarse en su versión concreta. No se copiarán datos clínicos dentro del repositorio público.

Los pesos de modelos de terceros también pueden imponer condiciones. El identificador comercial o técnico del modelo no basta. Deben conservarse la licencia, la revisión descargada y las restricciones de uso aplicables al experimento.

10.6.- REGULACIÓN DE SISTEMAS DE INTELIGENCIA ARTIFICIAL

10.6.1.- Reglamento europeo de inteligencia artificial

El Reglamento 2024/1689 establece las normas europeas en materia de inteligencia artificial [46]. Su artículo 2 contempla una exclusión para sistemas y modelos desarrollados y puestos en servicio específicamente con la única finalidad de investigación y desarrollo científicos antes de su comercialización o puesta en servicio. Esta exclusión es coherente con el alcance metodológico del TFG, pero no cubre automáticamente una prueba clínica en condiciones reales ni un producto desplegado.

Si el sistema se integrara en un producto sanitario, su clasificación dependería de la finalidad prevista y de su relación con la legislación sectorial. El artículo 6 vincula determinados productos sujetos a evaluación de conformidad por terceros con la categoría de alto riesgo.

Antes de cualquier despliegue, habría que revisar el texto jurídico aplicable, las obligaciones sectoriales y la relación del sistema con productos regulados. La memoria no presenta el prototipo como herramienta desplegable ni como sistema de alto riesgo listo para uso clínico.

10.6.2.- Producto sanitario

El Reglamento 2017/745 establece que un programa puede ser producto sanitario cuando el fabricante le atribuye una finalidad médica específica [47]. La intención declarada, las funciones, los usuarios y el contexto de uso son determinantes. Un prototipo de investigación que clasifica imágenes para comparar algoritmos no adquiere por ello una autorización clínica.

Si se desarrollara una herramienta para apoyar diagnóstico, pronóstico o tratamiento, habría que analizar la cualificación y clasificación del programa, la gestión de riesgos, la evaluación clínica, el ciclo de vida y la vigilancia posterior. Las guías MDCG sobre software sanitario e interacción con sistemas de inteligencia artificial orientan esa revisión [48, 49].

Por tanto, cualquier documentación o interfaz asociada debe incluir una limitación visible de uso. El sistema no está validado como producto sanitario y no debe utilizarse para diagnosticar, descartar enfermedad ni decidir tratamiento.

10.6.3.- Espacio Europeo de Datos de Salud

El Espacio Europeo de Datos de Salud será relevante para futuros proyectos que reutilicen datos sanitarios a escala europea [50]. Cualquier extensión deberá revisar sus reglas de acceso, finalidad secundaria y entornos seguros.

10.7.- EQUIDAD, ROBUSTEZ Y TRANSPARENCIA

La base sintética no representa grupos demográficos. Por tanto, no permite medir diferencias de rendimiento por sexo, edad, origen o comorbilidad. La fase real deberá describir las variables disponibles y analizar subgrupos solo cuando exista tamaño suficiente y una razón clínica. La ausencia de un análisis no debe interpretarse como ausencia de sesgo.

El modelo puede aprender propiedades del renderizado, del equipo o del centro. Las pruebas de robustez incluirán cambios de resolución, cuadrícula, recorte, contraste y ruido dentro de límites plausibles. Una caída intensa ante transformaciones inocuas indicaría dependencia de señales espurias.

La transparencia se apoya en mensajes exactos, esquemas de respuesta, versiones, matrices de confusión, ejemplos de error y descripción de datos. Las recomendaciones TRI-POD+AI y PROBAST+AI proporcionan referencias útiles para informar y evaluar modelos predictivos basados en aprendizaje automático [40, 41]. Las explicaciones visuales como Grad CAM pueden ayudar a auditar una CNN [30], pero no demuestran causalidad ni corrección clínica.

10.8.- SOSTENIBILIDAD

El impacto ambiental se reduce evitando barridos sin hipótesis, reutilizando predicciones, ejecutando primero pruebas pequeñas y deteniendo configuraciones claramente defectuosas según reglas previas. Se preferirán modelos abiertos de tamaño compatible con el objetivo experimental y se informará del tiempo de acelerador.

La comparación entre CNN y VLM debe considerar no solo la métrica, sino también coste de entrenamiento, coste por inferencia, latencia y posibilidad de despliegue local. Un incremento marginal de rendimiento puede no justificar un aumento grande de consumo.

10.9.- COMPROMISO DE USO RESPONSABLE

El producto de este TFG es un prototipo de investigación reproducible. Sus resultados deberán leerse dentro del conjunto, las etiquetas y el protocolo empleados. No se autoriza su uso autónomo con pacientes. Cualquier evolución clínica necesitará validación externa, evaluación prospectiva, supervisión profesional, revisión ética y cumplimiento regulatorio específico.

Esta limitación no reduce el valor del trabajo. Al contrario, delimita con precisión qué evidencia aporta y qué preguntas permanecen abiertas.

11 Conclusiones

11.1.- CONCLUSIÓN PRINCIPAL

Los resultados obtenidos permiten extraer una conclusión limitada: analizar el ECG como imagen es viable en condiciones controladas, pero una CNN supervisada con pocos ejemplos no se traslada de forma fiable a los datos reales cedidos por el HUCA. En el simulador, ResNet18 aprende una señal morfológica clara; en la cohorte real, la exactitud equilibrada se mantiene cerca del azar.

La comparación con ICL se mantiene separada de esta lectura. El capítulo 9 define el protocolo con Gemma 4 y MedGemma sin modificar la unidad de análisis ni las métricas.

11.2.- TRABAJO FUTURO

La continuación natural del trabajo debe centrarse en:

- incorporar los resultados VLM/ICL para cada presupuesto K , manteniendo los controles de etiquetas permutadas y demostraciones sin imagen;
- comparar de forma explícita CNN e ICL en el régimen de pocos datos;
- revisar los errores con criterio clínico, especialmente cuando la predicción contradiga la referencia de paciente;
- estudiar anotaciones morfológicas independientes para RBBB, elevación ST e inversión de T en una cohorte real;
- validar cualquier uso posterior en un entorno externo y siempre como apoyo al triaje, no como diagnóstico autónomo.

A Configuración experimental

Este apéndice recoge los parámetros principales de la configuración experimental utilizada en la memoria. Se incluyen los valores necesarios para interpretar los resultados y comparar las líneas CNN y VLM/ICL.

A.1.- ENTORNO DE SOFTWARE

El proyecto declara Python 3.12 o posterior y utiliza uv como gestor de entorno. Las dependencias directas y opcionales relevantes se recogen en la tabla A.1.

Paquete	Versión mínima
Matplotlib	3.9
NumPy	2.0
OpenAI Python	2.35.1
pandas	2.2
Pillow	10.4
Pydantic	2.8
scikit-learn	1.5
tqdm	4.66
PyTorch, extra cnn	2.3
Torchvision, extra cnn	0.18
WFDB, extra real-data	4.1
pytest, extra dev	8.3
Ruff, extra dev	0.6

Tabla A.1.- Dependencias principales declaradas por el proyecto.

La memoria se compila con XeLaTeX. Las figuras de resultados se generan en modo no interactivo, con el mismo estilo tipográfico usado en el documento. Las ejecuciones con PyTorch aplican las recomendaciones de reproducibilidad disponibles en su documentación oficial [33].

A.2.- CONJUNTO SINTÉTICO QRS/ST

Propiedad	Valor
Fuente	<code>ecg_few.simulator</code>
Pacientes	100
Imágenes	300
Familias fuente	NORMAL, RBBB, ST_ELEVATION, T_WAVE_INVERSION, COMBINED_QRS_ST
Pacientes por familia	20
Derivaciones renderizadas	V1, V2 y V3
Frecuencia de muestreo	500 Hz
Duración del beat	900 ms
Resolución de guardado	130 ppp
Positivos derivados	20
Negativos o incompletos	80
Presupuestos	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026

Tabla A.2.- Configuración del conjunto sintético final.

La etiqueta positiva se obtiene cuando RBBB, elevación ST e inversión T están presentes simultáneamente. La agregación de paciente promedia las probabilidades de las derivaciones y después aplica el umbral seleccionado.

A.3.- DATOS CEDIDOS POR EL HUCA

Propiedad	Valor
Fuente	Hospital Universitario Central de Asturias (HUCA), recurso Brugada HUCA 1.0.0
Pacientes brutos	363
Pacientes excluidos	46 por patrón basal limítrofe
Pacientes incluidos	317
Imágenes incluidas	951
Casos confirmados	116
Controles	201
Derivaciones	V1, V2 y V3
Ventana	300 ms antes de R y 600 ms después de R
Frecuencia de origen	100 Hz
Resolución de guardado	130 ppp
Separación	Leave-one-out por paciente

Tabla A.3.- Configuración del conjunto real procesado.

Los datos cedidos por el HUCA no contienen anotaciones independientes para las tres etiquetas morfológicas del simulador. La tarea real utiliza la etiqueta clínica `clinical_brugada`, recogida a nivel de paciente mediante revisión especializada.

A.4.- CONFIGURACIÓN CNN

Propiedad	Valor
Arquitectura	ResNet18
Pesos iniciales	default de Torchvision
Entrada	RGB, 224 por 224
Salida	Un logit binario
Pérdida	BCEWithLogitsLoss con loss_pos_weight=auto
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Lote	32
Épocas máximas	20
Estrategia de umbral	val_derived_balanced_accuracy
Métrica principal	Exactitud equilibrada por paciente
Grad CAM	12 paneles en sintético y 6 en datos reales por ejecución agregada

Tabla A.4.- Hiperparámetros de la CNN final.

A.5.- CONFIGURACIÓN DE ADAPTACIÓN DE DOMINIO

Propiedad	Valor
Origen etiquetado	data/simulator_qrs
Destino no etiquetado	data/brugada_huca
Métodos	SSL, CORAL, MMD y DANN [31]
Presupuestos	$K = 16$ y $K = 32$
Semillas	42, 123 y 2026
Peso de adaptación	0,1
Escalas MMD	0,5, 1,0, 2,0 y 4,0
SSL	SimCLR durante 3 épocas, ssl_pretrain_lr=0.0001
Política de destino	Transductiva compartida, sin etiquetas destino en la pérdida supervisada

Tabla A.5.- Configuración de la línea de adaptación de dominio.

A.6.- CONFIGURACIÓN VLM/ICL

La línea VLM/ICL usa los mismos pacientes reservados, presupuestos K y métricas por paciente que la línea CNN. Los modelos comparados son Gemma 4 y MedGemma 1.5, ejecutados con temperatura 0 y salida estructurada.

Elemento	Valor
Modelos	Gemma 4 y MedGemma 1.5
Entrada	Imagen ECG y demostraciones imagen-etiqueta
Presupuestos	$K = \{0, 2, 4, 8, 16, 32\}$
Condiciones	Sin ejemplos, ICL normal, ICL balanceado, etiquetas permutadas y sin imagen de apoyo
Salida morfológica	RBBB, ST_ELEVATION y T_WAVE_INVERSION
Salida clínica	clinical_brugada
Métrica principal	Exactitud equilibrada por paciente

Tabla A.6.- Configuración resumida de la línea VLM/ICL.

El capítulo 9 desarrolla las condiciones, controles y criterios de lectura de esta línea.

B Resultados completos

Este apéndice reúne las tablas de resultados agregadas utilizadas en los capítulos 7 y 8. Todas las cifras son medias sobre tres semillas salvo los recuentos, que acumulan las predicciones de las tres ejecuciones.

B.1.- CNN EN EL CONJUNTO SINTÉTICO

K	Acc.	BA	F1	Prec.	Sens.	Esp.	AP
2	0,610	$0,625 \pm 0,022$	0,401	0,291	0,650	0,600	0,268
4	0,640	$0,631 \pm 0,042$	0,407	0,304	0,617	0,646	0,268
8	0,687	$0,685 \pm 0,023$	0,468	0,357	0,683	0,688	0,383
16	0,757	$0,773 \pm 0,013$	0,569	0,442	0,800	0,746	0,534
32	0,827	$0,848 \pm 0,030$	0,673	0,545	0,883	0,812	0,614

Tabla B.1.- Resultados completos de la CNN sobre el conjunto sintético.

B.2.- CNN EN LA COHORTE CEDIDA POR EL HUCA

K	Acc.	BA	F1	Prec.	Sens.	Esp.	AP
2	0,460	$0,509 \pm 0,010$	0,484	0,372	0,693	0,325	0,404
4	0,450	$0,509 \pm 0,023$	0,493	0,373	0,730	0,289	0,388
8	0,442	$0,490 \pm 0,018$	0,469	0,360	0,672	0,308	0,383
16	0,478	$0,516 \pm 0,023$	0,480	0,379	0,658	0,375	0,478
32	0,461	$0,499 \pm 0,012$	0,466	0,366	0,644	0,355	0,423

Tabla B.2.- Resultados completos de la CNN base sobre los datos cedidos por el HUCA.

B.3.- COMPARACIÓN DE DOMINIOS

K	Sintético BA	BA datos reales
2	0,625	0,509
4	0,631	0,509
8	0,685	0,490
16	0,773	0,516
32	0,848	0,499

Tabla B.3.- Exactitud equilibrada sintética frente a real.

B.4.- ADAPTACIÓN DE DOMINIO

Método	K	Acc.	BA	F1	Prec.	Sens.	Esp.
Base	16	0,478	$0,516 \pm 0,023$	0,480	0,379	0,658	0,375
SSL	16	0,429	$0,477 \pm 0,027$	0,458	0,351	0,658	0,297
CORAL	16	0,493	$0,524 \pm 0,008$	0,481	0,384	0,641	0,408
MMD	16	0,484	$0,516 \pm 0,019$	0,474	0,378	0,635	0,396
DANN	16	0,487	$0,515 \pm 0,019$	0,470	0,378	0,621	0,410
Base	32	0,461	$0,499 \pm 0,012$	0,466	0,366	0,644	0,355
SSL	32	0,457	$0,503 \pm 0,014$	0,476	0,368	0,672	0,333
CORAL	32	0,499	$0,528 \pm 0,013$	0,480	0,388	0,632	0,423
MMD	32	0,522	$0,549 \pm 0,029$	0,498	0,404	0,649	0,448
DANN	32	0,473	$0,509 \pm 0,028$	0,472	0,373	0,644	0,375

Tabla B.4.- Resultados completos de adaptación de dominio sobre los datos cedidos por el HUCA.

B.5.- TRAZABILIDAD DE RESULTADOS

Las tablas anteriores proceden de ejecuciones agregadas por paciente. Para cada bloque se conservan las predicciones por imagen, la agregación por paciente, las matrices de confusión y las métricas resumidas por K y semilla.

La auditoría final verifica los conjuntos, los informes CNN, la comparación sintético-real y la adaptación de dominio. La línea VLM/ICL se documenta en el capítulo 9; sus tablas

mantienen la misma estructura de lectura, sin mezclar cifras no verificadas con los resultados cerrados de la CNN.

C Mensajes y respuestas estructuradas

C.1.- CRITERIO DE CONSERVACIÓN

Los mensajes forman parte de la configuración experimental. Una modificación de una palabra puede alterar la respuesta de un modelo de visión y lenguaje. Por esta razón se conservan los textos completos, su ruta y la revisión del repositorio. Los listados siguientes reproducen la versión utilizada para preparar la campaña.

C.2.- MENSAJE DE SISTEMA

Ruta: prompts/system/default.md

```

1 You are analyzing synthetic images of single ECG beats from a precordial-like lead.
2
3 This is a visual morphology classification task. It is not a patient diagnosis.
4
5 Use the waveform shown in the image as the only evidence. Follow the requested
6     JSON schema exactly. Do not add explanations, markdown, or additional keys.
7
8 Relevant terminology:
9
10 - Q is the first negative deflection before any positive ventricular deflection.
11 - R is the first positive ventricular deflection.
12 - S is the negative deflection after R.
13 - R prime is a second positive deflection after S.
14 - The J point marks the transition from the end of the QRS complex to the ST
    segment.
15 - The T wave follows the ST segment and represents ventricular repolarization.

```

C.3.- TAREA MULTIETIQUETA MÍNIMA

Ruta: prompts/multilabel/label_only.md

```

1 Analyze this synthetic single-beat ECG image.
2
3 Decide whether each visual morphology finding is present:
4
5 - RBBB
6 - ST_ELEVATION
7 - T_WAVE_INVERSION
8
9 Return only valid JSON with boolean values for exactly these keys:
10
11 {
12   "RBBB": true,
13   "ST_ELEVATION": false,
14   "T_WAVE_INVERSION": false
15 }

```

C.4.- TAREA MULTIETIQUETA DESCRITA

Ruta: prompts/multilabel/morphology_described.md

```

1 Analyze this synthetic single-beat ECG image.
2
3 Evaluate these visual morphology findings.
4
5 RBBB:
6
7 - Look for an RSR prime pattern with an initial positive R wave, a negative S wave
8   , and a distinct second positive peak.
9 - The second positive peak should occur late in the QRS region.
10 - The terminal positive component should be visibly broad rather than a narrow
11   isolated spike.
12
13 ST_ELEVATION:
14
15 - The ST region begins after the QRS complex at the J point and ends before the T
16   wave.
17 - In the absence of elevation, this region remains close to the baseline.
18 - ST elevation is present when the trace remains visibly above the baseline after
19   the QRS complex.
20 - The elevated region may be smooth, concave, convex, or coved.
21
22 T_WAVE_INVERSION:
23

```



```

20 - The T wave follows the ST region.
21 - An upright T wave forms a positive late deflection.
22 - T wave inversion is present when the late repolarization wave forms a sustained
    negative deflection below the baseline.
23
24 Return only valid JSON with boolean values for exactly these keys:
25
26 {
27   "RBBB": true,
28   "ST_ELEVATION": false,
29   "T_WAVE_INVERSION": false
30 }
```

C.5.- CONSULTAS BINARIAS

C.5.1.- RBBB

Ruta: prompts/binary/rbbb.md

```

1 Analyze this synthetic single-beat ECG image.
2
3 Finding: RBBB.
4
5 Operational visual definition:
6
7 - Look for an RSR prime pattern with an initial positive R wave, a negative S wave
    , and a distinct second positive peak.
8 - The second positive peak should occur late in the QRS region.
9 - The terminal positive component should be visibly broad rather than a narrow
    isolated spike.
10
11 Question: Is the RBBB morphology present?
12
13 Return only valid JSON:
14
15 {
16   "finding": "RBBB",
17   "present": true
18 }
19
20 Use `false` instead of `true` when the finding is absent.
```

C.5.2.- Elevación de ST

Ruta: prompts/binary/st_elevation.md

```

1 Analyze this synthetic single-beat ECG image.
2
3 Finding: ST_ELEVATION.
4
5 Operational visual definition:
6
7 - The ST region begins after the QRS complex at the J point and ends before the T
   wave.
8 - In the absence of elevation, this region remains close to the baseline.
9 - ST elevation is present when the trace remains visibly above the baseline after
   the QRS complex.
10 - The elevated region may be smooth, concave, convex, or coved.
11
12 Question: Is ST_ELEVATION present?
13
14 Return only valid JSON:
15
16 {
17   "finding": "ST_ELEVATION",
18   "present": true
19 }
20
21 Use `false` instead of `true` when the finding is absent.
```

C.5.3.- Inversión de la onda T

Ruta: prompts/binary/t_wave_inversion.md

```

1 Analyze this synthetic single-beat ECG image.
2
3 Finding: T_WAVE_INVERSION.
4
5 Operational visual definition:
6
7 - The T wave follows the ST region.
8 - An upright T wave forms a positive late deflection.
9 - T wave inversion is present when the late repolarization wave forms a sustained
   negative deflection below the baseline.
10
11 Question: Is T_WAVE_INVERSION present?
12
13 Return only valid JSON:
14
```

```

15 {
16   "finding": "T_WAVE_INVERSION",
17   "present": true
18 }
19
20 Use `false` instead of `true` when the finding is absent.

```

C.6.- EJEMPLOS DE RESPUESTAS

Una respuesta multietiqueta válida contiene exactamente tres booleanos:

```

1 {
2   "RBBB": true,
3   "ST_ELEVATION": true,
4   "T_WAVE_INVERSION": false
5 }

```

El siguiente contenido es JSON válido, pero no cumple el esquema porque incorpora una clave adicional:

```

1 {
2   "RBBB": true,
3   "ST_ELEVATION": true,
4   "T_WAVE_INVERSION": false,
5   "explanation": "The trace is elevated."
6 }

```

La respuesta siguiente tampoco es admisible porque utiliza cadenas en lugar de booleanos:

```

1 {
2   "RBBB": "true",
3   "ST_ELEVATION": "false",
4   "T_WAVE_INVERSION": "false"
5 }

```

En la tarea binaria, el nombre del hallazgo debe coincidir con la consulta. Una respuesta con finding distinto se registra como error aunque el booleano sea correcto.

C.7.- CONSTRUCCIÓN DEL CONTEXTO

Para $K > 0$, cada demostración contiene el mensaje de tarea, una imagen y la respuesta correcta. Las demostraciones se seleccionan una vez por ejecución y se reutilizan para todas las imágenes objetivo. Los identificadores quedan almacenados en el fichero de predicciones.

El control de respuestas permutadas reasigna las soluciones entre demostraciones. El control de demostraciones sin imagen conserva el texto y la respuesta, pero retira la entrada visual de cada ejemplo. La imagen objetivo nunca se retira.

C.8.- ANÁLISIS DE LA SALIDA

El servidor recibe un esquema JSON cuando admite `json_schema`. El texto devuelto se valida de nuevo mediante modelos Pydantic. Se conservan el texto original, la predicción analizada, la latencia, el uso informado y cualquier excepción.

El análisis principal no elimina silenciosamente las respuestas fallidas. Una campaña puede calcular un análisis secundario sobre respuestas válidas, pero debe informar también la tasa de error y considerar los fallos como predicciones incorrectas en la comparación principal.

D Reproducción

Este apéndice resume los criterios utilizados para que los resultados de la memoria puedan reconstruirse y auditarse. No se enumeran instrucciones de ejecución; se describen las condiciones que deben mantenerse constantes para interpretar las cifras de los capítulos principales.

D.1.- ENTORNO

El entorno de trabajo utiliza Python 3.12 o posterior, las dependencias declaradas en el proyecto y generación de figuras en modo no interactivo. La memoria se compila con XeLaTeX. Las gráficas se regeneran con la misma familia tipográfica y el mismo estilo visual que el documento, de modo que las tablas y figuras mantengan coherencia con el formato final del PDF.

D.2.- DATOS

El conjunto sintético QRS/ST contiene 100 pacientes simulados y 300 imágenes, con tres derivaciones por paciente. Las etiquetas se derivan de reglas morfológicas sobre RBBB, elevación del segmento ST e inversión de onda T.

La cohorte real procede de ECG cedidos por el Hospital Universitario Central de Asturias (HUCA). Tras excluir los casos con patrón basal limítrofe, la evaluación utiliza 317 pacientes y 951 imágenes. La etiqueta clínica distingue caso Brugada confirmado frente a control y se conserva siempre a nivel de paciente.

D.3.- LÍNEA CNN

La CNN se evalúa con validación leave-one-out por paciente, presupuestos $K = \{2, 4, 8, 16, 32\}$ y semillas 42, 123 y 2026. Cada ejecución conserva la selección de pacientes de entrenamiento, las predicciones por imagen, la agregación por paciente, el umbral aplicado, las matrices de confusión y las métricas finales.

La métrica principal es la exactitud equilibrada. Se reportan además F1, sensibilidad, espe-

cificidad, área ROC y precisión media. Los mapas Grad-CAM se conservan como inspección cualitativa, no como prueba clínica independiente.

D.4.- ADAPTACIÓN DE DOMINIO

La adaptación de dominio se interpreta como análisis complementario de la línea CNN. El origen etiquetado es el conjunto sintético y el destino no etiquetado son las imágenes reales cedidas por el HUCA. Las variantes revisadas son SSL, CORAL, MMD y DANN, evaluadas en $K = 16$ y $K = 32$ con las mismas semillas que la línea base.

Para que la comparación sea válida, cada variante mantiene la misma separación por paciente, la misma métrica principal y la misma regla de agregación que la CNN base.

D.5.- LÍNEA VLM/ICL

La línea VLM/ICL conserva la misma unidad experimental: paciente reservado, presupuesto K , semilla, imagen de consulta, demostraciones en contexto y salida estructurada. Las condiciones incluyen zero-shot, ICL normal, ICL balanceado, etiquetas permutadas y demostraciones sin imagen de apoyo.

La tarea morfológica evalúa RBBB, elevación ST e inversión de T como salidas booleanas. La tarea clínica directa produce `clinical_brugada`. Las respuestas inválidas se contabilizan como parte del rendimiento, ya que un VLM puede fallar tanto por clasificación incorrecta como por no respetar el formato solicitado.

D.6.- AUDITORÍA Y COMPILACIÓN

La auditoría comprueba que los conjuntos, particiones, predicciones por paciente, matrices de confusión, tablas agregadas y figuras principales sean consistentes entre sí. La revisión visual del PDF se centra en solapes, tablas cortadas, figuras desplazadas y referencias sin resolver.

Bibliografía

- [1] Zeppenfeld, K. y colaboradores. 2022 ESC Guidelines for the management of patients with ventricular arrhythmias and the prevention of sudden cardiac death. *European Heart Journal*, 43(40), 3997–4126, 2022. <https://doi.org/10.1093/eurheartj/ehac262>.
- [2] Kligfield, P., Gettes, L. S., Bailey, J. J. y colaboradores. Recommendations for the standardization and interpretation of the electrocardiogram. Part I. The electrocardiogram and its technology. *Circulation*, 115(10), 1306–1324, 2007. <https://doi.org/10.1161/CIRCULATIONAHA.106.180200>.
- [3] Surawicz, B., Childers, R., Deal, B. J., Gettes, L. S. y colaboradores. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part III. Intraventricular conduction disturbances. *Circulation*, 119(10), e235–e240, 2009. <https://doi.org/10.1161/CIRCULATIONAHA.108.191095>.
- [4] Rautaharju, P. M., Surawicz, B. y Gettes, L. S. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part IV. The ST segment, T and U waves, and the QT interval. *Circulation*, 119(10), e241–e250, 2009. <https://doi.org/10.1161/CIRCULATIONAHA.108.191096>.
- [5] Sieira, J. y Brugada, P. The definition of the Brugada syndrome. *European Heart Journal*, 38(40), 3029–3034, 2017. <https://doi.org/10.1093/eurheartj/ehx490>.
- [6] Wilde, A. A. M., Semsarian, C., Marquez, M. F. y colaboradores. Use, misuse, and pitfalls of the drug challenge test in the diagnosis of the Brugada syndrome. *European Heart Journal*, 44(27), 2427–2439, 2023. <https://doi.org/10.1093/eurheartj/ehad295>.
- [7] BrugadaDrugs.org Advisory Board. Diagnostic drugs for Brugada syndrome. BrugadaDrugs.org. https://www.brugadadrugs.org/druglist_diagnostic/.
- [8] CardioNetworks y ECGpedia. Brugada syndrome type1 example4. Wikimedia Commons, licencia CC BY-SA 3.0. [https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_\(CardioNetworks_ECGpedia\).png](https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_(CardioNetworks_ECGpedia).png).
- [9] Napolitano, C. y Priori, S. G. Brugada syndrome. *Orphanet Journal of Rare Diseases*, 1, 35, 2006. <https://doi.org/10.1186/1750-1172-1-35>.

- [10] Corrado, D., Pelliccia, A., Heidbuchel, H. y colaboradores. Recommendations for interpretation of 12 lead electrocardiogram in the athlete. *European Heart Journal*, 31(2), 243–259, 2010. <https://doi.org/10.1093/eurheartj/ehp473>.
- [11] Ribeiro, A. H. y colaboradores. Automatic diagnosis of the 12 lead ECG using a deep neural network. *Nature Communications*, 11, 1760, 2020. <https://doi.org/10.1038/s41467-020-15432-4>.
- [12] Wagner, P., Strodthoff, N., Bousseljot, R. D. y colaboradores. PTB XL, a large publicly available electrocardiography dataset. *Scientific Data*, 7, 154, 2020. <https://doi.org/10.1038/s41597-020-0495-6>.
- [13] Gow, B., Pollard, T., Nathanson, L. A. y colaboradores. MIMIC IV ECG. Diagnostic Electrocardiogram Matched Subset. Version 1.0. PhysioNet, 2023. <https://doi.org/10.13026/4nqg-sb35>.
- [14] Gliner, V., Keidar, N., Makarov, V. y colaboradores. Automatic classification of healthy and disease conditions from images or digital standard 12 lead electrocardiograms. *Scientific Reports*, 10, 16331, 2020. <https://doi.org/10.1038/s41598-020-73060-w>.
- [15] Sangha, V. y colaboradores. Automated multilabel diagnosis on electrocardiographic images and signals. *Nature Communications*, 13, 1583, 2022. <https://doi.org/10.1038/s41467-022-29153-3>.
- [16] Wu, H., Patel, K. H. K., Li, X. y colaboradores. A fully automated paper ECG digitisation algorithm using deep learning. *Scientific Reports*, 12, 20963, 2022. <https://doi.org/10.1038/s41598-022-25284-1>.
- [17] Gliner, V., Makarov, V., Avetisyan, A. I., Schuster, A. y Yaniv, Y. Using domain adaptation for classification of healthy and disease conditions from mobile captured images of standard 12 lead electrocardiograms. *Scientific Reports*, 13, 14023, 2023. <https://doi.org/10.1038/s41598-023-40693-6>.
- [18] Sayadi, O., Shamsollahi, M. B. y Clifford, G. D. Synthetic ECG generation and Bayesian filtering using a Gaussian wave based dynamical model. *Physiological Measurement*, 31(10), 1309–1329, 2010. <https://doi.org/10.1088/0967-3334/31/10/002>.
- [19] Gillette, K. y colaboradores. MedalCare XL. 16 900 healthy and pathological synthetic 12 lead ECGs from electrophysiological simulations. *Scientific Data*, 10, 531, 2023. <https://doi.org/10.1038/s41597-023-02416-4>.

- [20] Lopez Alcaraz, J. M. y Strodthoff, N. Diffusion based conditional ECG generation with structured state space models. *arXiv:2301.08227*, 2023. <https://doi.org/10.48550/arXiv.2301.08227>.
- [21] Liu, R., Bai, Y., Yue, X. y Zhang, P. Teaching multimodal language models to comprehend 12 lead electrocardiographic images. *npj Digital Medicine*, 9, 349, 2026. <https://doi.org/10.1038/s41746-026-02551-3>.
- [22] Zhang, D., Lan, X., Geng, S. y colaboradores. MEETI. A multimodal ECG dataset from MIMIC IV ECG with signals, images, features and interpretations. *Scientific Data*, 13, 527, 2026. <https://doi.org/10.1038/s41597-026-06796-1>.
- [23] Alayrac, J. B., Donahue, J., Luc, P. y colaboradores. Flamingo. A visual language model for few shot learning. *Advances in Neural Information Processing Systems*, 35, 23716–23736, 2022. <https://arxiv.org/abs/2204.14198>.
- [24] Chen, S., Han, Z., He, B., Liu, J., Buckley, M., Qin, Y., Torr, P., Tresp, V. y Gu, J. Can multimodal large language models truly perform multimodal in context learning. *IEEE/CVF Winter Conference on Applications of Computer Vision*, 6000–6010, 2025. <https://doi.org/10.1109/WACV61041.2025.00585>.
- [25] Qin, L., Chen, Q., Fei, H., Chen, Z., Li, M. y Che, W. What factors affect multimodal in context learning. An in depth exploration. *Advances in Neural Information Processing Systems*, 37, 2024. <https://arxiv.org/abs/2410.20482>.
- [26] Camba, S., Otero, A., García, D., Sánchez, L. y Costa, N. Can In-Context Learning Enable Large Vision Language Models to Detect ECG Abnormalities? En *Artificial Intelligence in Biomedicine. CIABiomed 2025*, Lecture Notes in Computer Science, vol. 16148, 200–213. Springer, Cham, 2026. https://doi.org/10.1007/978-3-032-10661-2_16.
- [27] Google DeepMind. Gemma 4 model card. Google AI for Developers. https://ai.google.dev/gemma/docs/core/model_card_4.
- [28] Google Health AI Developer Foundations. MedGemma 1.5 model card. Google for Developers. <https://developers.google.com/health-ai-developer-foundations/medgemma/model-card>.
- [29] He, K., Zhang, X., Ren, S. y Sun, J. Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770–778, 2016. <https://doi.org/10.1109/CVPR.2016.90>.

- [30] Selvaraju, R. R. y colaboradores. Grad CAM. Visual explanations from deep networks via gradient based localization. *Proceedings of the IEEE International Conference on Computer Vision*, 618–626, 2017. <https://doi.org/10.1109/ICCV.2017.74>.
- [31] Ganin, Y. y colaboradores. Domain adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59), 1–35, 2016. <https://jmlr.org/papers/v17/15-239.html>.
- [32] Tsoumakas, G. y Katakis, I. Multi label classification. An overview. *International Journal of Data Warehousing and Mining*, 3(3), 1–13, 2007. <https://doi.org/10.4018/jdwm.2007070101>.
- [33] PyTorch Contributors. Reproducibility. PyTorch documentation. <https://docs.pytorch.org/docs/stable/notes/randomness.html>.
- [34] PyTorch Contributors. BCEWithLogitsLoss. PyTorch documentation. <https://docs.pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html>.
- [35] Torchvision Contributors. ResNet18 and pretrained weights. Torchvision documentation. <https://docs.pytorch.org/vision/stable/models/generated/torchvision.models.resnet18.html>.
- [36] Loshchilov, I. y Hutter, F. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019. <https://arxiv.org/abs/1711.05101>.
- [37] vLLM Project. OpenAI compatible server. vLLM documentation. https://docs.vllm.ai/en/latest/serving/online_serving/openai_compatible_server/.
- [38] vLLM Project. Gemma 4 usage guide. vLLM recipes. <https://docs.vllm.ai/projects/recipes/en/latest/Google/Gemma4.html>.
- [39] Costa Cortez, N. y García Iglesias, D. Brugada-HUCA. 12-Lead ECG Recordings for the Study of Brugada Syndrome. Version 1.0.0. PhysioNet, 2026. <https://doi.org/10.13026/0m2w-dy83>.
- [40] Collins, G. S., Moons, K. G. M., Dhiman, P. y colaboradores. TRIPOD+AI statement. Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378, 2024. <https://doi.org/10.1136/bmj-2023-078378>.
- [41] Moons, K. G. M., Damen, J. A. A. G., Kaul, T. y colaboradores. PROBAST+AI. An updated quality, risk of bias and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388, e082505, 2025. <https://doi.org/10.1136/bmj-2024-082505>.

- [42] Unión Europea. Reglamento 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales. *Diario Oficial de la Unión Europea*. <https://eur-lex.europa.eu/eli/reg/2016/679/oj/spa>.
- [43] España. Ley Orgánica 3/2018 de Protección de Datos Personales y garantía de los derechos digitales. *Boletín Oficial del Estado*. <https://www.boe.es/buscar/act.php?id=BOE-A-2018-16673>.
- [44] España. Ley 14/2007 de Investigación biomédica. *Boletín Oficial del Estado*. <https://www.boe.es/buscar/act.php?id=BOE-A-2007-12945>.
- [45] Agencia Española de Protección de Datos. Gestión del riesgo y evaluación de impacto en tratamientos de datos personales. AEPD. Documento oficial de la AEPD.
- [46] Unión Europea. Reglamento 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial. *Diario Oficial de la Unión Europea*. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/spa>.
- [47] Unión Europea. Reglamento 2017/745 sobre los productos sanitarios. *Diario Oficial de la Unión Europea*. <https://eur-lex.europa.eu/eli/reg/2017/745/oj/spa>.
- [48] Medical Device Coordination Group. MDCG 2019-11 Rev. 1. Qualification and classification of software. Regulation (EU) 2017/745 and Regulation (EU) 2017/746. Comisión Europea. https://health.ec.europa.eu/latest-updates/update-mdcg-2019-11-rev1-qualification-and-classification-software-regulation-eu-2017745-and-2025-06-17_en.
- [49] Medical Device Coordination Group. MDCG 2025-6. FAQ on interplay between the Medical Devices Regulation, the In Vitro Diagnostic Medical Devices Regulation and the Artificial Intelligence Act. Comisión Europea. https://health.ec.europa.eu/latest-updates/mdcg-2025-6-faq-interplay-between-medical-devices-regulation-vitro-diagnostic-medical-devices-2025-06-19_en.
- [50] Unión Europea. Reglamento 2025/327 relativo al Espacio Europeo de Datos de Salud. *Diario Oficial de la Unión Europea*. <https://eur-lex.europa.eu/eli/reg/2025/327/oj/spa>.