



ESCUELA POLITÉCNICA DE INGENIERÍA DE GIJÓN

GRADO EN CIENCIA E INGENIERÍA DE DATOS

ÁREA DE CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

TÍTULO DEL TRABAJO

**Análisis de ECGs con grandes modelos de
lenguaje aplicados a enfermedades raras**

D. ALEJANDRO MORIS LARA
TUTOR: D. Nahuel Costa Cortez

Resumen

Este Trabajo de Fin de Grado aborda el análisis automático de electrocardiogramas cuando la información disponible no es la señal digital original, sino una imagen del trazado. Esta situación es frecuente en revisiones retrospectivas y en flujos clínicos donde los electrocardiogramas circulan como papel escaneado, documento digital o captura integrada en la historia electrónica. El problema se estudia en un escenario especialmente exigente: pocos pacientes etiquetados y una tarea de triaje relacionada con la sospecha de síndrome de Brugada. El sistema no se plantea como diagnóstico automático, sino como apoyo para priorizar trazados que deberían revisarse por especialistas.

Se comparan dos formas de afrontar esa escasez de datos etiquetados. Ambas reciben electrocardiogramas como imagen, se evalúan por paciente y utilizan los mismos tamaños de conjunto: 2, 4, 8, 16 y 32 ejemplos. La evaluación combina dos fuentes. La primera es un simulador morfológico que genera imágenes de las derivaciones precordiales derechas y asigna etiquetas mediante reglas sobre la forma del trazado. La segunda es un conjunto real cedido por el Hospital Universitario Central de Asturias, con 317 pacientes y 951 imágenes clasificadas como caso Brugada o control.

El primer enfoque es supervisado. Una ResNet18 utiliza pacientes etiquetados del simulador para actualizar sus pesos y aprender tres hallazgos morfológicos. Con los datos cedidos por el HUCA no se entrena una CNN supervisada real-real, porque el conjunto clínico no contiene anotaciones independientes de RBBB, elevación ST e inversión de T por imagen. Por ello, la evaluación real de la CNN mide transferencia desde el simulador hacia la cohorte clínica. En el simulador, la red neuronal convolucional alcanza una exactitud equilibrada de 0,848 con 32 ejemplos, sensibilidad de 0,883 y especificidad de 0,812. Con los datos reales, el rendimiento base queda cerca del azar, con una mejor exactitud equilibrada de 0,516 al usar 16 ejemplos. La adaptación de dominio mejora de forma modesta hasta 0,549 con MMD en $K = 32$.

El segundo enfoque es multimodal. Gemma 4 se utiliza como modelo de visión y lenguaje con aprendizaje en contexto: los ejemplos etiquetados no modifican los pesos del modelo, sino que se incorporan a la instrucción de entrada como demostraciones antes de la imagen que debe clasificarse. Se comparan tres condiciones: sin ejemplos previos, con demostraciones seleccionadas de forma estándar y con demostraciones balanceadas entre clases cuando el pliegue lo permite. En el simulador, las demostraciones mejoran de forma clara la condición sin ejemplos previos y alcanzan 0,754 de exactitud equilibrada con contexto balanceado al usar 8 ejemplos. En los datos reales, el mejor punto se sitúa alrededor de 0,522 con 16 ejemplos. El contexto balanceado aumenta la sensibilidad hasta 0,713, pero reduce la especificidad a 0,332.

En conjunto, el trabajo muestra que el electrocardiograma como imagen contiene señal útil en un dominio controlado, pero que la transferencia a datos reales de Brugada sigue siendo limitada con pocos ejemplos. La red neuronal convolucional aprovecha mejor el aumento de datos en el simulador. El aprendizaje en contexto no requiere reentrenar el modelo para cada nuevo conjunto y facilita su traslado entre escenarios, aunque en estos experimentos aumenta la sensibilidad a costa de menor especificidad. Cuando el VLM recibe contexto sintético y

consulta los ECG reales cedidos por el HUCA, el rendimiento vuelve a colapsar hacia la clase negativa, lo que refuerza la dificultad de la brecha sintético-real. Ningún enfoque alcanza todavía la robustez necesaria para un triaje clínico fiable. La principal aportación del Trabajo de Fin de Grado es delimitar esta dificultad mediante un protocolo reproducible y señalar que el avance requerirá más casos positivos, anotaciones morfológicas clínicas y validación externa.

Palabras clave: electrocardiograma como imagen, síndrome de Brugada, pocos datos etiquetados, aprendizaje supervisado, redes neuronales convolucionales, modelos de visión y lenguaje, aprendizaje en contexto, triaje clínico.

Abstract

This Bachelor's Thesis addresses automatic ECG analysis when the available input is not the original digital signal but an image of the trace. This setting is common in retrospective reviews and clinical workflows where ECGs are exchanged as scanned paper, PDF files or screenshots embedded in electronic health records. The problem is studied under a particularly restrictive condition: few labelled patients and a triage task related to suspected Brugada syndrome. The system is not proposed as an automatic diagnostic tool, but as a research prototype for prioritizing traces that should be reviewed by specialists.

The thesis compares two ways of dealing with this scarcity of labelled data. Both approaches receive ECGs as images, are evaluated at patient level and use the same example-set sizes $K = \{2, 4, 8, 16, 32\}$. The evaluation combines two sources. The first is a QRS/ST morphological simulator that generates V1, V2 and V3 images and assigns labels using rules on trace morphology. The second is a real dataset provided by the Hospital Universitario Central de Asturias, with 317 patients and 951 images classified as Brugada case or control.

The first approach is supervised. A ResNet18 uses labelled simulator patients to update its weights and learn three morphological findings. A supervised real-to-real CNN is not trained with the dataset provided by HUCA because the clinical cohort does not contain independent image-level annotations for RBBB, ST elevation and T-wave inversion. The real evaluation therefore measures transfer from the simulator to the clinical cohort. On the simulator, the CNN reaches balanced accuracy 0.848 at $K = 32$, with sensitivity 0.883 and specificity 0.812. On the real dataset, baseline performance remains close to chance, with a best balanced accuracy of 0.516 at $K = 16$. Domain adaptation improves this modestly to 0.549 with MMD at $K = 32$.

The second approach is multimodal. Gemma 4 is used as a vision-language model with in-context learning: the labelled examples do not modify the model weights, but are inserted into the prompt as demonstrations before the image to be classified. Zero-shot, normal ICL and balanced ICL are compared. On the simulator, demonstrations clearly improve over zero-shot and reach balanced accuracy 0.754 with balanced context at $K = 8$. On real ECGs, the best point is around 0.522 at $K = 16$. Balanced context increases sensitivity to 0.713, but specificity falls to 0.332.

Overall, the work shows that ECG-as-image analysis contains useful signal in a controlled domain, but transfer to real Brugada data remains limited with few examples. The CNN benefits more clearly from additional data on the simulator. In-context learning does not require retraining the model for each new dataset and is easier to move between evaluation settings, although in these experiments it increases sensitivity at the cost of lower specificity. When the

VLM receives simulator context and is queried on the ECGs provided by HUCA, performance collapses back towards the negative class, reinforcing the difficulty of the synthetic-to-real gap. Neither approach is yet robust enough for reliable clinical triage. The main contribution of the thesis is to characterize this limitation through a reproducible protocol and to show that further progress will require more positive cases, clinical morphological annotations and external validation.

Keywords: ECG as image, Brugada syndrome, few labelled data, supervised learning, convolutional neural networks, vision-language models, in-context learning, clinical triage.

Glosario de siglas

Este glosario reúne las siglas y abreviaturas que aparecen en la memoria. Se incluye el significado con el que se utilizan dentro del trabajo para mantener una lectura consistente entre capítulos, tablas y apéndices.

Tabla 1.- Siglas y abreviaturas utilizadas en la memoria.

Sigla	Significado	Uso en este trabajo
Acc.	Exactitud	Proporción global de predicciones correctas. Se informa como métrica complementaria en los apéndices.
ACCF	American College of Cardiology Foundation	Sociedad científica citada en recomendaciones de estandarización electrocardiográfica.
AHA	American Heart Association	Sociedad científica citada en guías y recomendaciones clínicas sobre electrocardiografía.
AP	Precisión media	Área bajo la curva precisión-recall. Se usa como métrica complementaria en las tablas completas.
API	Interfaz de programación de aplicaciones	Se menciona al discutir modelos servidos por proveedores externos.
AUC	Área bajo la curva	Resumen escalar de una curva de rendimiento, usado junto a ROC.
aVR, aVL, aVF	Derivaciones aumentadas de miembros	Derivaciones del electrocardiograma convencional citadas al describir el registro de doce derivaciones.
BA	Exactitud equilibrada	Métrica principal. Promedia sensibilidad y especificidad para no favorecer a la clase mayoritaria.
BCE	Entropía cruzada binaria	Función de pérdida para clasificación binaria o multietiqueta.
CAM	Mapa de activación de clase	En Grad CAM indica regiones de la imagen que influyen en una predicción.
CC BY	Creative Commons Attribution	Licencia de reutilización asociada a una de las imágenes clínicas citadas.
CC BY-SA	Creative Commons Attribution ShareAlike	Licencia de reutilización con atribución y obligación de compartir bajo condiciones equivalentes.

Sigla	Significado	Uso en este trabajo
CNN	Red neuronal convolucional	Modelo supervisado que ajusta pesos a partir de ejemplos etiquetados. En la memoria se concreta en ResNet18.
CORAL	Correlation Alignment	Método de adaptación de dominio incluido como resultado complementario.
CSV	Comma-separated values	Formato tabular utilizado en manifiestos y resultados.
DANN	Domain-Adversarial Neural Network	Método de adaptación de dominio incluido como resultado complementario.
ECG	Electrocardiograma	Trazado cardíaco utilizado como imagen, no como señal digital cruda.
ECGBench	ECG Benchmark	Banco de evaluación multimodal citado en trabajos relacionados.
ECGInstruct	ECG Instruction Dataset	Conjunto de instrucciones con imagen y texto citado en trabajos relacionados.
Esp.	Especificidad	Proporción de controles identificados correctamente.
F1	Medida F1	Media armónica entre precisión y sensibilidad.
FN	Falso negativo	Caso positivo clasificado como negativo.
FP	Falso positivo	Control clasificado como positivo.
HRS	Heart Rhythm Society	Sociedad científica citada en recomendaciones clínicas.
HUCA	Hospital Universitario Central de Asturias	Origen de los electrocardiogramas reales utilizados en la evaluación clínica.
ICL	Aprendizaje en contexto	Uso de ejemplos etiquetados dentro del prompt sin modificar los pesos del modelo.
ImageNet	ImageNet	Colección de imágenes usada como origen habitual de pesos preentrenados en modelos visuales.
JSON	JavaScript Object Notation	Formato estructurado exigido en las respuestas del modelo multimodal.
K	Número de ejemplos	Tamaño del conjunto usado en cada pliegue. En la CNN indica pacientes de entrenamiento y en el VLM indica demostraciones de contexto.
LOOCV	Validación leave-one-out	Evaluación por paciente reservado. En cada pliegue se deja un paciente fuera.
MEETI	MIMIC ECG Event-based Text-image	Recurso multimodal de electrocardiografía revisado en el estado del arte.

Sigla	Significado	Uso en este trabajo
MIMIC	Medical Information Mart for Intensive Care	Familia de recursos clínicos abiertos citada en trabajos relacionados.
MMD	Maximum Mean Discrepancy	Medida usada como método complementario de adaptación de dominio.
PDF	Portable Document Format	Formato habitual de documento clínico o de intercambio del electrocardiograma renderizado.
PR	Intervalo PR	Intervalo electrocardiográfico entre la activación auricular y ventricular.
Prec.	Precisión	Proporción de predicciones positivas que corresponden a positivos reales.
PTB XL	Physikalisch-Technische Bundesanstalt XL	Conjunto abierto de electrocardiogramas de doce derivaciones citado en trabajos relacionados.
PULSE	PULSE	Modelo multimodal especializado en ECG citado en el estado del arte.
QRS	Complejo QRS	Región asociada a la despolarización ventricular.
QRS/ST	Complejo QRS y segmento ST	Nombre abreviado del dominio sintético utilizado en la memoria.
QT	Intervalo QT	Intervalo electrocardiográfico relacionado con despolarización y repolarización ventricular.
QTc	Intervalo QT corregido	Intervalo QT ajustado por frecuencia cardíaca, mencionado en el contexto clínico.
RBBB	Bloqueo de rama derecha	En el simulador se usa como etiqueta morfológica compatible, no como diagnóstico completo.
ResNet18	Residual Network 18	Arquitectura convolucional utilizada como referencia supervisada.
RGB	Red, green, blue	Representación de imagen con tres canales de color.
ROC	Receiver Operating Characteristic	Curva que relaciona sensibilidad y tasa de falsos positivos.
RSR	Morfología RSR prima	Patrón visual con segunda deflexión positiva terminal en el complejo QRS.
Sens.	Sensibilidad	Proporción de positivos identificados correctamente.
SimCLR	Simple Framework for Contrastive Learning of Visual Representations	Método autosupervisado citado en la configuración complementaria.
SSL	Aprendizaje autosupervisado	Estrategia complementaria de adaptación de dominio incluida en resultados completos.

Sigla	Significado	Uso en este trabajo
ST	Segmento ST	Región posterior al QRS cuya elevación participa en la formulación morfológica del estudio.
TFG	Trabajo de Fin de Grado	Documento académico en el que se enmarca el proyecto.
TN	Verdadero negativo	Control clasificado correctamente como negativo.
TP	Verdadero positivo	Caso positivo clasificado correctamente como positivo.
TWI	Inversión de onda T	Deflexión tardía negativa utilizada como rasgo visible en el simulador.
V1–V6	Derivaciones precordiales	Derivaciones torácicas del electrocardiograma. En los experimentos se usan V1, V2 y V3.
VLM	Modelo de visión y lenguaje	Modelo multimodal que recibe imágenes y texto en un mismo prompt.

Índice general

Resumen	I
Abstract	III
Glosario de siglas	V
1. Introducción	1
1.1. Motivación clínica	1
1.1.1. Circuito clínico de confirmación	2
1.1.2. Papel del sistema propuesto	2
1.2. Motivación metodológica	3
1.3. Alcance y contribuciones	3
1.4. Estructura de la memoria	4
2. Fundamentos clínicos y técnicos	5
2.1. Origen y representación del electrocardiograma	5
2.2. Morfología básica de un latido	5
2.3. Hallazgos morfológicos utilizados en el proyecto	6
2.3.1. Morfología compatible con bloqueo de rama derecha	6
2.3.2. Elevación del segmento ST	7
2.3.3. Inversión de la onda T	7
2.3.4. Síndrome de Brugada como caso motivador y circuito diagnóstico .	7
2.4. La señal y la imagen como representaciones	11
2.5. Datos sintéticos y modelos gaussianos	12
2.6. Clasificación multietiqueta	13
2.7. Redes neuronales convolucionales	14
2.8. Modelos de visión y lenguaje	14
2.9. Aprendizaje multimodal en contexto	15
2.10. Explicabilidad y fidelidad	16
2.11. Adaptación de dominio	17
2.12. Implicaciones para el diseño experimental	17
3. Antecedentes y estado del arte	19
3.1. Alcance de la revisión	19
3.2. Aprendizaje profundo sobre señales electrocardiográficas	19

3.3.	Análisis directo de imágenes de ECG	20
3.4.	Datos sintéticos para ECG	21
3.5.	Conjuntos que integran señal, imagen y texto	21
3.6.	Modelos multimodales especializados en ECG	22
3.7.	Aprendizaje multimodal en contexto	23
3.8.	Modelos abiertos, médicos y propietarios	24
3.9.	Hueco de investigación	25
4.	Diseño experimental	27
4.1.	Planteamiento común	27
4.2.	Datos evaluados	28
4.3.	Valores de K y validación	28
4.4.	Métricas	29
5.	El simulador QRS/ST	30
5.1.	Objetivo del dominio sintético	30
5.2.	Representación matemática	30
5.3.	Muestreo temporal	32
5.4.	Rangos de parámetros	33
5.5.	Familias generadoras	33
5.5.1.	Familia normal	33
5.5.2.	Morfología RBBB	33
5.5.3.	Elevación de ST	34
5.5.4.	Inversión de T	34
5.5.5.	Familia Brugada	34
5.6.	Reglas de coherencia morfológica	35
5.7.	Muestreo con rechazo	35
5.8.	Validadores y semántica de las etiquetas	36
5.9.	Renderizado de las señales	36
5.10.	Construcción del conjunto de datos	37
5.11.	Comprobación de integración	38
5.12.	Riesgos de atajos visuales	39
5.13.	Limitaciones del simulador	39
6.	Dos enfoques de modelado	41
6.1.	Entrada y unidad de análisis	41
6.2.	Enfoque supervisado con CNN	42
6.2.1.	Qué aprende	42
6.2.2.	Riesgos con pocos ejemplos	42

6.3.	Enfoque multimodal con VLM e ICL	42
6.3.1.	Qué cambia frente al entrenamiento	42
6.3.2.	Tres condiciones de consulta	43
6.4.	Comparación entre enfoques	43
7.	Enfoque supervisado con CNN ResNet18	44
7.1.	Arquitectura y entrada	44
7.2.	Entrenamiento	45
7.3.	Uso de los datos cedidos por el HUCA en la CNN	45
7.4.	Validación por paciente	46
7.5.	Selección de umbral	46
7.6.	Adaptación de dominio	47
7.7.	Grad CAM	47
7.8.	Qué se mide	48
8.	Enfoque multimodal con VLM e ICL	49
8.1.	Motivación	49
8.2.	Modelos médicos, modelos cerrados y privacidad	49
8.3.	Modelo evaluado	50
8.4.	Construcción del prompt	50
8.5.	Condiciones de consulta	51
8.6.	Origen del contexto	51
9.	Resultados sintéticos	53
9.1.	CNN en el simulador	53
9.2.	VLM e ICL en el simulador	54
9.3.	Comparación entre enfoques	56
9.4.	Lectura del dominio sintético	57
10.	Resultados de la transición al dominio real	58
10.1.	Datos cedidos por el HUCA y etiqueta clínica	58
10.2.	Controles de transferencia sintético-real	59
10.2.1.	Adaptación de dominio en la CNN	59
10.2.2.	ICL con contexto del simulador	60
10.3.	Evaluación directa con los datos cedidos por el HUCA	62
10.3.1.	CNN transferida desde el simulador	62
10.3.2.	Gemma 4 con contexto real	64
10.4.	Comparación clínica principal	66
10.5.	Brecha integrada entre simulador y dominio clínico	68

10.6.	Lectura final	70
11.	Conclusiones generales	71
11.1.	Conclusión principal	71
11.2.	Aportaciones	72
11.3.	Limitaciones	73
11.4.	Trabajo futuro	74
11.5.	Cierre	74
12.	Aspectos éticos y protección de datos	76
12.1.	Aspectos éticos	76
12.2.	Protección de datos	76
A.	Configuración experimental	78
A.1.	Conjunto sintético QRS/ST	78
A.2.	Datos cedidos por el HUCA	79
A.3.	Configuración CNN	80
A.4.	Configuración de adaptación de dominio	80
A.5.	Configuración VLM/ICL	81
B.	Resultados completos	82
B.1.	CNN en el conjunto sintético	82
B.2.	CNN en los datos cedidos por el HUCA	82
B.3.	Comparación de dominios	83
B.4.	Adaptación de dominio	83
B.5.	VLM/ICL	83
C.	Mensajes y respuestas estructuradas	86
C.1.	Criterio de conservación	86
C.2.	Sistema para tarea morfológica	86
C.3.	Tarea morfológica	86
C.4.	Sistema para tarea clínica	87
C.5.	Tarea clínica directa	87
C.6.	Construcción del contexto	87
	Bibliografía	89
	Índice de figuras	94
	Índice de tablas	96

1 Introducción

El electrocardiograma suele estudiarse como señal temporal, pero en la práctica clínica también circula como imagen, ya sea en papel escaneado, PDF, captura de pantalla o trazado integrado en una historia electrónica. Esa forma de representación no es secundaria, puesto que muchas revisiones retrospectivas y muchos intercambios entre servicios se hacen sobre imágenes, no sobre la señal digital original.

Este trabajo aborda una pregunta metodológica concreta: qué puede hacerse cuando se quiere analizar ECG como imagen, pero solo se dispone de pocos pacientes etiquetados. La dificultad es doble, porque la imagen conserva información morfológica a la vez que pierde parte de la estructura de la señal original y, además, el síndrome de Brugada es una entidad infrecuente en la que reunir positivos confirmados exige revisión clínica especializada.

Para afrontar ese problema de pocos datos, el TFG sigue dos líneas complementarias: entrenar una CNN con los ejemplos disponibles para evaluar hasta dónde llega el aprendizaje supervisado cuando K es pequeño, y utilizar esos mismos ejemplos como contexto para un modelo de visión y lenguaje sin modificar sus pesos. La comparación estudia dos formas de usar el mismo conjunto reducido de pacientes etiquetados: actualizar los pesos de un modelo supervisado o condicionar la inferencia de un modelo multimodal mediante demostraciones.

El caso de estudio es la sospecha de síndrome de Brugada, una canalopatía hereditaria infrecuente asociada a riesgo de arritmias ventriculares y muerte súbita. En este contexto, el sistema evaluado se plantea como una herramienta de priorización de trazados para revisión clínica temprana, no como un mecanismo de diagnóstico automático.

1.1.- Motivación clínica

El síndrome de Brugada es un trastorno arrítmico hereditario relacionado con alteraciones de los canales de sodio cardíacos. Predispone a fibrilación ventricular y muerte súbita, especialmente en varones jóvenes durante el reposo o el sueño [1, 6]. Su prevalencia estimada se sitúa entre una de cada 2 000 y una de cada 5 000 personas, aunque probablemente esté infradiagnosticado porque muchos portadores permanecen asintomáticos.

El patrón electrocardiográfico tipo 1 se caracteriza por elevación del segmento ST de morfología convexa de al menos 2 mm en una derivación precordial derecha, seguida de onda T negativa [6]. Los patrones tipo 2 y tipo 3, de morfología en silla de montar, no son diagnósticos por sí solos. Además, existen fenocopias producidas por fiebre, alteraciones

electrolíticas, isquemia o fármacos, que pueden imitar el trazado y deben excluirse antes de confirmar la enfermedad [5].

La dificultad aumenta porque el patrón tipo 1 puede ser intermitente. Un ECG basal normal no descarta el síndrome y un trazado sospechoso debe interpretarse dentro del contexto clínico. Esa variabilidad convierte Brugada en un buen caso para estudiar métodos de apoyo, siempre que el resultado se entienda como triaje y no como decisión diagnóstica.

1.1.1.- Circuito clínico de confirmación

Ante una sospecha de Brugada, el circuito asistencial sigue una secuencia de complejidad creciente:

1. **ECG estándar de 12 derivaciones.** Se revisan especialmente V1 y V2 en busca de patrones sugestivos.
2. **Revisión por especialista.** Un cardiólogo o electrofisiólogo valora el trazado, la historia clínica y los antecedentes familiares.
3. **Reposicionamiento de V1/V2.** Si la sospecha persiste, se registra un nuevo ECG colocando V1 y V2 en espacios intercostales superiores para aumentar la sensibilidad [5].
4. **Prueba farmacológica.** En pacientes seleccionados se administra un bloqueante del canal de sodio, como ajmalina o flecainida, en un entorno monitorizado con capacidad de reanimación [7].
5. **Decisión clínica.** El diagnóstico y las decisiones terapéuticas corresponden al equipo médico.

1.1.2.- Papel del sistema propuesto

El sistema desarrollado se sitúa antes de la confirmación diagnóstica, de modo que una salida positiva debe interpretarse únicamente como una indicación de revisión prioritaria del trazado. En ningún caso se plantea como mecanismo para descartar pacientes, sustituir la prueba farmacológica o emitir recomendaciones terapéuticas.

Esta restricción condiciona la interpretación de las métricas. En una enfermedad de baja prevalencia, incluso un clasificador con sensibilidad alta puede producir muchas alertas no confirmadas si la especificidad es insuficiente. El compromiso entre ambas magnitudes es especialmente relevante en triaje: aumentar la sensibilidad reduce el riesgo de retrasar la revisión de un caso sospechoso, pero suele incrementar el número de falsos positivos y, con ello, la carga sobre el circuito asistencial. Por tanto, la evaluación debe valorar simultáneamente la capacidad de recuperar positivos y la proporción de controles derivados de forma

innecesaria.

1.2.- Motivación metodológica

Los modelos profundos han mostrado resultados destacados en análisis de ECG cuando disponen de grandes colecciones de pacientes y etiquetas consistentes [11, 15], pero esa situación rara vez se cumple en enfermedades de baja prevalencia. En Brugada, cada ejemplo confirmado exige revisión especializada y, en muchos casos, información clínica adicional o prueba farmacológica.

La comparación metodológica se organiza alrededor del uso de K . En la línea supervisada, una ResNet18 ajusta sus pesos con los K pacientes etiquetados y produce un clasificador específico para la tarea. En la línea multimodal, Gemma 4 mantiene sus pesos fijos y recibe esos mismos K ejemplos dentro del prompt como pares imagen-respuesta [28].

El núcleo del trabajo está precisamente en esa diferencia: los mismos datos pueden incorporarse al entrenamiento como gradiente o presentarse al modelo como demostraciones de contexto. A partir de esa alternativa, el experimento estudia qué ocurre cuando el número de pacientes etiquetados es reducido y la etiqueta clínica procede de una enfermedad de baja prevalencia. Esta segunda vía resulta metodológicamente atractiva porque evita entrenar un modelo nuevo para cada conjunto local y puede trasladarse con más facilidad entre evaluaciones, aunque su utilidad depende de que el contexto mejore la predicción sin degradar en exceso la especificidad.

1.3.- Alcance y contribuciones

El estudio se limita a un análisis experimental y retrospectivo orientado a comparar procedimientos de aprendizaje con pocos datos etiquetados. Por este motivo, los resultados no constituyen la validación de un producto sanitario ni permiten estimar utilidad clínica prospectiva. La comparación combina dos tipos de referencia: en el dominio sintético, las etiquetas se derivan de reglas sobre tres hallazgos morfológicos del trazado, mientras que en el dominio real proceden de los datos cedidos por el HUCA y distinguen entre caso Brugada confirmado y control.

Las aportaciones principales son un protocolo para estudiar ECG como imagen, un simulador QRS/ST revisado, el procesado de 317 pacientes del HUCA, una referencia CNN en sintético y real, y una evaluación VLM/ICL con Gemma 4 en zero-shot, ICL normal e ICL balanceado.

1.4.- Estructura de la memoria

La exposición avanza desde el contexto hasta la comparación. El capítulo 2 introduce los fundamentos clínicos y técnicos. El capítulo 3 sitúa el trabajo frente al estado del arte. El capítulo 4 formula el protocolo común. El capítulo 5 describe el simulador. El capítulo 6 presenta la comparación entre entrenamiento supervisado y aprendizaje en contexto.

Después, el capítulo 7 desarrolla el enfoque CNN sin mezclarlo con resultados. El capítulo 8 desarrolla el enfoque VLM/ICL. Los capítulos 9 y 10 comparan ambos enfoques en el simulador y en los ECG reales. El capítulo 11 cierra la interpretación científica y el capítulo 12 recoge la gestión ética, regulatoria y de privacidad.

2 Fundamentos clínicos y técnicos

2.1.- Origen y representación del electrocardiograma

El electrocardiograma registra diferencias de potencial producidas por la actividad eléctrica del corazón. La señal observada en cada derivación no corresponde a una estructura anatómica aislada. Es la proyección de un proceso eléctrico tridimensional sobre un eje definido por la posición de los electrodos. Por esta razón una misma activación puede generar deflexiones distintas según la derivación desde la que se observe.

El ECG convencional utiliza doce derivaciones obtenidas a partir de diez electrodos. Las derivaciones I, II, III, aVR, aVL y aVF describen la actividad en el plano frontal. Las derivaciones V1 a V6 ofrecen una perspectiva precordial en el plano horizontal. La colocación de los electrodos, la ganancia, la velocidad de registro y el filtrado influyen en la apariencia final. Las recomendaciones de estandarización insisten en conservar estos parámetros porque una modificación técnica puede alterar amplitudes, duraciones y relaciones espaciales que después se utilizan durante la interpretación [2].

La representación clínica habitual utiliza una velocidad de 25 mm por segundo y una ganancia de 10 mm por mV. Con esa convención, un milímetro horizontal equivale a 40 ms y un milímetro vertical equivale a 0,1 mV. Estas equivalencias permiten estimar intervalos y amplitudes directamente sobre el papel. Cuando el trazado se transforma en una imagen digital, la relación física deja de estar garantizada si la imagen se redimensiona, se recorta o se fotografía sin una referencia de escala.

El presente trabajo no intenta reconstruir el vector cardíaco completo. La unidad experimental es una imagen de un latido sintético semejante a una ventana precordial derecha. Esta simplificación permite controlar el complejo QRS, el segmento ST y la onda T. También impide aplicar de forma literal criterios que requieren comparar varias derivaciones. La memoria distinguirá por tanto entre la definición clínica de un hallazgo y la aproximación visual utilizada por el simulador.

2.2.- Morfología básica de un latido

Un latido normal puede describirse mediante una secuencia de ondas y segmentos. La onda P refleja la despolarización auricular. El intervalo PR incluye la propagación desde las aurículas hasta el sistema de conducción ventricular. El complejo QRS representa la despola-

rización ventricular. El punto J marca la transición entre el final del QRS y el comienzo del segmento ST. La onda T se relaciona con la repolarización ventricular.

Las letras Q, R y S no designan posiciones anatómicas fijas. La onda Q es la primera deflexión negativa anterior a una deflexión positiva. La onda R es la primera deflexión positiva del complejo ventricular. La onda S es una deflexión negativa posterior a una onda R. Si aparece una segunda deflexión positiva, se denomina R prima. Esta nomenclatura describe la geometría de la señal y no establece por sí sola un diagnóstico.

El segmento ST se evalúa con respecto a una referencia isoeléctrica. En un registro real, esa referencia puede aproximarse mediante el segmento TP o el segmento PR según el contexto. La elevación o depresión no se interpreta de forma independiente. Importan la derivación, la magnitud, la morfología, la distribución espacial y el cuadro clínico. Las recomendaciones de la AHA, el ACCF y la HRS separan de forma explícita la descripción del segmento ST, la onda T y el intervalo QT porque cada elemento aporta información diferente [4].

La onda T también depende de la derivación. Una deflexión negativa puede ser fisiológica en algunas posiciones y patológica en otras. Su significado cambia según la edad, el sexo, la secuencia de activación ventricular, los cambios del segmento ST y la presencia de otras alteraciones. El proyecto no intenta resolver esta interpretación completa. La etiqueta de inversión de T indica únicamente que la región tardía del latido sintético presenta una deflexión negativa que satisface las reglas del conjunto.

2.3.- Hallazgos morfológicos utilizados en el proyecto

2.3.1.- Morfología compatible con bloqueo de rama derecha

El bloqueo de rama derecha es una alteración de la conducción intraventricular. En su forma completa se caracteriza por una duración del QRS igual o superior a 120 ms y por una morfología terminal compatible en las derivaciones apropiadas. Las recomendaciones de estandarización describen patrones como rsR prima o rSR prima en V1 o V2, junto con una onda S ensanchada en derivaciones laterales [3].

La segunda deflexión positiva en las derivaciones precordiales derechas aparece por la activación tardía del ventrículo derecho. No obstante, una forma semejante a rsR prima en una sola derivación no basta para diagnosticar un bloqueo completo. También deben considerarse la duración global del QRS, la morfología en I y V6, la posición de los electrodos y otras causas de retraso terminal.

El simulador solo representa una ventana semejante a una derivación precordial. Por ello la etiqueta RBBB se entiende como *morfología compatible con bloqueo de rama derecha*. El validador busca dos máximos positivos separados por una deflexión negativa, exige que el

segundo máximo aparezca en una posición tardía y comprueba una anchura terminal mínima. Esta regla captura una forma visual útil para el experimento, pero no reproduce el criterio clínico completo.

2.3.2.- Elevación del segmento ST

El segmento ST comienza en el punto J y termina con el inicio de la onda T. Su desplazamiento se mide con respecto a una referencia isoeléctrica. La magnitud clínicamente relevante depende de la derivación, del sexo, de la edad y de la situación diagnóstica. Además, una elevación puede aparecer en contextos diferentes, entre ellos isquemia aguda, pericarditis, repolarización precoz, alteraciones de conducción y síndromes de onda J.

La etiqueta sintética ST_ELEVATION no representa ninguna etiología concreta. El validador exige actividad ventricular suficiente y comprueba que la amplitud media alrededor del punto J y durante el segmento ST sea positiva. Se trata de una definición geométrica diseñada para separar imágenes, no de un umbral clínico expresado en milímetros.

Esta distinción evita una inferencia incorrecta. El modelo aprende a reconocer una región elevada después del QRS. No aprende por ese hecho a diferenciar un patrón de Brugada, un infarto agudo u otra causa. Esa diferenciación requeriría varias derivaciones, contexto clínico y un conjunto de etiquetas mucho más amplio.

2.3.3.- Inversión de la onda T

La onda T refleja la repolarización ventricular y suele aparecer después del segmento ST. Su polaridad normal varía entre derivaciones. También puede modificarse como consecuencia secundaria de una secuencia anómala de despolarización. Por ejemplo, una alteración de conducción puede producir cambios discordantes del segmento ST y de la onda T.

En el conjunto sintético, la inversión se define mediante una deflexión tardía negativa. El validador comprueba la profundidad mínima, la posición temporal del mínimo y la duración de la región situada por debajo de un nivel negativo. La regla incluye además condiciones sobre el QRS y el segmento ST para evitar que una oscilación temprana se confunda con una onda T.

La etiqueta T_WAVE_INVERSION expresa por tanto una propiedad visual localizada. No determina si la inversión es primaria, secundaria, fisiológica o patológica. Esta limitación se conserva al evaluar con datos reales.

2.3.4.- Síndrome de Brugada como caso motivador y circuito diagnóstico

El síndrome de Brugada es una canalopatía hereditaria del canal de sodio, frecuentemente asociada a mutaciones en el gen *SCN5A*, que predispone a fibrilación ventricular y muerte súbita cardíaca. Su prevalencia se estima entre 1 y 5 por cada 10 000 personas, con predomi-

nio en varones adultos jóvenes, aunque puede manifestarse a cualquier edad. A pesar de su baja prevalencia, su asociación con arritmias malignas lo convierte en un problema clínico relevante [5].

El elemento electrocardiográfico central es el patrón tipo 1, también denominado patrón *coved*, con una elevación descendente del segmento ST de al menos 2 mm en las derivaciones precordiales derechas V1 o V2, seguida de una onda T negativa. Este patrón es el único considerado diagnóstico según las guías vigentes [1]. Los patrones tipo 2 y tipo 3, descritos históricamente, ya no se consideran suficientes por sí solos para establecer el diagnóstico.

La definición ha evolucionado con el tiempo. Los criterios actuales aceptan que el patrón tipo 1, ya sea espontáneo o inducido, es suficiente para el diagnóstico de síndrome de Brugada en ausencia de otras causas que lo expliquen [1]. No obstante, el contexto clínico es fundamental. Síntomas como síncope inexplicado, respiración agónica nocturna, antecedentes familiares de muerte súbita o arritmias ventriculares documentadas refuerzan la sospecha y orientan la estratificación del riesgo.

Circuito diagnóstico clínico


El diagnóstico del síndrome de Brugada sigue un circuito clínico estructurado que no puede reducirse al reconocimiento automático de un patrón en una imagen:

1. **ECG basal de 12 derivaciones.** La evaluación comienza con un ECG estándar. Si el trazado muestra un patrón tipo 1 espontáneo en V1 o V2, el diagnóstico se puede establecer tras excluir fenocopias y otras causas de elevación del ST.
2. **Recolocación de derivaciones precordiales.** Cuando el ECG basal es sospechoso pero no concluyente, las guías recomiendan registrar V1 y V2 en espacios intercostales superiores (segundo o tercero en lugar del cuarto estándar). Esta maniobra aumenta la sensibilidad para detectar el patrón tipo 1, porque la posición más alta acerca el electrodo al tracto de salida del ventrículo derecho [7].
3. **Valoración clínica integral.** Se evalúan síntomas actuales y pasados, historia familiar de muerte súbita o síndrome de Brugada confirmado, exposición a fármacos o situaciones que puedan provocar fenocopias (fiebre, trastornos electrolíticos, isquemia) y comorbilidades.
4. **Prueba farmacológica con bloqueantes del canal de sodio.** En pacientes seleccionados con sospecha persistente y ECG basal no diagnóstico, se realiza una prueba de provocación farmacológica. Los fármacos empleados son bloqueantes del canal de sodio de clase I, entre ellos ajmalina (la más utilizada, administrada por vía intravenosa a dosis aproximada de 1 mg/kg durante 10 minutos), flecainida, procainamida o pilsicainida según la disponibilidad local [6]. La prueba se administra en un entorno monitorizado con personal entrenado en reanimación cardiopulmonar avanzada y con equipo de des-


fibrilación disponible, dado el riesgo, infrecuente pero real, de desencadenar arritmias ventriculares malignas (taquicardia ventricular polimórfica o fibrilación ventricular). La monitorización electrocardiográfica continua debe prolongarse después de finalizar la infusión, ya que el patrón tipo 1 puede aparecer de forma diferida, incluso cuando los intervalos QRS y QTc han comenzado a normalizarse. La prueba se considera positiva si aparece un patrón tipo 1 durante o después de la administración del fármaco. La prueba está contraindicada en pacientes que ya presentan un patrón tipo 1 espontáneo, puesto que el diagnóstico ya está establecido [6].

5. **Estudio genético.** Se recomienda la secuenciación del gen *SCN5A* en pacientes índice para confirmar la base molecular y facilitar el cribado familiar.
6. **Decisión clínica final.** La decisión sobre estratificación de riesgo y tratamiento (seguimiento, modificación del estilo de vida, evitación de fármacos arritmogénicos, valoración de desfibrilador automático implantable) es siempre clínica, multifactorial y realizada por especialistas.

Este circuito subraya por qué el sistema desarrollado en este TFG se plantea exclusivamente como herramienta de triaje. Una predicción positiva del modelo no equivale a un diagnóstico de síndrome de Brugada. Equivale a una señal que sugiere priorizar la revisión del trazado por un especialista y, si procede, iniciar el circuito diagnóstico descrito. La decisión de realizar una prueba farmacológica, su interpretación y las consecuencias clínicas permanecen bajo responsabilidad médica [6].



(a) ECG con morfología tipo 1 en V1 y V2.



(b) Patrones tipo 1–3.

Figura 2.1.- Ejemplos clínicos de morfología Brugada. La imagen izquierda procede de ECGpedia, CC BY-SA 3.0 [8]. La imagen derecha procede de Napolitano y Priori, CC BY 2.0 [9].

La relación con el bloqueo de rama derecha requiere una precisión adicional. El trazado

tipo 1 puede recordar visualmente a una alteración terminal del QRS. Sin embargo, el mecanismo y los criterios no son equivalentes. La onda J del patrón de Brugada se concentra en las derivaciones precordiales derechas y no necesita la onda S lateral recíproca que forma parte del bloqueo de rama derecha [10]. En este TFG, RBBB se utiliza como una etiqueta morfológica auxiliar y no como requisito clínico para Brugada.

La familia generadora BRUGADA introduce una elevación inicial del segmento ST, una caída progresiva y una onda T negativa. Después de generar la señal, los tres validadores independientes determinan qué hallazgos están presentes. La familia de origen se conserva como metadato, mientras que la tarea predictiva utiliza únicamente las etiquetas observables. Esta separación es importante. El simulador crea un caso visual para probar modelos, no una reproducción diagnóstica del síndrome.




Figura 2.2.- Representación esquemática de los hallazgos visuales que motivan el triaje de patrón Brugada.

Hallazgo	Interpretación clínica resumida	Criterio utilizado en el conjunto sintético
RBBB	Trastorno de conducción que requiere duración y morfología compatibles en varias derivaciones	Dos máximos positivos en la región ventricular, una depresión intermedia y actividad terminal tardía y ancha
Elevación ST	Desplazamiento del punto J y del segmento ST cuya relevancia depende de derivación y contexto	Media positiva en ventanas posteriores al QRS junto con actividad ventricular suficiente
Inversión T	Onda T negativa con significado dependiente de la derivación y de la secuencia de activación	Deflexión tardía negativa con profundidad, posición y duración mínimas
Brugada tipo 1	Patrón descendente en precordiales derechas que debe interpretarse dentro de criterios clínicos	Familia generadora que combina elevación inicial, descenso del ST y T negativa. No se utiliza como etiqueta diagnóstica

Tabla 2.1.- Relación entre el concepto clínico y la traducción experimental utilizada en el proyecto

2.4.- La señal y la imagen como representaciones

Una señal digital conserva muestras de amplitud ordenadas en el tiempo. Esta representación permite medir intervalos, aplicar filtros y comparar derivaciones con una escala conocida. La imagen es el resultado de transformar esas muestras mediante un proceso de renderizado. Contiene la forma visible del trazado, pero también incorpora decisiones de presentación.

El renderizado establece el tamaño del lienzo, la cuadrícula, el grosor de la línea, los márgenes y la disposición de las derivaciones. Una red puede utilizar cualquiera de esos elementos si están correlacionados con la etiqueta. Por ello un conjunto de imágenes debe controlar que la clase no pueda deducirse a partir de una marca, un recorte o una diferencia de resolución.

La imagen posee una ventaja práctica cuando la señal original no está disponible. Sangha y colaboradores demostraron que un modelo multietiqueta podía analizar ECG renderizados y mantener un rendimiento alto en registros externos y trazados impresos [15]. Gliner y colaboradores mostraron además que una CNN puede trabajar con fotografías de ECG, aunque la diferencia de formato requiere estrategias específicas de adaptación [17].

La alternativa consiste en digitalizar primero la imagen. El trabajo de Wu y colaboradores desarrolló una herramienta automática para segmentar trazados impresos y reconstruir las

señales [16]. La digitalización permite reutilizar modelos temporales, pero introduce errores cuando las derivaciones se solapan o la calidad del documento es baja. El análisis directo de imagen y la digitalización no son soluciones excluyentes. Responden a compromisos distintos.

Esta doble naturaleza del ECG, señal temporal e imagen, es precisamente lo que hace relevante la comparación entre CNN y VLM. Una CNN entrenada con pocos ejemplos necesita extraer toda la información visual de los píxeles disponibles. Un modelo de visión y lenguaje puede complementar la imagen con conocimiento adquirido durante su preentrenamiento sobre colecciones masivas de imágenes y texto médico. La pregunta es si ese punto de partida mejora el uso de pocos ejemplos etiquetados.

2.5.- Datos sintéticos y modelos gaussianos

Los datos sintéticos permiten controlar factores que resultan difíciles de aislar en una colección clínica. Es posible generar clases equilibradas, conocer los parámetros que originan cada señal y repetir exactamente el proceso. También se evita utilizar información de pacientes durante las primeras fases del desarrollo.

Un modelo sintético no elimina el problema de los datos. Lo transforma. La validez depende de que las reglas de generación representen los rasgos que se quieren estudiar y de que no introduzcan atajos visuales. Una morfología demasiado regular puede producir un conjunto fácil para una red y poco informativo sobre el comportamiento en registros reales.

La representación mediante ondas gaussianas cuenta con precedentes en el procesamiento de ECG. Sayadi y colaboradores describieron un modelo dinámico basado en ondas gaussianas para generar señales y realizar filtrado bayesiano [18]. En el presente proyecto se adopta una variante más simple y directamente controlable. Cada componente se define como

$$g_i(t) = a_i \exp \left(-\frac{(t - \mu_i)^2}{2\sigma_i^2} \right), \quad (2.1)$$

donde a_i controla la amplitud, μ_i determina la posición temporal y σ_i regula la anchura. El latido completo se obtiene mediante

$$x(t) = \sum_{i=1}^M g_i(t). \quad (2.2)$$

La suma incluye componentes para P, Q, R, S, R prima, punto J, segmento ST y onda T. Los parámetros se muestrean dentro de intervalos dependientes de la familia generadora. Después se aplican relaciones temporales para mantener un orden coherente. Finalmente, un validador decide si la señal satisface las condiciones mínimas de la familia solicitada.

Este procedimiento es un muestreo con rechazo. Si la señal no supera el validador se descarta y se genera otra. La estrategia mejora la consistencia interna, aunque también puede concentrar las muestras cerca de las regiones que aceptan las reglas. La tasa de aceptación y la distribución de parámetros deben analizarse como parte del control de calidad.

Los simuladores de mayor fidelidad utilizan modelos electrofisiológicos y geometrías cardíacas completas. MedalCare XL, por ejemplo, ofrece miles de ECG sintéticos de doce derivaciones obtenidos mediante simulaciones electrofisiológicas [19]. Ese enfoque persigue realismo fisiológico y requiere un coste computacional mayor. El simulador de este TFG persigue interpretabilidad y control local. No son alternativas equivalentes.

2.6.- Clasificación multietiqueta

En clasificación multiclase cada ejemplo se asigna a una categoría exclusiva. En clasificación multietiqueta, una muestra se asocia con un subconjunto de etiquetas. Esta formulación es adecuada cuando los hallazgos pueden coexistir [37].

Sea L el número de etiquetas. Para una imagen x , la referencia se representa mediante un vector

$$\mathbf{y} = (y_1, \dots, y_L), \quad y_j \in \{0, 1\}. \quad (2.3)$$

Una red convolucional produce un logit z_j por etiqueta. La función sigmoide transforma cada logit en una probabilidad independiente

$$\hat{p}_j = \frac{1}{1 + \exp(-z_j)}. \quad (2.4)$$

La pérdida habitual es la entropía cruzada binaria

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{L} \sum_{j=1}^L [y_j \log(\hat{p}_j) + (1 - y_j) \log(1 - \hat{p}_j)]. \quad (2.5)$$

La independencia de las salidas no significa que las etiquetas sean estadísticamente independientes. La red puede aprender representaciones compartidas y aprovechar coocurrencias. Sin embargo, una coocurrencia excesiva puede crear atajos. Si todas las ondas T negativas aparecen siempre junto con elevación del ST, el modelo puede predecir una etiqueta a partir de la otra sin observar la región correcta.

La decisión binaria requiere un umbral. El valor 0,5 es una referencia simple, pero no tiene por qué ser óptimo para todas las etiquetas. Los umbrales deben fijarse con el conjunto de validación y conservarse para el test. Ajustarlos con el conjunto de prueba produciría una estimación optimista.

En los modelos de visión y lenguaje la salida no es una probabilidad sigmoide. El sistema genera texto o un objeto estructurado. La evaluación necesita convertir esa respuesta a un vector binario y registrar de forma separada las respuestas que no cumplen el esquema. Esta diferencia forma parte del protocolo y no debe ocultarse durante la comparación.

2.7.- Redes neuronales convolucionales

Una convolución aplica un conjunto de filtros compartidos sobre regiones locales de una imagen. Las primeras capas detectan transiciones y contornos. Las capas posteriores combinan esas respuestas para construir patrones de mayor escala. En una imagen de ECG, la red puede aprender inclinaciones, picos, valles y relaciones entre regiones temporales.

El uso de pesos compartidos aporta cierta tolerancia a desplazamientos pequeños. Sin embargo, el ECG no es completamente invariante a la posición. Una deflexión negativa tiene un significado diferente si aparece dentro del QRS o en la región de la onda T. La arquitectura debe conservar suficiente información espacial y el preprocesado debe alinear los latidos.

En este trabajo la referencia convolucional es una ResNet18 preentrenada. Las conexiones residuales facilitan la optimización de redes profundas al aprender transformaciones relativas a la entrada de cada bloque [31]. El uso de pesos de ImageNet no garantiza una ventaja en ECG, pero aporta filtros visuales iniciales útiles para contornos, trazos y texturas cuando el número de ejemplos etiquetados es pequeño.

La evaluación debe comprobar si esa transferencia visual se mantiene fuera del simulador. Un resultado alto en imágenes sintéticas puede reflejar que la red aprendió reglas de renderizado, mientras que un resultado más bajo en datos reales puede revelar ruido, variabilidad clínica o diferencias en la definición de etiqueta. Los resultados de este TFG confirman que la CNN aprende bien en sintético pero falla en datos reales, lo que motiva la exploración de alternativas que no dependan exclusivamente del entrenamiento supervisado con pocos ejemplos.

2.8.- Modelos de visión y lenguaje

Un modelo de visión y lenguaje (VLM) combina una representación visual con un modelo generativo de texto. La imagen se transforma en vectores que el componente lingüístico puede atender durante la generación. La salida puede adoptar la forma de una respuesta libre, una explicación o una estructura con campos definidos. Esta arquitectura introduce una capacidad fundamentalmente nueva respecto a las CNN. El modelo no solo procesa imágenes, sino que integra conocimiento visual y textual adquirido durante un preentrenamiento masivo.

Flamingo mostró que un modelo multimodal entrenado con secuencias intercaladas de imagen y texto podía adaptarse a tareas mediante ejemplos incluidos en el contexto [24]. Este paradigma evita actualizar los pesos para cada tarea. Las demostraciones especifican la relación entre entrada y salida durante la inferencia, eliminando la necesidad de un conjunto de entrenamiento propio.

Esta propiedad es especialmente relevante para el problema de este TFG. Cuando solo se dispone de pocos ejemplos etiquetados de un fenómeno raro como el patrón de Brugada, el entrenamiento supervisado de una CNN puede resultar insuficiente, como muestran los resultados experimentales. Un VLM parte de representaciones visuales y textuales adquiridas durante su preentrenamiento, que pueden incluir trazados, diagramas médicos, texto clínico y relaciones entre morfología y diagnóstico. La hipótesis central del TFG es que ese punto de partida puede ser útil cuando el conjunto etiquetado es pequeño.

El desarrollo reciente de modelos multimodales médicos ha abierto una vía intermedia entre los modelos generalistas y los sistemas entrenados para una tarea concreta. MedGemma 1.5 pertenece a esa línea de modelos médicos abiertos: parte de la familia Gemma y ha sido adaptado con modalidades clínicas como radiología, histopatología, dermatología, fondo de ojo, documentos y registros clínicos [29]. La documentación disponible no presenta el ECG como una de sus modalidades principales y remite a una validación específica antes de utilizarlo en una tarea concreta.

La evaluación cuantitativa de esta memoria se centra en Gemma 4, un VLM abierto de altas prestaciones que admite texto e imagen y permite ajustar el número de tokens visuales dedicados a cada imagen [28]. Un mayor número de tokens visuales conserva más detalle, aunque incrementa el coste computacional. Esta decisión es relevante para ECG porque los cambios morfológicos pueden ocupar una región pequeña del lienzo. La ejecución local facilita experimentos reproducibles, fija la versión del modelo y reduce la necesidad de enviar imágenes clínicas a un servicio externo.

2.9.- Aprendizaje multimodal en contexto

El aprendizaje en contexto (ICL) es la estrategia central propuesta en este TFG como alternativa al entrenamiento supervisado. En ICL se proporciona una secuencia de demostraciones

$$\mathcal{D}_K = \{(x_1, y_1), \dots, (x_K, y_K)\} \quad (2.6)$$

antes de la consulta objetivo x^* . El modelo genera una estimación condicionada por la instrucción y por las demostraciones

$$\hat{y}^* = f_{\theta}(x^*, \mathcal{D}_K, \text{instrucción}), \quad (2.7)$$

sin modificar los parámetros θ . Esta diferencia con el entrenamiento supervisado es fundamental. Los mismos K ejemplos etiquetados que una CNN utilizaría para actualizar millones de pesos, un VLM los recibe como contexto dentro del prompt. Los pesos del modelo permanecen fijos y el aprendizaje se produce de forma implícita durante la generación.

Esta formulación convierte al número de ejemplos K en la variable de comparación natural entre ambos enfoques. Con el mismo K de ejemplos etiquetados, la CNN debe aprender a distinguir patrones visuales mediante actualización de pesos, mientras que el VLM recibe esos ejemplos como guía de la tarea dentro del prompt. La pregunta experimental es a partir de qué valor de K merece la pena entrenar un modelo específico y en qué rango resulta más razonable usar ICL.

El número de ejemplos no determina por sí solo la calidad del contexto, ya que también importan la selección, la diversidad, el orden y la coherencia entre la imagen y la etiqueta. Qin y colaboradores identificaron la recuperación multimodal, el orden interno de cada demostración y la posición de la instrucción como factores relevantes [26].

Chen y colaboradores observaron que varios modelos podían depender más del texto que de la información visual contenida en las demostraciones [25]. Esta observación obliga a leer el ICL con cautela. En esta memoria, la comparación principal separa zero-shot, ICL normal e ICL balanceado. Si las condiciones con demostraciones mejoran el zero-shot, el contexto aporta señal. Si normal y balanceado divergen, la composición de las demostraciones también influye en el tipo de error.

2.10.- Explicabilidad y fidelidad

Los mapas de activación de clase permiten visualizar qué regiones de una imagen influyen en una salida. Grad CAM utiliza los gradientes de una clase para ponderar los mapas de activación de una capa convolucional [32]. En una tarea de ECG, una explicación razonable debería destacar regiones distintas para QRS, segmento ST y onda T.

Un mapa visual no demuestra causalidad clínica. La resolución suele ser inferior a la imagen de entrada y el resultado depende de la capa seleccionada. También puede señalar una región amplia aunque el modelo utilice un artefacto local. Su función en este proyecto es detectar comportamientos incompatibles con la tarea, no certificar una explicación.

Las explicaciones generadas por un modelo de visión y lenguaje plantean un problema diferente. El texto puede describir correctamente la morfología aunque esa descripción no haya causado la predicción. La plausibilidad lingüística y la fidelidad del razonamiento son propie-

dades distintas. La evaluación principal utilizará respuestas estructuradas. Las justificaciones se analizarán como un artefacto cualitativo separado.

2.11.- Adaptación de dominio

El dominio sintético y el dominio real difieren en fisiología, adquisición y presentación. El simulador genera un único latido alineado, con una cuadrícula uniforme y sin variabilidad entre pacientes. Un ECG real contiene ruido, deriva de línea base, diferencias de frecuencia cardíaca, trazos superpuestos, anotaciones y múltiples derivaciones.

Una red puede obtener un rendimiento elevado en sintético y fallar en real si aprende características exclusivas del renderizado. Este fenómeno es relevante en este TFG porque la pregunta principal no es solo si una CNN aprende en un escenario controlado, sino si esa señal visual conserva valor cuando se enfrenta a ECG clínicos reales. La comprobación complementaria de este salto se presenta al final de la evaluación sobre datos reales.

2.12.- Implicaciones para el diseño experimental

Los fundamentos anteriores determinan varias decisiones de diseño que sitúan la comparación CNN frente a VLM/ICL en el centro del trabajo.

Estas consideraciones se traducen en tres decisiones de diseño: describir las etiquetas como hallazgos morfológicos, tratar la familia BRUGADA como señal de triaje y no como diagnóstico automático, y asegurar que la CNN y los modelos de visión y lenguaje reciban la misma imagen objetivo junto con el mismo número de ejemplos K . La comparación se centra en el uso de esos ejemplos, ya que la CNN los emplea para actualizar sus pesos, mientras que el modelo de visión y lenguaje los recibe como demostraciones dentro del contexto.

La separación por pacientes no puede evaluarse en el conjunto sintético porque cada imagen se genera de forma independiente, pero en datos reales es obligatoria para impedir que registros de una misma persona aparezcan en entrenamiento y test. También es necesario preservar la escala o documentar cualquier normalización.

El rendimiento se analiza por etiqueta cuando la tarea es morfológica, porque cada hallazgo ocupa una región distinta. En ese análisis, la coincidencia exacta mide si se recupera el conjunto completo, la sensibilidad y la especificidad muestran qué tipo de error domina, y la medida F1 resume el equilibrio entre precisión y sensibilidad. Estas métricas se usan de forma común en CNN y VLM/ICL, garantizando una comparación justa.

En consecuencia, las conclusiones sobre utilidad clínica solo podrían sostenerse tras una evaluación específica en datos reales y en un circuito asistencial definido. El dominio sintético

permite estudiar aprendibilidad, sensibilidad al contexto y comportamiento relativo de los modelos, pero no estima por sí solo la seguridad de un sistema médico. La lectura clínica de los resultados debe interpretarse siempre dentro del circuito de triaje, con priorización de revisión y circuito diagnóstico completo cuando proceda.

3 Antecedentes y estado del arte

3.1.- Alcance de la revisión

La revisión se centra en trabajos que ayudan a responder la pregunta experimental del TFG. Se consideran cinco líneas. La primera estudia el diagnóstico automático a partir de señales de ECG. La segunda utiliza el trazado como imagen. La tercera genera datos sintéticos. La cuarta desarrolla modelos multimodales para imágenes electrocardiográficas. La quinta analiza aprendizaje en contexto con demostraciones visuales. Las dos últimas líneas reciben mayor atención porque constituyen la dirección experimental principal del proyecto.

La revisión prioriza artículos revisados por pares, conjuntos publicados con documentación técnica, guías clínicas y documentación oficial de modelos. Los resultados no se comparan como si procedieran del mismo banco de pruebas. Las bases de datos, las etiquetas y las métricas difieren entre estudios.

Esta precaución es necesaria porque una exactitud alta en una tarea binaria no puede compararse directamente con una clasificación multietiqueta. Tampoco es equivalente evaluar imágenes renderizadas desde señales limpias que fotografías de documentos clínicos. La revisión se utiliza para identificar decisiones de diseño y huecos metodológicos.

3.2.- Aprendizaje profundo sobre señales electrocardiográficas

El análisis automático moderno se desarrolló principalmente sobre señales temporales. Las convoluciones unidimensionales permiten aprender filtros directamente sobre las muestras y evitan diseñar manualmente todas las características. Las redes profundas amplían el campo receptivo hasta integrar información distribuida a lo largo de varios segundos.

Ribeiro y colaboradores entrenaron una red profunda con más de dos millones de ECG de doce derivaciones procedentes de una red brasileña de telemedicina [11]. El sistema reconocía seis alteraciones y fue comparado con médicos en un subconjunto anotado. El trabajo mostró que una gran colección clínica puede sostener un clasificador temporal de alto rendimiento.

Su escala también señala una limitación para enfermedades poco frecuentes. Reunir millones de registros con etiquetas fiables no es una estrategia disponible para todos los problemas. Además, las etiquetas de rutina pueden reflejar criterios locales, versiones de software y variabilidad entre observadores.

PTB XL proporcionó un punto de referencia abierto con 21 837 ECG de doce derivaciones

y 71 enunciados potencialmente multitiqueta [12]. Sus particiones recomendadas facilitan comparaciones reproducibles. MIMIC IV ECG amplió la escala hasta aproximadamente 800 000 registros vinculables con información clínica [13]. Estos recursos resultan valiosos para preentrenamiento y validación, aunque no garantizan una cantidad suficiente de cada condición rara.

La literatura sobre señal establece dos referencias para el presente trabajo. Primero, una arquitectura supervisada puede aprender morfología electrocardiográfica cuando dispone de datos adecuados. Segundo, el rendimiento depende de la correspondencia entre el dominio de entrenamiento y la población objetivo. El simulador se utiliza para estudiar el régimen anterior a una gran colección clínica, no para competir con sistemas entrenados sobre millones de registros.

3.3.- Análisis directo de imágenes de ECG

El análisis de imagen aborda situaciones en las que el trazado está disponible como documento. Gliner y colaboradores compararon redes que recibían señales digitales y redes que recibían imágenes de doce derivaciones [14]. Su estudio incluyó ocho condiciones para el modelo temporal y una evaluación visual centrada en fibrilación auricular. También aplicó transformaciones que imitaban capturas con teléfono.

Sangha y colaboradores desarrollaron una CNN multitiqueta a partir de 2 228 236 registros brasileños convertidos en imagen [15]. El modelo predijo seis etiquetas clínicas y se evaluó en un conjunto externo alemán y en ECG impresos. El estudio demostró que la representación visual puede generalizar cuando el entrenamiento incorpora escala, diversidad y variación de formato.

La principal diferencia con este TFG es la disponibilidad de datos. Sangha y colaboradores estudian aprendizaje supervisado a gran escala. El presente trabajo pregunta qué ocurre antes de alcanzar esa escala y compara el entrenamiento de una CNN con el uso inmediato de demostraciones en un modelo abierto.

La imagen puede analizarse directamente o convertirse de nuevo a señal. Wu y colaboradores desarrollaron un sistema automático de digitalización y evaluaron la correlación entre la señal reconstruida y la original [16]. Los resultados fueron altos en formatos favorables y disminuyeron cuando había solapamiento entre derivaciones. Esta variabilidad muestra que la digitalización añade sus propios fallos.

El trabajo de Gliner y colaboradores de 2023 se centra en la transferencia desde imágenes limpias a fotografías y formatos no observados [17]. Su arquitectura adversarial utiliza muestras objetivo sin etiqueta para reducir la dependencia del estilo de adquisición. Esta línea es directamente relevante para la futura transición del simulador a datos reales.

3.4.- Datos sintéticos para ECG

La generación sintética aparece en varios niveles de fidelidad. Los modelos gaussianos representan ondas mediante funciones paramétricas. Su principal ventaja es la interpretabilidad. Cada cambio puede relacionarse con amplitud, posición o anchura. Sayadi y colaboradores emplearon un modelo de este tipo dentro de un sistema dinámico para generación y filtrado [18].

Los modelos electrofisiológicos simulan la propagación eléctrica sobre geometrías cardíacas. MedalCare XL contiene 16 900 ECG sintéticos de doce derivaciones para un grupo sano y siete patologías [19]. La colección aporta señales con una base mecánica y permite estudiar condiciones difíciles de equilibrar en datos clínicos.

También existen modelos generativos aprendidos. Los modelos de difusión condicionados pueden producir señales asociadas a enunciados diagnósticos [20]. Su flexibilidad es mayor que la de un simulador manual, pero la relación entre cada parámetro y la morfología final resulta menos directa. Además, la calidad debe evaluarse mediante diversidad, fidelidad clínica y utilidad para tareas posteriores.

El simulador del proyecto se mantiene en una versión simple. No intenta reproducir un torso, un corazón tridimensional o una distribución clínica completa. Genera un latido para estudiar tres hallazgos localizados. Esta decisión reduce el realismo y mejora la capacidad de auditar las reglas.

La literatura sintética también advierte de un riesgo. Un conjunto generado puede amplificar los supuestos del modelo de simulación. Si la variabilidad no incluye ruido, escalas y formas intermedias, el clasificador aprenderá una frontera más limpia que la que existe en práctica clínica. La evaluación real sigue siendo necesaria.

3.5.- Conjuntos que integran señal, imagen y texto

Los modelos multimodales necesitan datos alineados. Una imagen sin informe permite clasificación supervisada, pero no ofrece una relación rica entre morfología y lenguaje. Un informe sin trazado tampoco permite comprobar si la explicación se apoya en evidencia visual.

MEETI se publicó en 2026 como una extensión de MIMIC IV ECG [23]. El recurso sincroniza señales, imágenes renderizadas, parámetros por latido e interpretaciones textuales. Cubre hasta 784 680 registros de 160 597 pacientes. Las imágenes se generan con una escala estándar y las interpretaciones detalladas se producen mediante un modelo de lenguaje a partir de informes y parámetros.

MEETI reduce la barrera de entrada para estudiar alineamiento multimodal a gran es-

cala. También requiere una lectura crítica. Parte del texto es generado por un modelo y no constituye una nueva anotación clínica independiente. El recurso resulta adecuado para pre-entrenamiento, recuperación y generación de informes, pero la evaluación diagnóstica debe conservar etiquetas y conjuntos de referencia validados.

MEETI no forma parte de los experimentos de esta memoria porque la tarea se limita a un latido sintético y tres hallazgos. Sin embargo, el conjunto permite plantear una ampliación hacia doce derivaciones y comparar imagen, señal y texto sobre los mismos registros.

3.6.- Modelos multimodales especializados en ECG

Los modelos generalistas de visión y lenguaje han sido entrenados principalmente con imágenes naturales, documentos y contenido web. Un trazado electrocardiográfico posee una estructura diferente. La información se codifica en deflexiones delgadas, relaciones temporales y comparaciones entre derivaciones. Esta distancia de dominio puede limitar la interpretación directa y motiva dos aproximaciones complementarias. Una adapta un modelo de gran tamaño al dominio médico y la otra aprovecha las capacidades de razonamiento visual de un modelo generalista sin modificar sus pesos. Ambas vías se exploran en este TFG.

Liu y colaboradores introdujeron ECGInstruct, PULSE y ECGBench [21]. ECGInstruct contiene más de un millón de pares de imagen y texto que cubren reconocimiento de características, ritmo, morfología y generación de informes. PULSE es un modelo de siete mil millones de parámetros adaptado a ECG. ECGBench evalúa cuatro tareas en nueve conjuntos e incluye imágenes sintéticas y reales.

Los autores informan que PULSE supera a modelos multimodales generalistas en su banco de pruebas [21]. Este resultado apoya la idea de que el conocimiento visual específico importa. Al mismo tiempo, PULSE se ha entrenado con una colección masiva de instrucciones. Su existencia confirma que la adaptación al dominio mejora el rendimiento, pero no responde a la misma pregunta que este TFG. El presente proyecto investiga qué rendimiento se puede obtener *sin ajuste* de pesos, utilizando un modelo generalista abierto cuando solo existen unos pocos ejemplos de una condición rara como Brugada.

PULSE marca un nivel adicional de especialización. Su incorporación al protocolo permitiría separar una CNN entrenada de forma supervisada con pocas muestras, un modelo generalista mediante aprendizaje en contexto y un modelo multimodal ya adaptado a ECG. La comparación entre estos niveles mediría el valor incremental de cada etapa de especialización para una tarea de baja prevalencia.

La aparición de PULSE modifica el estado del arte, pero no elimina la pregunta de investigación. Un modelo especializado puede no estar disponible para una modalidad rara, una definición local o un nuevo protocolo de anotación. El aprendizaje en contexto sigue sien-

do relevante durante las fases tempranas de formulación y recogida de datos, especialmente cuando el coste de entrenamiento especializado es prohibitivo y se necesita una evaluación rápida de viabilidad.

3.7.- Aprendizaje multimodal en contexto

El aprendizaje en contexto (*in-context learning*, ICL) modifica el ciclo habitual de entrenamiento supervisado. En lugar de ajustar los pesos de una red mediante descenso por gradiente, los ejemplos se colocan en la ventana de contexto del modelo durante la inferencia. Cada demostración consiste en una imagen y su etiqueta o descripción textual. El modelo produce una predicción para la imagen de consulta sin que sus pesos hayan cambiado. Esta propiedad es especialmente valiosa cuando los datos disponibles se reducen a unas pocas decenas de muestras, situación habitual en condiciones cardíacas de baja prevalencia como el síndrome de Brugada.

Flamingo estableció la arquitectura de referencia para esta capacidad. El modelo recibe secuencias intercaladas de imágenes y texto y resuelve tareas con demostraciones de ejemplo [24]. Flamingo demostró que un modelo preentrenado de gran escala puede adaptarse a tareas nuevas durante la inferencia cuando se le proporcionan ejemplos visuales y textuales relevantes. Este resultado impulsó el uso de modelos multimodales como sistemas flexibles que no requieren un ciclo de ajuste dedicado para cada tarea.

Sin embargo, los estudios posteriores demuestran que esta capacidad es frágil y que la contribución de cada componente de las demostraciones no es homogénea. Chen y colaboradores evaluaron si los modelos utilizaban realmente la parte visual de las demostraciones [25]. Encontraron una dependencia dominante del contenido textual en varios bancos de pruebas estándar. La selección de ejemplos basada en similitud visual seguía aportando valor marginal, pero la imagen dentro de la demostración podía tener menos influencia de la esperada. Ese resultado encaja con una duda central de este trabajo. Cuando las demostraciones contienen imágenes de ECG, ¿el modelo las procesa visualmente o se apoya solo en las descripciones textuales?

Qin y colaboradores estudiaron la selección, el orden y la construcción de los ejemplos [26]. Sus resultados muestran que la recuperación multimodal, la posición de la instrucción dentro del contexto y la diversidad de las demostraciones afectan al rendimiento de forma significativa. Esto impide tratar K como la única variable relevante. Dos contextos con el mismo número de ejemplos pueden contener información muy diferente y producir resultados dispares.

Por este motivo, cada valor positivo de K se repite con tres semillas para cuantificar la variabilidad asociada a la selección de ejemplos. La evaluación distingue zero-shot, ICL

normal e ICL balanceado. Esta separación permite analizar si las demostraciones aportan señal y cómo afecta el equilibrio de clases a la relación entre sensibilidad y especificidad.

Además, la aplicación de ICL a dominios médicos especializados plantea retos adicionales que la literatura general no ha abordado en profundidad. La morfología de un ECG carece de los objetos semánticos familiares que abundan en los bancos naturales. El modelo debe interpretar deflexiones de pocos milímetros, elevaciones del segmento ST y relaciones temporales entre ondas. No es evidente que la representación visual preentrenada sobre fotografías y documentos sea suficiente para capturar estas diferencias sutiles. El presente trabajo es, hasta donde sabemos, uno de los primeros en aplicar ICL multimodal a imágenes de ECG de un solo latido con condiciones raras.

3.8.- Modelos abiertos, médicos y propietarios

El estado del arte multimodal avanza en dos direcciones que interesan a este TFG. Una consiste en modelos generalistas cada vez más potentes, capaces de razonar sobre texto e imagen aunque no hayan sido entrenados específicamente para ECG. Otra consiste en modelos médicos adaptados a modalidades clínicas concretas. La elección del modelo no depende solo del rendimiento, sino también de privacidad, reproducibilidad y dependencia de servicios externos.

Los modelos propietarios accesibles por API, incluidos modelos comerciales de la familia de OpenAI, son una referencia natural porque han mostrado capacidades multimodales fuertes. Además, trabajos recientes han demostrado que los VLM pueden detectar anomalías en ECG como imagen mediante aprendizaje en contexto [27]. Sin embargo, para un prototipo de triaje con datos sanitarios, la ejecución local reduce la exposición de las imágenes de pacientes, conserva el control sobre el entorno y evita cambios no documentados de versión.

MedGemma 1.5 pertenece a la línea de modelos médicos abiertos. El modelo ha recibido adaptación con diferentes modalidades clínicas, incluyendo radiología y dermatología [29]. La documentación disponible no sitúa el ECG entre sus modalidades principales, por lo que su uso en este dominio requiere validación específica antes de extraer conclusiones sobre morfología electrocardiográfica.

Gemma 4 es la familia abierta y multimodal elegida para la evaluación cuantitativa [28]. Sus variantes admiten texto e imagen, contexto extenso y resolución visual variable. La elección se apoya en su carácter abierto, en su nivel de prestaciones y en la posibilidad de ejecutarlo localmente con un tamaño razonable para un entorno hospitalario de investigación. Esta combinación permite estudiar si el aprendizaje en contexto aporta señal sin entrenar pesos ni enviar datos a un proveedor externo.

La comparación exige informar la versión del modelo, la resolución visual y el número

de tokens dedicados a cada imagen. Sin esa información, dos evaluaciones con el mismo nombre de modelo podrían no ser equivalentes.

3.9.- Hueco de investigación

La literatura revisada demuestra que el ECG puede analizarse como señal y como imagen con resultados clínicamente útiles, siempre que se disponga de una cantidad suficiente de datos etiquetados. Cuando la escala de entrenamiento se reduce a millones o cientos de miles de muestras, los modelos supervisados alcanzan un rendimiento competitivo con expertos. Sin embargo, para condiciones de baja prevalencia como el síndrome de Brugada, que puede representar menos del uno por ciento de un archivo clínico, ninguno de los trabajos revisados aborda la situación en la que el número total de ejemplos etiquetados se limita a unas pocas decenas.

El enfoque CNN de este TFG documenta precisamente esta situación. Los resultados muestran que una red convolucional entrenada con muy pocas muestras alcanza un rendimiento limitado y pierde capacidad diagnóstica al pasar al dominio real. Este resultado no es un defecto del diseño, sino la consecuencia esperable de un entrenamiento supervisado sin datos suficientes. La CNN sirve como referencia para medir el coste de la especialización cuando los datos son escasos.

Frente a esta limitación, los modelos de visión y lenguaje abren una vía alternativa. En lugar de modificar pesos mediante descenso por gradiente, un VLM recibe los mismos K ejemplos como demostraciones dentro de su ventana de contexto y produce una predicción sin entrenamiento. Esta aproximación posee tres ventajas potenciales en el régimen de pocos datos. Primera, no requiere un ciclo de entrenamiento y, por tanto, elimina el riesgo de sobreajuste a un conjunto diminuto. Segunda, el modelo puede integrar conocimiento morfológico previo adquirido durante su preentrenamiento masivo. Tercera, el coste computacional de la inferencia es predecible y no depende del número de épocas.

Hasta donde sabemos, ningún trabajo publicado ha realizado la comparación directa que propone este TFG. Dado un mismo K de imágenes de ECG etiquetadas con una condición rara, se estudia si resulta más eficaz utilizar esas muestras para entrenar una CNN o para construir un contexto de demostraciones en un VLM abierto. Los trabajos de Ribeiro et al. [11] y Sangha et al. [15] estudian el entrenamiento supervisado a gran escala. Los trabajos de Alayrac et al. [24], Chen et al. [25] y Qin et al. [26] estudian el aprendizaje en contexto multimodal sobre tareas naturales. Liu et al. [21] especializan un modelo multimodal con más de un millón de instrucciones. Ninguna de esas direcciones responde a la comparación planteada con el mismo K sobre imágenes de ECG y, específicamente, sobre una condición rara.

El TFG aborda ese hueco mediante un diseño experimental que ofrece el mismo número de ejemplos a ambos enfoques. La CNN utiliza las K muestras para modificar sus pesos. Gemma 4 las utiliza dentro del contexto de inferencia. El simulador proporciona una tarea conocida y verificable antes de introducir la variabilidad del dominio clínico.

La contribución metodológica no es una nueva arquitectura ni un nuevo modelo entrenado. Es una caracterización experimental del modo de uso. La CNN responde a qué ocurre cuando se entrena un modelo visual específico con muy pocos ejemplos y se intenta llevarlo a un dominio real. El VLM/ICL completa la comparación al comprobar, con el mismo K , si usar los ejemplos como contexto cambia la relación entre sensibilidad, especificidad y coste de inferencia frente a usarlos como entrenamiento.

4 Diseño experimental

La pregunta de este trabajo nace de una limitación muy concreta: cómo aprovechar un conjunto pequeño de pacientes etiquetados cuando la entrada disponible es una imagen de ECG. El diseño experimental se construye para comparar dos respuestas a esa limitación. Los dos enfoques reciben la misma evidencia visual, respetan la separación por paciente y se evalúan con las mismas métricas.

En el enfoque supervisado, una ResNet18 utiliza los ejemplos disponibles para modificar sus pesos durante el entrenamiento. En el enfoque multimodal, Gemma 4 utiliza esos ejemplos de otra manera: no los convierte en gradiente, sino en demostraciones dentro del prompt. Esta diferencia metodológica es el eje del protocolo, y se mantiene explícito qué representa K en cada caso: pacientes de entrenamiento para la CNN y ejemplos de contexto para el VLM.

El papel clínico del sistema se define con prudencia. Una predicción positiva no confirma ni descarta síndrome de Brugada. Indica que el trazado merece revisión experta y podría entrar en el circuito habitual, que incluye revisión del ECG completo, posible reposicionamiento de V1/V2 y prueba farmacológica en pacientes seleccionados. Esta definición afecta a la lectura de las métricas. La sensibilidad mide cuántos positivos llegan a la alerta y la especificidad mide cuántos controles no se derivan innecesariamente.

La estructura del protocolo sigue una lógica habitual en estudios de modelos predictivos y de exactitud diagnóstica: separa datos, partición, métricas, papel previsto del sistema y resultados, e informa matrices 2×2 , sensibilidad y especificidad para que la lectura sea transparente [42, 40, 41]. En una tarea con imágenes clínicas, también es importante dejar claro qué entrada recibe el modelo, cómo se agregan las predicciones y qué evidencia queda fuera de la imagen.

4.1.- Planteamiento común

El enfoque supervisado entrena una ResNet18 con pocos ejemplos. El enfoque VLM/ICL usa Gemma 4 y evalúa zero-shot, ICL normal e ICL balanceado. Ambos comparten los mismos valores de K , la misma separación por paciente y la misma agregación de métricas, de modo que las diferencias observadas puedan atribuirse al modo de utilizar los ejemplos etiquetados.

La comparación se apoya en dos dominios. El simulador QRS/ST permite comprobar si

la imagen contiene una señal morfológica aprendible en condiciones controladas. Los datos cedidos por el HUCA permiten medir qué ocurre al pasar a ECG clínicos reales, con ruido de adquisición, variabilidad entre pacientes y una etiqueta clínica que no equivale exactamente a las reglas del simulador.

4.2.- Datos evaluados

La unidad de separación es siempre el paciente. En el conjunto sintético, cada paciente simulado aporta tres imágenes correspondientes a V1, V2 y V3. En los datos cedidos por el HUCA, cada paciente aporta las ventanas renderizadas de esas derivaciones precordiales derechas. El modelo produce una predicción por imagen y la decisión final se agrega por paciente.

Conjunto	Pacientes	Imágenes	Positivos	Negativos	Tarea
Sintético QRS/ST	100	300	20	80	Patrón derivado de Brugada con RBBB, elevación ST e inversión T presentes
Datos HUCA	317	951	116	201	Caso Brugada confirmado frente a control, tras excluir registros limítrofes

Tabla 4.1.- Conjuntos utilizados en los experimentos finales.


Esta diferencia de etiqueta es importante. En el simulador se evalúa una regla morfológica definida por construcción, mientras que en los ECG reales se evalúa una variable clínica recogida en los metadatos. El paso del simulador al entorno clínico no mide solo una diferencia visual, sino también una diferencia en el significado de la etiqueta.

4.3.- Valores de K y validación

Los valores de pocos ejemplos son $K = \{2, 4, 8, 16, 32\}$. En el enfoque VLM se añade $K = 0$, que corresponde a zero-shot. Para cada valor positivo de K se ejecutan tres semillas, 42, 123 y 2026. La selección de ejemplos se realiza dentro de cada pliegue y nunca incluye el paciente reservado para prueba.

En la evaluación real, K no tiene el mismo origen en todas las ramas. La CNN evaluada con los datos cedidos por el HUCA se ajusta con K pacientes del simulador porque la cohorte clínica no contiene las etiquetas morfológicas que exige la cabeza multietiqueta. En el

VLM, K indica demostraciones de contexto y se estudian dos posibilidades: demostraciones tomadas de la cohorte real para la comparación clínica principal y demostraciones sintéticas para analizar la transferencia desde el simulador.



LOOCV por paciente, tres semillas por K positivo y agregación por probabilidad media de $V1/V2/V3$.

Figura 4.1.- Validación leave-one-out por paciente y selección de ejemplos para cada valor de K .

Este esquema evita una fuente de sesgo muy común en ECG. Las derivaciones o registros de la misma persona no deben aparecer a la vez en entrenamiento y prueba. Si eso ocurriera, el modelo podría aprender rasgos del paciente, del dispositivo o del renderizado en lugar de rasgos relacionados con la tarea.

4.4.- Métricas

La métrica principal es la exactitud equilibrada, porque pondera sensibilidad y especificidad por igual aunque las clases estén desbalanceadas. Se calcula como

$$BA = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right).$$

También se informan F1, sensibilidad, especificidad, área ROC y precisión media. Las tablas principales muestran medias sobre tres semillas y, cuando procede, desviación estándar. Las matrices de confusión agregan las predicciones de las tres ejecuciones.

La interpretación clínica se mantiene prudente. Un modelo con sensibilidad alta y especificidad baja puede ser interesante para investigación exploratoria, porque recupera más positivos, pero no basta para un circuito asistencial si genera demasiadas alertas. Esa tensión guía las comparaciones de los capítulos finales.

Con este diseño, los capítulos siguientes separan método y resultado. El capítulo 6 fija el marco comparativo. Los capítulos 7 y 8 describen, respectivamente, la CNN y el enfoque VLM/ICL sin adelantar resultados. Los capítulos 9 y 10 presentan la comparación cuantitativa en el dominio sintético y en los ECG reales.

5 El simulador QRS/ST

5.1.- Objetivo del dominio sintético

La disponibilidad de datos sintéticos permite estudiar una pregunta metodológica sin esperar a reunir una colección clínica extensa. En este trabajo el simulador actúa como un laboratorio controlado. Cada beat se construye a partir de componentes interpretables, se valida mediante reglas explícitas y se transforma en una imagen que puede entregarse tanto a una CNN como a un modelo de visión y lenguaje.

El objetivo no es reproducir toda la fisiología cardíaca. Un simulador clínicamente exhaustivo tendría que modelar varias derivaciones, cambios de frecuencia, interacción entre ciclos, conducción auricular y ventricular, ruido de adquisición, variación anatómica y efectos del dispositivo. El sistema implementado reduce el problema a un único beat de apariencia precordial derecha. Esta simplificación permite controlar tres hallazgos visuales que intervienen en la motivación del proyecto.

El uso de datos sintéticos cumple cuatro funciones:

1. Generar etiquetas sin depender de anotación manual para cada imagen.
2. Separar la forma de una onda de factores externos como fabricante, hospital o estilo de documento.
3. Construir conjuntos de ejemplos con tamaños exactos y semillas conocidas.
4. Reservar una familia generadora compuesta para estudiar transferencia.

La contrapartida es una brecha inevitable entre el dominio sintético y el real. El simulador puede demostrar que una tarea controlada es aprendible. No puede demostrar que el mismo rendimiento se mantenga en un ECG clínico. Esa distinción se conserva en toda la memoria.

5.2.- Representación matemática

Cada beat se define como una suma de diez átomos gaussianos. Para el átomo i , la amplitud a_i , el centro temporal μ_i y la anchura σ_i determinan la función

$$g_i(t) = a_i \exp \left(-\frac{(t - \mu_i)^2}{2\sigma_i^2} \right). \quad (5.1)$$

La señal completa es

$$x(t) = \sum_{i=1}^{10} g_i(t). \quad (5.2)$$

El signo de a_i controla la dirección de la deflexión. El valor absoluto de a_i controla su magnitud. El parámetro μ_i desplaza el componente sobre el eje temporal y σ_i modifica su extensión. La suma permite formar transiciones suaves sin introducir discontinuidades.

La elección de gaussianas se inspira en modelos sintéticos previos que representan ondas electrocardiográficas mediante componentes paramétricos [18]. El presente simulador es más sencillo que un modelo dinámico electrofisiológico. Su ventaja es la capacidad de relacionar cada modificación con una región visual concreta.

Átomo	Región principal	Función dentro del generador
P	Onda P	Añade una deflexión auricular positiva anterior al QRS
Q	Inicio del QRS	Permite una pequeña deflexión negativa, aunque la configuración actual la mantiene anulada
R	QRS inicial	Produce el primer máximo positivo ventricular
S	QRS central	Forma la deflexión negativa posterior a R
R_prime	QRS terminal	Introduce un segundo máximo positivo y permite una forma RSR prima
J_elev	Punto J	Controla la transición entre el final del QRS y el segmento ST
ST1	ST inicial	Modela elevación temprana y la parte descendente de una forma cóncava
ST2	ST tardío	Controla la continuidad hacia la onda T
T1	Onda T principal	Define la polaridad y la magnitud principal de la repolarización
T2	Cola de la onda T	Suaviza y prolonga la repolarización

Tabla 5.1.- Átomos utilizados para construir un beat




Figura 5.1.- Generador gaussiano de un beat sintético. Los parámetros de cada átomo fijan su amplitud, posición y anchura antes de sumar las regiones P, QRS, ST y T.

5.3.- Muestreo temporal

La configuración final utiliza una frecuencia de 500 Hz y una duración de 900 ms. El número de muestras se calcula como

$$N = \text{round} \left(\frac{D}{1000} f_s \right), \quad (5.3)$$

donde D es la duración en milisegundos y f_s la frecuencia de muestreo. Con los valores finales se obtienen 450 muestras. El vector temporal es

$$t_n = \frac{1000n}{f_s}, \quad n \in \{0, \dots, N-1\}. \quad (5.4)$$

Los rangos de la repolarización se definieron sobre una duración de referencia de 900 ms. Cuando cambia la duración del beat, los centros posteriores a 390 ms se adaptan mediante

$$\mu_i^{(D)} = 390 + \left(\mu_i^{(900)} - 390 \right) \frac{D - 390}{900 - 390}. \quad (5.5)$$

Las anchuras de los componentes tardíos se escalan por el mismo factor, con un mínimo que impide gaussianas degeneradas. Los componentes anteriores al punto de pivote no se desplazan. De este modo el QRS conserva su posición mientras que ST y T se comprimen o expanden para ocupar la duración disponible.

5.4.- Rangos de parámetros

La generación comienza con un andamiaje compartido. Cada átomo dispone de intervalos para a , μ y σ . Después se aplican sustituciones específicas de la familia. El muestreo dentro de cada intervalo es uniforme. La distribución final no es uniforme porque las reglas morfológicas y los validadores rechazan parte de las propuestas.

Los rangos no deben interpretarse como límites clínicos. Son parámetros de un generador visual. Por ejemplo, el átomo R_{prime} tiene amplitud casi nula en la familia normal y puede alcanzar valores mayores en RBBB. Los átomos J_{elev} , ST1 y ST2 permanecen cerca de cero en una señal normal y se desplazan hacia amplitudes positivas en la familia de elevación del ST.

Separar rangos y validadores responde a dos responsabilidades distintas. Los rangos hacen probable una morfología. Los validadores determinan si la señal terminada satisface la definición de cada etiqueta. Si ambos elementos se mezclaran, cualquier cambio visual podría alterar de manera silenciosa el significado de las etiquetas.

5.5.- Familias generadoras

El simulador contiene cinco familias de origen. Una familia selecciona rangos de muestreo y reglas de coherencia, pero no determina directamente el vector objetivo.

5.5.1.- Familia normal

La familia NORMAL reduce la amplitud de R prima, mantiene la región J y ST próxima a la línea base y fuerza ondas T positivas. También exige que la señal no satisfaga ninguno de los tres validadores de hallazgos. Esta exclusión explícita es necesaria porque una señal generada con rangos normales podría producir por azar una combinación que superase un umbral patológico.

5.5.2.- Morfología RBBB

La familia RBBB favorece una segunda deflexión positiva posterior a S. La posición de R prima se obliga a aparecer al menos 24 ms después del centro de S. Su amplitud no puede quedar por debajo del 80 por ciento de la amplitud de R dentro de los límites permitidos. También se amplía su anchura respecto a la primera R.

El resultado busca una forma RSR prima visible. No reproduce todos los criterios clínicos de bloqueo completo de rama derecha, que dependen de la duración global del QRS y de la distribución entre derivaciones [3]. Por ello la etiqueta se denomina morfología compatible

en el texto interpretativo.

5.5.3.- Elevación de ST

La familia ST_ELEVATION utiliza amplitudes positivas en el punto J y en los dos componentes del ST. La primera sección del ST se ensancha para evitar un pico estrecho que pudiera confundirse con una deflexión del QRS. El validador exige además actividad ventricular positiva y negativa suficiente, con el fin de descartar señales planas elevadas.

5.5.4.- Inversión de T

La familia T_WAVE_INVERSION hace negativas las dos componentes de T y las separa de la región ST. También puede producir una R prima moderada y una elevación pequeña de J. Esta elección permite coocurrencias con RBBB y ST. El validador exige que la deflexión negativa sea tardía, suficientemente profunda y mantenida.

5.5.5.- Familia Brugada

La familia BRUGADA implementa únicamente una forma coved o tipo 1 esquemática. Combina elevación de J, ST inicial positivo, descenso posterior e inversión de T. La amplitud de R prima es menor que en la familia RBBB pura, pero puede mantener una alteración terminal del QRS.

El nombre de la familia no se incorpora al vector objetivo. Una señal aceptada por el validador interno de Brugada se vuelve a evaluar mediante los validadores independientes de RBBB, elevación de ST e inversión de T. Por tanto puede recibir una combinación parcial de hallazgos. Esta decisión convierte la familia en una prueba de composición y evita utilizar una etiqueta clínica que el simulador no puede justificar.

Familia	Modificación dominante	Interpretación experimental
NORMAL	ST próximo a cero, T positiva y R prima mínima	Referencia sin hallazgos del conjunto
RBBB	Segundo máximo positivo tardío y ancho	Componente terminal del QRS
ST elevado	Punto J y ST positivos	Componente de elevación posterior al QRS
Inversión de T	Repolarización tardía negativa	Componente de inversión de T
BRUGADA	J elevado, ST descendente y T negativa	Familia compuesta reservable para transferencia

Tabla 5.2.- Relación entre familias generadoras y rasgos favorecidos

5.6.- Reglas de coherencia morfológica

El muestreo independiente de los átomos puede producir órdenes temporales incoherentes. Para reducir este problema se aplican reglas deterministas antes de sumar las gaussianas. Q debe preceder a R. S debe aparecer después de R y ser más ancha. J se sitúa después de S. Los dos componentes del ST se ordenan tras J. T1 y T2 ocupan la región final.

Estas reglas no garantizan fisiología. Garantizan una geometría mínima para que cada parámetro conserve una interpretación. Las reglas específicas de una familia refuerzan relaciones adicionales, como la posición tardía de R prima o el signo negativo de T.

Modificar una regla puede tener efectos indirectos. Mover T1 cambia el resultado del validador de inversión y también puede alterar la media tardía del ST. Cada cambio debe acompañarse, por tanto, de una nueva generación de ejemplos, un análisis de frecuencias y una comprobación de aceptación.

5.7.- Muestreo con rechazo

El procedimiento de generación utiliza muestreo con rechazo. Para una familia c , el algoritmo sigue los siguientes pasos:

1. Combinar los rangos base con los rangos específicos de c .
2. Adaptar los componentes tardíos a la duración solicitada.
3. Muestrear los parámetros de los diez átomos.
4. Aplicar las reglas de orden y coherencia.
5. Sumar los átomos sobre el vector temporal.
6. Evaluar el validador correspondiente a c .
7. Aceptar la señal si supera las reglas o volver al paso de muestreo.

El límite por defecto es de 400 intentos. Si no se obtiene una señal válida, el generador lanza un error e incluye las últimas métricas calculadas. El número de intento se almacena en los metadatos de cada muestra. Esta variable permite detectar rangos mal alineados con los validadores.

Sea q_c la probabilidad de aceptación de una propuesta de la familia c . El número esperado de intentos antes de una aceptación es aproximadamente

$$\mathbb{E}[A_c] = \frac{1}{q_c}. \quad (5.6)$$

Una familia que requiere muchos intentos puede seguir generando imágenes correctas, pero revela que gran parte de su espacio paramétrico no satisface la definición de la etiqueta. Las tasas de aceptación deben registrarse cuando se cierre la versión final del simulador.

5.8.- Validadores y semántica de las etiquetas

Los validadores operan sobre ventanas temporales de la señal terminada. Las ventanas posteriores a 390 ms se adaptan mediante la ecuación 5.5. Las amplitudes se expresan en mV y las duraciones en ms.

Validador	Condiciones necesarias
RBBB	Dos máximos positivos entre 240 y 470 ms, separación mínima de 28 ms, primer máximo superior a 0,12 mV, segundo máximo superior a 0,20 mV, mínimo intermedio inferior a $-0,05$ mV, segundo máximo posterior a 345 ms y anchura terminal superior a 38 ms por encima de 0,10 mV
Elevación de ST	Máximo del QRS superior a 0,28 mV, mínimo del QRS inferior a $-0,14$ mV, media de J superior a 0,09 mV y media del ST superior a 0,09 mV
Inversión de T	Máximo del QRS superior a 0,22 mV, máximo de R prima superior a 0,08 mV, media del ST superior a $-0,03$ mV, mínimo de T inferior a $-0,12$ mV, mínimo posterior al umbral temporal equivalente a 640 ms y más de 45 ms por debajo de $-0,05$ mV
Normal	Máximo del QRS superior a 0,22 mV, mínimo inferior a $-0,10$ mV, media de ST entre $-0,04$ y 0,05 mV, máximo de T superior a 0,12 mV, R prima inferior a 0,10 mV y rechazo de los tres hallazgos
Brugada	Máximo del QRS superior a 0,18 mV, mínimo inferior a $-0,16$ mV, media de J superior a 0,09 mV, media de ST superior a 0,08 mV, ST temprano al menos 0,03 mV por encima del ST tardío y mínimo de T inferior a $-0,08$ mV

Tabla 5.3.- Criterios de los validadores sintéticos

Los umbrales se diseñaron para separar morfologías del simulador. No deben trasladarse a un ECG real ni compararse de forma directa con criterios clínicos. Un ECG real requiere calibración, derivaciones identificadas, velocidad de papel conocida y valoración del contexto. Los estándares clínicos revisados en el capítulo 2 se utilizan para orientar la forma general, no para validar pacientes.

Las tres etiquetas finales se calculan de forma independiente. Para una señal aceptada, se ejecutan los validadores de RBBB, ST y TWI y se construye un vector binario. Este paso puede producir coocurrencias que no coinciden con la familia. La etiqueta final es una propiedad de la señal, no una copia del mecanismo que la generó.

5.9.- Renderizado de las señales

Cada beat se representa sobre un lienzo cuadrado. La configuración final guarda imágenes de 896 por 896 píxeles a 130 puntos por pulgada. El eje horizontal utiliza una cuadrícula

menor cada 40 ms y una cuadrícula mayor cada 200 ms. El eje vertical utiliza divisiones menores de 0,1 mV y mayores de 0,5 mV. La señal se dibuja en negro con un grosor de dos puntos y la cuadrícula en rosa con dos intensidades.

El renderizado conserva títulos de ejes y valores numéricos. Estos elementos aportan información de escala, pero también pueden transformarse en atajos si los límites cambian entre muestras. Por ese motivo, los límites horizontal y vertical se fijan para todas las imágenes del experimento final. La inspección visual verifica que ninguna familia posee un encuadre, margen o patrón de marcas propio.

No se aplicarán reflejos horizontales. Invertir el eje temporal cambiaría el orden fisiológico de las ondas. Tampoco se aplicarán reflejos verticales, ya que intercambiarían elevación y depresión. Las transformaciones visuales admisibles deben conservar la semántica, como pequeñas variaciones de grosor, contraste, desplazamiento y escala dentro de límites conocidos.




Figura 5.2.- Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador.

5.10.- Construcción del conjunto de datos

La generación del conjunto sintético parte de las familias definidas y asigna a cada muestra una semilla propia. Una vez aceptadas las señales, se crean las particiones de entrenamien-

to, validación y prueba y se guardan las imágenes junto con el manifiesto correspondiente.

Cada muestra queda asociada a su imagen, partición, familia generadora, semilla, subtipo cuando procede, número de intento e índices internos, junto con las etiquetas binarias correspondientes. Además, se guardan ficheros auxiliares con el esquema de etiquetas y resúmenes de frecuencia por partición, familia y combinación de clases. De este modo, el entrenamiento puede realizarse directamente desde los manifiestos CSV, sin depender de la organización física de las carpetas, y los ficheros JSON quedan como apoyo para revisar el proceso o elaborar resultados.

5.11.- Comprobación de integración

La configuración final se ejecutó para generar 100 pacientes sintéticos, 300 imágenes, pliegues LOOCV y resúmenes de etiquetas. El conjunto contiene 20 pacientes con los tres hallazgos presentes y 80 pacientes normales o incompletos. Las combinaciones observadas incluyen NORMAL, RBBB, RBBB+ST, RBBB+ST+TWI, RBBB+TWI y TWI.

El conjunto generado constituye la base de la evaluación sintética posterior. La comprobación de integración confirma que la generación de señales, la aceptación por validadores, la partición por paciente y la escritura de manifiestos producen un artefacto experimental reutilizable. La presencia de varias combinaciones de etiquetas permite estudiar la evolución del rendimiento al variar K sin reducir la tarea a una separación trivial entre normalidad y un único patrón patológico.

La revisión de los ejemplos generados confirma que la familia de origen y las etiquetas finales cumplen funciones distintas. Una familia modifica los rangos de muestreo para favorecer una morfología concreta, pero los validadores se aplican después sobre la señal resultante. Por eso una señal orientada a elevación del ST puede activar también RBBB, y una señal con inversión de T puede conservar una deflexión terminal compatible con otros hallazgos. La tarea experimental queda definida por los rasgos detectados en la señal, no por el nombre de la familia que inició la generación.




Figura 5.3.- Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV.

5.12.- Riesgos de atajos visuales

Un modelo puede obtener resultados altos sin aprender la morfología pretendida. Entre los atajos posibles se encuentran límites automáticos del eje, diferencias de antialiasing, márgenes asociados a la amplitud, densidad de cuadrícula, nombres de fichero y estructura de carpetas.

Para reducir estos riesgos, las imágenes se cargarán desde el manifiesto y la familia no se entregará al modelo. Los límites visuales serán constantes. Los nombres de fichero solo contendrán un contador. La evaluación incluirá recortes de la zona de trazado y versiones sin texto de ejes como análisis de sensibilidad. Si el rendimiento cae de forma drástica al retirar elementos no fisiológicos, se investigará el origen antes de interpretar los resultados.

También se comprobará la atención espacial de las CNN mediante Grad CAM [32]. La finalidad no es demostrar causalidad, sino detectar si las regiones activas se concentran en QRS, ST y T o en elementos periféricos.

5.13.- Limitaciones del simulador

El simulador representa un beat aislado y una geometría semejante a una derivación precordial. No modela doce derivaciones ni una transformación eléctrica común entre ellas. No incluye variabilidad entre beats, arritmias, intervalos dependientes de frecuencia, ruido muscular, deriva de línea base, interferencia de red, pérdida de electrodos ni compresión de documentos.

La forma de cada onda se construye con gaussianas. Esta elección produce curvas suaves y puede simplificar bordes que en un ECG real son más irregulares. Los validadores se basan

en ventanas y umbrales creados para este dominio. Una señal clínica no debe procesarse con ellos como si fueran reglas diagnósticas.

En la familia Brugada se modela de forma simplificada una elevación del ST con morfología convexa, asociada al patrón de Brugada tipo 1. No representa la heterogeneidad del síndrome, la variación entre derivaciones ni la posibilidad de patrones intermitentes. Su uso se limita a estudiar la composición visual de los tres hallazgos.

Estas limitaciones no invalidan el laboratorio sintético. Delimitan qué afirmaciones puede sostener. El dominio permite comparar eficiencia de ejemplos bajo condiciones controladas. La validez clínica dependerá de la evaluación externa descrita en el capítulo de datos reales.

6 Dos enfoques de modelado

Este capítulo presenta las dos líneas seguidas en el TFG para abordar la escasez de datos etiquetados. La primera entrena modelos visuales directamente sobre las imágenes disponibles, ajustando el procedimiento a un número reducido de pacientes. La segunda utiliza modelos de visión y lenguaje con aprendizaje en contexto, de modo que los ejemplos etiquetados orientan la predicción sin modificar los pesos del modelo.

La distinción importa porque los dos enfoques consumen los mismos datos de forma diferente. En la CNN, K define el tamaño del conjunto de entrenamiento de cada pliegue. En el VLM, K define el número de demostraciones disponibles antes de la imagen que se quiere clasificar. Por tanto, el capítulo no compara únicamente arquitecturas, sino dos regímenes de uso de datos: entrenamiento supervisado frente a inferencia condicionada por contexto.




Figura 6.1.- Dos formas de utilizar el mismo conjunto reducido de pacientes etiquetados: entrenamiento de ResNet18 y aprendizaje en contexto con Gemma 4.

6.1.- Entrada y unidad de análisis

Todos los modelos reciben imágenes de ECG. En el caso de la CNN, cada imagen se redimensiona a 224 por 224 píxeles y se procesa como entrada RGB. En el caso del VLM, la imagen se introduce dentro de un mensaje multimodal junto con instrucciones textuales y, cuando procede, ejemplos etiquetados.

La evaluación se realiza por paciente. En los experimentos con V1, V2 y V3, las predic-

ciones por derivación se agregan antes de obtener la decisión final. Esta decisión evita que varias imágenes de una misma persona se traten como casos independientes y mantiene la interpretación clínica en el nivel correcto.

6.2.- Enfoque supervisado con CNN

6.2.1.- Qué aprende

La CNN aprende una función que transforma una imagen en una probabilidad de clase positiva. Durante el entrenamiento, los ejemplos etiquetados generan una pérdida y esa pérdida actualiza los pesos de la red. Una vez terminado el entrenamiento, el modelo queda fijado y cada nueva predicción es una inferencia directa.

Este enfoque es atractivo cuando hay suficientes ejemplos representativos. Permite ajustar rasgos visuales específicos de la tarea, produce salidas numéricas estables y tiene un coste bajo por predicción una vez entrenado. En un entorno hospitalario, esas propiedades son relevantes porque facilitan despliegues rápidos y reproducibles.

6.2.2.- Riesgos con pocos ejemplos

La dificultad aparece cuando K es pequeño. Una ResNet18 tiene millones de parámetros y puede adaptarse demasiado a los pacientes concretos seleccionados en cada pliegue. En ese escenario, cambiar unos pocos ejemplos puede modificar la frontera de decisión. También puede aparecer aprendizaje de atajos visuales, como diferencias de escala, grosor del trazo, recorte o aspecto de la cuadrícula que no corresponden al hallazgo clínico.

Por ese motivo, la CNN se interpreta como referencia supervisada. No se presenta como solución clínica por defecto, sino como una forma sólida de medir qué obtiene un entrenamiento visual clásico cuando la cantidad de datos es limitada.

6.3.- Enfoque multimodal con VLM e ICL

6.3.1.- Qué cambia frente al entrenamiento

En el enfoque VLM, los ejemplos etiquetados no modifican pesos. Se colocan en el prompt como demostraciones de la tarea. El modelo recibe la imagen objetivo, observa el formato esperado de respuesta y usa el contexto para decidir. El aprendizaje en contexto no reemplaza al entrenamiento supervisado, pero ofrece una alternativa cuando entrenar con muy pocos datos resulta frágil.

Esta diferencia es especialmente importante en enfermedades raras. Si cada positivo confirmado es costoso, puede interesar comprobar si un modelo generalista de visión y lenguaje ya contiene suficiente conocimiento visual para orientar la predicción con pocas demostraciones. La evaluación VLM contrasta esa hipótesis con Gemma 4, ejecutado en local.

6.3.2.- Tres condiciones de consulta

El enfoque multimodal se evalúa en tres condiciones. Zero-shot no incluye ejemplos locales. ICL normal añade demostraciones seleccionadas con el muestreo estándar del experimento. ICL balanceado intenta incluir positivos y negativos cuando el pliegue lo permite. Esta última condición es relevante porque puede aumentar sensibilidad, aunque también puede reducir especificidad.

La comparación con la CNN se hace con cautela. La CNN recibe K pacientes para entrenar. El VLM recibe K pacientes para construir el contexto. En ambos casos se respeta la separación por paciente y el paciente reservado no aparece entre los ejemplos.

6.4.- Comparación entre enfoques

La comparación mantiene explícito el significado de K en cada enfoque. En la CNN, K indica cuántos pacientes se incorporan al entrenamiento de cada pliegue. Sus imágenes contribuyen a la pérdida y modifican los pesos del modelo, con el riesgo esperado de sobreajuste y alta varianza cuando el conjunto es pequeño. En la evaluación con los datos cedidos por el HUCA, esos pacientes de entrenamiento proceden del simulador, ya que la cohorte real no dispone de etiquetas morfológicas para la cabeza multietiqueta. En el VLM, K indica cuántos pacientes se convierten en demostraciones dentro del prompt. No se actualizan parámetros, pero el resultado depende de la selección de ejemplos, de la ventana de contexto y del coste de cada consulta.

El objetivo de la evaluación es observar si entrenar pesos resulta más eficaz que condicionar una inferencia con demostraciones, y en qué rango de pocos ejemplos cambia esa relación. Esta lectura se mantiene en los dos dominios de evaluación: primero en el simulador, donde la etiqueta está controlada, y después en ECG reales, donde la etiqueta clínica introduce mayor variabilidad.

Los capítulos siguientes desarrollan los dos métodos por separado. El capítulo 7 describe la CNN y su protocolo de entrenamiento. El capítulo 8 describe el VLM, las condiciones de consulta y las decisiones de privacidad. La evaluación cuantitativa se presenta después en el simulador y en los ECG reales.

7 Enfoque supervisado con CNN

ResNet18

La CNN constituye la referencia supervisada del trabajo. Su función no es competir con todas las arquitecturas posibles, sino representar un enfoque estándar para aprender a partir de imágenes etiquetadas. En este caso, los ejemplos disponibles se usan para actualizar pesos y producir un modelo específico para la tarea.

7.1.- Arquitectura y entrada

El modelo ejecutado es una ResNet18 preentrenada [31]. La cabeza final se sustituye por tres salidas, una para cada hallazgo morfológico: RBBB, elevación ST e inversión de T. La entrada se procesa como imagen RGB de 224 por 224 píxeles. En el simulador, la etiqueta positiva de paciente se obtiene cuando los tres hallazgos están presentes.

Esta formulación condiciona toda la evaluación real. La CNN no aprende directamente la etiqueta clínica `clinical_brugada`. Aprende a detectar tres rasgos morfológicos y después deriva una decisión positiva cuando los tres aparecen simultáneamente. Por ello, los datos cedidos por el HUCA se usan como conjunto de prueba clínica, no como conjunto supervisado de entrenamiento morfológico.




Figura 7.1.- Uso supervisado de los ejemplos etiquetados en la CNN. Las muestras de entrenamiento actualizan los pesos de ResNet18 y la muestra reservada produce una predicción binaria junto con su mapa Grad CAM.

7.2.- Entrenamiento

La pérdida es entropía cruzada binaria multietiqueta. Cuando el pliegue lo requiere, la clase positiva se pondera automáticamente a partir de los ejemplos de entrenamiento. El optimizador es AdamW [38], con tasa de aprendizaje 3×10^{-4} , lote de 32 imágenes y 20 épocas máximas.

Propiedad	Valor
Arquitectura	ResNet18 con cabeza multietiqueta de tres salidas
Inicialización	Pesos preentrenados de ResNet18
Entrada	RGB, 224 por 224 píxeles
Pérdida	Entropía cruzada binaria multietiqueta con ponderación automática
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Épocas máximas	20
Tamaño de lote	32
Valores de K	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026
Umbral	Seleccionado por validación con exactitud equilibrada por paciente
Agregación	Media de probabilidades de V1, V2 y V3 antes del umbral

Tabla 7.1.- Configuración CNN utilizada en los experimentos finales.

7.3.- Uso de los datos cedidos por el HUCA en la CNN

Los datos cedidos por el HUCA no contienen anotaciones independientes de RBBB, elevación ST e inversión de T para cada imagen. Solo incorporan la referencia clínica de caso Brugada confirmado frente a control. Esto impide entrenar, con la arquitectura definida, una CNN supervisada con esa cohorte real y evaluarla después sobre la misma fuente manteniendo la tarea morfológica.

La evaluación real de la CNN se plantea por tanto como transferencia desde el simulador. En cada pliegue, los K pacientes que actualizan los pesos proceden del conjunto sintético QRS/ST. La muestra evaluada pertenece a los datos cedidos por el HUCA y su resultado se compara con la etiqueta clínica disponible. Esta decisión no inventa etiquetas morfológicas en el dominio real, pero hace que la lectura sea necesariamente una prueba de transferencia

sintético-real.

Entrenar una CNN supervisada directamente con los datos cedidos por el HUCA sería una línea distinta. Requeriría disponer de anotaciones morfológicas clínicas por imagen o rediseñar el modelo como clasificador binario directo de `clinical_brugada`. Esa segunda opción mediría otra tarea, más próxima a predicción clínica agregada que a detección de rasgos visuales.

7.4.- Validación por paciente

El entrenamiento y la evaluación se organizan mediante validación leave-one-out. En cada pliegue se reserva un paciente completo y el modelo se ajusta con un subconjunto de K pacientes del resto. Esto evita que imágenes de un mismo paciente aparezcan simultáneamente en entrenamiento y prueba. En los datos cedidos por el HUCA esta restricción es indispensable porque las tres derivaciones de un paciente comparten adquisición, calibración y contexto clínico.

La evaluación registra las probabilidades por imagen, la predicción agregada por paciente, el umbral elegido, la matriz de confusión y las métricas finales. También conserva paneles Grad CAM para inspección cualitativa.

7.5.- Selección de umbral

La ResNet18 se entrena con tres salidas, una para RBBB, otra para elevación ST y otra para inversión de T. Cada salida produce un logit, que se transforma mediante una sigmoide en una probabilidad. Por tanto, el umbral no se aplica sobre una clase Brugada directa, sino sobre cada hallazgo morfológico. Cuando un paciente tiene varias derivaciones disponibles, las probabilidades de V1, V2 y V3 se promedian por hallazgo.

La decisión de paciente se obtiene después de esa agregación. Un hallazgo se considera presente si su probabilidad media alcanza el umbral elegido. La predicción positiva de Brugada se deriva con la misma regla utilizada durante el experimento: RBBB, elevación ST e inversión de T deben estar presentes simultáneamente.

El valor del umbral se escoge dentro de cada pliegue usando solo pacientes de validación, nunca el paciente reservado para prueba. La búsqueda prueba umbrales candidatos y conserva el que maximiza la exactitud equilibrada de la etiqueta derivada a nivel de paciente. Si la validación del pliegue no contiene ambas clases, se mantiene 0,5. El paciente de prueba se evalúa siempre con un criterio fijado antes de consultar su etiqueta.

7.6.- Adaptación de dominio

Además de la transferencia directa, se probaron variantes de adaptación de dominio no supervisada. En todas ellas el origen etiquetado sigue siendo el simulador QRS/ST y los datos cedidos por el HUCA se usan como dominio objetivo sin etiquetas morfológicas. El objetivo no es convertir la cohorte real en un conjunto de entrenamiento clínico, sino reducir la discrepancia entre las representaciones aprendidas en imágenes sintéticas y las observadas en ECG reales.

El preentrenamiento autosupervisado usa SimCLR sobre imágenes sin etiquetas de los datos cedidos por el HUCA [34]. El encoder recibe dos vistas aumentadas de una misma imagen y aprende a acercar sus representaciones frente a otras imágenes del lote. Después, esos pesos inicializan la CNN supervisada sobre el simulador.

CORAL añade una pérdida que aproxima las covarianzas de las características fuente y destino, de modo que las activaciones de ambos dominios tengan estadísticas de segundo orden más parecidas [35]. MMD mide la discrepancia entre distribuciones de características mediante kernels RBF y penaliza que las medias embebidas de origen y destino permanezcan separadas [36]. DANN incorpora un clasificador de dominio y una capa de inversión de gradiente, de forma que el extractor aprende características útiles para la tarea supervisada pero poco informativas sobre si una imagen procede del simulador o de HUCA [33].

Método	Idea principal
SSL	Preentrenar el encoder con imágenes reales sin etiquetas mediante aprendizaje contrastivo.
CORAL	Alinear covarianzas de características entre simulador y HUCA.
MMD	Reducir una distancia de distribución con kernels RBF.
DANN	Aprender características invariantes al dominio con inversión de gradiente.

Tabla 7.2.- Métodos de adaptación de dominio evaluados para la CNN.

7.7.- Grad CAM

Grad CAM se utiliza como diagnóstico cualitativo, no como explicación clínica suficiente [32]. El mapa indica regiones que influyen en el logit del modelo, pero no prueba que la red haya aprendido un criterio médico correcto. En esta memoria se usa para comprobar si las activaciones se concentran en zonas plausibles del trazado y para detectar errores en los que una atención visual razonable termina en una decisión equivocada.




Figura 7.2.- Ejemplo Grad CAM del modelo CNN sobre el conjunto sintético.

7.8.- Qué se mide

La evaluación posterior mide tres cuestiones. La primera es si una CNN entrenada con pocos ejemplos aprende una regla visual en el simulador QRS/ST. La segunda es si ese modelo transferido desde el simulador mantiene utilidad cuando la etiqueta pasa a ser clínica y los ECG proceden de pacientes reales. La tercera es si la adaptación de dominio no supervisada reduce de forma apreciable esa brecha. Estas preguntas se analizan después en los dominios sintético y real.

8 Enfoque multimodal con VLM e ICL

El segundo enfoque usa un modelo de visión y lenguaje con aprendizaje en contexto. A diferencia de la CNN, el VLM no se entrena con los ejemplos del pliegue. Recibe la imagen objetivo dentro de un prompt y, cuando $K > 0$, observa antes algunas demostraciones etiquetadas. La hipótesis es que esas demostraciones ayudan a concretar la tarea sin modificar los pesos del modelo.

8.1.- Motivación

Los modelos supervisados necesitan suficientes datos etiquetados para ajustar sus parámetros con estabilidad. En una enfermedad rara, esa condición puede no cumplirse. El aprendizaje en contexto ofrece otra forma de usar ejemplos. No los convierte en gradientes, sino en una guía explícita para la inferencia.

No se da por hecho que esta vía sea mejor que la CNN. Se evalúa porque plantea una duda práctica. Si ya existe un modelo multimodal generalista ejecutable en local, ¿pueden unos pocos ejemplos orientar su lectura de un ECG como imagen? La respuesta solo tiene valor si se compara con la referencia supervisada y con una condición zero-shot.

8.2.- Modelos médicos, modelos cerrados y privacidad

En medicina han aparecido modelos multimodales cada vez más capaces, tanto generalistas como adaptados al dominio clínico. Una opción natural sería utilizar un modelo propietario servido por API, porque trabajos recientes han mostrado que los VLM pueden detectar ciertas anomalías en ECG tratados como imagen mediante aprendizaje en contexto [27]. Esa vía puede ser útil para demostrar viabilidad, pero no encaja del todo con el objetivo de esta memoria.

El caso de uso planteado trabaja con datos sanitarios. Aunque las imágenes estén seudonimizadas, proceden de pacientes y deben tratarse con prudencia. La evaluación prioriza modelos con pesos abiertos que puedan ejecutarse en local. Esta decisión evita enviar trazados a servicios externos, permite conservar el control sobre versiones y parámetros, y facilita

que otra persona reproduzca el protocolo sin depender de un proveedor cuyo modelo pueda cambiar.

8.3.- Modelo evaluado

El modelo evaluado es Gemma 4 [28]. La elección responde a criterios prácticos y metodológicos: es un VLM abierto de altas prestaciones, admite texto e imágenes, permite incluir varias imágenes en el mismo contexto y puede desplegarse en infraestructura local para inferencia. Estas propiedades son relevantes en un escenario hospitalario de investigación, donde interesa mantener los datos dentro de la infraestructura propia, controlar la versión del modelo y trabajar con un tamaño de inferencia razonable.

Gemma 4 no se utiliza porque exista una garantía previa de superioridad en ECG. Precisamente resulta útil porque permite probar si un modelo abierto y generalista puede aprovechar unos pocos ejemplos antes de entrenar un sistema especializado. Si obtiene señal útil, el aprendizaje en contexto puede servir como prueba inicial de viabilidad. Si no la obtiene, el resultado delimita cuándo hacen falta modelos adaptados al dominio o anotaciones clínicas más ricas.

8.4.- Construcción del prompt

La inferencia VLM se organiza siempre de la misma forma. Primero se seleccionan los pacientes que servirán como demostraciones, respetando que el paciente reservado para prueba no aparezca en el contexto. Después se construye un mensaje multimodal con una instrucción de sistema, las demostraciones disponibles y la imagen de consulta.




Figura 8.1.- Construcción del contexto en el enfoque VLM/ICL. Las demostraciones etiquetadas se incorporan al prompt antes de la imagen de consulta, y la predicción se obtiene sin actualizar los pesos del modelo.

Cada demostración contiene una imagen de ECG y la respuesta esperada en formato JSON. La imagen de consulta se coloca al final, después de las demostraciones. El modelo genera una respuesta textual, pero esa respuesta debe ajustarse al esquema definido. Si el formato no es válido, la predicción se registra como inválida en lugar de interpretarla a mano.

No se solicita una explicación libre obligatoria. El objetivo de esta evaluación no es producir informes clínicos, sino comparar decisiones binarias con la CNN. El formato cerrado reduce ambigüedades y evita que una respuesta verbalmente plausible se convierta en etiqueta por interpretación subjetiva.

8.5.- Condiciones de consulta

Se informan tres condiciones VLM. En *zero-shot*, el modelo recibe únicamente la imagen objetivo y las instrucciones. No se le enseña ningún ejemplo previo del conjunto. Esta condición mide qué hace Gemma 4 con su conocimiento previo y con la descripción textual de la tarea, sin ayuda local.

En ICL normal, el prompt incluye K demostraciones correctas tomadas del conjunto disponible. Cada demostración contiene una imagen de ECG y la respuesta JSON esperada. La selección no fuerza explícitamente la proporción entre positivos y negativos. Por tanto, refleja el contexto que aparece al seguir la estrategia estándar de muestreo del experimento.

En ICL balanceado, el prompt también incluye K demostraciones, pero la selección intenta mantener ejemplos positivos y negativos siempre que el pliegue lo permite. Esta condición permite estudiar si un contexto con más presencia de casos Brugada desplaza la decisión hacia una lectura más sensible. En triaje, aumentar la sensibilidad puede ser valioso porque reduce los positivos no detectados. Al mismo tiempo, puede bajar la especificidad y aumentar las alertas innecesarias.

8.6.- Origen del contexto

En el simulador, las demostraciones y la imagen de consulta pertenecen al mismo dominio morfológico. Con los datos cedidos por el HUCA se informan dos usos distintos del contexto. El primero usa ejemplos de la cohorte real como demostraciones y una imagen real V2 como consulta. Esta es la comparación clínica principal, porque el contexto y la consulta comparten dominio visual y etiqueta clínica.

El segundo usa el simulador como contexto etiquetado y consulta imágenes de la cohorte real. En esa rama, el modelo recibe demostraciones con etiquetas morfológicas sintéticas y debe transferir ese criterio a imágenes reales. No se considera una solución clínica, sino un

control de transferencia sintético-real. Su valor está en comprobar si el contexto generado por el simulador basta para orientar al VLM cuando cambia el dominio de la imagen y la referencia de evaluación pasa a ser clínica.

La comparación con la CNN se hace siempre a nivel de paciente y con las mismas métricas. La diferencia está en el modo de utilizar K : la CNN aprende pesos con esos pacientes y el VLM los usa como contexto.

9 Resultados sintéticos

El simulador QRS/ST es el dominio controlado del estudio. La etiqueta positiva está definida por construcción: RBBB, elevación ST e inversión de T deben aparecer simultáneamente. Por tanto, este capítulo no pretende demostrar utilidad clínica, sino comprobar si los dos enfoques recuperan una regla visual conocida cuando el ECG se representa como imagen.

La lectura se organiza de forma paralela a la evaluación real. Primero se presentan los resultados de la CNN, después Gemma 4 con aprendizaje en contexto y, finalmente, la comparación directa entre ambos enfoques. Las tablas del cuerpo recogen los puntos principales. Las tablas completas por K quedan en el apéndice B.

9.1.- CNN en el simulador

La CNN aprende de forma progresiva a medida que aumenta K . Con pocos ejemplos ya supera el azar, pero el salto más claro aparece cuando el entrenamiento dispone de 16 o 32 pacientes etiquetados por pliegue.

K	BA	F1	Sens.	Esp.	ROC AUC
2	$0,625 \pm 0,022$	0,401	0,650	0,600	0,520
4	$0,631 \pm 0,042$	0,407	0,617	0,646	0,566
8	$0,685 \pm 0,023$	0,468	0,683	0,688	0,629
16	$0,773 \pm 0,013$	0,569	0,800	0,746	0,755
32	$0,848 \pm 0,030$	0,673	0,883	0,812	0,857

Tabla 9.1.- Resultados CNN ResNet18 sobre el conjunto sintético QRS/ST. Las cifras son medias sobre tres semillas.




Figura 9.1.- Exactitud equilibrada de la CNN sobre el conjunto sintético según K . Los puntos muestran la media de tres semillas y las barras la desviación estándar.

El mejor punto de la CNN aparece en $K = 32$, con 0,848 de exactitud equilibrada, sensibilidad 0,883 y especificidad 0,812. La matriz agregada de ese punto contiene 53 verdaderos positivos, 195 verdaderos negativos, 45 falsos positivos y 7 falsos negativos.




Figura 9.2.- Matriz de confusión agregada de la CNN en el conjunto sintético para $K = 32$, acumulando las tres semillas.


9.2.- VLM e ICL en el simulador

Gemma 4 parte de una condición zero-shot poco útil para esta tarea. Predice todos los casos como negativos y obtiene una exactitud equilibrada de 0,500. Al añadir demostracio-

nes, el comportamiento cambia de forma clara: el modelo empieza a recuperar positivos y la exactitud equilibrada sube hasta valores propios de un clasificador visual razonable, aunque por debajo del mejor punto de la CNN.

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	0,500	0,000	0,000	1,000
ICL normal	16	0,750	0,529	0,817	0,683
ICL balanceado	8	0,754	0,511	0,950	0,558

Tabla 9.2.- Puntos principales de Gemma 4 en el simulador QRS/ST. Las cifras son medias sobre tres semillas.




(a) Exactitud equilibrada.

(b) F1.

Figura 9.3.- Curvas VLM/ICL de Gemma 4 en el simulador QRS/ST. Los puntos muestran la media de tres semillas y las barras la desviación estándar.

El ICL normal alcanza su mejor punto en $K = 16$, con 0,750 de exactitud equilibrada. El ICL balanceado obtiene el máximo VLM con 0,754 en $K = 8$. La diferencia entre ambos no está solo en la métrica principal: el contexto balanceado aumenta mucho la sensibilidad, pero paga ese aumento con menor especificidad.


(a) ICL normal, $K = 16$.(b) ICL balanceado, $K = 8$.**Figura 9.4.-** Matrices de confusión agregadas de Gemma 4 en el simulador para los dos puntos principales de ICL, acumulando las tres semillas.

9.3.- Comparación entre enfoques

La comparación directa muestra una lectura equilibrada. En el simulador, la CNN aprovecha mejor el aumento de ejemplos y alcanza el mejor rendimiento global. El VLM, sin entrenar pesos, transforma una condición zero-shot inútil en un clasificador razonable cuando recibe demostraciones.

Método	K	BA	F1	Sens.	Esp.
CNN ResNet18	32	0,848	0,673	0,883	0,812
Gemma 4 zero-shot	0	0,500	0,000	0,000	1,000
Gemma 4 ICL normal	16	0,750	0,529	0,817	0,683
Gemma 4 ICL balanceado	8	0,754	0,511	0,950	0,558

Tabla 9.3.- Comparación principal en el simulador QRS/ST.



(a) Exactitud equilibrada.

(b) F1.

Figura 9.5.- Comparación gráfica entre CNN, ICL normal e ICL balanceado en el simulador QRS/ST. Las curvas usan las mismas métricas y los mismos valores de K para los tres enfoques.

La CNN demuestra que, cuando la tarea está bien alineada con la imagen y hay suficientes ejemplos por pliegue, el entrenamiento supervisado extrae una señal estable. Por su parte, el VLM muestra que, incluso sin ajuste de pesos, las demostraciones visuales pueden desplazar la relación entre sensibilidad y especificidad. En un escenario de pocos datos, esta propiedad plantea una vía intermedia entre zero-shot y entrenamiento completo, con menor necesidad de adaptar el modelo a cada conjunto local.

9.4.- Lectura del dominio sintético

El resultado del simulador es favorable para ambos enfoques, aunque con ventaja cuantitativa para la CNN. No debe trasladarse directamente a clínica. El simulador es limpio, sus etiquetas están separadas por diseño y sus imágenes no incluyen toda la variabilidad de un ECG real. Su valor está en mostrar que la formulación visual funciona y en ofrecer un punto de comparación controlado para interpretar después la adaptación al dominio clínico.

10 Resultados de la transición al dominio real

El capítulo anterior presentó el primer escalón de la evaluación, compuesto únicamente por imágenes sintéticas del simulador QRS/ST. En ese entorno, la etiqueta está definida por reglas morfológicas y la tarea permite comprobar si los modelos recuperan una señal visual controlada. Este capítulo avanza hacia el dominio clínico de forma gradual.

La lectura se ordena de lo más sintético a lo más real. Primero se describe la cohorte cedida por el Hospital Universitario Central de Asturias, ya que es el destino común de las pruebas clínicas. Después se presentan dos controles de transferencia sintético-real: adaptación de dominio de la CNN usando los datos reales sin etiquetas morfológicas e ICL de Gemma 4 con contexto procedente del simulador. Por último se presenta la comparación principal sobre los ECG reales, formada por la CNN entrenada con el simulador y evaluada sobre la cohorte clínica, y Gemma 4 con demostraciones tomadas de esa misma cohorte.

10.1.- Datos cedidos por el HUCA y etiqueta clínica

El bloque real usa ECG cedidos por el Hospital Universitario Central de Asturias dentro del recurso Brugada HUCA [39]. A partir de 363 pacientes, el procesado excluye 46 registros con patrón basal limítrofe y conserva un conjunto final de 317 pacientes, formado por 116 casos Brugada confirmados y 201 controles. Para cada paciente se generan imágenes de V1, V2 y V3.


Grupo	Pacientes	Imágenes
Brugada confirmado	116	348
Control	201	603
Excluido por patrón basal limítrofe	46	–
Total evaluado	317	951

Tabla 10.1.- Datos cedidos por el HUCA utilizados en la evaluación real.

La preparación selecciona las derivaciones precordiales derechas, detecta un latido central y recorta una ventana de 300 ms antes de R y 600 ms después de R. Cada imagen queda

asociada a su paciente, derivación, etiqueta clínica y pliegue de evaluación.

Preparación de Brugada-HUCA



La etiqueta QRS/ST real no se inventa: HUCA aporta clinical_brugada para evaluar la regla final derivada.

Esto separa el detector morfológico entrenado en sintético de la referencia clínica usada para triaje y auditoría patient-level.

Figura 10.1.- Preprocesamiento de los ECG cedidos por el HUCA para V1, V2 y V3.

La etiqueta disponible no equivale a las tres etiquetas morfológicas utilizadas en el simulador. Los datos cedidos por el HUCA no incorporan anotaciones independientes para RBBB, elevación ST e inversión de T por imagen. La tarea real se formula por tanto como caso Brugada confirmado frente a control, y sus conclusiones se limitan a priorización para revisión especializada.

10.2.- Controles de transferencia sintético-real

Antes de comparar los métodos principales sobre los ECG reales, se evalúa si la información sintética puede reducir por sí sola la brecha de dominio. Esta parte incluye dos controles complementarios. El primero mantiene la CNN como modelo supervisado y añade adaptación de dominio usando los datos reales sin etiquetas morfológicas. El segundo mantiene Gemma 4 sin ajuste de pesos y le proporciona demostraciones del simulador antes de consultar imágenes reales.

10.2.1.- Adaptación de dominio en la CNN

En estos experimentos, el simulador sigue siendo el origen etiquetado. Los datos cedidos por el HUCA se usan solo como dominio objetivo no etiquetado. La pérdida supervisada nunca utiliza etiquetas morfológicas procedentes de la cohorte real. Esta restricción conserva la validez metodológica del experimento y evita convertir clinical_brugada en una etiqueta morfológica que no existe.

Método	K	BA	F1	Sens.	Esp.
Base	16	$0,516 \pm 0,023$	0,480	0,658	0,375
SSL	16	$0,477 \pm 0,027$	0,458	0,658	0,297
CORAL	16	$0,524 \pm 0,008$	0,481	0,641	0,408
MMD	16	$0,516 \pm 0,019$	0,474	0,635	0,396
DANN	16	$0,515 \pm 0,019$	0,470	0,621	0,410
Base	32	$0,499 \pm 0,012$	0,466	0,644	0,355
SSL	32	$0,503 \pm 0,014$	0,476	0,672	0,333
CORAL	32	$0,528 \pm 0,013$	0,480	0,632	0,423
MMD	32	$0,549 \pm 0,029$	0,498	0,649	0,448
DANN	32	$0,509 \pm 0,028$	0,472	0,644	0,375

Tabla 10.2.- Resultados de adaptación de dominio de la CNN usando los datos cedidos por el HUCA como dominio objetivo no etiquetado.

La mejora es modesta. CORAL mejora la especificidad frente a la base en $K = 16$ y $K = 32$. MMD ofrece el mejor punto de esta batería, con BA 0,549 en $K = 32$, F1 0,498, sensibilidad 0,649 y especificidad 0,448. Aun así, el rendimiento sigue lejos de una separación robusta. La adaptación reduce parcialmente la brecha, pero no elimina la discrepancia entre la morfología sintética aprendida y la etiqueta clínica real.

10.2.2.- ICL con contexto del simulador

Como análisis complementario de transferencia, se usaron demostraciones procedentes del simulador y consultas sobre la cohorte clínica cedida por el HUCA. Esta condición no constituye la comparación clínica principal. Su objetivo es medir si unas demostraciones morfológicas sintéticas bastan para orientar al VLM cuando cambia el dominio de la imagen y la referencia de evaluación pasa a ser clínica.

El modelo predice primero RBBB, elevación ST e inversión de T, deriva la decisión Brugada mediante la regla de los tres hallazgos y compara esa salida con la referencia clínica disponible. El resultado es marcadamente negativo. Zero-shot queda en BA 0,500, F1 0,000, sensibilidad 0,000 y especificidad 1,000. Con demostraciones sintéticas, casi todos los valores de K permanecen alrededor de BA 0,500. El mejor punto de esta condición, ICL balanceado con $K = 32$, solo alcanza BA 0,505, F1 0,022, sensibilidad 0,011 y especificidad 0,998. En términos prácticos, Gemma 4 mantiene un patrón de predicción casi siempre colapsado hacia la clase negativa.

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	0,500	0,000	0,000	1,000
ICL normal	16	0,501	0,006	0,003	0,998
ICL normal	32	0,500	0,006	0,003	0,997
ICL balanceado	8	0,501	0,006	0,003	1,000
ICL balanceado	32	0,505	0,022	0,011	0,998

Tabla 10.3.- Puntos principales de Gemma 4 con contexto sintético y consulta sobre los datos reales cedidos por el HUCA. Las cifras son medias sobre tres semillas.




Figura 10.2.- Controles de transferencia sintético-real. La parte izquierda resume la adaptación de dominio de la CNN y la parte derecha resume Gemma 4 con demostraciones sintéticas antes de consultar imágenes reales.




Figura 10.3.- Matriz de confusión agregada de Gemma 4 con contexto sintético balanceado, $K = 32$, y consulta sobre los datos reales cedidos por el HUCA.

Los dos controles apuntan a la misma lectura. La información sintética ayuda a estudiar una regla visual controlada, pero no basta por sí sola para trasladar el criterio al dominio clínico. En la CNN, la alineación de representaciones produce una mejora limitada. En el VLM, las demostraciones sintéticas apenas modifican el régimen de predicción.

10.3.- Evaluación directa con los datos cedidos por el HUCA

El último escalón utiliza los datos reales como referencia de evaluación principal. La CNN no se entrena de forma supervisada con la cohorte real, porque su cabeza multietiqueta exige anotaciones de RBBB, elevación ST e inversión de T que no están disponibles. Gemma 4 sí puede recibir demostraciones de la propia cohorte, porque el aprendizaje en contexto usa ejemplos etiquetados dentro del prompt sin modificar pesos.

10.3.1.- CNN transferida desde el simulador

La evaluación principal de CNN mide transferencia sintético-real directa. Los K pacientes usados para actualizar pesos proceden del simulador QRS/ST. La prueba se realiza con la cohorte real cedida por el HUCA y la decisión final se compara con `clinical_brugada`. En esta configuración, la CNN no reproduce el comportamiento observado en el simulador. Su mejor punto aparece en $K = 16$, con 0,516 de exactitud equilibrada, sensibilidad 0,658 y especificidad 0,375.

K	BA	F1	Sens.	Esp.	ROC AUC
2	$0,509 \pm 0,010$	0,484	0,693	0,325	0,525
4	$0,509 \pm 0,023$	0,493	0,730	0,289	0,495
8	$0,490 \pm 0,018$	0,469	0,672	0,308	0,496
16	$0,516 \pm 0,023$	0,480	0,658	0,375	0,569
32	$0,499 \pm 0,012$	0,466	0,644	0,355	0,491

Tabla 10.4.- Resultados CNN ResNet18 entrenada con simulador y evaluada con los datos cedidos por el HUCA. Las cifras son medias sobre tres semillas.




Figura 10.4.- Exactitud equilibrada de la CNN base evaluada con los datos cedidos por el HUCA según K . Los puntos muestran la media de tres semillas y las barras la desviación estándar.

La matriz agregada para $K = 16$, con 229 verdaderos positivos, 226 verdaderos negativos, 377 falsos positivos y 119 falsos negativos, evidencia el problema central. La CNN recupera una parte importante de los positivos, pero marca demasiados controles.




Figura 10.5.- Matriz de confusión agregada de la CNN evaluada con los datos cedidos por el HUCA para $K = 16$, acumulando las tres semillas.

10.3.2.- Gemma 4 con contexto real


El VLM se comporta de forma distinta a la CNN. En zero-shot, Gemma 4 tiende a una decisión casi monoclasa y clasifica la práctica totalidad de las imágenes como controles, por lo que conserva una especificidad muy alta, 0,993, pero deja la sensibilidad en 0,023. Este comportamiento no debe interpretarse como evidencia de ausencia de señal en el ECG, sino como una limitación del modelo para fijar la frontera de decisión clínica sin ejemplos locales.

Al añadir demostraciones tomadas de la propia cohorte cedida por el HUCA, el régimen de predicción cambia. El modelo empieza a aceptar con mucha más frecuencia la clase positiva y la sensibilidad aumenta de forma marcada. Con $K = 16$, el ICL normal alcanza BA 0,522, sensibilidad 0,690 y especificidad 0,355, mientras que el ICL balanceado mantiene una BA muy parecida, 0,522, pero sube la sensibilidad a 0,713 y baja la especificidad a 0,332. Por tanto, el contexto no resuelve el problema clínico, pero sí resulta informativo. Unos pocos ejemplos modifican de forma consistente el criterio de decisión frente al colapso conservador del zero-shot.

En las tablas completas, la denominación V2 real identifica este bloque de evaluación con Gemma 4 sobre la imagen de la derivación V2 de cada paciente. Se informa así porque el experimento VLM sobre datos reales utiliza V2 como derivación de consulta principal, manteniendo la etiqueta clínica por paciente.

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	0,508	0,044	0,023	0,993
ICL normal	16	0,522	0,491	0,690	0,355
ICL balanceado	16	0,522	0,496	0,713	0,332
ICL balanceado	32	0,521	0,484	0,658	0,385

Tabla 10.5.- Puntos principales de Gemma 4 con contexto real tomado de los datos cedidos por el HUCA. Las cifras son medias sobre tres semillas.



(a) Exactitud equilibrada.

(b) F1.

Figura 10.6.- Curvas VLM/ICL de Gemma 4 con consulta V2 y contexto real tomado de los datos cedidos por el HUCA. Los puntos muestran la media de tres semillas y las barras la desviación estándar.

Las matrices de confusión muestran el cambio de régimen al introducir ejemplos. Gemma 4 pasa de un zero-shot conservador, prácticamente colapsado hacia la clase negativa, a una configuración que detecta más casos, pero también desplaza numerosos controles hacia la clase positiva.


(a) ICL normal, $K = 16$.(b) ICL balanceado, $K = 16$.

Figura 10.7.- Matrices de confusión agregadas de Gemma 4 con contexto real para los dos puntos principales de ICL.





Figura 10.8.- Sensibilidad y especificidad de Gemma 4 según el origen del contexto. El contexto real cambia el régimen de predicción, mientras que el contexto sintético conserva una especificidad casi perfecta y apenas recupera positivos.

10.4.- Comparación clínica principal

La comparación principal queda muy ajustada en exactitud equilibrada. La CNN base alcanza 0,516 en $K = 16$, Gemma 4 con ICL normal llega a 0,522 en el mismo valor de K y el ICL balanceado mantiene 0,522. La diferencia relevante está en sensibilidad y especificidad. Como resultado complementario, MMD con $K = 32$ sube a 0,549 de BA, aunque no cambia la conclusión global sobre falta de robustez.

Método	K	BA	F1	Sens.	Esp.
CNN ResNet18 base	16	0,516	0,480	0,658	0,375
CNN MMD	32	0,549	0,498	0,649	0,448
Gemma 4 zero-shot	0	0,508	0,044	0,023	0,993
Gemma 4 ICL normal	16	0,522	0,491	0,690	0,355
Gemma 4 ICL balanceado	16	0,522	0,496	0,713	0,332
Gemma 4 contexto sintético	32	0,505	0,022	0,011	0,998

Tabla 10.6.- Puntos relevantes sobre los ECG reales cedidos por el HUCA.



(a) Exactitud equilibrada.

(b) F1.

Figura 10.9.- Comparación gráfica entre CNN base, ICL normal e ICL balanceado con los datos cedidos por el HUCA y contexto real para Gemma 4.

En un sistema de triaje, la sensibilidad tiene un peso especial. Un falso negativo puede retrasar la revisión de un paciente que quizá necesite reposicionamiento de derivaciones o prueba farmacológica. El aumento de sensibilidad del ICL balanceado frente a la CNN base, 0,713 frente a 0,658, es por tanto un resultado relevante. La otra mitad de la lectura es igual de necesaria, porque la especificidad baja de 0,375 en la CNN base a 0,332 con ICL balanceado y esa caída significa más alertas sobre controles.





Figura 10.10.- Sensibilidad y especificidad de los puntos principales con los datos cedidos por el HUCA. La figura resume el compromiso clínico entre recuperar positivos y evitar alertas sobre controles.

El VLM aporta una señal interesante para priorización cuando dispone de contexto real, pero no una herramienta asistencial fiable con los datos actuales. La adaptación de dominio de la CNN mejora parcialmente algunos puntos, aunque todavía con métricas propias de un prototipo exploratorio. El contexto sintético del VLM confirma que las demostraciones del simulador no bastan para trasladar el criterio al dominio clínico.

10.5.- Brecha integrada entre simulador y dominio clínico

La brecha de dominio afecta a los dos enfoques. En la CNN, la exactitud equilibrada crece en el simulador hasta 0,848 con $K = 32$, mientras que en los ECG reales se mantiene alrededor de 0,50 antes de la adaptación. En el VLM ocurre una compresión similar. El ICL normal alcanza 0,750 en el simulador con $K = 16$, pero baja a 0,522 con contexto real y se queda en torno a 0,500 cuando el contexto procede del simulador.



(a) Exactitud equilibrada.

(b) F1.

Figura 10.11.- Brecha sintético-real de la CNN base. Las líneas continuas corresponden al simulador y las discontinuas a los datos cedidos por el HUCA.




Figura 10.12.- Brecha sintético-real de Gemma 4 para exactitud equilibrada. Se comparan simulador, contexto real de los datos cedidos por el HUCA y contexto sintético del simulador.




Figura 10.13.- Brecha sintético-real de Gemma 4 para F1. Se comparan simulador, contexto real de los datos cedidos por el HUCA y contexto sintético del simulador.

Las gráficas muestran que el simulador separa mejor la tarea para ambos paradigmas, pero esa ventaja no se conserva cuando la etiqueta pasa a ser clínica. Las causas plausibles incluyen ruido y variabilidad de adquisición, diferencias de escala, presencia de fenotipos diversos, etiqueta clínica no reducible a una sola ventana de ECG y ausencia de anotaciones morfológicas finas. El resultado no invalida el simulador. Delimita su función como banco controlado y muestra que el problema real exige más información que una imagen aislada.

10.6.- Lectura final

Los datos reales muestran que el ECG como imagen contiene información, pero también que pocos ejemplos y una etiqueta clínica compleja no bastan para sostener una clasificación robusta. En ese escenario, la CNN ofrece una referencia supervisada transferida desde el simulador, la adaptación de dominio mide cuánto puede reducirse la brecha sin etiquetas morfológicas reales y el VLM permite explotar ejemplos de la cohorte clínica sin entrenamiento adicional.

La utilidad inmediata de esta comparación es metodológica. Permite saber dónde falla cada enfoque y muestra que, para avanzar, harían falta más casos positivos, anotaciones morfológicas clínicas, validación externa y una evaluación prospectiva diseñada desde el circuito asistencial.

11 Conclusiones generales

11.1.- Conclusión principal

El TFG partía de una pregunta concreta: cómo aprovechar pocos pacientes etiquetados cuando el ECG disponible es una imagen y no la señal digital original. Para responderla se han comparado dos enfoques. El primero es una CNN que convierte los ejemplos en entrenamiento y ajusta pesos específicos para la tarea. El segundo es un VLM que utiliza esos mismos ejemplos como contexto sin modificar sus parámetros. Esta diferencia organiza la lectura de los resultados y permite estudiar dos formas de incorporar conocimiento local con K reducido.

Los resultados deben leerse en tres escalones. El primero es puramente sintético. En el simulador QRS/ST, tanto la CNN como el VLM encuentran señal visual porque la etiqueta está definida por reglas morfológicas. La ResNet18 mejora de forma progresiva hasta alcanzar una exactitud equilibrada de 0,848 con $K = 32$. Gemma 4 también mejora al recibir demostraciones y llega a 0,754 con contexto balanceado en $K = 8$ y a 0,750 con ICL normal en $K = 16$. En un dominio limpio, con imágenes homogéneas y etiquetas separadas por construcción, ambos paradigmas aprenden una relación útil entre morfología y etiqueta.

El segundo escalón analiza la transferencia sintético-real antes de presentar la comparación clínica principal. En la CNN, la adaptación de dominio usa el simulador como origen etiquetado y los datos cedidos por el HUCA como dominio objetivo no etiquetado. Las mejoras son limitadas. MMD con $K = 32$ llega a 0,549 de exactitud equilibrada, sensibilidad 0,649 y especificidad 0,448. Este resultado sugiere una reducción parcial de la brecha, pero no una solución robusta. En el VLM, el control con demostraciones sintéticas resulta todavía más restrictivo. Al usar contexto procedente del simulador y consultar imágenes reales, casi todos los valores de K quedan alrededor de 0,500 de exactitud equilibrada. El mejor punto, ICL balanceado con $K = 32$, solo alcanza BA 0,505, F1 0,022, sensibilidad 0,011 y especificidad 0,998. En la práctica, el modelo permanece casi siempre colapsado hacia la clase negativa.

El tercer escalón corresponde a la evaluación directa con los datos reales cedidos por el HUCA. No se entrenó una CNN supervisada real-real con esa cohorte, porque la arquitectura estaba definida para tres etiquetas morfológicas y la referencia disponible es `clinical_brugada`. La evaluación de la CNN mide, por tanto, transferencia desde el simulador hacia una referencia clínica. En esa configuración, la red se mantiene cerca del azar y su mejor punto base alcanza 0,516 de exactitud equilibrada con $K = 16$, sensibilidad

0,658 y especificidad 0,375.

El VLM tampoco resuelve la tarea clínica, aunque su comportamiento es relevante. En zero-shot colapsa prácticamente hacia una única clase, con sensibilidad 0,023 y especificidad 0,993. Al introducir unos pocos ejemplos tomados de la cohorte real, el modelo abandona esa decisión conservadora y aumenta la detección de positivos. Con $K = 16$, el ICL normal llega a 0,522 de exactitud equilibrada, sensibilidad 0,690 y especificidad 0,355. El ICL balanceado mantiene 0,522 de exactitud equilibrada y eleva la sensibilidad a 0,713, aunque reduce la especificidad a 0,332.

Estos resultados permiten afirmar, con prudencia, que el ICL ha sido efectivo en sentido metodológico. No ofrece una solución clínica robusta, pero sí demuestra que las demostraciones modifican de forma útil el régimen de predicción frente al zero-shot. Esta lectura es coherente con trabajos recientes que estudian el aprendizaje en contexto multimodal y su aplicación a ECG como imagen [24, 27, 25, 26]. A la vez, la caída de especificidad impide interpretar la mejora de sensibilidad como una validación asistencial. En triaje de Brugada, no perder casos sospechosos es importante, pero demasiadas alertas sobre controles pueden saturar la revisión especializada y reducir la confianza del circuito clínico.

11.2.- Aportaciones

La primera aportación es un protocolo completo para estudiar ECG como imagen en un escenario de pocos datos. El trabajo incluye generación sintética, preprocesamiento de datos reales, separación por paciente, agregación de derivaciones, selección de umbral y métricas por semilla.

La segunda aportación es ordenar la evaluación desde un banco controlado hasta una cohorte clínica. El simulador permite comprobar si los modelos aprenden una regla visual conocida. Los controles de transferencia muestran cuánto de esa regla se conserva cuando cambia el dominio. La comparación final con los datos cedidos por el HUCA delimita el rendimiento frente a una referencia clínica real.

La tercera aportación es comparar directamente entrenamiento supervisado y aprendizaje en contexto. La CNN usa los K ejemplos para ajustar pesos y necesita repetir el entrenamiento cuando cambia el conjunto de referencia. Con los datos cedidos por el HUCA, además, no puede ajustarse con supervisión morfológica real sin nuevas anotaciones. El VLM incorpora los ejemplos como contexto sin modificar parámetros, lo que facilita su traslado entre evaluaciones y permite probarlo con mayor rapidez en escenarios con pocos datos. El experimento muestra que esta diferencia afecta a la relación entre sensibilidad y especificidad, pero no elimina la dificultad de fondo cuando la etiqueta real es clínica, el número de positivos es pequeño y la variabilidad morfológica es alta.

La cuarta aportación es documentar la brecha sintético-real con controles complementarios. La adaptación de dominio en la CNN y el VLM con contexto sintético apuntan a la misma conclusión. El simulador es útil para estudiar una regla visual controlada, pero sus ejemplos no bastan por sí solos para resolver una tarea clínica con los datos reales disponibles. Esta lectura evita sobreinterpretar los buenos resultados sintéticos.

La quinta aportación es delimitar el papel clínico del sistema. La memoria presenta un prototipo de investigación orientado a priorizar revisión, no un mecanismo de diagnóstico automático. Esta distinción es importante porque el diagnóstico de Brugada exige ECG completo, contexto clínico, valoración especializada y, en pacientes seleccionados, prueba farmacológica. Ningún resultado de este TFG sustituye ese circuito.

11.3.- Limitaciones

La limitación principal es el tamaño y la naturaleza de los datos reales. La etiqueta disponible, `clinical_brugada`, no se acompaña de anotaciones independientes para RBBB, elevación ST e inversión de T en cada imagen. Por tanto, la tarea real mezcla morfología visible, historia clínica y proceso diagnóstico, de modo que una sola ventana de V2, o incluso las tres derivaciones precordiales derechas, no contienen toda esa información. Esta es también la razón por la que no se entrenó una CNN supervisada real-real con la arquitectura morfológica actual.

La segunda limitación es la brecha entre simulador y práctica clínica. El simulador permite estudiar el aprendizaje en un entorno controlado, pero sus imágenes son más limpias y sus etiquetas están más separadas que las de un ECG real. El buen rendimiento sintético no debe interpretarse como evidencia clínica. La adaptación de dominio y el contexto sintético en VLM muestran que esa brecha no desaparece con alineaciones simples ni con demostraciones sintéticas.

La tercera limitación afecta al VLM. La evaluación final se centra en Gemma 4 y no permite comparar de forma concluyente familias de modelos médicos y generalistas. Además, el ICL depende del prompt, del orden de las demostraciones, de la selección de ejemplos, de la ventana de contexto y del coste de inferencia. La literatura reciente también recomienda cautela, ya que parte del rendimiento del ICL multimodal puede depender más del texto de las demostraciones que de su contenido visual [25], y su eficacia varía con la recuperación, el orden y la construcción del prompt [26].

La cuarta limitación es el estado actual de los modelos generalistas para ECG. Aunque ya existen modelos abiertos especializados en interpretación de ECG como imagen que superan a VLM generalistas en varios bancos de prueba [21], las evaluaciones recientes de modelos generalistas de visión y lenguaje en ECG reales muestran sensibilidad baja, acuerdo limitado

con expertos y rendimiento todavía insuficiente para despliegue clínico [22]. Este TFG se sitúa en esa misma frontera. La adaptación por contexto aporta señal, pero no sustituye a modelos validados para una tarea clínica concreta.

11.4.- Trabajo futuro

El siguiente paso no debería ser simplemente entrenar más variantes del mismo modelo. Harían falta anotaciones morfológicas clínicas independientes, de modo que el sistema pudiera aprender y evaluarse sobre rasgos visibles concretos antes de intentar una etiqueta clínica compuesta. También sería necesario ampliar el número de casos positivos, documentar de forma explícita qué pacientes fueron confirmados mediante prueba farmacológica y analizar si el rendimiento cambia en ese subgrupo.

Otra línea necesaria es la validación externa. Un modelo entrenado y evaluado en un único origen puede aprender propiedades del centro, del equipo o del renderizado. Antes de plantear cualquier uso asistencial habría que probarlo con datos de otro hospital, con otro flujo de adquisición y con revisión experta de errores.

Por último, la comparación entre CNN e ICL debe incorporar coste y facilidad de traslado. Una CNN ligera puede ser atractiva aunque su rendimiento sea modesto, porque su inferencia es rápida y barata una vez entrenada, pero exige un ciclo de ajuste cuando cambian los datos o la definición de la tarea. Un VLM puede probarse sin entrenamiento adicional y trasladarse con más facilidad a otra evaluación, aunque cada consulta es más costosa y depende de la calidad del contexto. En un sistema de triaje real, la decisión no dependería solo de una métrica, sino del equilibrio entre sensibilidad, especificidad, latencia, coste y supervisión humana.

Esta comparación abre una línea más amplia de inteligencia portable. Los modelos fundacionales médicos aspiran a reutilizar conocimiento en múltiples tareas con pocos datos etiquetados o sin ajuste específico [30]. En ECG, esa trayectoria podría permitir sistemas locales que ayuden a priorizar trazados, apoyar segundas lecturas, preparar auditorías retrospectivas o explorar cohortes raras sin reentrenar un modelo desde cero para cada hospital. Para que esa promesa sea clínicamente aceptable, deberá combinarse con validación externa, control de sesgos, trazabilidad de versiones y evaluación prospectiva.

11.5.- Cierre

En conjunto, el ECG como imagen contiene señal útil y merece estudiarse, sobre todo cuando no se dispone de la señal digital original. El zero-shot de un VLM generalista no

basta para una tarea clínica estrecha y puede colapsar hacia una clase. Sin embargo, unos pocos ejemplos en contexto cambian ese comportamiento y permiten una generalización mejor, aunque todavía insuficiente para uso asistencial. La aportación principal no es proponer un diagnóstico automático, sino mostrar que el ICL puede actuar como una forma inicial de adaptación portable. Con el desarrollo acelerado de la IA, de los modelos abiertos y del acceso al cómputo local, esta línea resulta prometedora para investigación, triaje y apoyo a la revisión experta en escenarios donde reentrenar no siempre es viable.

12 Aspectos éticos y protección de datos

12.1.- Aspectos éticos

El trabajo tiene carácter retrospectivo y metodológico. Su finalidad es comparar enfoques de aprendizaje con pocos datos etiquetados sobre imágenes de ECG, no automatizar decisiones asistenciales ni sustituir la revisión clínica. Cualquier predicción debe interpretarse como una señal experimental de priorización, nunca como diagnóstico, descarte de enfermedad o recomendación terapéutica.

La principal precaución ética es evitar conclusiones clínicas que el diseño no puede sostener. El síndrome de Brugada requiere valoración especializada, contexto clínico y, en pacientes seleccionados, pruebas complementarias. Por tanto, las métricas obtenidas en esta memoria solo describen el comportamiento de los modelos dentro de los datos y protocolos empleados.

Esta cautela se aplica de forma especial al enfoque VLM/ICL. Que un modelo modifique su decisión al recibir ejemplos no equivale a competencia clínica autónoma. En este trabajo, la mejora frente al zero-shot se interpreta como señal metodológica de adaptación al contexto, no como autorización para usar el sistema sin revisión profesional.

La misma cautela se aplica a la adaptación de dominio de la CNN. Una mejora modesta al usar los datos cedidos por el HUCA sin etiquetas morfológicas no constituye validación clínica. Solo indica que ciertas alineaciones de representación pueden reducir parcialmente la brecha entre simulador y datos reales.

También debe considerarse el posible sesgo de selección. El conjunto real procede de un recurso concreto y el tamaño de positivos es limitado. La ausencia de análisis por subgrupos no implica ausencia de sesgo, sino falta de tamaño suficiente para estudiarlo con garantías. Una extensión clínica exigiría validación externa, evaluación prospectiva y supervisión profesional.

12.2.- Protección de datos

Los datos de salud son una categoría especial según el artículo 9 del Reglamento General de Protección de Datos [43]. Su tratamiento exige una base jurídica adecuada, minimización

de datos, limitación de finalidad, confidencialidad y medidas de seguridad proporcionadas al riesgo. Para investigación científica, el artículo 89 exige salvaguardias técnicas y organizativas.

En España, la Ley Orgánica 3/2018 completa este marco y regula garantías para tratamientos con fines de investigación, especialmente cuando se trabaja con datos seudonimizados [44]. La Ley 14/2007 de Investigación biomédica añade principios de confidencialidad, control ético y protección de las personas participantes [45].

El recurso Brugada HUCA se publica sin información identificativa y declara anonimización mediante Safe Harbor [39]. Aun así, las imágenes derivadas de ECG deben tratarse con prudencia: solo deben conservarse los campos necesarios para el análisis, evitar identificadores directos en materiales de difusión y mantener los datos en entornos controlados. Si se incorporasen datos adicionales no anónimos, habría que revisar la base jurídica y realizar una evaluación de impacto antes del tratamiento.

A Configuración experimental

Este apéndice recoge los parámetros principales de la configuración experimental. Se incluyen los valores necesarios para interpretar los resultados y comparar los enfoques CNN y VLM/ICL.

A.1.- Conjunto sintético QRS/ST

Propiedad	Valor
Fuente	Simulador QRS/ST descrito en el capítulo 5
Pacientes	100
Imágenes	300
Familias fuente	NORMAL, RBBB, ST_ELEVATION, T_WAVE_INVERSION, COMBINED_QRS_ST
Pacientes por familia	20
Derivaciones renderizadas	V1, V2 y V3
Frecuencia de muestreo	500 Hz
Duración del beat	900 ms
Resolución de guardado	130 ppp
Positivos derivados	20
Negativos o incompletos	80
Valores de K	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026

Tabla A.1.- Configuración del conjunto sintético final.

La etiqueta positiva se obtiene cuando RBBB, elevación ST e inversión T están presentes simultáneamente. La agregación de paciente promedia las probabilidades de las derivaciones y después aplica el umbral seleccionado.

A.2.- Datos cedidos por el HUCA

Propiedad	Valor
Fuente	Hospital Universitario Central de Asturias (HUCA), recurso Brugada HUCA 1.0.0
Pacientes brutos	363
Pacientes excluidos	46 por patrón basal limítrofe
Pacientes incluidos	317
Imágenes incluidas	951
Casos confirmados	116
Controles	201
Derivaciones	V1, V2 y V3
Ventana	300 ms antes de R y 600 ms después de R
Frecuencia de origen	100 Hz
Resolución de guardado	130 ppp
Separación	Leave-one-out por paciente

Tabla A.2.- Configuración del conjunto real procesado.

Los datos cedidos por el HUCA no contienen anotaciones independientes para las tres etiquetas morfológicas del simulador. La tarea real utiliza la etiqueta clínica `clinical_brugada`, recogida a nivel de paciente mediante revisión especializada.

A.3.- Configuración CNN

Propiedad	Valor
Arquitectura	ResNet18
Pesos iniciales	Inicialización estándar de ResNet18
Entrada	RGB, 224 por 224
Salida	Tres hallazgos morfológicos
Pérdida	Entropía cruzada binaria multietiqueta
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Lote	32
Épocas máximas	20
Estrategia de umbral	Selección en validación mediante exactitud equilibrada
Métrica principal	Exactitud equilibrada por paciente
Grad CAM	12 paneles en sintético y 6 en datos reales por ejecución agregada

Tabla A.3.- Hiperparámetros de la CNN final.

A.4.- Configuración de adaptación de dominio

Propiedad	Valor
Origen etiquetado	Conjunto sintético QRS/ST
Destino no etiquetado	Datos cedidos por el HUCA
Métodos	SSL, CORAL, MMD y DANN [34, 35, 36, 33]
Valores de K	$K = 16$ y $K = 32$
Semillas	42, 123 y 2026
Peso de adaptación	0,1
Escalas MMD	0,5, 1,0, 2,0 y 4,0
SSL	SimCLR durante 3 épocas
Política de destino	Transductiva compartida, sin etiquetas destino en la pérdida supervisada

Tabla A.4.- Configuración de los experimentos de adaptación de dominio.

A.5.- Configuración VLM/ICL

El enfoque VLM/ICL usa los mismos pacientes reservados, valores de K y métricas por paciente que la CNN. La evaluación final corresponde a Gemma 4, ejecutado con temperatura 0 y salida estructurada.

Elemento	Valor
Modelo informado	Gemma 4
Entrada	Imagen ECG y demostraciones imagen-etiqueta
Valores de K	$K = \{0, 2, 4, 8, 16, 32\}$
Condiciones informadas	Zero-shot, ICL normal e ICL balanceado
Contextos sobre datos reales	Contexto tomado de la cohorte cedida por el HUCA y contexto sintético del simulador
Salida morfológica	RBBB, elevación ST e inversión de T
Salida clínica	Caso Brugada confirmado frente a control
Métrica principal	Exactitud equilibrada por paciente

Tabla A.5.- Configuración resumida del enfoque VLM/ICL.

El capítulo 8 describe este enfoque y los capítulos de resultados desarrollan su comparación con la CNN.

B Resultados completos

Este apéndice reúne las tablas de resultados agregadas utilizadas en los capítulos 9 y 10. Todas las cifras son medias sobre tres semillas salvo los recuentos, que acumulan las predicciones de las tres ejecuciones.

B.1.- CNN en el conjunto sintético

K	Acc.	BA	F1	Prec.	Sens.	Esp.	AP
2	0,610	$0,625 \pm 0,022$	0,401	0,291	0,650	0,600	0,268
4	0,640	$0,631 \pm 0,042$	0,407	0,304	0,617	0,646	0,268
8	0,687	$0,685 \pm 0,023$	0,468	0,357	0,683	0,688	0,383
16	0,757	$0,773 \pm 0,013$	0,569	0,442	0,800	0,746	0,534
32	0,827	$0,848 \pm 0,030$	0,673	0,545	0,883	0,812	0,614

Tabla B.1.- Resultados completos de la CNN sobre el conjunto sintético.

B.2.- CNN en los datos cedidos por el HUCA

K	Acc.	BA	F1	Prec.	Sens.	Esp.	AP
2	0,460	$0,509 \pm 0,010$	0,484	0,372	0,693	0,325	0,404
4	0,450	$0,509 \pm 0,023$	0,493	0,373	0,730	0,289	0,388
8	0,442	$0,490 \pm 0,018$	0,469	0,360	0,672	0,308	0,383
16	0,478	$0,516 \pm 0,023$	0,480	0,379	0,658	0,375	0,478
32	0,461	$0,499 \pm 0,012$	0,466	0,366	0,644	0,355	0,423

Tabla B.2.- Resultados completos de la CNN base sobre los datos cedidos por el HUCA.

B.3.- Comparación de dominios

K	Sintético BA	BA datos reales
2	0,625	0,509
4	0,631	0,509
8	0,685	0,490
16	0,773	0,516
32	0,848	0,499

Tabla B.3.- Exactitud equilibrada sintética frente a real.

B.4.- Adaptación de dominio

Método	K	Acc.	BA	F1	Prec.	Sens.	Esp.
Base	16	0,478	$0,516 \pm 0,023$	0,480	0,379	0,658	0,375
SSL	16	0,429	$0,477 \pm 0,027$	0,458	0,351	0,658	0,297
CORAL	16	0,493	$0,524 \pm 0,008$	0,481	0,384	0,641	0,408
MMD	16	0,484	$0,516 \pm 0,019$	0,474	0,378	0,635	0,396
DANN	16	0,487	$0,515 \pm 0,019$	0,470	0,378	0,621	0,410
Base	32	0,461	$0,499 \pm 0,012$	0,466	0,366	0,644	0,355
SSL	32	0,457	$0,503 \pm 0,014$	0,476	0,368	0,672	0,333
CORAL	32	0,499	$0,528 \pm 0,013$	0,480	0,388	0,632	0,423
MMD	32	0,522	$0,549 \pm 0,029$	0,498	0,404	0,649	0,448
DANN	32	0,473	$0,509 \pm 0,028$	0,472	0,373	0,644	0,375

Tabla B.4.- Resultados completos de adaptación de dominio sobre los datos cedidos por el HUCA.

B.5.- VLM/ICL

Se separan tres bloques. Simulador corresponde a la evaluación morfológica dentro del dominio sintético. Datos reales con contexto real corresponde a Gemma 4 sobre la imagen real V2 de cada paciente, usando demostraciones tomadas de la cohorte cedida por el HUCA y etiqueta clínica. Datos reales con contexto sintético corresponde al control de transferencia en el que las demostraciones proceden del simulador.

También se generaron controles de robustez con etiquetas permutadas y demostraciones sin imagen de apoyo. Esos controles se conservan en los artefactos de ejecución, pero se mantienen fuera de la comparación principal para no mezclar controles metodológicos con las tres condiciones interpretables: zero-shot, ICL normal e ICL balanceado.

Tarea	Condición	K	BA	F1	Sens.	Esp.
Simulador	Zero-shot	0	0,500	0,000	0,000	1,000
Simulador	ICL normal	2	0,638	0,418	0,300	0,975
Simulador	ICL normal	4	0,688	0,489	0,533	0,842
Simulador	ICL normal	8	0,717	0,517	0,650	0,783
Simulador	ICL normal	16	0,750	0,529	0,817	0,683
Simulador	ICL normal	32	0,727	0,481	0,967	0,487
Simulador	ICL balanceado	2	0,608	0,357	0,250	0,967
Simulador	ICL balanceado	4	0,696	0,470	0,767	0,625
Simulador	ICL balanceado	8	0,754	0,511	0,950	0,558
Simulador	ICL balanceado	16	0,719	0,471	1,000	0,438
Simulador	ICL balanceado	32	0,637	0,409	1,000	0,275
Real contexto real	Zero-shot	0	0,508	0,044	0,023	0,993
Real contexto real	ICL normal	2	0,489	0,382	0,414	0,564
Real contexto real	ICL normal	4	0,490	0,445	0,586	0,393
Real contexto real	ICL normal	8	0,517	0,487	0,684	0,350
Real contexto real	ICL normal	16	0,522	0,491	0,690	0,355
Real contexto real	ICL normal	32	0,517	0,478	0,647	0,388
Real contexto real	ICL balanceado	2	0,510	0,406	0,440	0,580
Real contexto real	ICL balanceado	4	0,506	0,458	0,601	0,411
Real contexto real	ICL balanceado	8	0,516	0,481	0,661	0,371
Real contexto real	ICL balanceado	16	0,522	0,496	0,713	0,332
Real contexto real	ICL balanceado	32	0,521	0,484	0,658	0,385

Tabla B.5.- Resultados VLM/ICL principales informados en los capítulos de resultados. Las cifras son medias sobre tres semillas.

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	0,500	0,000	0,000	1,000
ICL normal	2	0,500	0,000	0,000	1,000
ICL normal	4	0,500	0,000	0,000	1,000
ICL normal	8	0,500	0,000	0,000	1,000
ICL normal	16	0,501	0,006	0,003	0,998
ICL normal	32	0,500	0,006	0,003	0,997
ICL balanceado	2	0,500	0,000	0,000	1,000
ICL balanceado	4	0,500	0,000	0,000	1,000
ICL balanceado	8	0,501	0,006	0,003	1,000
ICL balanceado	16	0,499	0,000	0,000	0,998
ICL balanceado	32	0,505	0,022	0,011	0,998

Tabla B.6.- Resultados VLM/ICL con contexto sintético del simulador y consulta sobre los datos reales cedidos por el HUCA. Las cifras son medias sobre tres semillas.

C Mensajes y respuestas estructuradas

C.1.- Criterio de conservación

Los mensajes forman parte del protocolo experimental. En un modelo de visión y lenguaje, cambios pequeños en instrucciones, orden o formato pueden modificar la respuesta. Por esa razón se conserva el contenido de los prompts y el esquema de salida exigido.

C.2.- Sistema para tarea morfológica

```

1 You are evaluating single-beat right precordial ECG images.
2 Return only the requested JSON. Do not include prose, markdown, caveats, a
3 diagnosis, or a clinical recommendation.
```

C.3.- Tarea morfológica

```

1 Analyze this single-beat right precordial ECG image from lead {lead}.
2
3 Evaluate these morphology findings independently:
4
5 RBBB:
6   - terminal RSR' or rSr' morphology in the QRS complex
7   - delayed terminal right-precordial activation compatible with right bundle
   branch block
8
9 ST_ELEVATION:
10  - J-point or ST segment remains elevated above the baseline after the QRS
   complex
11  - coved, convex, or saddleback elevation can count when visually present
12
13 T_WAVE_INVERSION:
14  - the T wave after the ST segment is predominantly negative below baseline
15
```

```

16 Return only valid JSON with boolean values for exactly these keys:
17
18 {
19   "RBBB": true,
20   "ST_ELEVATION": true,
21   "T_WAVE_INVERSION": true
22 }

```

C.4.- Sistema para tarea clínica

```

1 You are evaluating right precordial ECG beat images from one patient.
2 Return only the requested JSON. Do not include prose, markdown, caveats,
3 a diagnosis, or a clinical recommendation.
4
5 The label is a research reference for suspected Brugada triage. It must not be
6 used as an autonomous diagnosis.

```

C.5.- Tarea clínica directa

```

1 Analyze this single right precordial ECG beat image from one patient.
2
3 Decide whether the patient is clinically compatible with the Brugada-positive
4 reference used in this study.
5
6 Return only valid JSON with exactly this key:
7
8 {
9   "clinical_brugada": true
10 }

```

C.6.- Construcción del contexto

En zero-shot no se añaden demostraciones. El modelo recibe el mensaje de sistema, la tarea y la imagen objetivo. En ICL normal, cada demostración contiene una imagen y la respuesta JSON correcta, sin forzar explícitamente la proporción de clases. En ICL balanceado, la selección intenta incluir pacientes positivos y negativos siempre que el pliegue lo permita. En ambos casos, el contexto nunca incluye el paciente reservado para test.

Las respuestas se validan de forma estricta. Una salida con claves ausentes, claves adicionales, texto libre o tipos incorrectos se registra como fallo de formato. En la evaluación final, la tasa de JSON inválido fue 0, por lo que las diferencias de rendimiento proceden de las decisiones del modelo y no de errores sintácticos.

Bibliografía

- [1] Zeppenfeld, K. y colaboradores. 2022 ESC Guidelines for the management of patients with ventricular arrhythmias and the prevention of sudden cardiac death. *European Heart Journal*, 43(40), 3997–4126, 2022. <https://doi.org/10.1093/eurheartj/ehac262>.
- [2] Kligfield, P., Gettes, L. S., Bailey, J. J. y colaboradores. Recommendations for the standardization and interpretation of the electrocardiogram. Part I. The electrocardiogram and its technology. *Circulation*, 115(10), 1306–1324, 2007. <https://doi.org/10.1161/CIRCULATIONAHA.106.180200>.
- [3] Surawicz, B., Childers, R., Deal, B. J., Gettes, L. S. y colaboradores. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part III. Intraventricular conduction disturbances. *Circulation*, 119(10), e235–e240, 2009. <https://doi.org/10.1161/CIRCULATIONAHA.108.191095>.
- [4] Rautaharju, P. M., Surawicz, B. y Gettes, L. S. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part IV. The ST segment, T and U waves, and the QT interval. *Circulation*, 119(10), e241–e250, 2009. <https://doi.org/10.1161/CIRCULATIONAHA.108.191096>.
- [5] Sieira, J. y Brugada, P. The definition of the Brugada syndrome. *European Heart Journal*, 38(40), 3029–3034, 2017. <https://doi.org/10.1093/eurheartj/ehx490>.
- [6] Wilde, A. A. M., Semsarian, C., Marquez, M. F. y colaboradores. Use, misuse, and pitfalls of the drug challenge test in the diagnosis of the Brugada syndrome. *European Heart Journal*, 44(27), 2427–2439, 2023. <https://doi.org/10.1093/eurheartj/ehad295>.
- [7] BrugadaDrugs.org Advisory Board. Diagnostic drugs for Brugada syndrome. BrugadaDrugs.org. https://www.brugadadrugs.org/druglist_diagnostic/.
- [8] CardioNetworks y ECGpedia. Brugada syndrome type1 example4. Wikimedia Commons, licencia CC BY-SA 3.0. [https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_\(CardioNetworks_ECGpedia\).png](https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_(CardioNetworks_ECGpedia).png).
- [9] Napolitano, C. y Priori, S. G. Brugada syndrome. *Orphanet Journal of Rare Diseases*, 1, 35, 2006. <https://doi.org/10.1186/1750-1172-1-35>.

- [10] Corrado, D., Pelliccia, A., Heidbuchel, H. y colaboradores. Recommendations for interpretation of 12 lead electrocardiogram in the athlete. *European Heart Journal*, 31(2), 243–259, 2010. <https://doi.org/10.1093/eurheartj/ehp473>.
- [11] Ribeiro, A. H. y colaboradores. Automatic diagnosis of the 12 lead ECG using a deep neural network. *Nature Communications*, 11, 1760, 2020. <https://doi.org/10.1038/s41467-020-15432-4>.
- [12] Wagner, P., Strodthoff, N., Bousseljot, R. D. y colaboradores. PTB XL, a large publicly available electrocardiography dataset. *Scientific Data*, 7, 154, 2020. <https://doi.org/10.1038/s41597-020-0495-6>.
- [13] Gow, B., Pollard, T., Nathanson, L. A. y colaboradores. MIMIC IV ECG. Diagnostic Electrocardiogram Matched Subset. Version 1.0. PhysioNet, 2023. <https://doi.org/10.13026/4nqg-sb35>.
- [14] Gliner, V., Keidar, N., Makarov, V. y colaboradores. Automatic classification of healthy and disease conditions from images or digital standard 12 lead electrocardiograms. *Scientific Reports*, 10, 16331, 2020. <https://doi.org/10.1038/s41598-020-73060-w>.
- [15] Sangha, V. y colaboradores. Automated multilabel diagnosis on electrocardiographic images and signals. *Nature Communications*, 13, 1583, 2022. <https://doi.org/10.1038/s41467-022-29153-3>.
- [16] Wu, H., Patel, K. H. K., Li, X. y colaboradores. A fully automated paper ECG digitisation algorithm using deep learning. *Scientific Reports*, 12, 20963, 2022. <https://doi.org/10.1038/s41598-022-25284-1>.
- [17] Gliner, V., Makarov, V., Avetisyan, A. I., Schuster, A. y Yaniv, Y. Using domain adaptation for classification of healthy and disease conditions from mobile captured images of standard 12 lead electrocardiograms. *Scientific Reports*, 13, 14023, 2023. <https://doi.org/10.1038/s41598-023-40693-6>.
- [18] Sayadi, O., Shamsollahi, M. B. y Clifford, G. D. Synthetic ECG generation and Bayesian filtering using a Gaussian wave based dynamical model. *Physiological Measurement*, 31(10), 1309–1329, 2010. <https://doi.org/10.1088/0967-3334/31/10/002>.
- [19] Gillette, K. y colaboradores. MedalCare XL. 16 900 healthy and pathological synthetic 12 lead ECGs from electrophysiological simulations. *Scientific Data*, 10, 531, 2023. <https://doi.org/10.1038/s41597-023-02416-4>.

- [20] Lopez Alcaraz, J. M. y Strodthoff, N. Diffusion based conditional ECG generation with structured state space models. *arXiv:2301.08227*, 2023. <https://doi.org/10.48550/arXiv.2301.08227>.
- [21] Liu, R., Bai, Y., Yue, X. y Zhang, P. Teaching multimodal language models to comprehend 12 lead electrocardiographic images. *npj Digital Medicine*, 9, 349, 2026. <https://doi.org/10.1038/s41746-026-02551-3>.
- [22] Soubh, N., Rasenack, E., Haarmann, H., Wiedmann, F., Zabel, M., Schmidt, C., Suliman, R. y Bergau, L. Performance of vision-enabled large language models in image-based electrocardiogram interpretation. Exploratory evaluation. *Journal of Medical Internet Research*, 28, e86692, 2026. <https://doi.org/10.2196/86692>.
- [23] Zhang, D., Lan, X., Geng, S. y colaboradores. MEETI. A multimodal ECG dataset from MIMIC IV ECG with signals, images, features and interpretations. *Scientific Data*, 13, 527, 2026. <https://doi.org/10.1038/s41597-026-06796-1>.
- [24] Alayrac, J. B., Donahue, J., Luc, P. y colaboradores. Flamingo. A visual language model for few shot learning. *Advances in Neural Information Processing Systems*, 35, 23716–23736, 2022. <https://arxiv.org/abs/2204.14198>.
- [25] Chen, S., Han, Z., He, B., Liu, J., Buckley, M., Qin, Y., Torr, P., Tresp, V. y Gu, J. Can multimodal large language models truly perform multimodal in context learning. *IEEE/CVF Winter Conference on Applications of Computer Vision*, 6000–6010, 2025. <https://doi.org/10.1109/WACV61041.2025.00585>.
- [26] Qin, L., Chen, Q., Fei, H., Chen, Z., Li, M. y Che, W. What factors affect multimodal in context learning. An in depth exploration. *Advances in Neural Information Processing Systems*, 37, 2024. <https://arxiv.org/abs/2410.20482>.
- [27] Camba, S., Otero, A., García, D., Sánchez, L. y Costa, N. Can In-Context Learning Enable Large Vision Language Models to Detect ECG Abnormalities? En *Artificial Intelligence in Biomedicine. CIABiomed 2025*, Lecture Notes in Computer Science, vol. 16148, 200–213. Springer, Cham, 2026. https://doi.org/10.1007/978-3-032-10661-2_16.
- [28] Google DeepMind. Gemma 4 model card. Google AI for Developers. https://ai.google.dev/gemma/docs/core/model_card_4.
- [29] Google Health AI Developer Foundations. MedGemma 1.5 model card. Google for Developers. <https://developers.google.com/health-ai-developer-foundations/medgemma/model-card>.

- [30] Moor, M., Banerjee, O., Shakeri Hossein Abad, Z., Krumholz, H. M., Leskovec, J., Topol, E. J. y Rajpurkar, P. Foundation models for generalist medical artificial intelligence. *Nature*, 616, 259–265, 2023. <https://doi.org/10.1038/s41586-023-05881-4>.
- [31] He, K., Zhang, X., Ren, S. y Sun, J. Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770–778, 2016. <https://doi.org/10.1109/CVPR.2016.90>.
- [32] Selvaraju, R. R. y colaboradores. Grad CAM. Visual explanations from deep networks via gradient based localization. *Proceedings of the IEEE International Conference on Computer Vision*, 618–626, 2017. <https://doi.org/10.1109/ICCV.2017.74>.
- [33] Ganin, Y. y colaboradores. Domain adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59), 1–35, 2016. <https://jmlr.org/papers/v17/15-239.html>.
- [34] Chen, T., Kornblith, S., Norouzi, M. y Hinton, G. A simple framework for contrastive learning of visual representations. *Proceedings of the 37th International Conference on Machine Learning*, PMLR 119, 1597–1607, 2020. <https://proceedings.mlr.press/v119/chen20j.html>.
- [35] Sun, B. y Saenko, K. Deep CORAL. Correlation alignment for deep domain adaptation. En *European Conference on Computer Vision Workshops*, 443–450, 2016. <https://arxiv.org/abs/1607.01719>.
- [36] Long, M., Cao, Y., Wang, J. y Jordan, M. I. Learning transferable features with deep adaptation networks. *Proceedings of the 32nd International Conference on Machine Learning*, PMLR 37, 97–105, 2015. <https://proceedings.mlr.press/v37/long15.html>.
- [37] Tsoumakas, G. y Katakis, I. Multi label classification. An overview. *International Journal of Data Warehousing and Mining*, 3(3), 1–13, 2007. <https://doi.org/10.4018/jdwm.2007070101>.
- [38] Loshchilov, I. y Hutter, F. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019. <https://arxiv.org/abs/1711.05101>.
- [39] Costa Cortez, N. y García Iglesias, D. Brugada-HUCA. 12-Lead ECG Recordings for the Study of Brugada Syndrome. Version 1.0.0. PhysioNet, 2026. <https://doi.org/10.13026/0m2w-dy83>.
- [40] Bossuyt, P. M., Reitsma, J. B., Bruns, D. E. y colaboradores. STARD 2015: an updated list of essential items for reporting diagnostic accuracy studies. *BMJ*, 351, h5527, 2015. <https://doi.org/10.1136/bmj.h5527>.

- [41] Sounderajah, V., Guni, A., Liu, X., STARD-AI Steering Committee y colaboradores. The STARD-AI reporting guideline for diagnostic accuracy studies using artificial intelligence. *Nature Medicine*, 31(10), 3283–3289, 2025. <https://doi.org/10.1038/s41591-025-03953-8>.
- [42] Collins, G. S., Moons, K. G. M., Dhiman, P. y colaboradores. TRIPOD+AI statement. Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378, 2024. <https://doi.org/10.1136/bmj-2023-078378>.
- [43] Unión Europea. Reglamento 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales. *Diario Oficial de la Unión Europea*. <https://eur-lex.europa.eu/eli/reg/2016/679/oj/spa>.
- [44] España. Ley Orgánica 3/2018 de Protección de Datos Personales y garantía de los derechos digitales. *Boletín Oficial del Estado*. <https://www.boe.es/buscar/act.php?id=BOE-A-2018-16673>.
- [45] España. Ley 14/2007 de Investigación biomédica. *Boletín Oficial del Estado*. <https://www.boe.es/buscar/act.php?id=BOE-A-2007-12945>.

Índice de figuras

2.1. Ejemplos clínicos de morfología Brugada. La imagen izquierda procede de ECGpedia, CC BY-SA 3.0 [8]. La imagen derecha procede de Napolitano y Priori, CC BY 2.0 [9].	9
2.2. Representación esquemática de los hallazgos visuales que motivan el triaje de patrón Brugada.	10
4.1. Validación leave-one-out por paciente y selección de ejemplos para cada valor de K	29
5.1. Generador gaussiano de un beat sintético. Los parámetros de cada átomo fijan su amplitud, posición y anchura antes de sumar las regiones P, QRS, ST y T.	32
5.2. Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador.	37
5.3. Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV.	39
6.1. Dos formas de utilizar el mismo conjunto reducido de pacientes etiquetados: entrenamiento de ResNet18 y aprendizaje en contexto con Gemma 4.	41
7.1. Uso supervisado de los ejemplos etiquetados en la CNN. Las muestras de entrenamiento actualizan los pesos de ResNet18 y la muestra reservada produce una predicción binaria junto con su mapa Grad CAM.	44
7.2. Ejemplo Grad CAM del modelo CNN sobre el conjunto sintético.	48
8.1. Construcción del contexto en el enfoque VLM/ICL. Las demostraciones etiquetadas se incorporan al prompt antes de la imagen de consulta, y la predicción se obtiene sin actualizar los pesos del modelo.	50
9.1. Exactitud equilibrada de la CNN sobre el conjunto sintético según K . Los puntos muestran la media de tres semillas y las barras la desviación estándar.	54
9.2. Matriz de confusión agregada de la CNN en el conjunto sintético para $K = 32$, acumulando las tres semillas.	54
9.3. Curvas VLM/ICL de Gemma 4 en el simulador QRS/ST. Los puntos muestran la media de tres semillas y las barras la desviación estándar.	55
9.4. Matrices de confusión agregadas de Gemma 4 en el simulador para los dos puntos principales de ICL, acumulando las tres semillas.	56

9.5. Comparación gráfica entre CNN, ICL normal e ICL balanceado en el simulador QRS/ST. Las curvas usan las mismas métricas y los mismos valores de K para los tres enfoques.	57
10.1. Preprocesamiento de los ECG cedidos por el HUCA para V1, V2 y V3. . .	59
10.2. Controles de transferencia sintético-real. La parte izquierda resume la adaptación de dominio de la CNN y la parte derecha resume Gemma 4 con demostraciones sintéticas antes de consultar imágenes reales.	61
10.3. Matriz de confusión agregada de Gemma 4 con contexto sintético balanceado, $K = 32$, y consulta sobre los datos reales cedidos por el HUCA.	62
10.4. Exactitud equilibrada de la CNN base evaluada con los datos cedidos por el HUCA según K . Los puntos muestran la media de tres semillas y las barras la desviación estándar.	63
10.5. Matriz de confusión agregada de la CNN evaluada con los datos cedidos por el HUCA para $K = 16$, acumulando las tres semillas.	64
10.6. Curvas VLM/ICL de Gemma 4 con consulta V2 y contexto real tomado de los datos cedidos por el HUCA. Los puntos muestran la media de tres semillas y las barras la desviación estándar.	65
10.7. Matrices de confusión agregadas de Gemma 4 con contexto real para los dos puntos principales de ICL.	66
10.8. Sensibilidad y especificidad de Gemma 4 según el origen del contexto. El contexto real cambia el régimen de predicción, mientras que el contexto sintético conserva una especificidad casi perfecta y apenas recupera positivos.	66
10.9. Comparación gráfica entre CNN base, ICL normal e ICL balanceado con los datos cedidos por el HUCA y contexto real para Gemma 4.	67
10.10 Sensibilidad y especificidad de los puntos principales con los datos cedidos por el HUCA. La figura resume el compromiso clínico entre recuperar positivos y evitar alertas sobre controles.	68
10.11 Brecha sintético-real de la CNN base. Las líneas continuas corresponden al simulador y las discontinuas a los datos cedidos por el HUCA.	69
10.12 Brecha sintético-real de Gemma 4 para exactitud equilibrada. Se comparan simulador, contexto real de los datos cedidos por el HUCA y contexto sintético del simulador.	69
10.13 Brecha sintético-real de Gemma 4 para F1. Se comparan simulador, contexto real de los datos cedidos por el HUCA y contexto sintético del simulador.	69

Índice de tablas

1.	Siglas y abreviaturas utilizadas en la memoria.	v
2.1.	Relación entre el concepto clínico y la traducción experimental utilizada en el proyecto	11
4.1.	Conjuntos utilizados en los experimentos finales.	28
5.1.	Átomos utilizados para construir un beat	31
5.2.	Relación entre familias generadoras y rasgos favorecidos	34
5.3.	Criterios de los validadores sintéticos	36
7.1.	Configuración CNN utilizada en los experimentos finales.	45
7.2.	Métodos de adaptación de dominio evaluados para la CNN.	47
9.1.	Resultados CNN ResNet18 sobre el conjunto sintético QRS/ST. Las cifras son medias sobre tres semillas.	53
9.2.	Puntos principales de Gemma 4 en el simulador QRS/ST. Las cifras son medias sobre tres semillas.	55
9.3.	Comparación principal en el simulador QRS/ST.	56
10.1.	Datos cedidos por el HUCA utilizados en la evaluación real.	58
10.2.	Resultados de adaptación de dominio de la CNN usando los datos cedidos por el HUCA como dominio objetivo no etiquetado.	60
10.3.	Puntos principales de Gemma 4 con contexto sintético y consulta sobre los datos reales cedidos por el HUCA. Las cifras son medias sobre tres semillas.	61
10.4.	Resultados CNN ResNet18 entrenada con simulador y evaluada con los datos cedidos por el HUCA. Las cifras son medias sobre tres semillas.	63
10.5.	Puntos principales de Gemma 4 con contexto real tomado de los datos cedidos por el HUCA. Las cifras son medias sobre tres semillas.	65
10.6.	Puntos relevantes sobre los ECG reales cedidos por el HUCA.	67
A.1.	Configuración del conjunto sintético final.	78
A.2.	Configuración del conjunto real procesado.	79
A.3.	Hiperparámetros de la CNN final.	80
A.4.	Configuración de los experimentos de adaptación de dominio.	80
A.5.	Configuración resumida del enfoque VLM/ICL.	81

B.1. Resultados completos de la CNN sobre el conjunto sintético.	82
B.2. Resultados completos de la CNN base sobre los datos cedidos por el HUCA.	82
B.3. Exactitud equilibrada sintética frente a real.	83
B.4. Resultados completos de adaptación de dominio sobre los datos cedidos por el HUCA.	83
B.5. Resultados VLM/ICL principales informados en los capítulos de resultados. Las cifras son medias sobre tres semillas.	84
B.6. Resultados VLM/ICL con contexto sintético del simulador y consulta sobre los datos reales cedidos por el HUCA. Las cifras son medias sobre tres semillas.	85